



学校代码: 10272

学 号: 2021214101

上海财经大学

SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS

硕士学位论文

MASTER DISSERTATION

论文题目: 基于投资者关注度因子的行业指数预
测研究

培养院系: 数学学院

论文类别: 应用统计硕士专业学位论文

论文作者: 陈浩越

指导教师: 郎艳怀 教授

完成日期: 2023 年 6 月

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品成果。对本人的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名：陈浩越

日期：2023年6月15日

学位论文版权使用授权书 (硕士学位论文用)

本人完全了解上海财经大学关于收集、保存、使用学位论文的规定，即：按照有关要求提交学位论文的印刷本和电子版本。上海财经大学有权保留并向国家有关部门或机构送交本论文的复印件和扫描件，允许论文被查阅和借阅。本人授权上海财经大学可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

论文作者签名：陈浩越

导师签名：邵晓军

日期：2023年6月15日

日期：2023年6月15日

摘 要

A 股市场已经成为全球最大的股票市场之一，包括了多种不同类型的投资者，投资者往往会通过一些方式将自己对未来市场的预期和投资计划表达出来，因此投资者关注股票市场的行为和情绪将可能暗示股票市场的价格走势，利用投资者关注度来预测价格趋势已经成为一个备受关注的研究领域。本文旨在利用一种新的融合模型基于文本数据构建投资者关注度因子，并通过 CNN-LSTM 模型验证因子在行业指数预测中的有效性，以提高投资决策的精度和效果，为投资者和市场参与者提供科学、实用的研究成果。本文做了如下研究工作：

(1) 构建投资者评论专用情感词典。研究中不直接使用基础词典，而是使用结合 Word2Vec 和 XGBoost 模型构建的投资者评论情感词典。同时在构建过程中，并未直接采用 Word2Vec 词向量余弦相似度的方式构建，而是先筛选出候选情感词，再通过 XGBoost 模型进行构建，使得情感词分类准确度得到了 11.8 个百分点的提升。

(2) 构建投资者关注度因子。本文提出一种新的融合情感词典和 BERT 情感分类的模型，使得投资者评论文本情感分类准确度在长短文本上均有较好表现。在实证过程中研究发现，虽然词典方法的分类精度仅有 72.3%，但在 9 个字符及以下的文本上表现出了 96.51% 的准确度，而 BERT 模型在长短文本上的准确度分布较为均匀，整体达到了 89.9% 的准确度。因此，我们将情感词典和 BERT 模型结合起来，根据文本长度的不同进行分类预测，最终融合模型使得准确度提升至 92.4%，并基于此融合模型构建了投资者评论关注度因子。

(3) 通过对比实验，选取了最佳的参数构建数据集，并证明了 CNN-LSTM 模型在行业指数预测中较其他模型具备更好的性能，此外，实验验证了投资者关注度因子在行业指数预测中的有效性，并以此设计了投资策略。具体而言，研究选取了五个维度的变量，通过在 CNN-LSTM 模型中加入 Dropout 机制及对输入数据进行主成分分析较好地避免了数据过拟合及数据冗余的问题。在对比

实验中，分析确定了滑动窗口取 5 天是较优选择，得出了 CNN-LSTM 模型较 LSTM 模型在此预测问题上有着更高准确度，较 XGboost 模型有明显进步的结论，并验证了投资者关注度因子加入模型能够较好地提升预测准确度。本文构建的基于投资者关注度因子的 CNN-LSTM 模型对行业指数涨跌预测准确度达到了 66.3%。最终，利用此模型，构建了简单的投资策略，半年的回测区间收益达到了 12.18%。

总之，以上研究工作除了为市场参与者提供投资策略建议外，也将帮助企业更好地了解投资者对公司关注的影响，从而制定更为有效的投资者关系战略，有利于企业更加关注自身在互联网上的评价，促进企业进步。同时，研究也为行业指数的波动提供更为深入的解释，有助于监管机构与投资者们更好地理解投资者关注度如何影响市场的价格波动。

关键词： 投资者关注度因子；行业指数预测；BERT；CNN-LSTM

Abstract

The A-share market has become one of the largest stock markets in the world, including a variety of different types of investors. Investors often express their expectations and investment plans for the future market in some ways. Therefore, investors' behavior and emotion of paying attention to the stock market may indicate the price trend of the stock market. Using investors' concern to predict the price trend has become a research field of great concern. The purpose of this paper is to use a new fusion model to construct investor's concern factor based on text data, and verify the effectiveness of the factor in industry index prediction through CNN-LSTM model, so as to improve the accuracy and effect of investment decision-making, and provide scientific and practical research results for investors and market participants. This paper has done the following research work:

(1) Build a special emotional dictionary for investor comments. In the study, the basic dictionary is not used directly, but the investor comment emotion dictionary built by combining Word2Vec and XGBoost model is used. At the same time, in the construction process, the method of Word2Vec word vector cosine similarity was not directly used to build, but the candidate sentiment words were screened out first, and then constructed by XGBoost model, which improved the classification accuracy of sentiment words by 11.8 percentage points.

(2) Build investor concern factor. This paper proposes a new model combining emotion dictionary and BERT emotion classification, which makes the accuracy of investor comment text emotion classification better in both long and short texts. In the empirical process, the research found that although the classification accuracy of the dictionary method is only 72.3%, it shows 96.51% accuracy

on the text with 9 characters or less, while the accuracy of the BERT model on the long and short text is relatively uniform, reaching 89.9% accuracy on the whole. Therefore, we combine the emotion dictionary and BERT model to classify and predict according to the different text length, and finally improve the accuracy of the fusion model to 92.4%. Based on this fusion model, we construct the investor comment concern factor.

(3) Through comparative experiments, the best parameters are selected to construct the data set, and it is proved that the CNN-LSTM model has better performance than other models in the industry index prediction. In addition, the experiment verifies the effectiveness of the investor's concern factor in the industry index prediction, and designs the investment strategy based on this. Specifically, the study selected five dimensions of variables. By adding the Dropout mechanism to the CNN-LSTM model and performing principal component analysis on the input data, the problems of data over-fitting and data redundancy were well avoided. In the comparative experiment, it is determined that the sliding window of 5 days is the best choice, and it is concluded that the CNN-LSTM model has a higher accuracy than the LSTM model in this prediction problem, and has a significant improvement over the XGboost model, and it is verified that the investor's concern factor can better improve the prediction accuracy by adding the model. The accuracy of the CNN-LSTM model built in this paper based on the investor's concern factor in predicting the rise and fall of the industry index has reached 66.3%. Finally, using this model, a simple investment strategy was constructed, and the return of the half-year back-test interval reached 12.18%.

In short, the above research work will not only provide investment strategy suggestions for market participants, but also help enterprises better understand the impact of investors on the company's concerns, so as to formulate more effective investor relationship strategies, which will help enterprises pay more at-

tention to their own evaluation on the Internet and promote enterprise progress. At the same time, the research also provides a more in-depth explanation for the fluctuations of the industry index, which helps regulators and investors better understand how investors' concern affects the price fluctuations of the market.

Keywords: Investor Concern Factor; Industry Index Forecast; BERT; CNN-LSTM

目 录

摘要	I
Abstract	III
第一章 引言	1
1.1 研究背景及意义	1
1.1.1 选题研究背景	1
1.1.2 研究的目的与意义	2
1.2 国内外研究现状	3
1.3 研究思路与框架	6
1.4 本文的创新点	7
第二章 相关理论基础	9
2.1 文本情感分析概述	9
2.2 文本数据的表示方法	10
2.2.1 离散表示	10
2.2.2 分布表示	13
2.3 基于词典的分析方法	16
2.4 基于深度学习的文本分析模型	17
2.4.1 多头注意力机制与 Transformer 模型	17
2.4.2 BERT 模型	20
2.5 指数预测相关模型理论	21
2.5.1 XGBoost 模型	21
2.5.2 卷积神经网络模型	23
2.5.3 长短时记忆网络模型	24

第三章 基于文本情感分析构建投资者关注度因子	27
3.1 python 网络爬虫数据获取	27
3.1.1 投资者关注数据内容	27
3.1.2 代理 ip 池技术	29
3.1.3 数据爬取、处理及统计描述	31
3.1.4 数据集标注	33
3.2 投资者评论的文本情感分析模型	34
3.2.1 结合 Word2vec 及 XGBoost 构建情感词典的分析模型	34
3.2.2 基于 BERT 情感分类的分析模型	40
3.2.3 融合情感词典和 BERT 情感分类的分析模型	42
3.3 构建投资者关注度因子	43
第四章 基于投资者关注度因子的行业指数预测	45
4.1 指标选取与变量说明	45
4.2 数据集的获取处理及统计描述	48
4.3 基于投资者关注度因子的 CNN-LSTM 预测模型	51
4.3.1 CNN-LSTM 混合模型概述	51
4.3.2 模型的输入输出数据说明及处理	52
4.3.3 CNN-LSTM 模型参数设置	55
4.4 因子作用及模型效果的评价分析	56
4.5 投资策略及收益分析	63
第五章 总结与展望	65
5.1 研究结论	65
5.2 不足与未来展望	66
参考文献	67
致谢	71
个人简历	72

第一章 引言

第一节 研究背景及意义

1.1.1 选题研究背景

中国股市在 20 世纪 80 年代末期开始逐步开放，1990 年成立了上海证券交易所和深圳证券交易所，这标志着中国股市的诞生。随着经济的发展和改革开放的不断深化，中国股市经历了快速发展的阶段。在 2015 年，中国股市曾达到历史高点，但随后出现了大幅波动和市场崩盘。在政策调控和市场监管的努力下，中国股市逐渐稳定，并呈现出长期稳健的发展趋势。目前，中国 A 股市场已经成为全球最大的股票市场之一，包括了多种不同类型的投资者，如个人投资者、机构投资者、外资机构等。

在股票市场中，投资者关注度是影响价格的重要因素之一，因为投资者的行为和情绪可能会影响股票价格的波动。利用投资者关注度来预测股票市场资产价格已经成为一个备受关注的研究领域。近年来，随着互联网和社交媒体的快速发展，投资者获取信息的途径变得更加便利，投资者关注度数据也变得更加丰富，主要来源于网络信息和社交媒体数据。网络信息包括新闻报道、公告等；而社交媒体数据包括股吧，百度搜索，资讯等，这些平台上的投资者评论和讨论可以反映出投资者的情绪和态度。相较而言，后者作为个体投资者表达的内容，更饱含情感值，带有明显的情绪倾向，而正式的官方文本往往摒弃了个人情绪的客观表达，因此从了解分析投资者情绪角度来看，个体投资者的非正式文本更值得研究。

同时，近年来利用机器学习和深度学习模型和算法进行量化投资逐渐兴起，已经成为股票市场中的重要投资方式，其对市场的影响和作用越来越大。利用深度学习模型进行量化投资通常会利用大量历史数据，通过对股票市场的分析和预测，实现投资组合的优化和风险控制，目前已经成为股票市场中的重要力

量之一。

因此，随着数据源的扩充，处理和预测算法的发展，利用投资者关注度数据来预测价格涨跌趋势的研究变得更加可行和有前景。

1.1.2 研究的目的是与意义

本文旨在探究投资者对行业内股票的关注度与行业指数价格之间的关系，以此为基础建立一种价格预测模型，构建投资策略。投资者关注度是指投资者对行业内股票的关注程度，这可以通过各种途径来衡量，如在公开网站上的股票评论、社交媒体上的股票关注度、搜索股票资讯的次数等。许多研究表明，投资者关注度对股票价格有一定的影响，但这个影响并不是单纯的正向或负向的，而是取决于多种因素。

此外，研究不局限于个股层面，而是放大到行业指数层面，一方面，中国 A 股上市公司 5000 余家，许多公司的投资者关注度很低，不利于个股层面的研究。另一方面，个股的偶然性和突发性，诸如“黑天鹅”“重组”等小概率事件可能极大地影响股价走势，难以保证数据和预测的稳定性。相较而言，行业指数的信息量与关注度充足，个股的风险被充分分散，稳定性优秀，同时行业指数也可以通过成比例的购买行业内的股票达到投资的目的。具体的研究目的包括三个内容：

- 1、搜集投资者关注度数据，包括网络信息和公开网站数据，研究挖掘文本信息背后情感倾向的模型方法。

- 2、利用文本情感分析等方法对投资者关注度数据进行处理和分析，并构建基于深度学习等理论的行业指数涨跌预测模型，评估模型的预测精度和效果，验证投资者关注度因子在行业指数预测中的有效性。

- 3、探究基于投资者关注度的模型在投资中的应用，构建投资策略，评估投资收益效果。

总之，本文的研究意义旨在利用投资者关注度数据，探究 A 股市场中行业指数涨跌预测的问题，以提高投资决策的精度和效果，为投资者和市场参与者

提供科学、实用的研究成果。此外，也将帮助企业更好地了解投资者对自己的关注影响，从而制定更为有效的投资者关系战略，有利于企业更加关注自身在互联网上的评价，促进企业进步。最后，可以为行业指数的波动提供更为深入的解释，有助于监管机构与投资者们更好地理解市场的运作机制。

第二节 国内外研究现状

在预测市场股票价格或行业指数走势方面，相关文献较多，大多都是从数学统计方法研究和复杂模型的深化方面展开的。例如，王哲等 (1999)^[1] 通过对市场行情数据的分析和研究，证明了无论是短期还是长期，股票市场都具有一定的可预测性，未进一步深入构建预测模型。雷鸣等 (2010)^[2] 从统计推断角度，利用伽玛分布和生存分析，证明了技术分析在个股和行业指数预测中的有效性，但其模型方法上涵盖复杂的变量较为有限。徐迪等 (1998)^[3] 新颖地利用了在当时前沿的神经网络技术对四川长虹的股价进行预测，不过由于研究较为早期，数据量、范围及模型方法等方面在当下看来可以进一步提升。随着信息时代的到来，计算机和互联网大数据的迅猛发展，市场量化分析投资方法多基于计算机技术，如深度学习等方面。Jonathan(2013)^[4] 将人工神经网络引入股票市场价格预测。Yan 等 (2017)^[5] 得出了 LSTM 在金融时间序列预测中具有良好效果的结论。同时，通过对金融时间序列进行小波分解和重构，还能够提高 LSTM 预测模型的普适性和准确度。此外，LSTM 神经网络还克服了循环神经网络的一些梯度消失和爆炸问题，LSTM 也得益于此，成为了当下预测股票市场价格走势的重要模型之一。彭燕等 (2019)^[6] 通过调整 LSTM 层数与隐藏神经元个数，使得模型的预测准确度进一步提高。上述这些研究的数据集主要是基于行情数据层面，并未涵盖一些当下市场较为重要的非理性变量，主要为单纯的股票市场内数据研究，且模型方法上也有待进一步改进。

在分析投资者关注度方面，国内外已有一些基于财经文本的情感分析文献。游家兴和吴静 (2012)^[7] 基于我国多家财经报社的文章，分析文章中的媒体关注度情绪，探究对资产误定价的影响。王靖一等 (2018)^[8] 收集和讯网的文章报道

构建了金融科技指数。张宗新等 (2021)^[9] 收集分析百度资讯文章数据, 计算文章的关注情绪值。范小云 (2022)^[10] 从 33 家知名报纸的 200 余万篇新闻出发, 分析文本的社会关注情绪变量, 探究银行业的系统性风险。而曾庆生等 (2018)^[11] 则是从年报出发, 研究年报中文本数据表达倾向和公司内部的交易行为关系。上述论文主要是基于官方的来源渠道, 经过了加工、处理和审核后的文字资料。而得益于互联网和自媒体的发展, 个体投资者自身也能够有途径表达关注情绪, 可收集信息源爆发式增长, 而个体投资者也是市场参与者中的一个庞大群体。此外, 个体投资者所表达的内容更饱含情感值, 带有明显的情绪倾向, 而正式的官方文本往往摒弃了个人情绪的客观表达, 因此从了解分析投资者情绪角度来看, 个体投资者的非正式文本更值得研究。Bollen (2011)^[12] 关注 twitter 中的投资者信息, 利用情感跟踪等进行分析挖掘, 段江娇等 (2017)^[13] 则从东方财富网股吧文本角度出发, 分析文本的信息含量和情感倾向。而钱宇等 (2022)^[14] 着重研究分析在线社区的文本信息。总之, 已有文献由于官方来源文本数据的结构统一, 收集方便, 报道权威, 因此多是基于官方新闻、报纸等进行研究的, 其涵盖的个体投资者情绪有限, 而从个体投资者角度出发的文献较少, 且已有文献在数据收集范围和文本分析模型优化方面还可以进一步扩充。

在文本情感分析的模型研究方面, 类别较多。Cowles (1933)^[15] 是最早一批对财经文本数据进行情感分析的研究学者, 主要通过人工分类的方式对《华尔街日报》中的文章分类。当前, 文本分析方法主要分为三类, 情感词典方法、回归方法和深度学习模型方法。Loughran 等 (2011)^[16] 从情感词典方法角度, 分析了哈佛词典不利于财经文本数据的分析, 因此寻求构建了一种金融领域的情感词典。Jegadeesh 等 (2013)^[17] 和 Manela 等 (2017)^[18] 则从文本回归角度, 通过对新闻文本的回归方式进行研究。而最后一种深度学习模型方法成为了越来越热门的领域, 诸如 BERT、GPT 等模型横空出世, 极大地推动了文本情感分析领域的发展, 王乃钰等 (2021)^[19] 详细的阐述了近年来文本分析领域的深度学习发展进程。总之, 上述文献讲述了不同的文本分析模型, 虽然深度学习模型快速发展, 但不代表过去的情感词典等传统文本分析方法无可取之处, 少有文献

能将多种方法进行结合，取出多个模型的优势之处进行融合。

将以上文本分析模型和预测模型结合，利用投资者关注度构建预测模型方面。首先，胡昌生等 (2013)^[20] 通过研究证明，投资者的关注度情绪的确能够影响股票价格走势。Tetlock (2007)^[21] 通过对《华尔街日报》中的财经新闻数据建模，人工分析处财经新闻文本的消极关注度将使得股票价格下行，并通过统计方法中的回归分析，得出消极关注度会降低企业的收益和股票市场表现。虽然 Tetlock (2007)^[21] 结合了投资者关注信息去预测股价，但数据集的标注上采用耗时的人工方法，且预测模型上是采用传统的回归分析，有待进一步提升。黄润鹏等 (2015)^[22] 以新浪微博数据为对象，分析投资者关注情感值，利用格兰杰因果关系检验和 SVM 模型对上证指数进行预测研究，证明了新浪微博情感数据能够良好的帮助预测上证指数。Kleinberg 等 (2016)^[23] 对 Twitter 软件上的投资者评论帖信息进行情感分析，利用 ANN 模型基于情感分析结果和市场行情数据预测股价，结果表示预测效果良好。许雪晨和田侃 (2021)^[24] 提出了一种改进的 LSTM 模型，在分析东方财富文本数据得出情感值后，再引入行情数据利用 Bi-LSTM 模型预测沪深 300 指数，其所选用的数据集主要为行情数据和财经文本数据。范小云等 (2018)^[25] 创建了一种新的财经文本情绪词典，并基于朴素贝叶斯、随机森林、逻辑回归、梯度提升决策树等机器学习模型构建混合式情绪测度方法，结果表明投资者情绪能够一定程度上预测宏观经济指标，股票新闻能够预测价格走势。整体而言，上述模型几乎所选取的数据集均停留在行情数据及投资者情感数据，并未涵盖其他诸如技术指标、宏观数据、基本面数据等重要变量，此外，模型方法上也较为单一，且少有文献将近年来快速发展的深度学习技术应用于该领域。

总之，通过文献研究发现，LSTM 模型适合用于股票市场数据预测建模，而文本分析领域的快速发展使得诸如 BERT 模型等能够在财经文本分析领域得到深入应用。本文正是基于此，将提出一种融合情感词典和 BERT 模型的情感分析方法，并基于改进后的 CNN-LSTM 模型进行行业指数的预测研究。

第三节 研究思路与框架

本文的研究思路框架主要分为五个大的板块，包括引言、相关理论、构建投资者关注度因子、行业指数预测及总结与展望，如图1-1。



图 1-1 本文研究思路框架

五个部分具体而言：

第一部分：引言部分。介绍投资者关注度因子和行业指数预测的研究背景和研究意义，并分析国内外已有文献的研究方法、观点及结论，在此基础上提出自己的观点和看法。最后基于对文献的分析、深入的研究和细致的挖掘，提出本文的创新之处，并落实到后续的研究中去。

第二部分：相关理论部分。主要分为两个板块，一是介绍用于构建投资者关

注度因子的文本情感分析理论，二是介绍用于预测行业指数趋势的机器学习及深度学习理论。文本情感分析方面，主要包括文本的表示方法、情感词典、BERT 模型等理论。机器学习及深度学习方面，主要包括 XGBoost, CNN, LSTM 等模型。这一板块主要是为后文的实证研究中提出创新性地应用打下理论和模型基础。

第三部分：构建投资者关注度因子。主要分为两个板块，一是爬取和处理投资者关注度相关数据，二是基于文本情感分析理论对数据进行分析，并构建投资者关注度因子。在数据方面，需用到 Python 爬虫，构建 IP 代理池，缺失填补等方法。在文本分析方面，先利用 Word2vec 和 XGBoost 模型构建词典，再融合情感词典和 BERT 模型完成对文本数据的分析处理，最终构建投资者关注度因子。

第四部分：基于投资者关注度因子的行业指数预测。主要分为四个部分，一是选取纳入模型的其他相关因子，二是构建 CNN-LSTM 模型，并进行预测，三是进行模型的对比实验并与已有文献对比，四是基于模型构建投资策略。

第五部分：总结部分。对全文的结论进行总结，并提出不足与未来的展望。

第四节 本文的创新点

本文从投资者关注度因子角度利用 CNN-LSTM 模型预测行业指数的涨跌趋势，主要在以下几个方面进行了一定的创新。

1、模型方面。在投资者评论的文本情感分析过程中，本文不直接使用基础词典，而是构建专用的投资者评论情感词典，同时在构建过程中，不采用传统的 Word2Vec 词向量余弦相似度的方式构建，而是先筛选出候选情感词，再通过 XGBoost 模型进行构建。此外，情感词典方法在不同长度的文本上存在着较大差异的准确度，在短文本时准确度表现优异。并基于此发现，创新性地融合情感词典模型和 BERT 模型，使得投资者评论文本情感分类的准确度进一步提高。

2、数据选取和预测对象方面。已有文献大多只是将行情数据和技术指标纳入模型对单一股票走势进行预测，一方面很少有文献同时将投资者关注度和宏

观指标两个非股票市场的非理性数据纳入模型。另一方面，大多是对单一的股票进行预测，而单一股票的数据信息量往往是不足的，此外股价走势的偶然性与突发性也较多，且在当下 A 股市场结构化特征显著，具有同一行业内的个股走势趋同性高的特点。而本文选取五个维度，包括投资者关注度因子维度、行业数据维度、技术指标维度、基本面维度以及宏观层面维度纳入模型，同时选择行业指数作为预测对象，使得预测模型能够涵盖更多的数据信息，更加准确。

3、数据获取与处理方面。大多数文献基本直接将行情数据输入模型，但本文因输入变量数目较多，将采用主成分分析的方法对数据进行降维，以提取关键信息，降低信息的冗余性，并将主成分作为模型的输入。此外在传统的 LSTM 模型中加入 CNN 和 Dropout 结构，在提取关键特征并防止模型过拟合的同时，进一步提高模型的预测准确度。

第二章 相关理论基础

第一节 文本情感分析概述

文本情感分析 (Sentiment Analysis) 是近年来人工智能领域发展的重要分支。于 2023 年初风靡全球的一种 OpenAI 研发的聊天机器人程序——ChatGPT, 正属于文本分析领域的最前沿应用。文本情感分析是一种自然语言处理 (Natural Language Processing, NLP) 的应用之一, 其高速发展得益于深度学习领域技术的不断突破。文本情感分析的核心是将文本语句分解, 经过例如深度学习等模型加工处理后, 得到文本的情感倾向, 即判断语句是消极的或者积极的, 从而为文本打上情感标签。针对大量的、杂乱的互联网文本数据, 人工处理极为麻烦, 但通过文本情感分析技术, 能够在一定程度上替代部分人工处理工作。谢法举 (2018) 等^[26] 指出一般而言, 文本情感分析分为两大类别, 细粒度情感分析和粗粒度情感分析。

细粒度情感分析方法相对复杂, 需要对文本内部进行细致分析, 包括文本评价对象、多元情感倾向、情感倾向程度、对象相关联物体、上下文语句联系等, 其输出结果包含多维数据。细粒度情感分析所要求的数据集庞大, 训练时间极长。

粗粒度情感分析方法则更加关注文本整体, 将文本切片拆分, 通过基础统计方法或者深度学习方法, 得出文本整体的情感倾向及程度, 但由于不包含文本的评价对象, 因此对数据集的要求更加苛刻, 需要是对单一对象的评论。粗粒度情感分析所要求的数据集相对适中, 适合快速处理文本。

联系本文实证所用文本数据来源于单一股票对象的特征, 并且结合后文的投资者关注度因子模型要求, 本文将采用粗粒度情感分析方法。常见的分析方法主要分为两类, 一类是基于传统统计方法的分析法, 最为经典的例子是情感词典法, 通过切分文本形成片段字符串, 再将字符串于预先标注好的情感词典中进行匹配得到, 好处是能够清晰合理的解释判断文本情感值的过程, 但准确

率和效率无法保证，且对预先准备的情感词典有一定要求，有时需要情感词典与待判断文本属于同一个专业领域，例如杨小平等 (2017)^[27] 对情感词典进行了详细叙述。另一类是基于深度学习方法的分析法，将大量样本输入到诸如卷积神经网络的模型中去挖掘文本与情感倾向之间的联系，这样的方法对样本量的要求较高，但能够尽可能的简化人工工作，准确度也更高。不过，由于是黑箱模型，难以展示和解释其中的判断过程，只能通过端对端的方式训练得到分析模型。




图 2-1 文本情感分析概述

第二节 文本数据的表示方法

将文本转化为具备一定结构的数值信息是分析模型能够对文本进行处理的前提。在本节中，详细论述了高效提取并储存文本信息的方法。目前，常见的文本向量表示方法分别为离散表示法和分布式表示法，前者通常将文本转化为稀疏矩阵形式，而后者则往往形成稠密向量。

2.2.1 离散表示

根据离散词向量表示方法的发展来看，出现了 One-hot 独热向量、Bag of words 词袋法、TF-IDF，以及基于 Andrey Markov (1913)^[28] 提出的马尔科夫过程的 N-gram 表示法。为了更详细地对比几种方法的区别与优劣势，本文以三句白酒股票投资者的评论例子加以说明。



图 2-2 文本示例

One-hot 独热向量作为最简单的词向量表示法, 简易直观, 是其他词向量表示法的基础。One-hot 的原理是根据文本库中所有互异的词语片段数量形成基础向量组, 进而每个基础向量可以唯一的表示每个词语。上述文本示例中, 共有 8 个互异的词语, 分别是:

{五粮液 : 1, 明天 : 2, 大涨 : 3, 贵州茅台 : 4, 小涨 : 5, 和 : 6, 都 : 7, 上涨 : 8}

因此, 所构建的基础向量应该是 8 维。其中五粮液和明天两个词语的 One-hot 词向量表示分别为:

{五粮液 : (1, 0, 0, 0, 0, 0, 0, 0)}

{明天 : (0, 1, 0, 0, 0, 0, 0, 0)}

虽然这样的 One-hot 独热向量表示简单直观, 但缺点也十分明显, 一是 One-hot 词向量的维数随着词语数量增加而增加, 当文本库较为庞大时, 词向量的维数将会极大, 使得后续分析处理非常麻烦。二是 One-hot 词向量不能表示出词语与词语之间的联系, 词向量都是相互正交的, 但实际上各个词语之间是存在联系的, 例如“明天”和“后天”, “涨”和“跌”等等存在关联的词语, 因此 One-hot 将各个词语的意思割裂开来, 信息损失较大。

Bag of words 词袋表示法则是 One-hot 方法的进一步拓展。对于每一条文本, 将其构成成分的词向量简单相加而得到。例如文本 3 即可被唯一的表示为:

{文本 3 : (1, 1, 0, 1, 0, 1, 1, 1)}

Bag of words 法表示的好处是, 使得每一条文本都可以被唯一的表示, 但

是缺点也很明显，Bag of words 法在每一条文本中赋予了每个词语相同的权重，然而各个词语的重要程度显然是不一样的，应当结合词语在整个文本库中出现的频率来定义词条文本。于是出现了曾在小型语料库广泛使用的 TF-IDF 方法，例如黄承慧等 (2011)^[29] 将 TF-IDF 方法用于度量文本相似度。

TF-IDF 是 Bag of words 法的进阶方法，TF-IDF 的 TF (Term Frequency) 表示词频，而 IDF 表示逆文档频率 (Inverse Document Frequency)。词频 TF 代表一条文本中的某个词语在该文本中所出现的频率，在该文本中出现的频次越多，那么这个词语的重要程度也就越大。当然这是在去除语气词、关系词等 Stop Words (停用词) 下的重要程度，侧重于刻画实义词，例如前述文本例子中的词语“明天”在文本 1 中出现了一次。逆文档频率 IDF 则不同，一条文本中的某个词语若在整个文本库中出现频率较少，则代表这是此条文本的一个重要特征。例如前述文本例子中的“大涨”在文本库中仅出现了一次，因此能够成为文本 1 的一个重要特征。TF-IDF 方法是在基于 Bag of words 法的情况下，通过公式将 TF 与 IDF 指标结合而形成的文本词向量进阶表示法。TF-IDF 的公式可以表示为：

$$TFIDF_{i,j} = tf_{i,j} \times \log \frac{N}{1 + df_{i,j}} \quad (2-1)$$

公式2-1中，角标 i, j 表示第 j 个文本中的第 i 个词语，而 $tf_{i,j}$ 表示 TF 值，第 j 个文本中的第 i 个词语在第 j 个文本中出现的频率， $df_{i,j}$ 表示第 j 个文本中的第 i 个词语在全部 N 个文本中出现的频率，因此 $\log \frac{N}{1 + df_{i,j}}$ 代表 IDF 值。通过公式2-1可以得到文本 3 的 TF-IDF 表示值为：

$$\{\text{文本 3} : (0.11, 0.04, 0, 0.11, 0, 0.23, 0.23, 0.23)\}$$

对比 TF-IDF 表示法和 Bag of words 表示法，不难发现，TF-IDF 为词向量赋予了不同的权重，虽然解决了权重问题，但词向量维数仍等于互异的词语数量，随着文本库的增大，仍存在词向量维数较大的问题。

N-gram 模型是一种统计语言模型，通过词语来刻画某条文本出现的概率。假设文本 W 的长度为 n ，即包含 n 个词语，可表示为 $\{W = (w_1, w_2, w_3, \dots, w_n)\}$ ，

则此条文本出现的概率（即 n 个词语同时出现的概率，简称为共现概率）可表示为：

$$P(W = (w_1, w_2, \dots, w_n)) = P(w_1)P(w_2|w_1)P(w_3|w_2, w_1) \dots P(w_n|w_{n-1}, \dots, w_1) \quad (2-2)$$

语言模型的核心是使得各个条件概率 $P(w_t|w_{t-1}, \dots, w_1)$ 最大。对于自然语言而言，一般词语的含义仅与其最接近 N 个词语相关联，而较远的词语则无明显关联。因此，可以简化为最大化 $P(w_t|w_{t-1}, \dots, w_{t-N})$ 。而 N -gram 模型中的 N 的定义正是如此，即该词语附近与其相关联的词语个数。 N -gram 模型虽然同样未能解决词向量长度较大的问题，但在一定程度上联系了词语的前后文，更加贴合实际。

总之，One-hot 独热向量、Bag of words 词袋法、TF-IDF 法、 N -gram 模型均无法准确刻画词语之间的联系，并且在大型文本库中，由于维数较大，所表示的文本矩阵均非常稀疏，有效信息丢失较为严重，因此需要一种更先进的文本表示方法。

2.2.2 分布表示

针对上一小节中词向量所表示出的文本矩阵过于稀疏以及向量长度较长的问题，学界出现了文本信息的分布表示。分布表示是将 Harris 在 1954 年提出的分布假说（distributional hypothesis）作为理论基础而出现的，分布假说指出：在上下文本中相似的词语，其语义也相似。分布表示方法的原理之一是将词语表示到高维空间，从而得到稠密向量，同时包含了上下文关系，使得词语之间的联系得以凸显。分布表示需要构建“单词-上下文”矩阵，具体可分为“词语-文本”矩阵、“词语-词语”矩阵和“词语- N 元词组”矩阵，之所以出现三种类别，是因为上下文考虑的所属范围不同。例如最常用的“词语-文本”矩阵是将词语所在的整个文本作为上下文，而“词语-词语”矩阵和“词语- N 元词组”矩阵则是将词语前后一个或多个词语作为上下文而构建的。“单词-上下文”矩阵的元素可选取共现次数、TF-IDF 等。一般而言，得到的矩阵非常稀疏，需要进行降维处理，常用的降维方法包括主成分分析（PCA），奇异值分解等。

词嵌入 (Word embedding) 是指通过神经网络模型构建的分布表示方法, 又称神经网络语言模型 (Neural Network Language Model, NNLM), 由 Bengio 等 (2003)^[30] 提出。其结构图如2-3所示。NNLM 的问题在于训练时间极长, 对于现在动辄千万级别的真实语料库, 几乎不可能完成。




图 2-3 经典的神经网络语言模型

随后文本分析技术的发展, 一些改进的词嵌入模型出现了, 常见的包括 Word2vec、BERT、GloVe、ELMo 等被广泛应用。Word2vec 是基于经典的 NNLM 模型进行改进: 1、移除了前反馈神经网络中非线性的隐藏层, 中间层 Embedding layer 与输出层 softmax layer 直接连接。2、输入的所有 One-hot 词向量均传递到同一个中间层。3、上下文环境纳入 Future words。由此, 形成了经典的 Word2vec 算法的第一个模型, CBoW 模型 (Continuous Bag-of-Words Model)。而 CBoW 模型是从待预测词语的前后词语出发进行预测的, 而逆向的从当前词出发预测上下文词语, 则形成了 Skip-gram 模型。




图 2-4 Word2vec 的两类模型

ELMo (Embeddings from Language Models) 模型是 2018 年 3 月由 AllenNLP 的 Matthew E. Peters (2018) 等^[31] 首次提出，是一种用于生成动态词向量的预训练语言模型。ELMo 与 Word2vec 不同，采用多层 LSTM 搭建语言模型，同时结合 CBoW 模型与 Skip-gram 模型特点，双向训练模型，因此能够根据前后文本词语动态地改变词向量的表达式，结构图如2-5所示。




图 2-5 ELMo 模型

ELMo 模块分为左右两部分，本质上是一个双向语言模型。对于左半部分，给定了 N 个词语 $t_1, t_2, \dots, t_N$ ，语言模型通过前面 $k-1$ 个位置的词语序列来计算第 k 个词语出现的概率，构成前向双层 LSTM 模型。

$$p(t_1, t_2, \dots, t_N) = \prod_{k=1}^N p(t_k | t_1, t_2, \dots, t_{k-1}) \quad (2-3)$$

同理, 对于架构中的右半部分, 给定了 N 个词语 $t_{k+1}, t_{k+2}, \dots, t_N$, 语言模型通过后面 $N - k$ 个位置的词语序列来计算第 k 个词语出现的概率, 构成后向双层 LSTM 模型。

$$p(t_1, t_2, \dots, t_N) = \prod_{k=1}^N p(t_k | t_{k+1}, t_{k+2}, \dots, t_{k+N}) \quad (2-4)$$

结合公式2-3和公式2-4可知, ELMo 模型训练的核心在于最大化公式2-5, 其中 $\vec{\Theta}_{LSTM}$ 代表前向 LSTM 的网络参数, $\overleftarrow{\Theta}_{LSTM}$ 表示反向的 LSTM 的网络参数, Θ_x 表示映射层的共享, Θ_s 表示上下文矩阵的参数。

$$\sum_{k=1}^N [\log p(t_k | t_1, \dots, t_{k-1}; \Theta_x, \vec{\Theta}_{LSTM}, \Theta_s) + \log p(t_k | t_{k+1}, \dots, t_N; \Theta_x, \overleftarrow{\Theta}_{LSTM}, \Theta_s)] \quad (2-5)$$

对于每个词语而言, 通过一个 L 层的双向 LSTM 网络可以计算出 $2L + 1$ 个表示向量如下2-6, 其中前向 LSTM 语言模型的第 j 层第 k 时刻的输出向量命名为 $\vec{h}_{k,j}^{LM}$, 后向类似表示。

$$R_k = \{x_k^{LM}, \vec{h}_{k,j}^{LM}, \overleftarrow{h}_{k,j}^{LM} | j = 1, \dots, L\} = \{h_{k,j}^{LM} | j = 1, \dots, L\} \quad (2-6)$$

通过 ELMo 模型, 便可以得到公式2-6表示的词向量, 充分解决了离散表示方法中的各个问题。

第三节 基于词典的分析方法

情感词典分析方法直观易懂, 其分析步骤是先将文本分句、分词, 然后通过对比停用词表, 删除停用词。常见的停用词表包括四川大学机器智能实验室停用词库、哈工大停用词表以及百度停用词表等, 本文拟采用上述三个词表的并集。

随后, 将去除停用词后的词语与情感词典对比, 若为积极情绪, 则情绪系数视为 1, 若为消极情绪, 则情绪系数视为-1, 且需要乘以其在分句中的重要权重。同时, 若有否定词、程度词的出现, 则分别乘以-1 和情绪程度系数, 再加权即可得到该分句的情感值。此外, 还需要对文本最后的“?”和“!”标点进行处理, 若带有“?”的句子同时出现“难道”等反问词和否定词, 将被判断为反问

句，则影响系数设为-0.8，若为疑问句，则影响系数设为 0.5。若出现“!”，则影响系数设为 1.5。最终通过分句求和，得到该文本的情感值。




图 2-6 情感词典分析方法

分句情感数值 EM 具体的计算公式可以表示为公式2-7。

$$EM = q \times \frac{\sum_{i=1}^{N_p} w_i \times p_i - \sum_{j=1}^{N_n} w_j \times p_j}{N_p + N_n} \quad (2-7)$$

其中 N_p 和 N_n 分别表示分句中积极词汇与消极词汇的数量， w_i 表示词汇在分句中的重要性权重， p_i 代表否定词和程度词联合作用的影响系数，而 q 代表疑问句、反问句对分句的影响系数。

第四节 基于深度学习的文本分析模型

2.4.1 多头注意力机制与 Transformer 模型

注意力机制 (Attention) 由 D. Bahdanau、K. Cho 和 Y. Bengio (2014)^[32] 提出，在论文中首次将注意力机制应用于神经网络机器翻译中。目前已被广泛地应用于各个领域，其作用可以简单地表达为“注意”重要信息部分。在大规模的神经网络模型训练过程中，存在着信息过载的问题，而引入注意力机制能

够聚焦与任务相关的关键信息，以提高运行效率。Attention 机制的公式如2-8所示：

$$Attention(Q, K, V) = softmax(Similarity(Q, K))V \quad (2-8)$$

其中 Q 代表查询向量， K, V 代表键值对，而 $Similarity$ 为可定义的相似度函数。注意力公式可理解为：寻找查询向量 Q 和 K 的相似度 α ，再与值 V 加权求和。常用的 $Similarity$ 包括：

- 1、点积缩放 $\alpha = \frac{Q \cdot K_i}{\sqrt{d_k}}$
- 2、余弦相似度 $\alpha = \frac{Q \cdot K_i}{\|Q\| \cdot \|K_i\|}$
- 3、加法变换 $\alpha = [Q, K_i]W + b$
- 4、矩阵变换 $\alpha = Q^T W K_i$

有时神经网络模型的输入变量长度并不相同，且输入变量之间也存在着一定联系，为进一步优化，于是出现了自注意力机制（Self-Attention）。自注意力机制可以发生在输入或者输出序列的内部，例如可寻找文本的语句结构。

设输入的序列长度为 N ，表示为 $X = [x_1, x_2, \dots, x_N]$ ，输出序列 $H = [h_1, h_2, \dots, h_N]$ ，可学习的参数矩阵为 W_Q, W_K, W_V 。利用参数矩阵，输入序列 X 通过线性变换2-9便可以得到公式2-8中的 Q, K, V 。

$$\begin{aligned} Q &= W_Q X \in \mathbb{R}^{d_Q \times N} \\ K &= W_K X \in \mathbb{R}^{d_K \times N} \\ V &= W_V X \in \mathbb{R}^{d_V \times N} \end{aligned} \quad (2-9)$$

可学习的参数矩阵通过线性变换2-9将注意力机制与自注意力机制联系了起来，两者的区别就在于自注意力机制中的 Q, K 均来源于同一个输入序列 X 在三个空间的映射。

而多头自注意力机制（Multihead Self-Attention）则是对 Q, K, V 利用参数矩阵 W^Q, W^K, W^V 进行线性变换后，再计算 $Attention$ ，重复 h 次，且每一次的参数矩阵 W^Q, W^K, W^V 均有更新，将 h 个结果拼接而形成。给定可学习的参数矩阵 $W_i^Q, W_i^K, W_i^V, i = 1, 2, \dots, h$ ，多头注意力机制 $MultiHead$ 可表示为式2-10，

其中 $concat$ 表示向量拼接，Attention 函数为上述公式2-8。

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (2-10)$$

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O$$

Transformer 模型是 Google 团队 Vaswani 等 (2017)^[33] 提出的一种自然语言处理模型，模型中多次使用多头自注意力机制，而不使用循环神经网络的迭代，且能够高效率的并行完成任务，Transformer 模型的框架如图2-7所示。




图 2-7 Transformer 模型架构

Transformer 模型通过词嵌入和位置编码 (Positional Encoding) 完成数据处理操作，Positional Encoding 的公式如2-11所示：

$$PE_{pos,2i} = \sin \frac{pos}{10000^{\frac{2i}{d_{model}}}} \quad (2-11)$$

$$PE_{pos,2i+1} = \cos \frac{pos}{10000^{\frac{2i}{d_{model}}}}$$

其中 $PE_{pos,i}$ 代表第 $pos - 1$ 位置的词语的词向量在第 i 个维度的数值， d_{model} 是指模型的维度。而 Positional Encoding 与词嵌入的向量结合形成了 Transformer 模型的输入变量。随后通过前述的多头自注意力机制2-10，得到多头自注意力矩阵，再通过全连接层转化为向量 x 。在经过残差连接及归一化处理后输入到前馈神经网络中，即如下式子2-12中。

$$FFN(X) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (2-12)$$

而 Decoder 部分相似，不过包括两个多头自注意力机制，且第一个多头自注意力机制存在掩码操作，在训练阶段屏蔽尚未翻译的词语，最后通过全连接层及 *Softmax* 输出概率。

2.4.2 BERT 模型

BERT(Bidirectional Encoder Representation from Transformers) 是由 Google Jacob Devlin (2018) 等^[34] 在 Transformer 的基础上提出的一种语言处理模型。BERT 模型的输入层结构如图2-8所示。




图 2-8 BERT 模型输入层例子

输入部分主要包括三个嵌入板块，词嵌入 (Token Embedding)、段嵌入 (Segment Embedding) 和位置嵌入 (Position Embedding)，分别代表词语信息、所在文本段落信息及位置信息，其中位置嵌入如式子2-11所示。此外 BERT 模型架构包括两个阶段，预训练 (Pre-Training) 及微调 (Fine-Tuning)。




图 2-9 BERT 模型结构

图2-9展示了 BERT 模型架构。其中预训练阶段包括两个任务，遮蔽预测

(Masked Language Model, MLM) 和下一句预测 (Next Sentence Prediction, NSP)。其中 MLM 是在训练的时候, 随机掩盖一些输入序列中的词, 遵从如下两条规则:

- 1、选取 15% 的词语进行掩盖。
- 2、在这 15% 被掩盖的词语中, 80% 被替换为记号 $[mask]$, 10% 会被其他随机词语替换, 剩下 10% 不做处理。

而 NSP 是判断两个句子片段是否存在上下文关系。从文本库中随机选取连续的两个短句和不连续的两个短句, 各占 50%, 随后由模型判断两个短句是否连续。

BERT 模型的 Fine-Tuning 阶段则是为了使得模型适应不同的文本分析任务, 包括情感分析、文本理解等问题。不同的文本分析任务, BERT 模型的主体框架不会改变, 只需要加上所要的网络结构层即可完成任务要求, 极大地增强了 BERT 模型的适用性。

第五节 指数预测相关模型理论

2.5.1 XGBoost 模型

XGBoost (Extreme Gradient Boosting) 是一个强大的机器学习模型, 是由陈天奇等 (2016)^[35] 提出, 被广泛应用于数据挖掘、自然语言处理和计算机视觉等领域。XGBoost 是基于树模型的集成学习算法, 它采用了 Boosting 的方法, 即通过不断迭代来提高模型的准确性。

具体来说, XGBoost 使用多个决策树模型来进行预测, 每个决策树模型都是一个弱学习器。在每一轮迭代中, XGBoost 会根据前一轮迭代的结果调整每个弱学习器的权重, 然后将它们组合起来形成一个更强的学习器。同时, XGBoost 还采用了正则化技术来避免过拟合, 包括 L1 和 L2 正则化、缺省值处理和子采样等。

XGBoost 是梯度提升树模型的一种, 属于对 GBDT 算法改进的高效算法。GBDT 即梯度提升决策树 (Gradient Boosting Decision Tree) 是一种基于 Boost-

ing 集成思想的加法模型，训练时采用前向分布算法进行贪婪的学习，每次迭代都学习一棵 CART 树来拟合之前 $t-1$ 棵树的预测结果与训练样本真实值的残差。一般有可加结构的提升树 $f_K(x)$ 可以表示为：

$$f_K(x) = \sum_{k=1}^K T_k(x, \theta_k) \quad (2-13)$$

其中 $T_k(x, \theta_k)$ 是决策树，使用逐步向前法获得。每步使用一棵决策树来拟合前 $t-1$ 棵树的预测结果与训练样本真实值的残差，每步估计 θ_m 的目标函数可以表示为：

$$l(\theta_k) = \sum_{i=1}^N l(y_i, f_{k-1}(x_i) + T_k(x_i, \theta_k)) \quad (2-14)$$

直接求解该目标函数一般较困难，且过于贪婪，可以对目标函数做一阶泰勒展开近似：

$$l(\theta_k) \simeq \sum_{i=1}^N l(y_i, f_{k-1}(x_i)) + g_{ik} T_k(x_i, \theta_k) = \sum_{i=1}^N [g_{ik} T_k(x_i, \theta_k)] + Con \quad (2-15)$$

$$g_{ik} = \left. \frac{\partial l(y_i, f(x_i))}{\partial f(x_i)} \right|_{f(x)=f_{m-1}(x)}$$

具体的算法的实现流程可以表示如下：

第一步：初始化 $f_0 = \arg \min_{\gamma} \sum_{i=1}^N l(y_i, f_{k-1}(x_i) + \gamma)$;

第二步：迭代 $k = 1, 2, \dots, K$ 次

1) 对训练样本 x_i 计算损失函数的梯度。

$$g_{ik} = \left. \frac{\partial l(y_i, f(x_i))}{\partial f(x_i)} \right|_{f(x)=f_{m-1}(x)} \quad (2-16)$$

2) 求解回归树 $\sum_{i=1}^N [g_{ik} T_k(x_i, \theta_k)]$, 得到

$$\hat{\theta}_m = \{(\hat{R}_{mk}, \hat{c}_{mk}), m = 1, \dots, M_k\} \quad (2-17)$$

3) 保留 $\{\hat{R}_{mk}, m = 1, \dots, M_k\}$, 再次估计:

$$c_{mk} = \arg \min_{\gamma} \sum_{x_i \in \hat{R}_{mk}} l(y_i, f_{k-1}(x_i) + \gamma) \quad (2-18)$$

4) 更新如下式子:

$$f_k(x) = f_{k-1}(x) + \sum_{m=1}^{M_k} \hat{c}_{mk} I(x \in \hat{R}_{mk}) \quad (2-19)$$

第三步：输出 $f(x) = f_M(x)$

XGBoost 相比 GBDT，对目标函数展开到了二阶：

$$l(\theta_k) \simeq \sum_{i=1}^N [l(y_i, f_{k-1}(x_i)) + g_{ik} T_k(x_i, \theta_k) + \frac{1}{2} h_{ik} (T_k(x_i, \theta_k))^2] \quad (2-20)$$

$$h_{ik} = \frac{\partial^2 l(y_i, f(x_i))}{\partial f(x_i)^2} \Big|_{f(x)=f_{k-1}(x)}$$

同时 XGBoost 对目标函数引入了正则化惩罚项，并加入了预剪枝处理防止过拟合。总之，XGBoost 的优点包括准确性高、速度快、可扩展性好等，已经成为了许多数据科学家和机器学习从业者的首选模型之一。

2.5.2 卷积神经网络模型

卷积神经网络（Convolutional Neural Network, CNN）是一种深度学习神经网络，是由 LeCun 等（1998）^[36] 提出，主要用于图像、音频、视频等数据的识别和分类任务。CNN 通过卷积、池化等操作提取特征，并通过全连接层进行分类。

CNN 模型主要由卷积层、池化层和全连接层组成。其中卷积层是 CNN 模型的核心，通过卷积操作提取图像特征。池化层用于降低特征图的维度和大小，减少参数数量，增加模型的鲁棒性。全连接层将特征图转换为分类结果，CNN 的结构如图2-10所示。




图 2-10 CNN 的结构图

卷积层的数学公式为：

$$h_{i,j}^k = \sigma \left(b_k + \sum_{u=1}^m \sum_{v=1}^n w_{u,v}^k \cdot x_{i+u-1,j+v-1} \right) \quad (2-21)$$

其中, $h_{i,j}^k$ 表示第 k 个卷积核在位置 (i, j) 的卷积结果, $x_{i+u-1, j+v-1}$ 表示输入特征图在位置 $(i+u-1, j+v-1)$ 的值, $w_{u,v}^k$ 表示第 k 个卷积核在 (u, v) 位置的权重, b_k 表示第 k 个卷积核的偏置, σ 表示激活函数。

池化层的数学公式为:

$$y_{i,j}^k = \max_{u=1}^p \max_{v=1}^q x_{i \times p + u - 1, j \times q + v - 1} \quad (2-22)$$

其中, $y_{i,j}^k$ 表示第 k 个池化核在位置 (i, j) 的池化结果, $x_{i \times p + u - 1, j \times q + v - 1}$ 表示输入特征图在位置 $(i \times p + u - 1, j \times q + v - 1)$ 的值, p 和 q 表示池化核的大小。

全连接层的数学公式为:

$$y_k = \sigma \left(b_k + \sum_{i=1}^n w_{i,k} \cdot x_i \right) \quad (2-23)$$

其中, y_k 表示第 k 个输出类别的得分, x_i 表示输入特征向量的第 i 个分量, $w_{i,k}$ 表示第 i 个输入和第 k 个输出之间的权重, b_k 表示第 k 个输出的偏置, σ 表示激活函数。

CNN 模型在训练时通过反向传播算法更新卷积核和全连接层的权重, 以使得模型能够更好地提取特征和分类。

2.5.3 长短时记忆网络模型

长短时记忆网络 (Long Short-Term Memory, LSTM) 是一种循环神经网络 (Recurrent Neural Network, RNN) 模型, 由 Hochreiter 等 (1997)^[37] 提出, 主要用于处理时间序列数据, 例如语音识别、自然语言处理等任务。相比传统的 RNN 模型, LSTM 模型可以更好地避免长期依赖 (Long-term Dependency) 问题。

LSTM 模型包含了一个称为 “LSTM 单元” 的重复模块, 这个模块有三个门 (Gate) 来控制信息的流动: 输入门 (Input Gate)、遗忘门 (Forget Gate) 和输出门 (Output Gate)。输入门控制新输入信息的流入, 遗忘门控制过去信息的流出, 输出门则控制输出信息的流出。LSTM 模型还使用了一些辅助变量, 如细胞状态 (Cell State) 和隐状态 (Hidden State), 以便更好地捕获时间序列数据中的长期依赖关系。LSTM 模型的结构图如图2-11所示。




图 2-11 LSTM 模型的结构图

输入门：

$$i_t = \sigma(W_i[x_t, h_{t-1}] + b_i) \quad (2-24)$$

其中， x_t 表示时间步 t 的输入， h_{t-1} 表示时间步 $t-1$ 的隐状态， W_i 和 b_i 是输入门的权重矩阵和偏置向量， σ 表示 Sigmoid 函数。

遗忘门：

$$f_t = \sigma(W_f[x_t, h_{t-1}] + b_f) \quad (2-25)$$

其中， W_f 和 b_f 是遗忘门的权重矩阵和偏置向量。

细胞状态更新：

$$\tilde{C}_t = \tanh(W_C[x_t, h_{t-1}] + b_C) \quad (2-26)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

其中， $\tanh$ 表示双曲正切函数， $\odot$ 表示逐元素乘法。

输出门：

$$o_t = \sigma(W_o[x_t, h_{t-1}] + b_o) \quad (2-27)$$

隐状态更新：

$$h_t = o_t \odot \tanh(C_t) \quad (2-28)$$

其中， W_o 和 b_o 是输出门的权重矩阵和偏置向量。LSTM 模型还包括一些变体，对 LSTM 单元的不同部分进行了一些改进和调整，以适应不同的任务和数据。在金融数据的实践中，LSTM 模型表现优异，可以用于多种预测任务，如时间序列预测、风险管理、投资组合优化、交易策略，具体而言：

1、时间序列预测：LSTM 模型可以对金融市场的时间序列数据进行预测，如股票价格、货币汇率等。通过使用历史数据来训练 LSTM 模型，可以预测未

来的市场趋势，为交易策略提供有用的信息。

2、风险管理：LSTM 模型可以用于识别潜在的金融风险和市场异常。通过监控市场变化并实时预测风险，金融机构可以及时采取措施来降低风险。

3、投资组合优化：LSTM 模型可以用于预测不同投资组合的回报和风险，从而帮助投资者构建优化的投资组合。

4、交易策略：LSTM 模型可以用于开发交易策略。通过对历史市场数据的学习，LSTM 模型可以发现市场中的模式和趋势，并基于这些信息生成交易信号。

第三章 基于文本情感分析构建投资者关注度因子

本章节的内容主要分为三个部分，获取投资者关注度数据、文本数据分析及构建因子。获取数据方面，主要通过 python 网络爬虫程序爬取股票投资者评论相关的文本数据，然后对其进行一些数据清洗及处理工作。而构建因子方面，由于文本数据不能够直接输入到后续的机器学习模型中，我们需要先将文本数据转化为数值，因此将通过文本情感分析构建投资者关注度因子。

第一节 python 网络爬虫数据获取

3.1.1 投资者关注数据内容

本节的研究内容以白酒行业为例，共计 11 支股票，均为行业的龙头股票，能够充分代表行业指数走势，数据的时间范围选取 2016 年 1 月 1 日-2022 年 10 月 31 日。

成分券代码 Constituent Code	成分券名称 Constituent Name	成分券英文名称 Constituent Name(Eng.)	交易所 Exchange
600559	老白干酒	LAO BAI GAN JIU	SHH
600519	贵州茅台	KWEICHOW MOUTAI	SHH
600779	水井坊	SCSF	SHH
600809	山西汾酒	SHANXI FEN WINE	SHH
603589	口子窖	KOUZIJIAO	SHH
600199	金种子酒	AGSW	SHH
000568	泸州老窖	LUZHOU LAO JIAO	SHZ
002304	洋河股份	YANGHE	SHZ
000596	古井贡酒	GUJING DISTILLERY	SHZ
000799	酒鬼酒	JGJC	SHZ
000858	五粮液	WULIANGYE	SHZ

图 3-1 白酒行业个股

投资者关注度因子相关数据来源包括两个方面，第一类是指数类数据。采用百度指数中的搜索指数以及资讯指数：其中搜索指数是指互联网用户通过百度搜索引擎对某只股票的搜索频次，能够合理反映出一段时间内散户投资者对某只股票的关注程度。根据搜索来源的不同，分为电脑搜索指数和移动端（手机、ipad 等）搜索指数。而资讯指数是指官方媒体、自媒体等在一定时间范围内，所发布的资讯、新闻和分析等文章中，提及到某只股票的频次，能够合理反映出机构投资者（或具备一定社会影响力的投资者）对某只股票的总体关注度。




图 3-2 百度搜索指数（五粮液）

第二类数据是金融文本类数据。主要包括投资者对某只股票的评论，以及相应的能反映此条评论影响力的数值类指标。东方财富作为市场上最具影响力的互联网券商，其市值为上市券商中规模最大，而东方财富网也受益于此，成为投资者们的讨论平台，投资者能够自由地在股吧栏目上发表对某一股票的观点看法，同时网站披露阅读量、评论数及时间等可分析数据，因此东方财富网股吧数据具备较大影响力、数据披露程度高等特点。本章节实证分析主要从东方财富股吧中利用 Python 爬取网站内容，并对数据进行结构化预处理，以便后续进行自然语言处理及输入机器学习模型。

阅读	评论	标题	作者	最后更新
119	0	就这只老白干让我赚了钱是最棒的。	如玉柴8534	11-04 09:54
94	0	这个垃圾是没救了	沈慕慕	11-04 09:51
103	0	涨了，我卖了。祝各位发财。	股友77tZ609772	11-04 09:47
118	1	金种子都要涨停了我真是服了你	博天可以涨一次吗	11-04 09:46
86	0	诱多吗	沉罐溪	11-04 09:40
95	0	今天涨停见	了凡一休	11-04 09:39
104	1	金种子yyds	韭菜怎么练成得	11-04 09:37
92	0	追高者陪惨	股市英雄不论出身	11-04 09:35
499	3	如果老白干这次底部能太高到20.91，白酒来波行情，有	与恶庄为伍	11-04 08:59

图 3-3 东方财富股吧网站包括的数据内容

python 爬取代码的思路主要包括提取股票列表、生成个股股吧 URL、提取

其中每条评论页面的 URL、解析评论页面内容、CSV 文件储存数据、数据结构化处理等步骤。




图 3-4 东方财富股吧爬虫流程

3.1.2 代理 ip 池技术

需要注意的是，东方财富网股吧作为公开的网站，因过去频繁地被爬取，故网站设置了反爬取策略，单位时间频繁访问会被禁用 IP，致使爬虫程序难以进行。本实证所需公开数据量未达到 1GB 以上，数据量非常有限，因此决定采用限制访问频率的方法，设置访问网站时间间隔，合理地模拟人工访问，此种做法的唯一缺点只是所需时间较长，并且不会对东方财富网服务器造成负担。首先，需要测试出东方财富网对爬取进行限制的阈值，以便后续通过代理 IP 池等方法完成数据爬取工作。经过程序测试，如图3-5中左图所示，东方财富网站的反爬取策略约为每 24 小时限额约 1000 次（测试结果为 936 次）访问。



图 3-5 东方财富反爬阈值约为 936 次/24h

若在 24 小时内超过 1000 次访问，将会被短时间禁用 ip，禁止再次访问，此时通过浏览器访问将会得到图3-5中右图所示的禁止访问反馈。值得注意的是，

网站采取的并非强制 24 小时禁止访问，而是滚动释放访问次数限制，每半个小时可访问约 20 次，等待一段时间后即可再次访问。

为解决东方财富网的访问次数限制，考虑到实证研究所需数据有限，估计访问次数约在 2-3 万次左右，因此我们可以合理地采用代理 IP 池的方式爬取数据，并尽可能的拉长爬取时间，在符合相关法律法规的同时，也不会对网站服务器造成较大负担。

Python 爬虫代理 IP 池 (proxy pool) 是一种爬虫领域的常见方法。代理 ip 的本质是代理服务器，能够替代用户去访问网站，并取得所需信息，是网站信息的中转接口。一般通过浏览器请求网站信息时，需要将请求信息发送给 web 服务器，而如果 web 服务器设置了单用户 ip 访问频率限制，将使得在该 ip 较多数据请求的情况下，web 服务器拒绝该 ip 的所有请求，无法正确获取信息。理论上，这样的措施的目的是保护 web 服务器，但常常设置地过于严格，几乎仅限于人工访问，从而导致一些合理的信息爬取程序无法正常进行，即使这些爬取程序并不会损伤服务器。因此爬虫代理 IP 池技术出现，通过设置代理服务器，在本机和服务器之间搭建桥梁，通过代理服务器向 Web 服务器发起访问请求，Web 服务器再将响应信息发送给代理服务器，代理服务器再将信息传回给本机。这一过程中 Web 服务器识别出所识别出的 ip 并非本机 ip，而是代理服务器 ip，因此实现了 IP 地址的替代，能够合理解决爬虫中 web 服务器封锁 IP 的难题。Python 爬虫代理 IP 池技术是在能够合理地爬取信息的情况下使用，需要保证所请求的次数合理、请求的信息量合理，任何恶意的使用是不被允许的。而本文实证研究所需请求次数约在 2-3 万次，爬取信息量总计不超过 1GB，爬取程序运行时间拉长至 3-4 天，因此不会对 web 服务器造成负担。




图 3-6 爬取过程中的 IP 代理

代理 IP 池设计框架主要包括四个板块内容，分别是获取模块、检测模块、存储模块、接口模块。其中，获取模块是指：爬取一些公开的代理服务器。如果条件允许，可以使用自行搭建的更好的代理接口接入。检测模块是指：检测代理服务器的可用性。因为公开的代理服务器存在不可用部分，需要通过简短的检测程序判断是否可以正常使用。存储模块是指：存储代理服务器。需保证各代理服务器地址不重复，同时动态实时处理各个代理，本文利用 MongoDB 来存储。接口模块：一般使用 API 来提供对外服务的接口。




图 3-7 代理 IP 池设计框架

3.1.3 数据爬取、处理及统计描述

通过 python 中的 requests 库，即可完整实现数据爬取工作。下方展示爬取过程中两个主要循环，抓取帖子主要内容。其中，代码通过 `time.sleep(random.uniform(1,1.5))` 命令用于降低访问频次，每 1-1.5 秒访问一次，避免对网站服务器造成较大负担。

代码 3.1 spider.py

```

for i in range(pagee):
    url = "http://guba.eastmoney.com/list,{0},f_{1}.html".format(
        stock, i+1)
    record=spiderPage(url,i+1,stock)
    if record_con.shape[0]==0:
        record_con=copy.deepcopy(record)
    else:
        record_con=record_con.append(record,ignore_index=True)
    if i%500==0:
        print('股票{0}: 已完成{1}/{2}页帖子列表抓取'.format(stock,i
            +1,pagee))
        time.sleep(random.uniform(1,1.5)) ##用于降低访问频次, 每1-1.5秒
            才访问一次, 避免对网站服务器造成较大负担

```

使用前述的东方财富网股吧数据的爬取方法, 我们得到大量的文本数据。由于数据量较多, 为方便后续输入模型, 需要对数据进行一定的结构化处理, 同时清洗异常值。其中异常值的出现是由于在东方财富股吧网站中存在少量的推广类帖子, 其数据格式与投资者自行发布的讨论贴不同, 并且也不能客观反映投资者情绪。因此, 需要剔除掉这一部分数据。最终以 titles (评论标题)、reads (阅读数)、comm (评论数)、hrefs (帖子网址)、users (用户名)、uids(用户 id)、post (发帖时间)、update (最后更新评论时间)、page (帖子所在页码) 制作数据结构。最终结构化处理后的数据结构如图3-8所示, 其中较为关键的变量为 titles (评论标题)、reads (阅读数)、comm (评论数)、post (发帖时间) 等四个变量。

titles	reads	comm	hrefs	users	uids	post	update	page
明天给一个站上5日线的机会	['120']	['0']	/news,6005	['我挺好的不']	['202338']	['10-31 23:58']	['10-31 23:58']	1
发利好, 必大跌	['98']	['0']	/news,6005	['股友TxFUX']	['882521']	['10-31 23:49']	['10-31 23:49']	1
民生证券给予老白干酒推荐评级	['760']	['7']	/news,6005	['老白干酒资']	['882521']	['10-31 20:19']	['10-31 20:19']	1
德邦证券给予老白干酒买入评级 业绩超预期 中高档酒持续发力	['590']	['1']	/news,6005	['老白干酒资']	['882521']	['10-31 20:19']	['10-31 20:19']	1
民生证券维持老白干酒推荐评级 预计2022年净利润同比增长74.71%	['209']	['0']	/news,6005	['公司研报提']	['484534']	['10-31 20:16']	['10-31 20:16']	1
2022年三季报点评: 精耕渠道, 提质增效, 业绩增长亮眼	['2076']	['1']	/news,6005	['老白干酒资']	['882521']	['10-31 20:16']	['10-31 20:16']	1
业绩超预期, 中高档酒持续发力	['1670']	['0']	/news,6005	['老白干酒资']	['882521']	['10-31 20:12']	['10-31 20:12']	1
德邦证券维持老白干酒买入评级 预计2022年净利润同比增长78.31%	['184']	['0']	/news,6005	['公司研报提']	['484534']	['10-31 20:11']	['10-31 20:11']	1
招商证券维持老白干酒强烈推荐评级 目标价32元	['1290']	['1']	/news,6005	['公司研报提']	['484534']	['10-31 18:52']	['10-31 18:52']	1
哥们今天全仓抄底买入, 看到30, 到了就走	['340']	['3']	/news,6005	['骑在牛上的']	['418320']	['10-31 17:22']	['10-31 17:22']	1
跟着板块涨是没前途的	['166']	['0']	/news,6005	['匠心读档']	['833234']	['10-31 15:56']	['10-31 15:56']	1
坚决抛弃白酒股, 换医药见底的凯莱英	['310']	['10']	/news,6005	['A七星刀']	['562819']	['10-31 15:41']	['10-31 15:41']	1
我估计一下, 今天不入手的, 明天要眼红了, 明天或者后天大概率开始涨起来	['317']	['2']	/news,6005	['股场穿越者']	['971830']	['10-31 14:57']	['10-31 14:57']	1
不到20, 老白干	['117']	['0']	/news,6005	['龙行天下15']	['425009']	['10-31 14:40']	['10-31 14:40']	1
白酒基金连跌七天	['188']	['0']	/news,6005	['每周目标3']	['562856']	['10-31 14:40']	['10-31 14:40']	1
还没加速下跌呢, 慌个啥?	['153']	['0']	/news,6005	['股友27127']	['778338']	['10-31 14:39']	['10-31 14:39']	1

图 3-8 结构化数据输出的 csv 文件

需要注意的是, 在后续研究中, 由于所需的是能够代表广大投资者的指标,

同一用户在当日多次发言应当不被重复计入，因此在结合预测模型的实际意义后，应当在输入模型前剔除重复值，此时需要使用到具备唯一用户识别码的 uids(用户 id) 变量。

最终，通过以上爬取、清洗及去重步骤，获得了 11 支白酒股票 2016 年 1 月 1 日-2022 年 10 月 31 日的所有东方财富股吧帖子评论，共计 1070355 条文本数据。指数类数据中的搜索指数及资讯指数均为 27445 条。

表 3-1 投资者关注度数据

数据类别	数据结构	总计
投资者评论	股票代码、评论文本、阅读数、评论数、发帖时间	1070355
搜索指数	股票代码、指数、日期	27445
资讯指数	股票代码、指数、日期	27445

由于后续将要构建融合模型，我们需要着重关注投资者评论的标题文本长度特征，如下图3-9所示，可以看到，文本长度不足 9 个字符的约为 293277 条，约占数据总量的 27.4%。




图 3-9 投资者评论文本长度分布

3.1.4 数据集标注

由于爬取的文本数据均不带有情感标签，为使得后续情感分析模型顺利训练，我们需要人工标注以得到训练集。针对股吧的评论数据，若表达积极情况

(股票会上涨), 则标记为 1, 若表达消极情绪 (股票会下跌), 则标记为 0。为确保训练集的随机性, 从 11 只白酒股票的所有文本数据中随机选取了 9800 条数据进行人工标注, 这一过程主要通过互联网的众包平台委托人工完成, 最终数据集标注结果如下示例。

表 3-2 数据集标注示例

股票代码	评论	阅读数	评论数	发帖时间	情感类别
000858	业绩远超预期。 真稳	116	0	2022/10/27	1
000858	梭哈了, 明天 应该可以吃点 肉, 加油。	1211	30	2022/10/24	1
...	...	共计 9800 条	...	...	...

第二节 投资者评论的文本情感分析模型


3.2.1 结合 Word2vec 及 XGBoost 构建情感词典的分析模型

3.2.1.1 构建投资者评论情感词典

利用情感词典的方法对文本分析得到情感值需要用到情感词典, 常见的基础情感词典包括知网 Hownet 情感词典、台湾大学 NTUSD 简体中文情感词典等。但这些情感词典属于基础词典, 适用于日常领域, 而非专业领域。若将专业领域的文本信息用基础词典匹配, 则可能使得大量专业情感词语被遗漏, 因此需要构建专用领域的情感词典。胡家珩等 (2018)^[38] 通过 Word2vec 构建的词向量, 并利用神经网络模型, 分析专业领域候选情感词的情感倾向, 进而结合基础情感词典构成专业领域的情感词典。姜富伟等 (2021)^[39] 通过人工筛选和 Word2vec 向量方法构建了中文金融情感词典。

而对于本文研究的金融投资者评论领域, 尚无能够使用的专业领域词典, 因此本文将采用前文所述的 Word2vec 模型构建投资者评论情感词典。而构建专

业领域的情感词典方法流程图如图3-10所示。



而根据本文的研究内容，我们需要构建出金融领域的投资者评论情绪词典。根据图3-10所示，分别完成了以下步骤：

1、确定文本库。随机选取前述在东方财富股吧中爬取的 11 支白酒股票投资者评论数据的 10%，共计约 107035 条。以及 2022 年 8 月 1 日-2022 年 9 月 30 日新浪财经、每经网、金融界、中国证券网、证券时报网中的财经新闻，共计约 2015 篇^{注 1}。

2、文本处理。将上述搜集的文本资料利用 jieba 库完成分词，分词步骤，对比四川大学机器智能实验室停用词库、哈工大停用词表以及百度停用词表的并集，去除停用词。

3、转化为词向量。将处理后的文本库利用 Word2vec 模型转化为词向量。

4、选取种子词。利用信息检索，并对比文本库，人工筛选出 80 个能够代表金融领域的投资者评论的词汇作为种子词集合，如表3-3所示。

5、筛选出与种子情感词相似的候选情感词。词语的分布表示的优势在于能够刻画词语语义之间的相似性，从第三步中所有的文本库词向量中选取与种子词词向量余弦相似度大于 0.7 的情感词，共计 852 个候选情感词。

^{注 1} <https://github.com/DemonDamon/Listed-company-news-crawl-and-text-analysis>

表 3-3 金融领域的投资者评论种子词

种子词
涨停、拉板、地板、跌停、大跌、大涨、拉升、补仓、低位、反弹、跳水、抄底、重组、清仓、企稳、退市、亏损、扭亏、大赚、高送转、补涨、连板、小涨、翻红、回本、不玩、保本、增发、回购、装死

6、构建融合基础词典。融合基础词典来源采用知网 Hownet 情感词典、台湾大学 NTUSD 简体中文情感词典、清华大学李军中文褒贬义词典等三种词典^{注 2}，词典简述如表3-4，取并集后，随后进行去重，得到融合后的基础词典。

表 3-4 融合基础词典

基础词典	积极词语	消极词语
台湾大学 NTUSD	2811	8277
知网 Hownet	836	1254
清华大学李军中文	5567	4469
总计	9214	14000
融合基础词典	7852	11523

7、构建训练集并训练 XGBoost 模型。训练集包括两个部分，已有的训练集及人工标注的训练集。第一部分的已有训练集是通过融合基础词典和投资者评论文本库对比匹配，将相同的词语去除，这部分相同词语即带上了情感标签。第二部分是人工标注了 80 个投资者评论文本库中频率较高的情感词。两者结合形成训练集输入到 XGBoost 模型中训练。

8、分类候选情感词得到投资者评论情绪词典。将第 5 步得到的候选情感词输入第 7 步构建的情感分类器模型中进行分类，同时与第 6 步得到的融合基础词典进行合并，得到投资者评论情绪词典。

值得注意的是，大多数构建情感词典的方法中，在第 5 步的时候，就可以

^{注 2}数据来源：<https://github.com/ppzhenghua/SentimentAnalysisDictionary>

表 3-5 投资者评论情绪词典

积极词语	消极词语
冲锋、乐观、蓄力、坚强、上涨 等共计 8241 个词语	污染、拒绝、造假、弱势等共计 11986 个词语

确定候选情感词的情感标签，不必进行第 7 步的情感分类器模型去判断。因为一般而言，在第 5 步中，采用 Word2vec 词向量的余弦相似度判断，与积极情感种子词相似的词语更倾向于表达积极情绪，而与消极情感种子词相似的词语更倾向于是消极情绪。而本文采用 XGBoost 模型进行判断则提高了约 11.8 个百分点的准确度。在样本量为 220 的测试集上的准确度对比如下表3-6所示。

表 3-6 两种方法构建词典效果对比

评价维度	词向量余弦相似度构建	XGBoost 情感分类器构建
Accuracy	0.809	0.927
Precision	0.816	0.928
Recall	0.809	0.927
F1-score	0.809	0.927

3.2.1.2 情感词典模型效果及评价

根据前述图2-6中的流程，以及情感值的计算公式2-7，将前述章节中标注好的 9800 条数据输入投资者评论情绪词典模型进行测试，并选用 Accuracy, Precision, Recall 和 F1-score 作为模型的评价指标。

1、Accuracy (准确率): 指模型预测正确的样本数与总样本数之间的比例。当数据集中类别分布比较均匀时，准确率可以作为一个有效的评估指标。然而，在不平衡的数据集中，准确率可能会给出误导性的结果，而本文研究的投资者评论数据积极与消极比例约为 6:4，样本整体相对平衡。计算公式：

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (3-1)$$

其中，TP 表示真正例数（模型正确预测为正例的样本数），TN 表示真负例数（模型正确预测为负例的样本数），FP 表示假正例数（模型错误地将负例预测为正例的样本数），FN 表示假负例数（模型错误地将正例预测为负例的样本数）。

2、Precision (精确率)：精确率是指模型预测为正例的样本中，实际为正例的样本占比。精确率可以帮助我们评估模型在给出正例预测时的准确性。计算公式：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (3-2)$$

3、Recall (召回率)：召回率是指实际为正例的样本中，模型成功预测为正例的样本占比。召回率可以帮助我们评估模型对于真正例的覆盖程度。计算公式：

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (3-3)$$

4、F1-Score (F1 值) F1-Score 是精确率和召回率的调和平均数。F1-Score 的值越高，表示模型的性能越好。计算公式：

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3-4)$$

模型中分句情感分数计算函数的部分代码如3.2所示，其核心在于前面章节中的公式2-7，且注意需通过已有词表识别程度词和否定词。

代码 3.2 情感分数计算函数.py

```
def sen_score(emo_ciyu, Neg_word, degree, res):
    W = 1; score = 0; sen_ind = -1 ; sen_ind_list = list(emo_ciyu.
    keys())
    for i in range(0, len(res)):
        if i in emo_ciyu.keys():
            score += W*float(emo_ciyu[i])
            sen_ind += 1
            if sen_ind < len(sen_ind_list)-1: #判断是否存在程度词或
            否定词
                for j in range(sen_ind_list[sen_ind], sen_ind_list[
                sen_ind+1]):
                    if j in Neg_word.keys():
                        W *= -1
                    elif j in degree.keys():
                        W *= float(degree[j])
```



```

if sen_ind < len(sen_ind_list)-1:
    i = sen_ind_list[sen_ind+1]
return score

```

最终，投资者评论的专用情感词典模型的分类效果如下表3-7所示，模型在测试集上的准确度仅为 72.3%，因此词典模型的分类效果一般。

表 3-7 情感词典模型效果评价

类别	Precision	Recall	F1-Score
0	0.646	0.733	0.687
1	0.792	0.717	0.753
Accuracy			0.723
Macro Avg	0.719	0.725	0.720
weighted avg	0.732	0.723	0.725

词典模型在测试集上的部分结果3-8展示如下，其中情感值为归一化后的情感倾向概率，若情感值 ≤ 0.5 ，则被分类为消极，情感标签取 0。若情感值 > 0.5 ，则被判断为积极，情感标签取 1。

表 3-8 情感词典测试集输入结果展示

评论	情感值	情感类别标签
明显涨不动，有机构偷偷出货，慎入！	0.22	0
填单全仓买入五粮液！白酒大涨！大家不要错过良机	0.78	1
...	...	...

虽然投资者评论情感词典分析方法的整体准确度并不高，仅为 72.3%。但值得注意的是，模型在不同文本长度上的准确度表现是有明显差异的。当文本长度小于等于 9 个字符时，分类的准确度达到了 96.51% 的，而随着文本长度的增加准确度迅速下滑。情感词典分类准确度随着文本长度的变化图如3-11所示。




图 3-11 情感词典分类准确度随文本长度的变化图

3.2.2 基于 BERT 情感分类的分析模型

根据前面章节所述的 BERT 模型方法，本节中将标注好的数据按照 9: 1 的比例划分训练集和测试集，并将训练集输入模型。BERT 情感分类模型的核心在于多头自注意力机制，如代码3.3所示，主要需要引入三个 BERT 模型的核心元素：Queries, Values 和 Keys，且本文选取点积缩放公式 $\alpha = \frac{Q \cdot K_i}{\sqrt{d_k}}$ 作为 *Similarity* 函数。

代码 3.3 BERT 自注意力函数.py

```
class self_attention(attention.Module):
    def __init__(self, size, mulheads):
        super(self_attention,self).__init__()
        self.size=size;self.mulheads=mulheads;self.head_dim=size//mulheads
        assert(self.head_dim*mulheads==size)
        self.queries=attention.Linear(self.head_dim, self.head_dim, bias=False)
        self.keys=attention.Linear(self.head_dim, self.head_dim, bias=False)
        self.values=attention.Linear(self.head_dim, self.head_dim, bias=False)
        self.fc_out=attention.Linear(mulheads*self.head_dim, size)
    def forward(self,values,keys,query,mask):
        N=query.shape[0]
        value_len,key_len,query_len=values.shape[1],keys.shape[1],query.shape[1]
```

```

        values=values.reshape(N,value_len,self.mulheads,self.
head_dim)
        keys=keys.reshape(N,key_len,self.mulheads,self.head_dim)
        queries=query.reshape(N,query_len,self.mulheads,self.
head_dim)
        values=self.values(values);keys=self.keys(keys);queries=
self.queries(queries)
        energy=torch.einsum("nqhd,nkhd->nhqk",[queries,keys])
        if mask is not None:
            energy=energy.masked_fill(mask==0,float("-1e20"))
        attention=torch.softmax(energy/(self.size**(1/2)),dim=3)
        out=torch.einsum("nhql,nlhd->nqhd",[attention,values]).
reshape(N,query_len,self.mulheads*self.head_dim)
        out=self.fc_out(out)
        return out

```

最终，BERT 文本情感分类效果如下表3-9所示，模型在测试集上的准确度达到了 89.9%，明显高于情感词典的方法，且接近 90% 的精度在深度学习领域已经属于非常好的模型效果了。但是考虑到投资者评论情绪这样的二分类具有较高辨识度，评论大多带有明显的情绪倾向，且后续的趋势预测要求文本情感分析尽可能的准确以保证预测效果，因此理论上分类准确度应当进一步提高。

表 3-9 BERT 文本情感模型效果评价

类别	Precision	Recall	F1-Score
0	0.864	0.896	0.880
1	0.925	0.901	0.913
Accuracy			0.899
Macro Avg	0.895	0.899	0.896
weighted avg	0.900	0.899	0.899

与上一节相似，绘制出 BERT 情感分类准确度随文本长度的变化图3-12。不难看出 BERT 模型在不同的文本长度均保持较为相似的分类准确度，其中文本小于等于 9 个字符时的准确度相对较低，为 87.12%，低于整体 89.9% 的准确度。




图 3-12 BERT 情感分类准确度随文本长度变化图

3.2.3 融合情感词典和 BERT 情感分类的分析模型

前面两个小节评估了投资者评论情感词典和 BERT 情感分类模型两种方法的模型效果，得到了具有较大差距的两种准确度结果，但我们也发现了准确度在不同文本长度上的差异化分布。本节将继续研究这种差异化分布，并结合两种模型，提出一种新的分段融合模型。

针对投资者评论情感词典在文本小于等于 9 个字符时的准确度较高的特性，下文将围绕此类短文本进行分析。如表3-10展示了测试集中一些小于等于 9 个字符的短文本示例。不难发现，短文本评论具备共同特征：一个文本基本仅出现一个（或同一类）带有明显情感倾向的词语。例如表3-10中文本编号 1 的“减仓”“卖出”，编号 3 的“下跌”，编号 5 的“看多”等等。短文本正是因为其字符数较少，往往通过 1-2 个同向情感词表达语义，因此很难具备情感转折。而词典分析方法正是抓住了这些明显情感倾向的词语，且不存在其他异类词语干扰，因此词典方法给短文本打上情感标签是较为准确的。

利用词典分析在短文本上的高精度特性，本节将融合两种模型。按照分段的思想，将短文本按照长度进行分类，再输入不同的模型。具体如下式3-5所示。

$$\begin{cases} \text{投资者评论情感词典模型,} & len_x \leq 9 \\ \text{BERT 情感分类模型,} & len_x > 10 \end{cases} \quad (3-5)$$

表 3-10 测试集短文本

编号	评论	情感类别标签
1	开始减仓卖出	0
2	加仓了，明天看涨。	1
3	近期大概率大幅下跌	0
4	五粮液真垃圾！	0
5	看多大方向不动摇	1
...	...	

其中， len_x 代表投资者评论 x 的文本长度。需要注意的是，由于融合模型里面，BERT 模型仅用于判断 10 个字符以上的文本，因此需要重新训练模型。最终，构建的融合模型效果如表3-11所示，融合模型的准确度达到了 92.4%，较两个单一模型均有了明显提升。

表 3-11 融合情感词典和 BERT 模型的效果评价

类别	Precision	Recall	F1-Score
0	0.903	0.916	0.909
1	0.940	0.930	0.935
Accuracy			0.924
Macro Avg	0.921	0.923	0.922
weighted avg	0.925	0.924	0.925

第三节 构建投资者关注度因子

上一章节的分析确立了最终的融合模型，将此前爬取并清洗处理好后的 107 万余条数据输入到模型中，得到了每一条投资者评论的情感标签。这一节的内容将结合阅读数、评论数等其余数据构建投资者关注度因子。

每一条投资者评论贴都存在与之对应的阅读数、评论数，而这些数据能够代表此条评论贴在市场上的影响力，因此需要将上一章节的情绪值与阅读数、评

论数结合起来，形成综合投资者评论影响指标。通过对数据集的观察，我们可以发现评论数整体分布相对稀疏，约有 58.2% 的投资者评论贴不存在评论数，因此此项特征需要做一定处理。综合考量，我们构建的单条投资者评论影响指标如式3-6所示。

$$Atte_{i,t} = (2 \times emo_{i,t} - 1) \times \frac{read_{i,t}}{\sum_{j=1}^{N_t} read_{j,t}} \times [\ln(com_{i,t} + 1) + 1] \quad (3-6)$$

其中， $Atte_{i,t}$ 代表第 t 天的第 i 条投资者评论的影响力。 $emo_{i,t}$ 代表第 t 天的第 i 条投资者评论的情感标签，是上一节融合模型的输出结果，通过 $2 \times emo_{i,t} - 1$ ，将其值转化为-1 或 1。 $read_{i,t}$ 代表阅读数， $\sum_{j=1}^{N_t} read_{j,t}$ 代表第 t 天共计 N_t 篇投资者评论贴的阅读量和之和。 $com_{i,t}$ 代表该条投资者评论贴的评论数。

结合上式3-6和如下式子3-7，我们得到了某只股票第 t 天投资者评论关注度因子 $Atte_t$ ，若指标大于 0，则代表投资者评论第 t 天对该只股票表达正向的关注度，若指标小于 0，则代表持有负向的关注度。

$$Atte_t = \sum_{j=1}^{N_t} Atte_{j,t} \quad (3-7)$$

综合投资者评论关注度因子、投资者搜索因子及媒体资讯因子三个层面，我们得到了投资者关注度因子，如表3-12所示。

表 3-12 投资者关注度因子

投资者关注度因子			
类别	评论关注度	搜索关注度	资讯关注度
符号	$Atte_t$	$Sear_t$	$Artc_t$
主要来源群体	个体投资者	个体投资者	机构投资者

其中，投资者评论关注度因子与搜索关注度因子主要代表个体散户投资者的关注度，而资讯关注度因子则主要代表机构投资者的关注度。至此，投资者关注度因子的构建工作完成，后续将进一步研究此因子在行业指数趋势预测中的作用。

第四章 基于投资者关注度因子的行业指数预测

在这一节中，我们将利用 CNN-LSTM 混合模型对行业指数趋势进行预测，并通过控制变量和对比实验的方式，验证投资者关注度因子的有效性及 CNN-LSTM 混合模型在指数趋势预测方面的良好表现。

第一节 指标选取与变量说明

本章我们研究的目的是验证投资者关注度因子对行业指数趋势，即涨跌方向的有效性，为保证模型效果，需要关注行业指数的其他影响因素。首先，行业指数是通过行业内各个股票价格的加权平均而形成的，因此行业指数趋势的本质是行业个股的股价走势，而影响个股股票价格趋势的包括市场层面、微观层面和宏观层面。市场层面，指的是过去的价格涨幅，成交量等相关数据及技术指标等。微观层面，包括个股的盈利情况，资产状况等财务估值指标。宏观层面，括能反映社会整体经济运行形势的指标等。

具体而言，本节实证数据主要包括五个维度，行情数据维度，技术指标维度，基本面维度，宏观数据维度，以及本文重点研究的投资者关注度因子维度。国内已有较多文献证明了上述维度变量与股价或者行业指数之间存在着密不可分的关系。戴洁等 (2002)^[40] 及向诚等 (2018)^[41] 从不同角度分析了技术指标的预测有效性。而刘勇 (2004)^[42] 和许均华等 (2001)^[43] 在中国股市发展早期便已经证明宏观因素能够充分影响市场价格。陆静等 (2002)^[44] 和张娆 (2017)^[45] 的研究表明，公司的盈利或者基本面情况能够对股价造成较大影响。

本文所选取的行情数据，指标数据，基本面数据与宏观数据均来自于 Wind 金融终端，如表4-1所示，表中共计 30 个指标。

表4-1中，部分指标的计算与价格有关，而价格均采用前复权形式以保证连续性。下面选取上述的部分变量进行详细说明，未说明部分指标均可在 Wind 金融终端、同花顺、东方财富等金融股票市场行情软件中查阅。

1、Bbi(BullAndBearIndex)：可以用来判断股票价格的短期和长期趋势，当

表 4-1 五个维度的实证数据变量及符号

维度 1: 投资者关注度因子维度				
投资者关注度	Atte	评论关注度	Sear	搜索关注度
	Artc	资讯关注度		
维度 2: 行情数据维度				
价格数据	Pctchg	涨跌幅	High	最高价涨幅
	Avgpri	成交均价涨跌幅	Low	最低价跌幅
成交数据	Volume	成交量	Amount	成交额
	Turn	换手率		
维度 3: 技术指标维度				
趋向指标	Bbi	BBI 多空值	Vroc	量变动速率指标
	Bias	乖离率	Si	SI 摆动值
	Mtm	MTM 动力指标	Rsi	RSI 相对强弱指标
能量指标	Cr	CR 能量值	Psy	PSY 心理值
	Obv	OBV 能量潮	Wad	WAD 威廉聚散指标
	Pvt	量价趋势指标		
维度 4: 基本面维度				
财务估值指标	PE	市盈率	PB	市净率
	PS	市销率	PCF	市现率
维度 5: 宏观层面维度				
宏观指标	CnyUsd	人民币汇率	Pros	宏观经济景气指数
	Invt	固定资产投资额	CCI	消费者信心指数
	Govm	公共财政支出		

Bbi 指标向上运动并穿越价格均线时,意味着股票价格上涨的可能性较大,应该适当买入;相反,当 Bbi 指标向下运动并穿越价格均线时,意味着股票价格下跌的可能性较大,应该适当卖出。

$$Bbi = \frac{\text{均线 1} + \text{均线 2} + \text{均线 3} + \text{均线 4}}{4} \quad (4-1)$$

其中,四条均线天数默认为 3, 6, 12, 24, 均线的计算: n 日均价 = n 日收盘价之和/ n 。

2、乖离率:也称为 Y 值,是一种常用的技术分析指标,用于判断股票价格的偏离程度。它通过计算股票价格与其移动平均线之间的差异,来反映股票价格的波动情况和市场趋势。当乖离率为正时,表示股票价格高于其移动平均线,市场处于超买状态;当乖离率为负时,表示股票价格低于其移动平均线,市场处于超卖状态。

$$Bias(n) = \frac{\text{当日股市收盘价} - n \text{ 日移动平均值}}{n \text{ 日移动平均值}} \quad (4-2)$$

其中, n 默认取 12。

3、CR 能量指标:全称“累积能量线”(Cumulative Energy Line),它通过计算股票收盘价与当日最高价和最低价之间的关系,来反映股票价格的市场情况和力量。CR 能量指标的计算过程比较复杂,主要包括以下几个步骤:(1) 计算当日股票收盘价与前一日股票收盘价之间的差异(即当日价格动量)。(2) 分别计算当日最高价和最低价与前一日收盘价之间的差异(即当日最高价动量和最低价动量)。(3) 分别计算当日价格动量、最高价动量和最低价动量的平均值,并将它们相加。(4) 最后计算 CR 指标的数值:

$$CR = \frac{3 \text{ 日价格动量平均值} + 3 \text{ 日最高价动量平均值}}{3 \text{ 日价格动量平均值} + 3 \text{ 日最低价动量平均值}} \times 100 \quad (4-3)$$

CR 指标的数值通常在 0-100 之间变动,如果 CR 指标数值超过了 50,则表明股票价格处于上涨趋势;相反,如果 CR 指标数值低于 50,则表明股票价格处于下跌趋势。

4、OBV 指标:全称“On Balance Volume”。是一种用于判断股票价格趋势和买卖信号的技术分析指标,可以帮助投资者更好地分析股票价格的变化和市

场情况。OBV 指标的计算基于股票成交量和价格的变化。其计算方式如下：

(1) 将当日股票成交量与前一日成交量进行比较，如果当日成交量大于前一日，则将当日成交量加上前一日 OBV 值，得到当日的 OBV 值；如果当日成交量小于前一日，则将当日成交量的负值加上前一日 OBV 值，得到当日的 OBV 值；如果当日成交量等于前一日，则当日 OBV 值等于前一日 OBV 值。

(2) 将每日的 OBV 值相加，得到总的 OBV 值。如果 OBV 值持续上升，则表明股票价格处于上涨趋势；相反，如果 OBV 值持续下降，则表明股票价格处于下跌趋势。

OBV 指标主要用于判断股票价格的趋势和买卖信号。如果 OBV 指标持续上升，意味着买盘力量较强，投资者可以适当买入；相反，如果 OBV 指标持续下降，意味着卖盘力量较强，投资者应该适当卖出。此外，如果股票价格上涨，而 OBV 指标却下降，意味着市场上的多头力量在减弱，投资者应该警惕可能的价格反转。

第二节 数据集的获取处理及统计描述

本章数据的时间范围与上一章相同，选取 2016 年 1 月 1 日-2022 年 10 月 31 日，共计 1659 个交易日。由于东方财富股吧投资者评论数据在 2016 年以前数量较少，有明显的删除痕迹，故数据的时间范围不能再延长至 2016 年以前。但后续神经网络模型的训练需要较大样本，仅采用白酒行业数据可能存在样本量不足的问题，进而导致模型预测精度下降，故考虑扩充数据集的办法。

本章将同时选取与白酒行业相似的啤酒行业及乳制品行业，共计三个行业的数据，数据总量可达 4977 条。下文的数据描述与处理均是基于三个行业的所有数据而言的。乳制品行业及啤酒行业的成分股如下图4-1和图4-2所示。

成分券代码 Constituent Code	成分券名称 Constituent Name	成分券英文名称 Constituent Name(Eng.)	交易所 Exchange
600597	光明乳业	BRIGHT DAIRY	SHH
600882	妙可蓝多	GROUND	SHH
600887	伊利股份	YILI	SHH
600419	天润乳业	TIANRUN DAIRY	SHH
002570	贝因美	BEINGMATE	SHZ
002732	燕塘乳业	YANTANG DAIRY	SHZ

图 4-1 乳制品业个股

乳制品行业包含六只个股，多数为具有代表性的乳制品龙头企业，长期被涵盖于乳制品行业指数中。

成分券代码 Constituent Code	成分券名称 Constituent Name	成分券英文名称 Constituent Name(Eng.)	交易所 Exchange
600132	重庆啤酒	CBC	SHH
000729	燕京啤酒	YANJING BREWERY	SHZ
600573	惠泉啤酒	HUIQUAN BEER	SHH
002461	珠江啤酒	PEARL RIVER	SHZ
600600	青岛啤酒	TSINGTAO BREWERY	SHH

图 4-2 啤酒行业个股

啤酒行业包含五只个股，行业与白酒相似，且选取个股多为老牌啤酒企业，以下几家合计占有 70% 以上的啤酒市场份额。

首先我们利用上一章的方法，获取到三个行业共计 22 支股票的投资者关注度因子维度的数据。然后再使用 Wind 金融终端，在 Wind 中，白酒行业、啤酒行业、乳制品行业代码分别为 884705.WI，882477.WI，884662.WI，利用 wind 在 excel 的函数及 EDB 插件，即可直接导出余下四个维度共计 27 个变量 2016 年 1 月 1 日-2022 年 10 月 31 日的所有数据。需要注意的是，这里不必导出三个行业个股的所有数据，可以直接导出行业的数据，诸如涨跌幅、成交量、成交额、各项技术指标等等，Wind 金融终端自动将行业内的个股数据按照个股市值加权求和（如涨跌幅，换手率，市盈率等）或直接求和（如成交量，成交额等）形成了行业指标的数据，故直接利用 Wind 函数以上述三个行业代码为对象导出数据即可。

但是维度 1 的投资者关注度数据是我们以个股为单位收集处理形成的，因此需要转化为行业层面的指标。与 Wind 金融终端类似的处理办法，我们按照个

股市值加权，得到了行业的投资者关注度因子。至此，行业数据收集工作完成。

下面进行数据处理工作。需要说明，数据的时间轴以交易日为准，非连续时间，在利用 wind 金融终端导出数据时已默认仅导出交易日。

首先，需要进行缺失值填补。我们的变量选取中，宏观层面维度数据均以月度为单位，因此需要进行填充操作。具体而言，数据以时间轴降序排列，采用向后向前缺失值填充法。若缺失值前面的数据非缺失，则用前面的非缺失值进行填充，这样的填充方式更符合宏观数据所涵盖的时间段，而对于头部缺失且前面无非缺失值的数据，则采用后面非缺失值进行填充。下表4-2展示了技术指标的描述性统计数据。

表 4-2 技术指标的描述性统计

变量	Mean	Std	Min	25%	50%	75%	Max
涨幅	0.11	2.16	-9.75	-1.07	0.08	1.37	8.52
Bbi	47180	30156	13664	22543	33762	81121	111521
Vroc	10.25	53.04	-89.09	-26.08	-2.06	34.97	463.18
Bias	0.52	4.12	-15.23	-1.96	0.58	3.13	13.29
Si	391	25138	-173043	-5518	872	8200	131182
Mtm	203	3228	-20822	-897	210	1322	15303
Rsi	53.33	18.40	8.24	39.39	53.24	67.22	95.54
Cr	131.82	67.97	33.21	77.97	111.87	174.83	449.58
Obv	5.48E+08	1.21E+08	3.96E+08	4.54E+08	4.95E+08	6.73E+08	7.82E+08
psy	55.29	13.50	16.67	50.00	58.33	66.67	91.67
Wad	63787	56523	11939	21596	33232	116058	186851
Pyt	1.51E+09	3.44E+08	1.01E+09	1.24E+09	1.44E+09	1.88E+09	2.11E+09

从描述性统计表，我们可以看出，数据之间的数量级差异较大，且量纲不同，因此需要进行归一化处理，将数据映射到 $[0, 1]$ 上，归一化的公式如下。

$$x_i^* = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (4-4)$$

其中， x_i 代表指标 x 的第 i 个数据， $x_{\min}$ 与 $x_{\max}$ 代表指标 x 的最大数据和最小数据。

第三节 基于投资者关注度因子的 CNN-LSTM 预测模型

4.3.1 CNN-LSTM 混合模型概述

CNN-LSTM 是一种深度学习网络，它将卷积神经网络（CNN）和长短时记忆网络（LSTM）结合在一起，用于处理时间序列数据中的特征提取和序列建模。卷积神经网络通常用于提取输入数据序列中的空间特征。这些特征图会被传递给 LSTM 层，然后 LSTM 会对时间序列进行建模，捕捉序列中的关系。最后，LSTM 层的输出结果被传递到一个全连接层中，用于生成最终的预测结果。CNN-LSTM 的结构如图4-3所示。而 CNN 与 LSTM 模型的原理及公式已在前面章节表述，这里不再赘述。




图 4-3 CNN-LSTM 混合模型结构图

当一个复杂的神经网络在使用较小数据集进行训练时，容易造成过拟合，因此我们引入了 Dropout 机制以避免过拟合的出现。Dropout 由 Hinton 等 (2012)^[46] 人在 2012 年提出，Dropout 机制是一种用于神经网络的正则化技术，其目的是减轻过拟合现象，提高神经网络的泛化能力。Dropout 机制是在每次训练迭代中随机忽略（“dropout”）一部分神经元，以此来防止过拟合。

具体地说，Dropout 的原理示意图如图4-4^{注 1}所示。Dropout 是通过在训练过程中随机将一部分神经元输出设置为 0 来实现的。每个神经元的输出被保留的概率称为“保留率”，一般取 0.5。这意味着，如果保留率为 0.5，那么每个神经元的输出有 50% 的概率被设置为 0。通过这种方式，每个神经元都不能依赖于任何其他神经元的输出，从而迫使网络去学习更加鲁棒的特征，从而更好地

^{注 1}来源：<https://www.cnblogs.com/zingsp/p/11631913.html>

泛化到未见过的数据。




图 4-4 Dropout 机制

Dropout 可以被看作是一种集成学习技术，因为它通过训练多个具有不同随机忽略神经元的网络来降低方差，从而提高了泛化能力。此外，Dropout 还可以减少神经网络对特定输入特征的依赖，从而可以更好地处理缺失数据的情况。需要注意的是，在测试时，不需要使用 Dropout，因为所有神经元都需要被保留，以保证网络能够输出正确的结果。因此，在测试阶段，需要将所有神经元的输出都保留下来，以获得最终的输出。

4.3.2 模型的输入输出数据说明及处理

4.3.2.1 滑动窗口重构数据集

在 CNN-LSTM 模型中，我们需要将所有指标及它们过去几天的数值输入，并对下一天的涨跌方向 y 进行预测，即输出。这里，我们选择涨跌方向而非直接选取涨跌幅进行预测主要基于三点原因：

- 1、许多技术性指标能够出买入或者卖出信号，但其大小不能代表涨跌幅，因此选择预测涨跌方向。
- 2、预测涨跌幅不利于与其他文献模型进行对比，不同文献预测区间的样本量、预测对象、量纲等的不同使得难以比较，而涨跌方向是个分类问题，可以用前述的 Accuracy, Precision, Recall 和 F1-score 等统一指标进行对比。
- 3、预测涨跌幅构建投资策略并不能带来额外的收益，只要预测上涨，就应该买入，预测下跌，就不应该持有，因此涨跌幅的预测在实际应用中意义不大。

因此，模型是一个二分类模型，按照下一个交易日的涨跌方向进行二分类。数据集的涨跌方向分类标签由涨跌幅 $Pctchg$ 转化形成的，如式4-5，若涨跌幅 $Pctchg$ 大于等于 0，则涨跌方向 y 为 1，若小于 0，则 y 为-1。

$$y = \begin{cases} 1, & \text{if } Pctchg \geq 0 \\ -1, & \text{if } Pctchg < 0 \end{cases} \quad (4-5)$$

我们将采用滑动窗口的方式构建输入数据，即如图所示。滑动窗口方式是指将原始的时间序列数据集划分为多个时间窗口，每个时间窗口包含连续的一段时间内的数据，然后使用这些时间窗口来训练模型。具体地，对于给定的时间窗口大小和步长，从数据集中选取连续的一段时间作为一个时间窗口，然后将该时间窗口中的数据作为输入序列，将该时间窗口下一个时间点的数据作为输出值。然后，将时间窗口向前滑动步长个单位，并再次提取相应的输入和输出数据，以此类推，直到遍历整个数据集。



图 4-5 数据集的滑动窗口

通过使用滑动窗口的方式，可以获得更多的数据样本，增加模型训练的数据量，提高模型的预测性能。此外，滑动窗口还能够帮助模型捕捉更长期的趋势和周期性，从而提高模型的预测准确性。

需要注意的是，滑动窗口的大小 N_{window} 和步长 N_{step} 需要根据具体的数据集和预测任务进行调整，一般 N_{step} 取 1 以保证数据量，但过大的滑动窗口 N_{window} 可能会导致数据冗余和过拟合，而过小的滑动窗口可能会导致数据不足和欠拟合。滑动窗口的大小 N_{window} 参数的具体设置我们将在下一章节进行讨论。

通过滑动窗口的方式，我们得到了输入变量共有 $N_{window} \times N_{index}$ 个，其中 N_{window} 代表滑动窗口的大小，即用过去 N_{window} 天的数据预测下一天的涨跌幅 Pctchg，而 N_{index} 代表选取输入模型的指标个数。

4.3.2.2 主成分分析降维

考虑到采用滑动窗口构建的数据集的变量数目 $N_{window} \times N_{index}$ 较大，若滑动窗口长度 N_{window} 选取 5 天，且选取全部的 $N_{index} = 30$ 个指标，则输入变量达到了 150 个，需要对数据进行处理，提取信息的主要特征，以加速后续模型的学习过程。同时，过多的变量可能会导致模型出现过拟合现象，信息过于冗余，因此我们需要对输入数据进行降维处理，这里选用主成分分析 (Principal Component Analysis, PCA)。

PCA 是一种常见的多变量数据分析方法，它通过线性变换将高维数据转化为低维数据，并在新的坐标系下发掘数据中最重要的信息，以便更好地理解数据和分析数据之间的关系。在 PCA 中，我们将数据映射到一个新的低维空间，使得数据在该空间中的方差最大，因此新的坐标系通常被称为主成分。PCA 的目标是找到最能代表原始数据的一组正交基（即主成分），使得原始数据中的方差最大化。

假设我们有 m 个样本，每个样本有 n 个特征，可以将原始数据表示为一个 $m \times n$ 的矩阵 X 。首先需要对数据进行标准化处理，而本文数据已在前面章节进行归一化处理，故可直接用于 PCA。然后，我们计算数据的协方差矩阵 C ，其定义为：

$$C = \frac{1}{m-1} X^T X \quad (4-6)$$

接着，对协方差矩阵进行特征值分解，得到特征值 λ 和特征向量 v ，其中 λ 和 v 满足以下关系：

$$Cv = \lambda v \quad (4-7)$$

特征向量 v 表示新坐标系的基向量，而特征值 λ 表示数据在这个方向上的方差。通常，我们会按照特征值的大小排序，选取前 k 个特征向量构成矩阵 V_k ，

而一般 k 是我们指定的降维后的维度。

最后，我们将原始数据投影到主成分上，得到新的低维数据 Y ，其定义为：

$$Y = XV_k \quad (4-8)$$

最终，我们得到新的低维数据 Y ，其维度为 k 。通过 PCA 方法对数据进行降维，减少特征数量，可以加速模型训练过程，同时在一定程度上避免过拟合，并剔除一些不必要的信息和噪声，从而使得模型更简单、更易于理解和泛化。

4.3.3 CNN-LSTM 模型参数设置

本节所使用的硬件环境为 Windows10 系统的电脑，CPU 为英特尔 i7-6700HQ，主频 2.60HZ，显卡为 GTX1060，显存 6G。语言为 Python，编辑器为 VSCode。

数据集方面，按照 8:1:1 的比例划分训练集、验证集和测试集。损失函数方面，选用 MSE 函数，即均方误差，如式子4-9所示。

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (4-9)$$

其中， n 是数据集中样本数量， y_i 是第 i 个样本的真实值， $\hat{y}_i$ 是第 i 个样本的预测值。

经过多次调整，训练轮数 Epochs 设定为 50，选取的一维卷积神经网络层卷积核个数为 90，卷积核的步数为 1，LSTM 层数设定为 1，dropout 参数设定为 0.4，而模型中使用的激活函数均为 ReLU 函数，即式子4-10所示， x 是输入的实数，max 函数表示取两个数中的较大值。在实际应用中，ReLU 函数通常作为神经网络的激活函数使用，用于引入非线性变换，增强神经网络的表达能力。

$$f(x) = \max(0, x) \quad (4-10)$$

优化算法方面选取 Adam (Adaptive Moment Estimation)。Adam 是一种常用的优化算法，它用于在神经网络的训练过程中自适应地调整学习率，以加速模型的收敛速度和提高模型的泛化能力。Adam 算法结合了动量法和自适应学习率方法的优点，具有较快的收敛速度和较好的鲁棒性。它的主要思想是在

梯度下降的基础上，根据梯度的一阶矩估计和二阶矩估计分别调整每个参数的学习率。

第四节 因子作用及模型效果的评价分析

模型将输入数据根据下一日的涨跌分为两类，二分类问题的评价标准仍然延续前述的 Accuracy, Precision, Recall 和 F1-score。根据研究目的，这一节的模型对比实验需要验证三个方面：

- 1、确定滑动窗口 N_{window} 的最优数值，我们选取 3 天、5 天和 10 天分别构建数据集输入 CNN-LSTM 模型进行对比实验。
- 2、验证 CNN-LSTM 模型是否较机器学习模型 XGBoost 和传统的 LSTM 模型有明显提升。
- 3、最后也是本文的主要研究目的，通过对比加入与不加入投资者关注度因子的模型效果，验证因子有效性。

实验一：对比滑动窗口 N_{window} 分别取值 3、5 和 10 天时的行业指数涨跌预测效果。实验选取 CNN-LSTM 模型，输入五个维数的所有 30 个变量及其滞后 N_{window} 天的变量对第二天的涨跌方向进行判断。训练集和测试集比例 9:1，训练集中的验证集比例采用模型的默认参数，训练集样本量分别为 4473、4468 和 4455，测试集从最新时间 2022 年 10 月 31 日往前取。首先，需要将数据进行主成分分析，结果如下表4-3所示。

表 4-3 N_{window} 不同取值时达到累计贡献度所需主成分数量

累计贡献度	$N_{window} = 3$	$N_{window} = 5$	$N_{window} = 10$
90%	7	9	12
95%	14	18	26
98.5%	31	42	64

模型以主成分累计贡献度达到 98.5% 作为选取主成分的数量，最终确定的主成分数量分别为 31、42 和 64 个，利用 Python 中 sklearn 库的 PCA 的 fit_transform 函数可直接将训练集替换为选取的主成分数据集。经过训练，并

在测试集上预测，最终模型的分类效果对比如下表4-4所示。

表 4-4 实验一： N_{window} 不同取值时的 CNN-LSTM 模型效果对比

加入所有维度变量且 $N_{window} = 3$ 的 CNN-LSTM 模型			
	Precision	Recall	F1-Score
-1	0.586	0.592	0.589
1	0.662	0.657	0.659
Macro Avg	0.624	0.624	0.624
Weighted Avg	0.628	0.627	0.627
Accuracy		0.627	
加入所有维度变量且 $N_{window} = 5$ 的 CNN-LSTM 模型			
	Precision	Recall	F1-Score
-1	0.626	0.628	0.627
1	0.693	0.691	0.692
Macro Avg	0.659	0.660	0.659
Weighted Avg	0.663	0.663	0.663
Accuracy		0.663	
加入所有维度变量且 $N_{window} = 10$ 的 CNN-LSTM 模型			
	Precision	Recall	F1-Score
-1	0.633	0.578	0.604
1	0.676	0.725	0.699
Macro Avg	0.655	0.651	0.652
Weighted Avg	0.657	0.658	0.657
Accuracy		0.658	

首先对比滑动窗口长度 $N_{window} = 3$ 和 $N_{window} = 5$ 的 CNN-LSTM 模型效果，可见滑动窗口的提升带来的变量增量能较好地提高行业指数涨跌预测准确度 (Accuracy)，从 62.7% 提升到了 66.3%，同时其他指标均有不同程度的提升，

且涨 (1) 和跌 (-1) 两类样本各自的精度 (Precision) 和召回率 (Recall) 差距相对较小, 没有出现明显失衡现象, 滑动窗口长度的提升是合理的。

再对比 $N_{window} = 5$ 和 $N_{window} = 10$ 的 CNN-LSTM 模型效果, 滑动窗口的提升反而使得模型在测试集上的准确度下降, 从 66.3% 下降到了 65.8%, 且 $N_{window} = 10$ 的 CNN-LSTM 模型涨 (1) 和跌 (-1) 两类样本的召回率出现了较大的差异, 因此模型可能出现了过拟合和数据冗余的问题, 可见滑动窗口长度并不是越大越好, 信息量不是越大越好, 需要进行合理选择。

在实际意义层面, 5 天正好是一周的交易日数量, 滑动窗口长度选择 5 天正好包含这一周交易周期内的特征, 而股市中一些类似“黑色星期五”等经验结论均具备以周为单位的特征, 因此滑动窗口 N_{window} 从经验角度分析也是合理的。

实验二: 对比 XGBoost, LSTM 和 CNN-LSTM 三个模型的预测效果。滑动窗口 N_{window} 选取实验一中的最优结论 5 天, 指标仍选取包含投资者关注度因子在内的五个维数所有 30 个变量, 总共 5×30 个变量。同样的, 先对输入变量进行主成分分析获得主成分, 主成分的累计贡献度详细数据如表4-5所示, 最终选取累计贡献度达到 98.5% 时的主成分输入 XGBoost, LSTM 和 CNN-LSTM 模型, 共计 42 个主成分。

在测试集上检验 XGBoost, LSTM 和 CNN-LSTM 三种模型的预测效果, 结果如表4-6所示。

首先, 对比 XGBoost 和 LSTM 模型, 两者在测试集上分别达到了 58% 和 63.6% 的涨跌预测准确度。作为机器学习领域的 XGBoost 模型预测效果明显低于深度学习领域的 LSTM 模型, 主要是由于 XGBoost 模型结构相对简单, 而 LSTM 模型结构更为复杂, 更能把握数据特征。在训练过程中, LSTM 通过前一个时间步的状态来影响当前时间步的状态, 并通过当前时间步的状态来影响后续时间步的状态, 从而实现对序列数据的建模, 因此能够捕捉不同样本之间的时间序列依赖关系。在实验二中, 我们输入每个样本包含 42 个主成分, 而基于股票市场的前后样本之间的成分是具有时间序列关系的, LSTM 模型把握了这样的时序特征进而使得预测准确度提高, 而 XGBoost 并未探究, 因此预

表 4-5 $N_{window} = 5$ 时数据集的主成分分析

主成分	累计贡献度	主成分	累计贡献度	主成分	累计贡献度
1	0.69065	17	0.94971	33	0.97763
2	0.79274	18	0.95287	34	0.97868
3	0.83867	19	0.95576	35	0.97968
4	0.86120	20	0.95841	36	0.98066
5	0.87432	21	0.96100	37	0.98161
6	0.88374	22	0.96298	38	0.98252
7	0.89211	23	0.96466	39	0.98342
8	0.89994	24	0.96627	40	0.98423
9	0.90695	25	0.96780	41	0.98499
10	0.91387	26	0.96920	42	0.98573
11	0.92020	27	0.97057	43	0.98645
12	0.92590	28	0.97186	44	0.98714
13	0.93134	29	0.97309	45	0.98780
14	0.93667	30	0.97428	46	0.98842
15	0.94152	31	0.97544	47	0.98904
16	0.94612	32	0.97655	48	0.98963

测准确度相对低一些。

其次，我们再对比 LSTM 和 CNN-LSTM 模型的涨跌预测准确度。通过在 LSTM 模型中增加 CNN 结构，行业指数预测的准确度从 63.6% 提升至 66.3%。CNN-LSTM 模型同时考虑了数据的空间特征和时间特征，因此可以更好地建模时间序列数据，使得预测准确度能够进一步提高。此外 CNN 结构具有的局部连接和权值共享特点，可以一定程度上减少模型的参数量，减低冗余性。实验二中准确度提升，说明 CNN-LSTM 中的 CNN 结构起到了良好的特征提取的作用。整体来说，CNN-LSTM 模型较 XGBoost 模型和经典的 LSTM 模型均有明显的

表 4-6 实验二：不同模型的预测效果对比

加入所有维度变量且 $N_{window} = 5$ 的 XGBoost 模型			
	Precision	Recall	F1-score
-1	0.534	0.541	0.538
1	0.618	0.611	0.615
Macro avg	0.576	0.576	0.576
Weighted avg	0.580	0.580	0.580
Accuracy		0.580	
加入所有维度变量且 $N_{window} = 5$ 的 LSTM 模型			
	Precision	Recall	F1-score
-1	0.597	0.592	0.594
1	0.667	0.672	0.669
Macro avg	0.632	0.632	0.632
Weighted avg	0.635	0.636	0.635
Accuracy		0.636	
加入所有维度变量且 $N_{window} = 5$ 的 CNN-LSTM 模型			
	Precision	Recall	F1-Score
-1	0.626	0.628	0.627
1	0.693	0.691	0.692
Macro Avg	0.659	0.660	0.659
Weighted Avg	0.663	0.663	0.663
Accuracy		0.663	

优势。

实验三：验证投资者关注度因子的有效性。在本次实验中，将对比不加入投资者关注度因子维度变量和加入投资者关注度因子维度变量的 CNN-LSTM 模型的预测准确度。投资者关注度因子维度共有投资者评论关注度，搜索关注度

及资讯关注度三个因子，因此设计三个模型分别选取加入全部三个因子、加入搜索关注度及资讯关注度因子和都不加入，对应的指标数量分别为 30 个、29 个和 27 个，滑动窗口长度仍选取 $N_{window} = 5$ ，故两个模型训练集的变量数分别为 150 个、145 个和 135 个。在将训练集输入模型前，需要进行主成分分析，如下表4-7所示，仍选取累计方差贡献度达到 98.5% 的主成分作为输入变量。

表 4-7 加入不同投资者关注因子达到累计贡献度所需主成分数量

累计贡献度	都加入	加入搜索关注度及资讯关注度因子	都不加入
90%	9	9	9
95%	18	16	15
98.5%	42	40	38

确定的主成分数量分别为 42、40 和 38 个，主成分数量的不同一定程度上能说明三个投资者关注度因子确实能够带来信息增量。经过训练，得到的涨跌预测准确度如表4-8所示。

当加入搜索关注度因子及资讯关注度因子时，模型的准确率从 56.3% 上升至 59.5%，提升了约 3.2 个百分点，说明搜索关注度因子及资讯关注度因子有效，能够帮助模型决策。而当再加入评论关注度因子时，模型准确度从 59.5% 继续上升至 66.3%，预测涨跌的准确度进一步提升了 6.8 个百分点，一方面说明了评论关注度因子有效，另一方面提升效果明显优于搜索关注度因子及资讯关注度因子，表明投资者评论关注度因子的预测作用更强。从最后一个加入了所有投资者关注度因子的模型结果中可以看到，模型预测第二天上涨（1）的效果（Precision, Recall, F1-Score）是高于下跌（-1），且这种差距较第一个不加入任何投资者关注度因子的模型更加突出。其实不难理解，在 A 股市场中，投资者上涨情绪的连续性更好，“追涨情绪”较为浓厚，而连续下跌却由于不能做空，只能抄底，因此下跌的连续性较差，在这种环境下，投资者关注度的激增很大程度上能够反映投资者对股票后市看涨，因此预测看涨的准确度更高。总之，加入投资者评论关注度、搜索关注度及资讯关注度的模型预测效果是最好的，三个投

表 4-8 实验三：是否加入投资者关注度因子的模型预测效果对比

不加入投资者关注度因子维度变量			
	Precision	Recall	F1-score
-1	0.515	0.541	0.53
1	0.61	0.581	0.59
Macro avg	0.56	0.561	0.56
Weighted avg	0.57	0.563	0.56
Accuracy		0.563	
加入搜索关注度及资讯关注度			
	Precision	Recall	F1-score
-1	0.549	0.564	0.56
1	0.633	0.619	0.63
Macro avg	0.591	0.592	0.59
Weighted avg	0.595	0.594	0.60
Accuracy		0.595	
加入投资者评论关注度、搜索关注度及资讯关注度			
	Precision	Recall	F1-Score
-1	0.626	0.628	0.627
1	0.693	0.691	0.692
Macro Avg	0.659	0.660	0.659
Weighted Avg	0.663	0.663	0.663
Accuracy		0.663	

投资者关注度因子能够在行业指数预测中发挥较好作用。

最后，我们可以对比一些已有文献的模型以衡量预测效果。季子峥等(2020)^[47]利用 ETS 算法和 SVM 机器学习模型，并结合了行情数据和投资者评论数据对一些个股涨跌进行了预测，但受限于 SVM 模型的劣势，准确度仅有

57.4%。王伟晶 (2015)^[48] 通过经典的 BP 神经网络利用行情数据对个股进行预测，数据变量选取较少且 BP 神经网络有待提升，准确率约为 62.0%。谢琪等 (2019)^[49] 和顾文涛等 (2020)^[50] 分别利用了 F-TVF 和概率推断的模型方法对沪深 300 和上证指数进行预测，准确度分别为 62.0% 和 64.0%。许雪晨 (2021)^[24] 将行情数据和媒体情绪值输入到 Bi-LSTM 模型中，对沪深 300 指数涨跌预测准确度达到 64.0%。彭益 (2012)^[51] 利用概率统计的方法，对深证指数的涨跌预测准确度达到了 64.2%。而本文提出的模型和方法相较于上述模型，准确度有较好优势，达到了 66.3%。

通过上述三个对比实验和与其他文献结果的对比，我们验证了基于投资者关注度因子的 CNN-LSTM 模型效果是较为优秀的，且投资者关注度因子能够在行业指数预测中发挥较大作用。A 股市场的确是一个充满情绪的市场，无论投资者充满情感的评论还是对某只股票关注度的变化，都能在一定程度上反映市场走势。但本质上，本文认为并不是情绪或者关注度在直接地左右市场，而是投资者通过有倾向性的评论和关注度的变化将投资者自己对未来的投资计划给隐性地表达了出来，本文研究正是将这种表达出来的因子收集起来、处理、分析，最终得以成功帮助我们预测行业指数的走势。

第五节 投资策略及收益分析

在这一节中，我们将根据前述的基于投资者关注度因子的 CNN-LSTM 模型结果，构建简单的投资策略。我们按照行业指数的计算公式购买相应股票，即按照市值比例持有行业内的股票。在预测第二天上涨时，于收盘集合竞价时进行买入或继续持仓，在预测第二天下跌时，于收盘集合竞价时进行卖出或空仓。但是由于模型预测第二天行业指数需要用到当天数据，我们将用收盘集合竞价前即 14:57 分数据进行预测。假设买卖一次的手续费为万分之二，印花税为千分之一，选取白酒行业指数 2022 年 5 月 1 日-10 月 31 日进行回测。最终投资策略净值和行业指数走势如下图4-6所示，各项收益指标如表4-9所示。




图 4-6 投资策略净值变化

表 4-9 投资策略收益指标

	白酒行业指数	投资策略净值
日均收益率	-0.20%	0.12%
回测区间收益率	-16.88%	12.18%
最大回撤	45.57%	26.85%
最大回撤区间	[2022-06-30,2022-10-31]	[2022-08-31,2022-10-31]

从表4-9中可以看到，投资策略在白酒行业指数中收益表现良好，回测区间内的收益达到了 12.18%，较白酒行业指数高出了 29.6%，同时最大回撤也得到了控制，从 45.57% 降低至 26.85%，投资策略的效果明显。从图4-6中可以看到，在白酒行业指数的下跌过程中，构建的投资策略跌势明显较小，空仓时间更多，因此投资策略的整体收益更高，回撤更小。

总之，结合了投资者关注度因子和 CNN-LSTM 模型的投资策略效果显著，表现出良好的盈利能力。

第五章 总结与展望

第一节 研究结论

股票市场并非是一个完全有效的市场，投资者往往会通过一些隐性的方式将自己对股票未来的预期表达出来，或在股吧文本评论，或网页搜索股票信息，或阅读股票资讯文章等等，而这反映了投资者对未来的投资计划，因此从这些信息的出发能够预测市场走势。本文正是基于此，利用文本情感分析和 CNN-LSTM 模型对这样的信息进行一定的处理和分析，从而预测行业指数的涨跌趋势。通过实证研究，得到了三个方面的研究结论或成果：

1、不直接使用基础词典，而是结合 Word2Vec 和 XGBoost 模型成功构建了专用的投资者评论情感词典。在构建过程中，并未直接采用传统的 Word2Vec 词向量余弦相似度的方式构建，而是先筛选出候选情感词，再通过 XGBoost 模型进行分类，使得情感词分类准确度得到了 11.8 个百分点的提升。而在爬取数据的过程中，本文研究设计了 IP 代理池，并调整爬取频率，尽可能降低对网站服务器造成的负荷，解决了 IP 被禁无法获取数据的问题，最终获得了实证所需数据。

2、融合情感词典和 BERT 情感分类的模型，使得投资者评论文本情感分类准确度在长短文本上均有较好表现。在实证过程中研究发现，虽然词典方法的分类精度仅有 72.3%，但在 9 个字符及以下的文本上表现出了 96.51% 的准确度，而 BERT 模型在长短文本上的准确度分布较为均匀，整体达到了 89.9% 的准确度。因此，我们将情感词典和 BERT 模型结合起来，根据文本长度的不同进行分类预测，最终融合模型使得准确度提升至 92.4%，并基于此融合模型构建了投资者评论关注度因子。

3、通过对比实验，选取了最佳的参数构建数据集，并证明了 CNN-LSTM 模型在行业指数预测中较其他模型具备更好的性能，此外，实验验证了投资者关注度因子在行业指数预测中的有效性，以此设计了投资策略。具体而言，研究

选取了五个维度的变量，并通过在 CNN-LSTM 模型中加入 Dropout 机制及对输入数据进行主成分分析较好地避免了数据过拟合及数据冗余的问题。在对比实验中，本文分析确定了滑动窗口取 5 天是较优选择，得出了 CNN-LSTM 模型较 LSTM 模型在此预测问题上有着更高准确度，较 XGboost 模型有明显进步的结论，并验证了投资者关注度因子加入模型能够较好地提升预测准确度。本文构建的基于投资者关注度因子的 CNN-LSTM 模型对行业指数涨跌预测准确度达到了 66.3%。最终，利用此模型，构建了简单的投资策略，半年的回测区间收益达到了 12.18%。

第二节 不足与未来展望

本文对行业指数的预测仍有一些不足和可以改进的地方：

1、模型参数方面，在情感词典方法中，可以进一步优化参数，例如一些程度副词系数，通过训练学习的办法进一步调整提升。在最后利用 CNN-LSTM 模型构建的投资策略中，虽然收益较好，但回撤幅度较大，因此可以调整模型预测分类的阈值，牺牲一些上涨的机会，但降低下跌却被错误预测为上涨的假阳率，达到控制回撤的目的。

2、模型结构方面，也有进一步优化和提升的空间，例如在 CNN-LSTM 模型中，可以加入本文提到的 bert 模型中的注意力机制，将注意力机制引入 LSTM 模型，可能使得 CNN-LSTM 模型的准确度可以进一步提升。

3、指标选取方面，本文虽然选取了五个维度共计 30 个指标，但股票市场是复杂多变的，行业指数的预测充满着许多不确定性，因此，可以进一步扩充变量选取范围，使得预测模型包含更多的信息。

参考文献

- [1] 王哲, 王春峰, 顾培亮. 小波分析在股市数据分析中的应用[J]. 系统工程学报, 1999, 14(3):286-289.
- [2] 雷鸣, 叶五一, 缪柏其, 等. 生存分析与股指涨跌的概率推断[J]. 管理科学学报, 2010, 13(04):57-66+75.
- [3] 徐迪, 马大军, 李元熹. 神经网络在股价预测中的应用[J]. 系统工程理论与实践, 1998(11):112-117.
- [4] TICKNOR J L. A bayesian regularized artificial neural network for stock market forecasting[J]. Expert Systems with Applications, 2013, 40(14):5501-5506.
- [5] YAN H, OUYANG H. Financial time series prediction based on deep learning[J]. Wireless Personal Communications, 2017, 3(3):116-136.
- [6] 彭燕, 刘宇, 张荣芬. 生存分析与股指涨跌的概率推断[J]. 计算机工程与应用, 2019, 55(11):209-212.
- [7] 游家兴, 吴静. 沉默的螺旋: 媒体情绪与资产误定价[J]. 经济研究, 2012, 47(07):141-152.
- [8] 王靖一, 黄益平. 金融科技媒体情绪的刻画与对网贷市场的影响[J]. 经济学 (季刊), 2018, 17(04):1623-1650.
- [9] 张宗新, 吴钊颖. 媒体情绪传染与分析师乐观偏差——基于机器学习文本分析方法的经验证据[J]. 管理世界, 2021, 37(01):170-185+11+20-22.
- [10] 范小云, 王业东, 王道平. 基于新闻大数据与机器学习的中国银行业系统性风险研究[J]. 世界经济, 2022, 45(04):3-30.
- [11] 曾庆生, 周波, 张程, 等. 年报语调与内部人交易: “表里如一” 还是 “口是心非”? [J]. 管理世界, 2018, 34(09):143-160.
- [12] BOLLEN J, MAO H, ZENG X. Twitter mood predicts the stock market[J]. Journal of Computational Science, 2011, 2(1):1-8.
- [13] 段江娇, 刘红忠, 曾剑平. 中国股票网络论坛的信息含量分析[J]. 金融研究, 2017(10):178-192.
- [14] 钱宇, 李子饶, 李强, 等. 在线社区支持倾向对股市收益和波动的影响[J]. 管理科学学报, 2020, 23(02):141-155.

- [15] COWLES A. Can stock market forecasters forecast?[J]. *Econometrica*, 1933, 1(3): 309-324.
- [16] LOUGHRAN T, MCDONALD B. When is a liability not a liability? textual analysis, dictionaries, and 10-ks[J]. *Journal of Finance*, 2011, 66(1):35-65.
- [17] JEGADEESH N, WU D. Word power: A new approach for content analysis[J]. *Journal of Financial Economics*, 2013, 110(3):712-729.
- [18] MANELA A, MOREIRA A. News implied volatility and disaster concerns[J]. *Journal of Financial Economics*, 2017, 123(1):137-162.
- [19] 王乃钰, 叶育鑫, 刘露, 等. 基于深度学习的语言模型研究进展[J]. *软件学报*, 2021, 32(04):1082-1115.
- [20] 胡昌生, 池阳春. 投资者情绪、资产估值与股票市场波动[J]. *金融研究*, 2013(10):181-193.
- [21] TETLOCK, P.C. Giving content to investor sentiment: the role of media in the stock market[J]. *Journal of Finance*, 2007, 3(62):1139-1168.
- [22] 黄润鹏, 左文明, 毕凌燕. 基于微博情绪信息的股票市场预测[J]. *管理工程学报*, 2015, 29(01):47-52+215.
- [23] JON K, HIMABINDU L, JURE L, et al. Human decisions and machine predictions [J]. *The Quarterly Journal of Economics*, 2018, 133(1):237-293.
- [24] 许雪晨, 田侃. 一种基于金融文本情感分析的股票指数预测新方法[J]. *数量经济技术经济研究*, 2021, 38(12):124-145.
- [25] 范小云, 王业东, 王道平, 等. 不同来源金融文本信息含量的异质性分析——基于混合式文本情绪测度方法[J]. *管理世界*, 2022, 38(10):78-101.
- [26] 谢法举, 刘臣, 唐莉. 在线评论情感分析研究综述[J]. *软件导刊*, 2018, 17(02):1-4+7.
- [27] 杨小平, 张中夏, 王良. 基于 word2vec 的情感词典自动构建与优化[J]. *计算机科学*, 2017, 44(1):42-47+74.
- [28] MARKOV A. Extension of the limit theorems of probability theory to a sum of variables connected in a chain[J]. In *Proceedings of the 3rd International Congress of Mathematicians*, 1913, 2:160-164.
- [29] 黄承慧, 印鉴, 侯方. 一种结合词项语义信息和 TF-IDF 方法的文本相似度量方法[J]. *计算机学报*, 2011, 34(05):856-864.

- [30] BENGIO Y, DUCHARME R, VINCENT P, et al. A neural probabilistic language model[J]. Journal of machine learning research, 2003, 3(Feb):1137-1155.
- [31] PETERS M E, NEUMANN M, IYYER M, et al. Deep contextualized word representations[J]. CoRR, 2018, 05365.
- [32] BAHDANAU D, CHO K, BENGIO Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473., 2014.
- [33] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30:5998–6008.
- [34] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
- [35] CHEN T, GUESTRIN C. Xgboost: A scalable tree boosting system[J]. arXiv preprint arXiv:1603.02754, 2016.
- [36] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11):2278-2324.
- [37] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural computation, 1997, 9(8):1735-1780.
- [38] 胡家珩, 岑咏华, 吴承尧. 基于深度学习的领域情感词典自动构建——以金融领域为例[J]. 数据分析与知识发现, 2018, 2(10):95-102.
- [39] 姜富伟, 孟令超, 唐国豪. 媒体文本情绪与股票回报预测[J]. 经济学 (季刊), 2021, 21(04):1323-1344.
- [40] 戴洁, 武康平. 中国股票市场技术分析预测力的实证研究[J]. 数量经济技术经济研究, 2002(04):99-102.
- [41] 向诚, 陆静. 基于技术分析指标的投资者情绪指数有效性研究[J]. 管理科学, 2018, 31(01):129-148.
- [42] 刘勇. 我国股票市场和宏观经济变量关系的经验研究[J]. 财贸经济, 2004(04):21-27.
- [43] 许均华, 李启亚. 宏观政策对我国股市影响的实证研究[J]. 经济研究, 2001(09):12-21+95.
- [44] 陆静, 孟卫东, 廖刚. 上市公司会计盈利、现金流量与股票价格的实证研究[J]. 经济科学, 2002(05):34-42.

- [45] 张娆, 薛翰玉, 赵健宏. 管理层自利、外部监督与盈利预测偏差[J]. 会计研究, 2017(01): 32-38+95.
- [46] HINTON G E, SRIVASTAVA N, KRIZHEVSKY A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. arXiv preprint arXiv:1207.0580, 2012.
- [47] 季子峥, 沈婷婷, 张孝. 利用社交媒体情感分析的短期股价趋势预测方法[J]. 北京理工大学学报, 2020, 40(01):83-89.
- [48] 王伟晶. 基于 BP 神经网络预测股票的涨跌趋势[J]. 现代经济信息, 2015(16):280+282.
- [49] 谢琪, 程耕国, 徐旭. 基于神经网络集成学习股票预测模型的研究[J]. 计算机工程与应用, 2019, 55(08):238-243.
- [50] 顾文涛, 王儒, 郑肃豪, 等. 金融市场收益率方向预测模型研究——基于文本大数据方法[J]. 统计研究, 2020, 37(11):68-79.
- [51] 彭益. 基于数据挖掘的股票指数涨跌概率推断[J]. 统计与决策, 2012(16):159-161.

致谢

两年的研究生学习生活，时光匆匆，转眼即逝。感谢郎艳怀导师在论文各方面对我的指导和建议以及在研究生期间不断的教诲和指引方向。感谢上海财经大学数学学院对我的培养以及所有授课老师在课堂上的知识传授，顺利毕业离不开您们的悉心指导和支持。感谢在研究生这两年的学习和生活中父母的全力支持以及同学们的热心帮助。也感谢上海财经大学，在论文研究的过程中，为我提供了丰富的图书和数据资源。

再次，感谢郎老师的悉心指导，感谢在上海财经大学攻读研究生的日子里我所遇见的每一位老师，感谢一起学习、生活的室友及同学们，毕业快乐！

个人简历

基本情况

陈浩越, 男, 四川成都人, 1999 年 9 月出生.

教育状况

2021 年 9 月至 2023 年 7 月, 上海财经大学数学学院, 硕士研究生, 专业全称: 应用统计 (统计计算与数据建模)。

2017 年 9 月至 2021 年 7 月, 西南财经大学数学学院, 本科, 专业全称: 数学与应用数学 (金融数学创新实验班)。

研究兴趣

量化投资, 机器学习, 金融统计.

联系方式

E-mail: chenhy47@163.com