



学校代码: 10272

学 号: 2019212623

上海财经大学

SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS

硕 士 学 位 论 文

MASTER DISSERTATION

基于机器学习方法的投资者情绪与股票价格预测分析

Analysis of stock price prediction with investor sentiment based on machine learning method

作者: 杨玉华

院 (系所) 数学学院

专 业 概率论与数理金融

指 导 教 师 曾旭东

完 成 日 期 2022 年 4 月

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品成果。对本人的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名：杨玉华

日期：2022年06月17日

学位论文版权使用授权书

(硕士学位论文用)

本人完全了解上海财经大学关于收集、保存、使用学位论文的规定，即：按照有关要求提交学位论文的印刷本和电子版本。上海财经大学有权保留并向国家有关部门或机构送交本论文的复印件和扫描件，允许论文被查阅和借阅。本人授权上海财经大学可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

论文作者签名：杨玉华

日期：2022年06月17日

导师签名：

常旭东

日期：2022年06月17日

摘 要

近年来,我国股票市场发展速度很快,股票各项指数波动较大,股市的不稳定很大程度上受投资者的投资情绪所致。随着自媒体的快速发展,其具有时效性,普泛性,不可控性强等特点,媒体报道的新闻内容可能会使得上市公司面临着更加恶劣的舆论环境,影响投资者的决策行为,进而对股价产生影响。基于此,学者们产生了诸多文本情感倾向的研究,通过大量的技术手段得出股市的趋势运行思想与方法,但是这些研究方法却很难在现实中去实现。在当今大数据时代,通过有效的研究,可以为投资者以及管理者提供决策与管理意见,规避市场风险,在实际应用与理论研究中都具有重要的意义。

本论文在前人研究的基础上,设计出一种资讯情感量化的方法,并与股票行情及技术指标结合,构建了一个新的股票价格预测模型,本文的研究结果可以为市场投资策略提供有力的研究思路,为监管者提供决策意见。核心工作有:

(1)从投资者情绪视角,利用爬虫技术自动化爬取个股资讯信息,运用 BERT 模型对个股资讯进行分类,然后构建资讯情绪指数(下文统称 senti);使用 LSTM 模型,基于市场客观影响情绪指标的开盘价,收盘价,最高价,最低价,市盈率,换手率,乖离率,MACD 指标,对比加入 senti 指标前后对股票预测效果的影响。通过实验研究,融入量化文本指标的股票预测模型可以很好的拟合股票的短期走势。

(2)使用格兰杰因果检验以及时间滞后互相关性分析技术分析不同股票的资讯与对数收益率之间的因果关系,最后采用策略能否收益来衡量模型的有效性,通过以资讯情绪指数以及股价预测模型作为交易信号,设计了两个投资策略,回测验证了本文设计的资讯量化方法具有一定的获利机会,说明本研究具有一定的参考意义。通过对比研究分析,不同股票资讯情感与对数收益率之间的因果程度也不一样,股价受多因素影响。

关键词: 爬虫;资讯情绪指数;BERT 预训练模型;LSTM 模型;回测

Abstract

In recent years, China's stock market has developed rapidly, various stock indexes fluctuate greatly, the instability of the stock market is largely caused by the investment sentiment of investors. With the rapid development of media, it has the characteristics of timeliness, universality and strong uncontrollability. The news reported by the media may make the related companies face a worse public opinion environment, affect the investor's investment decision and then affect the stock price. Based on the above, scholars have produced a lot of research on text emotional tendency, the operation ideas and methods of predicting the trend of the stock market are obtained through a large number of technical means, but these research methods are difficult to realize in reality. In today's big data era, effective research can provide investors and managers with decision-making and management system opinions and avoid market risks, which is of great significance in practical application and theoretical research.

Based on predecessors' exploration, this paper achieved a information emotion quantification method, it combines with stock market data and technical indicators to build a new stock price prediction model. The core works are:

(1) From the perspective of investor's sentiment, we use the Reptile Technology to automatically crawl individual stock information and use the Bert Pre-training model to classify the emotion with individual stock information, then the information sentiment index (hereinafter referred to as senti) is constructed. Using LSTM model, based on the market objectively affecting sentiment indicators of the opening price, closing price, highest price, lowest price, P/E ratio, turnover rate, deviation rate and MACD index, explore the influence of adding senti index before and after to stock forecasting model. Through experimental research, the

stock prediction model integrated with senti index can well fit the short-term trend of stocks.

(2) Granger causality test and time lag correlation analysis technology are used to analyze the causal relationship between the information of different stocks and logarithmic return. Finally, the effectiveness of the model is measured by whether the strategy benefits or not, two investment strategies are designed by taking the information sentiment index and stock price prediction model as trading signals, the back test verifies that the information quantification method designed in this paper has a certain profit opportunity, which shows that this study has a certain reference significance. Through comparative research and analysis, the degree of causality between different stock information emotion index and logarithmic return is also different, the prediction results of different models are also different, the stock price is affected by many factors.

Keywords: Reptiles; Information emotion index; BERT Pre-training model; LSTM model; Back test

目 录

摘要	I
Abstract	II
第一章 引言	1
1.1 选题背景与意义	1
1.2 研究内容与方法	5
1.3 论文组织结构	6
1.4 技术流程图	7
1.5 研究的主要创新之处	8
第二章 相关理论介绍	9
2.1 理论基础	9
2.1.1 股价影响因素	9
2.1.2 基本分析方法	10
2.1.3 融入资讯文本的股市预测研究的理论基础	10
2.1.4 机器学习与神经网络理论	11
2.2 模型原理	12
2.2.1 BP 神经网络理论	12
2.2.2 BERT 文本分类技术	16
2.2.3 LSTM 模型理论	22
第三章 实证研究	25
3.1 研究路线及数据准备	25
3.1.1 文本数据的来源	26
3.1.2 文本信息的量化	28
3.1.3 特征的选取	29
3.1.4 数据预处理及分析	31

3.2 模型实现与评估	33
3.2.1 BERT 文本分类的实现与评估	33
3.2.2 LSTM 模型股价预测的实现与评估	35
3.2.3 相关性分析	40
3.2.4 模型回测分析	42
3.3 实证总结	45
第四章 总结与展望	47
4.1 总结	47
4.2 不足与展望	47
参考文献	49
致谢	52
个人简历	53

第一章 引言

第一节 选题背景与意义

随着自媒体的快速发展，其具有时效性，普泛化，不可控性强等特点，可能会使得上市公司面临着更加恶劣的舆论环境。随着我国经济水平不断提高，股票作为常见的投资工具，受到了越来越多人的关注，截至 21 年年底国内开户人数高达两亿人，内地股市投资者以散户为主，值得注意的是，众多非专业投资者通过媒体新闻获取信息，分析师通过搜集整合行业资料、公司新闻以及国家政策调整作为投资的起始路径，媒体报道的新闻内容可能导致大量投资者情绪发生变化，改变投资者的预期，进而引发股票价格的波动。从 1997 年由汇率制导致的第一次亚洲金融危机波及了多个国家，2001 年纳斯达克由互联网带动的泡沫危机到后来的 2007 年美国发生的借贷危机事件中表明，投资者在利润的驱动下往往缺乏理性的思考。中国股市近几年，从 2008 年“三鹿奶粉”事件的曝光，三鹿集团破产，同时也致使多家奶粉厂家股价大跌，18 年刘强东事件导致京东股价暴跌逾 7%，欧莱雅直播差价风波以及特斯拉刹车失灵事件，均对公司的股价产生了影响。现代金融学的经典理论体系受到了挑战，行为金融学是包括心理学在内的行为科学理论，利用心理学的方法分析投资者的心理特征以及投资行为对资产价格产生的重要影响，行为金融学在整个金融领域占据着非常高的地位。

行为金融学将市场非理性行为加入金融决策中，解决了现代金融理论难以解释的金融异常现象，认为股票市场价格的影响因素不仅仅只是上市公司内在价值决定，同时受投资者自身情绪与偏好的影响。人们往往通过某一信息快速做出决策，而不是分析所有的信息；也有实验表明，投资者对某一上市公司研究时间越长，越容易产生心理偏差导致判断失误，以上说明，由于投资者认知的局限性，往往进行噪音交易。在我国金融市场中，以散户为主体的更容易受到噪音的影响，比如在一些业绩或者基本面并不是很好的股票中，相关政策或者行业

新闻的出现,可能会导致股票出现暴涨暴跌现象,这些异象均是游资与散户进行噪音交易导致。

目前国内外学者对新闻情绪的一般定义主要有以下三种:一是新闻媒体的撰稿人对客观事件进行描述的时候加入了自身的情感影响了投资者的投资决定;二是新闻对上市公司的客观事实描述传递出的客观信号导致投资者做出的投资决策;三是由于投资者阅历不同,个人对新闻事件的主观看法所做出的投资决定。本次研究主要使用的定义是第二种,即新闻对上市公司的客观事实描述传递出的客观信号导致投资者做出的投资决策。

目前在投资者情绪与股市的研究领域中,主要分为以下两个方面:一是构建综合情绪指标,结合多因素特征涉及基本面,消息面,技术面,资金,宏观及政策面等方面,构造综合指标对股票走势进行预测或者分析两者联动性, [Baker et al. \(2006\)](#) 选取纽交所股票市场的每日换手率,封闭式基金折价, IPO 上市日均发行申购数量,发行首日收益率,新配发股票数量与股票溢价六个指标,然后与工业生产指数进行正交取残差,使用第一主成分构造了 BW 指数,并验证了该指数可以减少非情绪因素的干扰; [易志高等 \(2009\)](#) 等基于股票交易量, IPO 指标,新增开户数, CCI 等代表投资者情绪指标进行主成分分析构造情绪指标,结果表明,投资者情绪对中国股票市场产生一定的影响; [Bollen et al. \(2011\)](#) 基于 Twitter 文本构建七个层次的情绪指标,发现该指标与道琼斯工业平均指数收盘值的日变化具有统计显著相关性; [汪昌云等 \(2015\)](#) 基于 IPO 公司的相关资讯中正负面词汇数量,构建了媒体语气指标,并验证了媒体语气作为投资者情绪代理变量的可靠性; [裴曼如等 \(2020\)](#) 使用股票市场数据在加入媒体报道评论情感指标后构建情绪综合指标,并验证了媒体报道评论情感指标的加入更有利于神经网络对股票趋势预测。二是单独分析新闻报道对投资者的投资情绪影响,分析该影响产生的投资行为是否与股市变动有关,大量分析是构建新闻情绪指标与股票收益率,波动率,成交量以及换手率等的关联以及研究验证了该情绪指标对市场指数,投资交易策略构建等方面的影响, [王美今等 \(2004\)](#) 使用央视资讯构建了投资者情绪指数,发现该指数和沪深两市指数具有较强的相关

性，并且可以反向修正沪深两市行情的波动；[王晓丹等\(2019\)](#) 基于百度搜索引擎，构建了资讯媒体的关注度及情感指标，分别验证了指标对上证指数的交易量，收益率以及波动率的影响。

新闻媒体文本传递出来的情感是难以测度的，但是随着计算机与大数据的发展，通过文本挖掘技术构造资讯情绪指标，取得了一些学术成果，也有研究从文本的组织结构及语言可读的难易程度对投资者投资行为是否产生影响，结果表明文章可读性越高，买入该公司股票的可能性越大。资讯情绪的度量大量研究是基于词典的统计方法（相关文献见[张成功等\(2012\)](#)，[周咏梅等\(2013\)](#)），该方法将词汇分为不同情绪程度的列表，使用赋予的权重或者词频将资讯按照词汇情感等级进行加权，最终得到资讯的情感强度，当前比较流行的词典为哈弗通用词典，亨利词典，知网 HowNet 情感词典，台湾大学中文情感词典，大连理工情感词典等，但是近期文本情绪的大量学术研究转向神经网络方面。

随着互联网的高速发展，人们在线通过搜索相关信息获取想要的产品，对某些产品的使用效果进行评论以及对国家某些事件发表自己的观点，这些都无时无刻不影响我们生活，对它们进行信息挖掘，文本处理，数据统计等具有重要的作用。文本情感指标的构建属于自然语言处理（NLP）领域，它在国内的研究依然处于发展之中，相关成果仍有待进一步的完善。文本分类技术是 NLP 的基础任务，但是仍在飞速发展，它的应用非常广泛，比如：新闻分类，垃圾过滤，顾客意图分类调查等。在自然语言处理领域文本分类研究的方法大致可以分为三种：基于规则的方法，基于机器学习的浅层学习方法以及深度学习方法。基于规则的方法是将一组预定义好的规则对文本分为不同的类别；从 1960 年到 2010 年基于统计理论的浅层学习文本分类模型占主导位置，例如 TFIDF 方法（相关文献见[施聪莺等\(2009\)](#)），朴素贝叶斯模型（相关文献参见[李静梅等\(2003\)](#)），K 邻近方法（相关文献参见[张华鑫等\(2015\)](#)），隐马尔科夫模型（相关文献参见[Baum et al.\(1966\)](#)，[杨健等\(2010\)](#)），梯度增强树（相关文献参见[刘春磊等\(2019\)](#)），随机森林（相关文献见[Breiman\(1995\)](#)，[张华伟等\(2006\)](#)）与支持向量机模型（[刘晓亮等\(2010\)](#)）等，特征的提取与分类器的设置在模型中起

重要作用，这种方法在稳定性与准确性较早期基于规则的方法具有一定程度的提升，但是这种方法仍然需要改进，因为它通常会忽略文本数据的上下文信息以及文本数据的顺序，功能设计耗时长，难以推广到新的任务以及不能充分利用大量训练数据等弱点；自 2020 年以来，文本分类技术从浅层学习文本分类模型发展为深度学习文本分类模型，它可以自动提取特征和学习，避免了人工设计耗时问题，具有很高的计算复杂性，它包括递归神经网络（黄磊等(2017)），卷积神经网络（郭东亮等(2017)），Transformers 等模型（Devlin et al.(2018), Vaswani et al.(2017), Yang et al.(2019) 等），该技术尝试从输入端学习特征表示并分类，可以发现数据中潜在隐藏的模式，不仅省去了繁杂的设计过程还易于将其推广到新的模型中，成为近年来文本分类任务的主流框架，但是与浅层模型相比并不足以解释其原因和工作方式。本文使用的是深度学习 BERT 模型进行分类，它可以通过预训练好的语言模型通过微调方式得到非常好的文本分类以及阅读理解效果。

常见的股票价格预测模型根据是否基于统计理论分为两种：基于统计原理与基于非统计理论的模型。在统计原理方面，Engle(1982) 提出 ARCH 模型，较好的模拟出股票波动率特征；French et al.(1987) 用 GARCH 模型估计出美股市场预期收益率与股票波动的关系，此后该模型得到多次证实可被提供较理想的数据拟合与预测效果；Bollerslev(1986) 在 1986 年提出随机波动率模型成为一个经典的金融波动模型。历史股价是最能反映市场变化的数据，很多预测模型都是基于历史数据建模。在非统计原理领域的预测模型，常见的有灰色模型（相关文献见陈海明等(2003)），机器学习，深度学习等模型，股票作为在市场上典型的交易工具，其价格影响因素比较复杂，价格序列具有非线性特征（相关文献见宿成建(2006), 王承炜等(2002)），而神经网络系统可以逼近任意非线性函数，这就是目前股票市场中使用神经网络方法展开大量研究的理论基础。对于不同模型适用于不同对象，对数据的要求与处理也不一样。使用深度学习等非线性模型进行市场价格的预测取得了很大成功，但是大部分实践者都证明，没有任何一个模型适合所有股票的预测，每种模型有其适合的数据类型。从现有

文献来看,我国股市价格进行预测基于非统计的预测效果要比基于统计原理好,LSTM 模型由Hochreiter et al. (1997) 提出,在很多回归预测问题上都取得相当巨大的成功,并在此基础上不断创新并得到了广泛的使用(相关文献见林杰等(2020),刘宁宁等(2020),赵红蕊等(2021))。本次研究曾尝试了基于非统计原理的 LSTM, CNN+LSTM 以及 GRU 等方法进行预测对比,最终以 LSTM 模型作为本文的论证模型。

对金融资讯报道情感的研究一直以来都是研究的热点,在金融领域属于行为金融学范畴,相关研究获得了有价值成果的同时仍存在问题。本论文在前人研究的基础上,设计出一种资讯情感量化的方法,并与股票行情指标结合,使用机器学习方法的 LSTM 模型构建了一个新的股票价格回归预测模型,并对不同股票价格预测结果以及多个股票资讯与对数收益率之间的因果程度的研究分析。在当今大数据时代,仅仅依靠股票行情数据相关指标对股票市场进行预测不具有完全性,投资者转向文本挖掘与信息量化可以提高预测精确度,有效规避风险,从我国金融管理制度的现状来看,管理机制并不完善,在现代金融企业管理过程中,金融业需要有敏锐的风险意识,现阶段我国金融业的风险意识薄弱,金融管理体制的应对能力有待提高,有效的研究,可以为投资者以及管理者提供决策与管理制度意见,规避市场风险。从情绪量化方面研究媒体资讯对股票市场的影响,在实际应用与理论研究都具有重要的意义。

第二节 研究内容与方法

媒体发布资讯会间接地影响投资者行为。本文从行为金融学出发,针对情感分析领域,使用 Python 爬虫软件爬取中新经纬网,股吧资讯,每经网相关股票资讯,对资讯标题使用 BERT 模型进行文本情感分类建模,将分类文本量化成情绪指标,并将影响投资者行为的个股股市历史日度行情数据与技术指标融入资讯情感特征进行建模,使用双层 LSTM 模型的机器学习模型进行预测建模,对多个个股未来的一天的收盘价进行预测并通过格兰杰因果检验以及时间滞后互相关性分析来分析不同股票之间资讯与对数收益率之间的因果关系,并

以 senti 指标与股价预测模型为交易信号进行回测。

本研究使用 BERT 模型对金融资讯进行分类,在适用范围以及效果上相比于其它文本模型会更好;将交易数据,技术指标与 senti 指标融入股价预测模型,增加了模型预测影响因素的有效性,在一定程度上为股市的预测研究提供新思路。使用工具为 Python。

本文的研究方法有:

- 理论与实际相结合。在大量收集学习与股票市场预测相关的研究理论之上,设计了一种简单且有效的资讯情感量化方法,构建出基于资讯情感量化的股票市场价格预测模型,最后通过实证研究以及回测证实了本文构建的模型具有一定的有效性;
- 实证研究方法。本研究依据现有文献及技术理论并立足科学实践的需要,设计了一种简单且有效的股票市场预测方法,通过有目的,有步骤地实施,根据观察、记录、评估模型,主要目的在于说明资讯与股票市场价格的关系以及模型是否具有实践性,是一种科学的实证研究形式。
- 跨学科研究法。也称“交叉研究法”,运用金融学,人工智能等理论与方法对股票市场价格预测进行建模,使用多学科结合的综合研究的方法。
- 文献研究法。以研究新闻情感与股票价格预测之间的关系为目的,通过调查文献来获得资料,全面、正确地了解到所要研究该领域的问题以及方法。

第三节 论文组织结构

第一章,引言。该部分详细介绍了本文所研究的内容,背景以及意义,根据现有关键技术及理论研究概述了国内外股票市场预测研究,融入文本的金融市场预测研究,文本分类相关研究现状,最后说明了本文研究的内容以及所采用的方法。

第二章,相关理论介绍。该部分首先介绍了金融市场中影响股票价格的因素,然后阐述了股票价格预测理论,最后介绍了本文文本分类技术 BERT 模型和采用的文本量化方法及 LSTM 模型,为接下来的实证研究提供了理论上面的

支撑。

第三章，实证研究。该部分基于资讯情感与股票行情的股票价格预测研究，爬取了实验所需资讯文本以及从 Wind 终端获取股票每日行情交易指标，基于 BERT 文本分类构建资讯综合情感指标 senti，然后以八只行业内比较成熟的股票为研究对象，使用 LSTM 模型对输入 senti 前后进行了预测的效果对比的研究，同时检验了 senti 与对数收益率之间的关系，最后通过回测验证了模型的具有一定的收益能力。

第四章，不足与展望。该部分首先总结了论文的研究成果，然后概述了论文的创新点，最后对本文研究中存在的不足进行了总结，并对研究的下一步改进提出了几点想法。

第四节 技术流程图

本文的技术流程图如图1-1:




图 1-1 技术流程图

第五节 研究的主要创新之处

本论文的创新点体现在以下几个方面：

(1) 虽然深度学习 BERT 预训练模型在文本分类领域取得很大成果，但是在情感分类领域主要汇集在评论文本的分类任务上。本研究首次尝试将 BERT 模型使用在中国股票市场的资讯情感分类预测模型中进行探究，发现该方法有较好的预测效果；

(2) 本文采用的 BERT 模型以及结构简单的量化方法，有效地解决了使用文本复杂特征进行金融文本量化研究的问题。针对资讯情感量化方法尝试了使用长文本（资讯内容）对应标签为收益率的回归方法、文本分类 softmax 层取出作为情感特征的多维度的自适应网络方法、长文本的金融词典量化方法以及短文本（资讯标题）的几种机器学习分类算法。在分析各种方法背后的原理，特点及效率的基础上，选择了本文所采用的 BERT 文本分类模型以及结构简单的量化方法；

(3) 对资讯量化指标与股票收益率之间进行了相关性分析，分析并验证了资讯量化指标对股市影响。同时采用策略收益来衡量模型的有效性，构建了基于资讯情绪指标为交易信号与股价预测模型为信号的交易策略，回测验证了模型具有良好的收益能力，构建的资讯量化指标为投资策略提供了有力的思路。

第二章 相关理论介绍

第一节 理论基础

2.1.1 股价影响因素

股票价格未来的涨跌是由买卖双方供求关系决定，投资者通过证券交易所进行交易，价格的短期波动有助于股票交易市场的供需关系的平衡。中国股票市场变化复杂，股票价格受到众多因素影响。

公司自身经营状况以及未来发展方向。公司整体经营现状的变化和企业未来发展方向是股票价格的基石，公司未来经营发展形式的优劣取决于公司治理的水平与管理层的质量，以及公司竞争力与财务状况等，从价值理论上分析，公司整体经营状况与股票价格正相关。

行业因素。股票市场中，我们经常观察到来自某一行业或者相同板块的股票在相同时期表现出共涨或者共跌的情况，这通常说明股市存在着某种行业影响或产业性的影响因素，对这些因素的分析即为行业分析。行业因素包括一些定性因素和若干定量因素，常见的涉及有行业结构或产业竞争结构，行业可持续性，监管措施，政府关系以及行业总体估值水平。

宏观经济发展水平。宏观经济对股票价格影响的突出特点是涉及领域广，对股市的干扰与作用机制比较复杂，可能导致股价发生较大水平的波动。

在我国股市上，股票的长期内在价值是由股票背后相关企业的内生价值决定的，但股票短期的价格却是情绪化的，受大多数人短期的情绪影响。从短期投资角度来看，当发生某种系统性风险事件时或大盘发生连续暴跌情况时，股民基本上是先根据自己的情绪来判断事件对股价的影响，如果股民认为这可能是一则较大利空消息时，将会迅速地抛售出相关的股票，间接的引起了该股票价格短期内的下降；而当股民认为是利多消息时，将很快买入股票，从而促使股价进一步上涨。股民个人的投资价值观是影响股价涨跌的关键因素，要在一个股市

上取得丰厚的投资收益，了解股民们的投资价值观可以被认为是一个关键步骤。

除此之外，还有财政政策、市场利率、通货膨胀、汇率变化等因素影响股价变动。归纳起来主要包括公司经营环境因素，宏观经济因素，市场行业因素，政治因素以及其他影响股民情绪的因素。

2.1.2 基本分析方法

分析股票市场价格的方法主要从以下几个方面：政策面，个股基本面，盘面，技术分析面，心理面。主要的方法可以分为以下三种：

- 基本面分析法。基于基本面分析的预测方法是通过研究企业内在价值来测算公司自身发展潜力的长期投资价值以及根据公司所处行业的宏观发展情况从而做出投资建议，是一种定性的方法，能够发现股票价格的决定因素及影响方式和程度，但是严重依赖基本面数据的真实性与完整性，适合长线投资的判断，而对短期价格走势的预测能力较弱；

- 技术分析法。基于市场运作规律作为预测理论依据，认为市场行为包容一切信息，通过公开的市场数据，采用图表等方法构建技术性指标从而对市场走势作出预判，是一种定量的分析方法，该方法包括形态理论，周期理论等方法，指标由股票的成交量与换手率以及衍生出来的技术性指标等，但是技术分析可以反应出问题的范围比较窄，对市场长远的趋势不能进行有益的判断；

- 量化分析法。该分析方法使用数理以及计算机技术作为理论依据，可以对股市短期波动进行建模并获得不错的效果，但是模型稳定性差，一旦外部因素发生重大变化，模型有效性便会受到影响。

2.1.3 融入资讯文本的股市预测研究的理论基础

有效市场假说。该假说由 Fama 提出，该假说认为，在充分的股票市场中，股价走势便可以解释一切信息，投资者不可能通过历史信息获得高于市场平均水平的超额利润，信息是影响市场价格的重要因素之一。根据反映程度可分为三种市场，但是无论出于何种程度的有效市场，信息都是影响市场价格的重要因素之一。由此，公司资讯作为信息的一种表现形式可以认为是对股票产生影

响的因素之一。

行为金融学理论。该理论注意到了在某些状况下市场表现出有效市场假说难以解释的现象，该理论采用了投资者非理性以及羊群效应等特征解释该异象的发生。该理论虽然对有效市场假说提出了质疑，但是又是对有效假说的一种补充，为市场预测研究提供了新的思想，修正了传统理论。资讯新闻对股票市场价格的影响可以通过资讯自身的表达引起的投资者的投资行为，也在该理论中得到了体现。

2.1.4 机器学习与神经网络理论

人工智能 (AI) 领域近年来取得了迅速的进展，在某些情况下性能与人类相当甚至超过人类。机器学习是人工智能的一个分支，机器学习项目流程图如图2-1，它的原理是通过用算法处理数据，通过机器学习经验并积累知识来达到解决问题的方法。深度学习是使用多层神经网络的算法，网络的每一层定义数据中的特征和模式，属于机器学习的一个分支，可以被广泛应用在计算机视觉，信息检索，金融交易，医疗保健，目标识别，自然语言处理等等。




图 2-1 机器学习研究流程图

神经网络具有复杂性，它可以使得算法自行执行特征提取，但是可解释性不强，且它的参数比机器学习会更多，调参是一个深度学习面临的最大的技术

问题之一。简单的神经网络示意图如图2-2^{注 1}，输入层（input layer）负责神经网络信息的传入，隐藏层（hidden layer）负责特征提取与处理，输出层（output layer）显示模型计算成果。




图 2-2 简单神经网络结构图

第二节 模型原理

目前对股票预测方法进行研究，主要方法基于统计学原理和人工智能方法。用传统统计学预测方法诸如回归分析法、时间序列法、统计概率法等均为股票的预测做出了历史性的贡献。人工智能方法主要有 SVM，决策树，神经网络等方法，是目前比较主流的预测方法。

2.2.1 BP 神经网络理论

作为常用的网络训练算法，反向传播（BP）算法通过计算期望值与网络的输出层之间的误差来调整网络参数。BP 算法包含前向与反向两个阶段。前向阶段是给定输入及参数计算输出值，反向阶段是计算梯度，沿最小化误差方向更新权重系数。BP 算法流程图如图2-3。

^{注 1}：图片来源：https://www.jianshu.com/p/35ac2f062fa1?utm_campaign=hugo




图 2-3 BP 算法流程图

激活函数是作用在神经网络上运行的非线性函数，它的功能是使网络模型可以逼近任意非线性函数。常见的激活函数有：

- sigmoid 函数也称 S 型生长曲线，常被用来作为神经网络输出层的激活函数。它将变量映射到区间 $[0,1)$ 内，具有连续可导性。但由于函数在两端取值比较平坦，容易产生梯度消失问题。函数表达式为：

$$f(x) = \frac{1}{(1 + e^{-x})}. \quad (2-1)$$

- tanh 函数是双曲函数中的一个。取值区间为 $[-1,1]$ ，相比于 sigmoid 函数更容易达到最优值。函数表达式为：

$$f(x) = \frac{(e^x - e^{-x})}{(e^x + e^{-x})}. \quad (2-2)$$

- relu 函数解决了 tanh 与 sigmoid 函数会在端点值趋于饱和导致训练速度缓慢的问题，被广泛地用在深层网络模型中。函数表达式为：

$$f(x) = \max(0, x). \quad (2-3)$$

- softmax 函数常用于输出层的激活函数，在有 n 个神经元的输出层中，输出层的第 k 个神经元 y_n 的输入 a_k 到第 k 个神经元的输出计算方式为：

$$y_k = \frac{e^{a_k}}{\sum_{i=1}^n e^{a_i}}. \quad (2-4)$$

成本函数是多个训练样本的平均损失，网络层的训练在于通过优化算法来最小化成本函数，是监督学习算法的技术核心。成本函数值是衡量回归模型优化程度以及效果的重要指标。常见回归成本函数有：

- 平均绝对误差损失（MAE）也称 L1 Loss，用于衡量预测值与真实值之间距离：

$$MAE = \frac{1}{n} \sum_{k=1}^n |\text{real}_k - \text{pre}_k|. \quad (2-5)$$

- 平均平方误差损失（MSE）是回归任务最常见的一种损失函数，也称 L2 Loss，MAE 损失对于异常点具有更好的鲁棒性，MSE 对异常点很敏感，当数据中出现异常值的时候会对模型产生较大的影响，MAE 相比 MSE 通常可以更快地收敛：

$$MSE = \frac{1}{n} \sum_{k=1}^n (\text{real}_k - \text{pre}_k)^2. \quad (2-6)$$

- 平均绝对误差比（MAPE）衡量了预测结果与真实结果的平均偏离程度：

$$MAPE = \frac{1}{n} \sum_{k=1}^n \left| \frac{\text{real}_k - \text{pre}_k}{\text{real}_k} \right|. \quad (2-7)$$

神经网络的训练过程就是最小化成本函数值的过程，成本函数的值衡量了模型在给定数据集下的拟合表现能力。优化器的作用就是加速损失函数收敛到最小，它的基本原理都是基于梯度下降算法，基本的算法有 BGD，SGD 以及 MBGD，后来出现了基于随机梯度之上的一些优化算法，旨在加速学习速率，更有效地快速收敛，主要有加入动量的随机梯度下降法，自适应学习率算法以及在此之上加入动量的混合思想的算法，如 RMSProp，AdaGrad 等。优化算法一般流程图如图2-4：




图 2-4 优化算法一般流程图

最常见的优化方法为 MBGD 与 Adam。

网络权重更新是从梯度方向与学习率两个方面进行的，BGD 算法使用所有样本进行参数更新，效率低下，而 SGD 下降每次随机选取一个样本用于参数更新，准确度会降低。MBGD 算法对上述算法进行了折中，使用小批量样本进行参数更新，提升了综合性能。

Adam 本质上是带有动量项的 RMSProp，利用梯度的一阶与二阶矩估计动态调整不同参数的自适应学习速率，使得参数变化比较平稳，性能优越。BERT 在预训练过程中使用的是 AdamW 优化算法，它是在 Adam+L2 正则化的基础上进行改进的算法，限制了参数值的变化范围。公式如2-8：

$$\left\{ \begin{array}{l} m_t = \mu * m_{t-1} + (1 - \mu) * g_t \\ n_t = \nu * n_{t-1} + (1 - \nu) * g_t^2 \\ \widetilde{m}_t = \frac{m_t}{1 - \mu} \\ \widetilde{n}_t = \frac{n_t}{1 - \nu} \\ \omega_t = \omega_{t-1} - \eta_t * \left(\frac{\alpha \widetilde{m}_t}{\sqrt{\widetilde{n}_t} + \epsilon} + \lambda \theta_{t-1} \right). \end{array} \right. \quad (2-8)$$

2.2.2 BERT 文本分类技术

文本分类是自然语言处理中最基本的任务，同时也是非常重要的任务。相关领域研究的成功大多得益于人工智能的成果，已有许多相关文献。文本分类技术有基于前馈网络的词袋模型，有基于卷积神经网络模型，时间序列及相关衍生出来的各种变体或者混合体等模型。

BERT 模型来源于论文《BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding》，BERT 的全称为 Bidirectional Encoder Representations From Transformers。实验表明 BERT 模型取得了 11 项任务的最优结果，是自然语言处理领域中重要的突破。谷歌提供了九种预训练好的模型文件，其中中文语言模型使用了简体中文和繁体中文，12 层编码，每层有 768 层隐藏层，12 个头，共 110M 个参数。模型使用双向的 Transformer 搭建，使用 Masked LM 任务捕获字词级别的语义表示，使用 Next Sentence Prediction 捕获句子级别的逻辑表示，提高模型性能，解决了传统词向量搭配神经网络解决文本情感分析以及人工阅读效率低不高的问题。

BERT 是自编码语言模型，模型构架分为两部分：Pre-training 部分与 Fine-tuning 部分。

Pre-training 部分是用来训练语言模型，使用是 Masked LM 机制与 NSP 任务，使训练出来的语言模型可以使语言的表达具有语义的完整以及上下文的逻辑关系。Masked LM 机制是指随机屏蔽或者替换一句话中的任意词或者字，然后让模型预测被遮蔽或者替换的部分，对做遮蔽部分计算损失进行反向传播。由于随机替换只发生在所有输入 token 的 1.5%，基本上不会损害模型的语言理解能力。模型在两个句子之间加一些特殊的 token，也就是在两句话中间及句末加 [sep]，在句子开头加 [cls]，经常使用 [cls] 所对应的向量代表整个句子的信息，然后初始化一个权重矩阵做逻辑回归以及激活函数得到分类，这个就是 NSP 任务，训练了模型理解句子关系的能力。

Fine-tuning 部分是对 Pre-training 部分输出的隐藏层信息使用线性变换以

及激活函数使得该阶段的输出与最终任务相匹配。通常在 BERT 预训练好的语言模型基础上增加一个全连接层作为微调过程，以最小的调节代价来实现最先进的结果，被证明可以应用在广泛的任务中。BERT 模型结构图如2-5:




图 2-5 BERT 模型结构图

模型训练的语料来自维基百科语料；模型的输入为使用分词（字）后的 token 序列，进入 Embedding 层得到 Input Embeddings:

$$InputEmbeddings = TE + PE + SE, \quad (2-9)$$

其中 TE, PE, SE 分别代表 Token Embedding, Positional Embedding, Segment Embedding。TE 一般是训练好的词向量，它是通过语料库的词典是字加 id 的形式，然后通过训练（或者第三方已训练好的词向量例如 CNN, LSTM 等通过反向传播不断调整）得到，PE 一般是使用三角函数得到（也可以通过学习得到）

得到位置嵌入，支持序列长度可达 512 个，计算方式为：

$$\begin{cases} PE_{(t,2i)} = \sin \frac{t}{10000^{\frac{2i}{d}}} \\ PE_{(t,2i+1)} = \cos \frac{t}{10000^{\frac{2i}{d}}}, \end{cases} \quad (2-10)$$

上述 PE 计算公式中，t 表示 token 在句子中的位置，d 表示嵌入维度，2i,2i+1 代表维度的位置索引，三角函数内分母不是固定不变的，通常取上述形式。SE 一般是由 0 或者 1 组成的序列，用于区分该字属于第一句与第二句；BERT 结构主体主要用了 Transformer 的 Encoder 部分（称为 Transformer Block）如下图 2-6。多个 Transformer block 一层一层地堆叠起来，然后通过下游任务进行全连接输出。在 BERT 的原模型中，分别用了 12 层和 24 层组装了两套 BERT 模型，训练的 loss 函数使用的是 MLE 函数。




图 2-6 Transformer Block 结构图

在 Transformer Block 层中，多头注意力机制 (Multi-head Attention) 可以被认为是核心的特征提取器，这种结构设计能让每个注意力机制去优化每个词的不同特征部分，从而均衡同一种注意力机制可能产生的偏差，让词义拥有来自更多元表达，实验表明可以通过这样的结构设计来提升模型效果。它的基本思想是使用自注意力机制为输入的每个 token 学习一个权重，解决了传统序列模型在编码过程中需要顺序进行的弊端问题，可以使得模型实现并行化计算，以

输入两个 token 为例的 Multi-head Attention 计算流程图2-7:




图 2-7 Multi-head Attention

其中:

x_1, x_2 : 句子经过切分分别输入的文字;

$f(x)$: Embedding 层映射;

a_1, a_2 : Input Embedding;

① $W_{ij}^q, W_{ij}^k, W_{ij}^v$: 可训练的权重矩阵;

$q_{ij} = w_{ij}^q \cdot a_i, k_{ij} = w_{ij}^k \cdot a_i, v_{ij} = w_{ij}^v \cdot a_i, i = 1, 2; j = 1, 2, \dots, m$

$$\textcircled{2} \begin{pmatrix} z_{j1} \\ z_{j2} \end{pmatrix} = \text{softmax}\left(\frac{\begin{pmatrix} q_{1j} \\ q_{2j} \end{pmatrix} \begin{pmatrix} k_{1j} & k_{2j} \end{pmatrix}}{\sqrt{d}}\right) \begin{pmatrix} v_{1j} \\ v_{2j} \end{pmatrix}$$

$d = \dim(q_{ij}) = \dim(k_{ij}) = \dim(v_{ij}); j = 1, 2, \dots, m$

$$Z = \begin{pmatrix} z_{11} & z_{21} & \cdots & z_{m1} \\ z_{12} & z_{22} & \cdots & z_{m2} \end{pmatrix} W_0$$

其中 W^0 可训练.

我们设计网络结构的时候，不知道具体设置多少层次的网络可以达到优化，深层网络层的设计在参数更新过程中，容易随着网络的深入而导致梯度消失，产生多余的训练层，往往模型很难将这些冗余层学习为恒等映射，模型产生退化现象。残差连接节点使用 $h(x)=\text{Relu}(F(x)+x)$ 函数进行参数的更新时，只需保证 $F(x)=0$ 就能保证参数更新时不会发生梯度消失现象，可以解决上述梯度消失和网络退化的问题。

用 $X_{\text{Multi-HeadAttention}}$ 表示 Input Embedding 经过 Multi-Head Attention 的输出, $X_{\text{Multi-HeadAttention}}$ 第一次经过 Add 层处理后，需要进行 Relu 操作，输出为：

$$x_1 = \text{Relu}(\text{InputEmbedding} + X_{\text{Multi-HeadAttention}}), \quad (2-11)$$

然后经过 Norm 层：

$$X_{\text{AddNorm1}} = \text{LayerNorm}(x_1) = \frac{x_1 - \mu}{\sqrt{\sigma^2 + \epsilon}} \cdot a + b, \quad (2-12)$$

其中 μ, σ 为在样本方向取平均与方差， a, b 为可训练参数。




图 2-8 前馈与残差连接

随后 $X_{AddNorm1}$ 经过 Feed Forward 层处理：

$$X_{FeedForward} = \max(0, X_{AddNorm1}W^1 + b_1)W^2 + b_2, \quad (2-13)$$

进入 Add 层，输出为：

$$x_2 = \text{Relu}(X_{AddNorm1} + X_{FeedForward}), \quad (2-14)$$

最后第二次经过 Norm 层：

$$X_{AddNorm2} = \text{LayerNorm}(x_2) = \frac{x_2 - \mu}{\sqrt{\sigma^2 + \epsilon}} \cdot a + b, \quad (2-15)$$

其中 μ, σ 为在样本方向取平均与方差。

常见的二分类损失函数有，二分类交叉熵损失函数与 Hinge 损失函数。多分类损失函数有，KL 散度与多分类交叉熵损失函数。

Hinge 损失函数标准形式如下：

$$L(\text{real}, \text{pred}) = \max(0, 1 - \text{real} \cdot \text{pred}), \quad (2-16)$$

其中 pred 是预测值，real 是目标值。函数表示如果样本被正确分类，损失为 0，否则为 $1 - \text{real} \cdot \text{pred}$ ，对异常点不敏感，经常被用在 SVM 模型，使得 SVM 模型仅通过少量的支持向量就能确定最终超平面。

熵是对所有可能发生事件产生的信息量的期望。一个事件的不确定越大，信息量就会越大，对应熵值就会越高。 $H(x) = -\sum_{i=1}^n p(x_i) \log(p(x_i))$ 。

KL 散度用于衡量对于同一随机变量 x 的两个分布 $p(x)$ 和 $q(x)$ 之间的差异。在机器学习中， $p(x)$ 常用于描述样本的真实分布， $q(x)$ 则常常用于表示预测的分布， $q(x)$ 需要不断地学习来拟合准确的分布 $p(x)$ 。

$$D_{KL}(p||q) = \sum_{i=1}^n p(x_i) \log\left(\frac{p(x_i)}{q(x_i)}\right). \quad (2-17)$$

KL 散度的值越小表示两个分布越接近。KL 散度公式可拆成 $p(x)$ 的熵与交叉熵 (CE)：

$$CE(p, q) = -\sum_{i=1}^n p(x_i) \log(q(x_i)). \quad (2-18)$$

交叉熵是 KL 散度去除常量后的一部分。其值越小，模型预测效果就越好，它可以解决逻辑回归中采用 MSE 导致梯度优化缓慢的问题。

我们定义字母 T,F 代表分类器结果为 True, False。P, N 代表分类器分类结果是 P 类与不是 P 类。将其两两组合得到 4 个值，根据这四个值，定义出以下模型评价指标：

准确率 (Accuracy) 指对于给定的测试数据集，分类器正确分类的样本数与总样本数之比，该指标在正负样本不平衡的情况下有很大的缺陷。

$$Accuracy = \frac{(TP + TN)}{(TP + TN + FP + FN)}. \quad (2-19)$$

精确度 (Precision) 是分类器正确分类的正例个数占预测分类为正例个数的比例，衡量的是模型系统的查准率。

$$Precision = \frac{TP}{(TP + FP)}. \quad (2-20)$$

召回率 (Recall) 指分类器正确分类的正例个数占实际正例个数的比例，衡量的是模型系统的查全率。

$$Recall = \frac{TP}{(TP + FN)}. \quad (2-21)$$

F-1 值是对 Precision 和 Recall 进行整体评价的指标，也称 F-得分，F-Score。

$$F1 = \frac{(2 \times Precision \times Recall)}{(Precision + Recall)}. \quad (2-22)$$

混淆矩阵是最常见的用来衡量分类器任务的成功程度的指标。当进行多个标签的分类任务时，混淆矩阵是一个矩阵 $A = (a_{i,j})_{k \times k}$ ，其中 $a_{i,j}$ 表示标签 i 被预测为标签 j 的次数，因此， $a_{i,i}$ 表示正确预测的标签，非对角线元素表预测错误。

2.2.3 LSTM 模型理论

图2-9^{注 2}表示包含 2 个隐含层的 LSTM 网络，从单个时刻看，它是一个普通的 BP 网络，输入与输出特征维数为 5 个，且每个隐层含有五个神经元；沿着时间轴方向，上一时刻隐含层信息会被传递到下一个时刻。

注 2：图片来源：<https://zhuanlan.zhihu.com/p/139617364>




图 2-9 LSTM 模型网络结构

LSTM 模型中包含三个 Sigmoid 和一个 tanh 层，如图2-10^{注 3}，Sigmoid 与 tanh 函数的设置，有助于信息的更新与遗忘。




图 2-10 LSTM 模型内部结构

LSTM 模型中三个门以及传输带的运行如下：

- 遗忘门，决定了上一个时刻的单元状态 C_{t-1} 有多少保留到当前时刻单元状态信息 C_t 。

$$f_t = \sigma(W_f \bullet [h_{t-1}, x_t] + b_f). \quad (2-23)$$

- 输入门，根据上一次的输出 h_{t-1} 与本次输入 X_t 计算当前输入的单元状态，避免当前无关紧要的信息进入记忆。

$$i_t = \sigma(W_i \bullet [h_{t-1}, x_t] + b_i); \quad (2-24)$$

注 3: <https://mp.weixin.qq.com/s/1FcwTcY9S3uiIG9FjPkWLQ>

$$\tilde{C}_t = \tanh(W_C \bullet [h_{t-1}, x_t] + b_C). \quad (2-25)$$

c. 传输带，选择性遗忘 C_{t-1} 的一些信息，并添加新的信息 $\tilde{C}_t$ 。

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_{t-1}. \quad (2-26)$$

d. 输出门，决定了当前时刻网络的控制单元 C_t 有多少信息输出到当前状态量 h_t 。

$$O_t = \sigma(W_o \bullet [h_{t-1}, x_t] + b_o); \quad (2-27)$$

$$h_t = O_t * \tanh(C_t). \quad (2-28)$$

第三章 实证研究

第一节 研究路线及数据准备

当前主流的股票价格预测特征选择主要包括两种：基于股票指标与宏观指数作为影响因素以及在此基础上融入文本信息作为综合影响因素。融入文本信息的股票价格预测思路是基于高速发展的媒体以及行为金融学研究影响非理性投资者决策的因素，而研究忽略融入文本信息的模型预测效率比较低，并不能有效提高股票价格预测的精度。

基于此，本文综合中国股票市场现实情况以及现有学者的研究成果，针对资讯情感量化方法尝试了使用资讯内容长文本向量对应标签为收益率的回归方法、文本分类 softmax 层取出作为情感特征的多维度的自适应网络方法、资讯内容长文本的金融词典量化方法以及资讯标题短文本的几种机器学习分类算法，在分析各种方法背后的原理，特点及效率上，选择 BERT 模型进行短文本情感分类，然后构建了综合情感 senti 指标公式的方法进行资讯的情感量化；针对忽略文本信息价格预测效果不理想的问题，采用文本信息与市场行情相结合的思想以更高效地达到文本信息真实融入股价预测的特征；使用双层 LSTM 模型对多只股票未来一天价格进行预测分析，对加入 senti 前后模型的预测效果进行了对比，同时使用格兰杰检验以及时间滞后互相关对资讯情感与对数收益率进行相关性分析，最后以 senti 指标与以股票预测结果为交易信号进行了回测分析。




图 3-1 实验研究框架

3.1.1 文本数据的来源

目前较主流的股票资讯网站有中国证券网，新浪财经，东方财富网，和讯网，中新经纬网，证券之星，每日财经等。考虑到研究文本资讯的全面性，专业性，爬取了东方财富网股吧资讯，每经网，中新经纬网相关股票资讯，它们是国内交易者经常获取金融行情数据、公司及行业资讯信息以及交流投资经验的平台，具有很高的专业性。为了提高课题研究的代表性，选择不同行业股票不同网页资讯进行爬取。爬取页面资讯发布时间，网页标题。网站页面如下：



图 3-2 中新经纬网



图 3-3 每经网



图 3-4 股吧

本文基于 Python 的 Selenium 库的爬虫技术,使用的开发工具是 PyCharm,浏览器为谷歌以及使用对应的驱动,爬取资讯标题、日期,由于主页面标题信息可能存在不全的问题,爬取操作要涉及翻页,然后点击进入详情页,窗口的打开以及关闭,信息的存储等操作。

Selenium 工具主要用于驱动浏览器,给浏览器发一些指令,让浏览器执行各种动作:输入、跳转、点击、下拉等操作。它在爬虫中主要解决 JavaScript 渲染问题,模拟网页的加载,支持各种浏览器。以爬取股吧资讯为例3-5。




图 3-5 爬取流程图

```

date,title,
2022-1-25,隆基股份01束4日获沪股通增插12.19万股,
2022-1-25,银行股四季度遭基金大比例减持 十大重仓股仅余招徕,
2022-1-25,连续3日净买入 隆基股份获沪股通净买入2.48亿元,
2022-1-25,基金头号重仓股仍是贵州茅台至四季度末持有市值达1805亿,
2022-1-25,隆基股份:融资净买入1.89亿元,两市排名第四 (01-24),
2022-1-24,大宗交易:隆基股份成亿82.7万元,成交价76.54元 (01-24),
2022-1-24,【基金持仓】基金四季度合计持有隆基股份721.8亿元 环比增加79.67亿元,
2022-1-23,隆基股份本周沪股通持股市值增势.47亿元,居光伏设备板块第二,
2022-1-23,隆基股份本周融资净偿还4336.34万元,居光伏设备板块第六,
2022-1-22,中欧基金葛兰管理规模1103亿入“千亿顶流”,新进这些股,
2022-1-21,隆基股份:公司组件主要应用自产电池片 少部分外购,
2022-1-21,隆基股份:公司和森特合作的主要产品是“隆顶”,产品依据客户需求提便,
2022-1-21,隆基股份:公司具备生10硅片的能势,
2022-1-21,隆基股份01束0日获沪股通增插87.41万股,
2022-1-21,隆基股份:融资净偿还3340.16万元,融资余颀01.56亿元_1-20_,
2022-1-21,隆基股份:目前公司P型PERC电池量产转换效率超过23%,
2022-1-21,隆基股份:公司组件主要应用自产电池片,少部分外购,
2022-1-21,隆基股份:公司制氢目前聚焦于碱性水电解路线,对于其他技术路线保持关浪,
2022-1-21,隆基股份:公司和森特合作的主要产品是“隆顶”,产品依据客户需求提便,
2022-1-21,隆基股份:公司制氢目前聚焦于碱性水电解路线 对于其他技术路线保持关浪,
2022-1-20,又来抄底了? 美国最大中国股票ETF,一周吸金超50亿,
2022-1-20,隆基股份:公司难以将全部成本上涨转嫁至下漆,
  
```

图 3-6 爬取结果示例图

3.1.2 文本信息的量化

市场是不稳定性的，投资者情绪客观地影响股价，但是很难度量。基于情感指标的量化一般采取主成分分析法等线性方法，主要针对影响投资者情绪的行情数据，技术指标，资讯情感以及宏观等多维度数据进行主成分分析进行降维提取情绪指标输入预测模型，另一种便是将所有影响投资者情绪的指标输入预测模型。

目前处理文本情感量化的方法主要是基于词典构造的方法，机器学习方法以及神经网络方法。基于词典量化构造方式一般采取的是对文章中所有的情感词进行加权或者使用词频统计的方法，可以准确反映文本的非结构化特征，但是它依赖于情感词典的构建，情感词典的设置规则及更新对文本分类效果具有很大的影响，而且该方法往往考虑不到上下文之间的语义关系。基于机器学习的情感分析方法是指通过监督，无监督或者半监督学习方式，使用机器学习算法抽取特征，该方法在对文本内容进行情感分析时，容易忽略上下文语义的问题，这对任务的准确性有一定的影响。基于神经网络的方法是将文本输入神经网络，让机器提取情感特征，能够有效解决基于传统情感分析方法中忽略上下文语义的问题。深度网络学习在情感分析任务上，能够更好地捕获上下文相关信息，提取语义信息，防止重要信息的丢失，可以有效提高文本情感分类的准确率。现阶段比较主流的技术是通过对大规模语料进行深度网络训练的预训练模型，被证明在很多 NLP 任务中显示出了强大的能力。

通过对现有文本情感分析与股市预测模型的研究，大多文本情感的构造使用词典法构造文本情感值或进行文本倾向分析，也有许多学者使用机器学习方法对文本进行分类或构建文本情感向量对股市进行预测，这些方法在文本分类以及构建情感值的大小上存在一定的局限性，如何从文本数据中挖掘出股票价格影响因子，将非结构化的文本数据表示成简单且包含语义特征是十分重要的。本文综合前人经验，使用 BERT 预训练模型对文本进行分类并对分类好的文本进行统计，然后使用分类好的文本统计值构建文本情感值，这种方法是借鉴前

人所使用的词典的情感量化计算方法，在文本分类效果上讲，往往比基于词典和机器学习方法效果要好，而且该情感值构造方法可以反映出日情绪方向与股市的变动呈正相关性的合理性，同时还可以反映当日情绪强度，形式上也简单。

本研究将文本进行了三分类：正向情感，中性情感以及负向情感，使用的每日文本情感值 $sinti_t$ 的计算方法为：

$$sinti_t = \ln \frac{1 + N_{post}}{1 + N_{negt}}, \quad (3-1)$$

其中 $sinti_t$ 表示第 t 天新闻资讯情感值。

$\ln$ 表示取对数； N_{post} 表示第 t 天正向新闻报道次数； N_{negt} 表示第 t 天负面报道次数。若 $sinti_t > 0$ ，表示消息面呈良好状态，认为行情乐观，为正向情感指标；反之，若 $sinti_t < 0$ ，表示行情不是很乐观，为负向情感指标。 $sinti_t$ 绝对值越大，表示未来市场上涨或下跌的可能性越大。

计算结果如图3-7，其中 senti0，senti1，senti2 分别表示当日负向，中性，正向的资讯个数。

date	senti0	senti1	senti2	senti
2015-6-26	5	6	9	0.510826
2015-6-29	1	2	0	-0.69315
2015-6-30	0	1	1	0.693147
2015-7-1	1	1	1	0
2015-7-2	1	2	0	-0.69315
2015-7-3	3	1	0	-1.38629
2015-7-6	1	2	2	0.405465
2015-7-7	1	1	2	0.405465
2015-7-8	4	3	5	0.182322
2015-7-9	4	3	3	-0.22314
2015-7-10	1	1	1	0
2015-7-13	3	3	3	0
2015-7-14	1	1	2	0.405465
2015-7-15	1	2	3	0.693147
2015-7-16	1	1	1	0
2015-7-17	0	1	1	0.693147
2015-7-20	1	2	2	0.405465
2015-7-21	3	3	2	-0.28768

图 3-7 每日文本情感值计算数据示例

3.1.3 特征的选取

现有股票预测模型主要利用股票的交易数据特征，这种预测方法不够全面，考虑到互联网传播范围不断扩大，财经资讯通过影响投资者情绪改变投资者决

策, 本文采用深度学习方法进行分析处理, 模型研究包括股票相关影响因素有: 开盘价 (open), 收盘价 (close), 最高价 (high), 最低价 (low), 市盈率 (pe_ttm), 换手率 (turn), 移动平均线 (MACD), 乖离率 (BIAS) 与资讯情感特征 (senti)。

大多研究都是以历史数据作为依据进行建模。历史股价可以说是反应市场中交易者普遍认可的价格, 最高价最低价被认为是交易者在投资过程中认为最合适的买入卖出价位, 开盘价收盘价也一定程度上反映了投资者在参与起初期未对行情的预期。

市盈率常被用来评估公司股价水平是否合理的指标之一, 等于股价与年度每股盈余的比值。按照净利润时间区间的取法不同, 有静态与动态之分。市盈率与公司业绩有关, 可能会随着业绩的增减而暴增暴减。不同行业, 市盈率差别比较大, 仅依赖于数值大小进行判断是不客观的, 需要仔细分析辨别。

MACD 指标是对买入、卖出时机作出判断的技术指标, 数值取收盘价的短期指数移动平均线与长期指数移动平均线之差。

换手率反映了股票流通性的强弱, 计算公式为: $\text{换手率} = \frac{\text{vol}}{S} \times 100\%$ (在中国: $\frac{\text{vol}}{\text{sto}} \times 100\%$), vol 为对应时间段内的成交量, S 为公司发行总股数, sto 为流通股本。将该指标与近期走势联系起来, 可以对市场短期动向做出分析判断。

乖离率是反映当前股价偏离某根移动平均线程度的指标, 计算方式为: $\frac{(\text{close} - \text{Nclose})}{\text{Nclose}} \times 100\%$, close 为当日收盘价, 其中 Nclose 为 N 天收盘价的均值, 它是对技术指标的重要补充和完善, 可以作为短线投资者判断是否进场的较为有效的工具。

人们在投资决策中, 往往通过某一信息进行快速做出决策, 而不是分析所有的信息; 也有实验表明, 投资者对某一上市公司研究时间越长, 越容易产生心理偏差导致判断失误。以上说明, 由于投资者认知的局限性, 往往进行噪音交易。在我国金融市场中, 以散户为主体的投资者更容易受到噪音的影响, 比如在一些业绩或者基本面并不是很好的股票中, 相关政策或者行业新闻的出现, 可能会导致股票出现暴涨现象, 这些异象均是游资与散户进行噪音交易导致, 影

响投资者行为，资讯作为信息的一种表达方式，是影响股市波动的一个关键因素，本文探究性地尝试了文本情感值的构造方法。

3.1.4 数据预处理及分析

综合考虑市场整体表现与现实中构造词典的复杂性，对文本进行标记，去除大量融资融券信息，并将少量融资融券信息标记为中性作为 BERT 分类器的训练数据，对数据编码格式统一为 UTF-8，使用工具为 Notepad++，同时需要注意到文本标注标签过程中不可以标注为负值，否则输入 BERT 模型会报错。

对预测模型的输入特征进行预处理，例如数据归一化，补全缺失数据等。为了减少不同特征量纲对模型的影响，提高模型的精度与运算速度，对各个输入特征使用 Min-Max Normalization 方法进行归一化处理，该方法使用训练集数据的最大值和最小值进行数据的标准化，经过处理的数据数值转换到 0 至 1，转化函数为： $x_i^* = \frac{x_i - \min_x}{\max_x - \min_x}$ ，非交易日资讯进行累加至临近交易日，且考虑到收集到的文本数据存在不全，我们进行中性情感填充，交易停牌数据采用向上填充的方法补齐交易日中存在的缺失值。

股票金融市场中有众多行业，每种行业风格都不一样，受投资者情绪影响也具有差异性，直接用同一种预测模型预测不同风格企业个股需要进一步验证。在股票价格预测部分，为提高实验研究的代表性，本文实验对象选取了行业内具有代表性的，相对来说比较热门，成熟的八只股票作为研究对象，由于不同上市公司媒体报道资讯量不同，导致在爬取资讯覆盖时间区间不一致，考虑到机器学习需要大量数据进行建模，尽可能地充分利用所采集的数据，并未对数据时间区间进行统一（数据集如表3-1）。行情数据及技术指标来源于 wind，可视化股票收盘价如图3-8，横坐标为（交易天数），纵坐标为（元/每股）：

表 3-1 数据集选取时间段及对应收盘价

股票名称	code	数据集起始时间	对应收盘价	数据集终止时间	对应收盘价
中国平安	601318	2015-06-26	77.44	2022-02-08	53.0
中国石油	601857	2015-09-08	8.70	2021-11-10	4.85
万科 A	000002	2015-09-09	13.76	2022-02-08	22.88
隆基股份	601012	2016-11-22	13.93	2022-02-18	68.55
五粮液	601318	2014-01-02	15.44	2022-04-22	165.43
新希望	601857	2016-06-28	8.38	2022-04-22	15.2
中航重机	000002	2014-01-02	12.79	2022-04-22	32.36
海螺水泥	601012	2015-03-02	20.63	2022-04-22	38.32




图 3-8 收盘走势图

第二节 模型实现与评估

3.2.1 BERT 文本分类的实现与评估

由于信息噪音比较大,综合考虑到人工处理信息的复杂性对模型的影响,我们对爬取的文本进行如下处理:本文爬取了八个行业每个行业选取了三只股票共 1.3W 条的资讯数据作为 BERT 模型的原始数据集,它们有紫金矿业,恒立液压,招商银行,江特电机,正泰电器,天合光能,复星医药,泸州老窖等。将爬取的资讯去除大量融资融券信息,去除新闻来源以及标题同时重复的新闻,将少量融资融券信息作为模型的输入标注为中性,其余资讯进行标注,选取正向,负向以及中性资讯各 3000 条放入训练集以及验证集。从不同类别中随机选取等量文本数据,按照近似 7:3 的比例划分为训练集与验证集,为了验证模型的泛化能力,对来自其它网站爬取的 2000 条金融资讯标注好的文本进行测试。

Google 在训练中文 BERT 预训练模型时使用的语料库来自维基百科,语言模型的训练模式是固定的,在使用中可以是采用 Google 训练好的语言模型也可以采用相同的设计原理进行无监督训练,而分类任务的训练采用的数据则是根据自己需求所收集到数据。Google 提供 Large 和 Base 两种原始 BERT 预训练模型,两者参数虽然不同但网络结构是一致的。本文下载 Bert-Base-Chinese 配置文件,采用 Base 参数设置,利用中文维基百科语料库训练的原始 BERT 预训练模型。




图 3-9 BERT 文本分类实现流程图

本次实验环境电脑操作系统 Windows10, Python 版本 3.8, Pytorch 版本 1.9.0, GPU 显卡 GTX1065 Ti。信息的情感负面, 中性, 正面特征依次用 senti0, senti1, senti2 表示, 构建综合情绪指标用 senti 表示。对爬取的资讯进行文本字段长度统计性描述。训练数据最短长度为 6, 最长长度为 137, 平均长度为 25, 25% 水平长度为 22, 50% 水平为 25, 75% 水平为 30, 考虑到实际情景以及 BERT 模型最大可输入长度为 512, 本文模型最大输入长度设置为 50, 使用 AdamW 优化器以及交叉熵损失, softmax 函数预测分类结果, batchsize 设置为 32, 训练轮数为 8。

表 3-2 BERT 文本分类模型参数设置

LossFunction	Optimizer	LearningRate	Batchsize	Epoch	max_len
CrossEntropyLoss	AdamW	0.00001	32	8	50

BERT 情感分类模型结果如图3-10:




图 3-10 BERT 情感分类模型结果图

验证集准确率评估指标能够达到 0.88, 说明模型对短文本进行情感分类的

效果很好。测试集准确率能达到 0.83，说明 BERT 模型有很好的语义理解及泛化能力。

表 3-3 测试集分类评价指标

指标	负类	中性	正类
精确度	0.821	0.801	0.892
召回率	0.837	0.756	0.819
F1-值	0.829	0.778	0.854

3.2.2 LSTM 模型股价预测的实现与评估

在构建预测模型时，本文设计了两种预测方案，以开盘价，收盘价，最高价，最低价，市盈率，换手率，移动平均线指标，乖离率为特征输入以及上述特征之上融入资讯情感指标作为输入特征的两种预测实验。本研究采用人工试错与经验调参得到最优模型，调参原则是降低损失值，在调整某参数时先固定另一组参数，在确定了该参数最佳后再对其他参数进行调优，主要调的参数为：输入序列步长，LSTM 层数及神经元个数，随机丢弃神经元个数比例 Dropout，训练周期 Epoch，单批次输入样本数 Batch-Size 等。




图 3-11 LSTM 模型预测实现

实验过程中, 我们使用 350 条数据作为基础训练集, 根据人工试错与经验调参原则, 我们发现 LSTM 层数为 2 的网络模型在测试集上表现更稳定; 本文尝试了以 1 个交易日, 3 个交易日, 10 个交易日为步长, 每个交易日的多个特征为输入, 一个交易日的收盘价为输出 (以 3 个交易日为例如图3-12) 进行训练, 发现以 3 交易日为输入步长的交易数据与资讯情感作为特征, 预测未来一天股价时网络拟合效果较好, 同时 3 个交易日的步长预测可以降低模型训练时长, 步长较远会造成数据冗余, 过短又会降低模型训练过程中特征的提取; 此外神经网络层超参数的设定还有: Adam 优化器, MSE 损失函数, 在模型调优的过程中加入 Dropout 层减少模型的过拟合, 参数设置为 0.1, epoch 设置为 50, batch-size 设置为 128, 同时使用测试集来验证模型的预测效果。




图 3-12 单输出训练数据构造

由于股票市场行情复杂, 数据及信息风格更新速度快的特点, 需要实时对模型不断地调整, 本论文使用滚动数据集进行训练的方法更新模型, 更新一次模型时长为 50 个交易日, 数据集划分如图3-13:




图 3-13 滚动训练数据集划分

我们将训练好的模型进行保存，每隔 50 个交易日进行一次模型的保存，以每只股票数据集最末端 250 天为总测试区间长度，设置输入特征添加 senti 前后的预测走势对比图如3-14,3-15：




图 3-14 未添加 senti 测试集拟合效果图




图 3-15 添加 senti 测试集拟合效果图

图3-15中的两条曲线分别代表测试集的真实值与预测值，期间模型更新 5 次，单个测试集长度为 50 个交易日，通过对比模型在测试集上的预测值与真实值曲线，可以看出 LSTM 模型的预测曲线都很接近于股价的真实曲线，具有相同的走势，虽然存在一定的偏差，但是能够很好地捕捉到趋势，说明 LSTM

模型对时间序列数据有很强的预测能力，但是需要注意的是使用 LSTM 模型预测不同风格股票预测效果不一样，而且随着时间的推移，模型有效性降低，使用滚动训练模型不断更新训练的数据集，优化模型参数才能更好地跟进实际问题。为了进一步评估模型预测不同股票的性能，选择了四个指标作为实验结果的评判标准，分别是均方误差 MSE，平均绝对误差 MAE，平均绝对百分比误差 MAPE 以及决定系数 R^2 作为模型评价标准，使用滚动模型进行训练，记录并计算各只股票在测试集上的平均评价指标3-4，3-5：

表 3-4 未加入 senti 指标的双层 lstm 模型评价标准

测试集	MAE	MSE	MAPE	R^2
601318	0.689	1.640	0.015	0.927
601012	0.545	0.698	0.023	0.922
601857	0.0436	0.103	0.023	0.918
000002	0.279	0.150	0.011	0.962
000858	2.903	18.7	0.028	0.954
000876	0.616	0.913	0.0374	0.911
600765	1.101	3.261	0.030	0.967
600585	0.482	0.420	0.009	0.979

表 3-5 加入 senti 指标的双层 lstm 模型评价标准

测试集	MAE	MSE	MAPE	R^2
601318	0.612	1.401	0.013	0.933
601012	0.171	0.426	0.022	0.937
601857	0.008	0.032	0.019	0.923
000002	0.204	0.090	0.010	0.971
000858	1.850	9.281	0.007	0.996
000876	0.265	0.273	0.014	0.986
600765	0.900	1.773	0.026	0.987
600585	0.341	0.237	0.008	0.983

当 MAE, MSE, MAPE 值越小, R^2 值越接近 1 时，说明模型的拟合效果越好。由表3-4,3-5可以看出，LSTM 模型在测试集上平均拟合优度 R^2 均达到了 90% 以上，取得了不错的拟合效果；模型在加入 senti 指标前后，拟合程度整体

有所提升, 损失值减少, 说明加入 senti 指标对股票预测模型具有一定的影响。

3.2.3 相关性分析

为进一步研究本文构建的研究资讯综合情感指数与股票价格之间的关系, 本研究采用以下两种的研究方法与思路: 首先, 对 senti 指标与对数收益率进行格兰杰因果关系检验; 然后, 对 senti 指标与对数收益率进行时间滞后互相关检测。

3.2.3.1 格兰杰因果关系检验

为研究构建的资讯综合情感指标 senti 与股票价格之间的关系, 本文采用格兰杰因果关系检验来验证 senti 与对数收益率之间的因果关系。在进行因果关系检验之前需要对数据进行平稳性检验, 使用 ADF 检验的结果如表3-6,3-7。

表 3-6 senti_ADF 检验

senti	检验统计值	P-value	1%	5%	10%
601318	-15.6390	1.65e-20	-3.4344	-2.8633	-2.5677
601012	-4.4106	0.2e-6	-3.4356	-2.8638	-2.5679
601857	-18.3136	2.27e-16	-3.4347	-2.8634	-2.5677
000002	-8.5476	9.41e-21	-3.4349	-2.8635	-2.5678
000858	-19.8748	0.0000	-3.4336	-2.8629	-2.5675
000876	-29.7467	0.0000	-3.4350	-2.8636	-2.5675
600765	-43.0785	0.0000	-3.4336	-2.8636	-2.5675
600585	-20.3118	0.0000	-3.4336	-2.8630	-2.5680

表 3-7 ln_r_ADF 检验

senti	检验统计值	P-value	1%	5%	10%
601318	-15.656	1.58e-28	-3.4344	-2.8633	-2.5677
601012	-4.4106	0.0003	-3.4356	-2.8639	-2.5680
601857	-9.5838	2.29e-30	-3.4349	-2.8635	-2.5677
000002	-19.519	1.13e-13	-3.4349	2.8636	-2.5678
000858	-4.430	0.0003	-3.43363	-2.8629	-2.5675
000876	-3.537	0.0024	-3.4350	-2.8636	-2.5679
600765	-4.850	4.37e-05	-3.4336	-2.8630	-2.5675
600585	-4.846	4.43e-05	-3.434	-2.8630	-2.5675

由表3-6,3-7知, senti 与 lnr 时间序列的 ADF 统计检验值同时小于 1%, 5%, 10% 三个水平条件下的值, P 值小于 0.01, 很大程度上拒绝原假设, 序列 senti 与 lnr 不存在单位根, 表明被分析的序列是一个平稳的序列, 考虑到文本信息对股市的短期影响, 这里对其进行最大滞后期为 3 的格兰杰因果检验, 格兰杰检验结果如表3-8。


表 3-8 lnr 与 senti 之间格兰杰检验结果

code	601318	601012	601857	000002	000858	000876	600765	600585
lag=1 的 p 值	0.638	0.314	0.101	0.143	0.020	0.183	0.011	0.127
lag=2 的 p 值	0.207	0.131	0.437	0.029	0.160	0.284	0.018	0.024
lag=3 的 p 值	0.070	0.321	0.480	0.020	0.120	0.31	0.003	0.360

在表3-8的 lnr 与 senti 的短期格兰杰检验结果中, 不同股票在不同滞后期的格兰杰检验结果具有差异性。在 5% 水平下, 000002, 000858, 600765 及 600585 在不同阶数下表现出格兰杰因果关系, 此时 senti 有助于解释对数收益率的将来变化。

3.2.3.2 时间滞后互相关检测

该检验通过反复计算数据集之间的相关系数, 寻找相关性系数最大的时间点及相关系数值, 如果两个数据集之间存在引导-跟随关系, 相关性系数最大点会出现在不同时间点。使用时间滞后互相关检测寻找引导因子及领先时间窗口, 使用的窗口期为 30 天, 由图看到在 senti 与 lnr 呈现正相关关系且 senti 领先驱动 lnr, 两者相关系数最高达到 0.31, 驱动时间均为 1 天。






图 3-16 时间滞后互相关检验

3.2.4 模型回测分析

该部分制定了两个交易策略：以 senti 指标为交易信号的策略以及以股价预测模型为交易信号的策略，对上述 8 只股票进行了回测分析，时间区间为 2018 年 1 月 2 日至 2021 年 11 月 10 日，总共 936 个交易日。

策略一：

交易信号为前一天的资讯 senti 指标，若 senti 值大于 0 则为买入或持有信号，若 senti 值小于 0，则为卖出或观望信号，每次进出场每只股票为一股，不允许卖空，不计交易过程产生的费用，以当日收盘价为交易价格。若按照 senti 信号进行交易，最终可以获得 166.28 元收益。如果按照每只股票第一次入场的买入价作为整个投资过程的本金计算，累积收益率为 57%，年化收益为 15.3%。




图 3-17 累计收益图

表 3-9 回测结果数据

code	601318	601012	601857	000002	000858	000876	600765	600585
回测区间价差	-21.8	57.27	-3.42	-13.35	124.8	7.76	32.5	5.03
累计最低收益	-7.6	0	-0.7	0	-4.35	0	-3.91	-18.94
累计最高收益	26.54	91.53	0.78	20.81	169.66	19.84	12.54	6.44
累计总收益	-4.96	77.22	-0.24	15.04	70.29	13.58	13.54	-18.18
胜率	0.51	0.55	0.49	0.64	0.58	0.62	0.51	0.32

使用 senti 作为交易信号对上述八只股票的 936 个交易日的回测数据进行分析, 我们发现股票集合整体的最终收益为正值, 说明我们的策略具有一定的收益能力, 虽然平均胜率仅为 53%, 但是有五只股票的累计总收益较大幅度超过回测区间的价差, 说明资讯信号可以规避风险, 在一定程度上对投资决策起积极作用。在分析单只股票收益曲线时, 我们发现并非每一只股票在使用此策略时都会取得好的收益, 相比而言, 对于股性活跃 (601012, 000858), 本身走势较好的股票其收益表现可能会更佳。

策略二:

调用训练好的 LSTM 模型对上述八只股票进行预测, 并使用股价预测值与

当前值的差额为交易信号，若差额大于 0 则为买入或持有信号，若差额小于 0，则为卖出或观望信号，每次进出场每只股票为一股，无卖空操作，不计入手续费，以收盘价为交易价格。交易最终可以获得 327.9 元收益，如果按照每只股票第一次入场的买入价作为整个投资过程的本金，累积收益率为 102%，年化收益约为 27.2%。




图 3-18 累计收益图

表 3-10 回测结果数据

code	601318	601012	601857	000002	000858	000876	600765	600585
回测区间价差	-21.8	57.27	-3.42	-13.35	124.8	7.76	32.5	5.03
累计最低收益	-15.34	-15.04	-3.58	-12.28	-16.82	-0.30	-3.11	0
累计最高收益	27.12	78.22	0.77	7.71	251.6	30.07	25.76	35.70
累计总收益	-8.46	78.22	-0.80	-9.28	222.9	21.24	1.46	22.58
胜率	0.43	0.62	0.53	0.39	0.64	0.71	0.53	0.67

使用股价预测结果作为交易信号对上述八只股票的交易日的回测数据进行分析，我们发现股票集合最终取得了不错的收益。除了 600765 外，七只股票的总收益均高于回测区间价差，说明信号在一定程度上有规避投资风险的作用。对比策略一，策略二平均胜率均有提高，说明我们的股票价格预测模型对趋势性行情有一定的预测作用，构建的股价预测模型可以捕捉到更多的大涨趋

势，降低总的收益风险。

由于我国证券场所包含的行业较多，每个行业的上市公司质量也参差不齐。本研究选取了八只较为成熟的行业，石油石化，保险，白酒，新能源光伏，地产等行业中具有代表性的个股作为样本。对八只样本股票进行回测，选择较为简单的交易信号入场并取得了较好的收益，实际策略中可以扩大选股范围以及加入更多的策略因子进行研究。影响股票市场的运行因素是非常复杂的，对不同类型股票建立预测模型时，要综合各种影响因素。

第三节 实证总结

近年来，国内企业的发展不断向好，许多公司不断进入金融市场，截至 2021 年底，A 股开户数近两亿，股票市场的变动不仅牵动着股民的心，而且关乎公司的繁荣和衰落，但影响股市趋势的原因有很多，使得价格走势很难被完全掌握。本文使用 BERT 模型对新闻资讯进行情感分类并量化，以国内排名靠前的金融企业作为研究对象，以行情数据与技术指标加资讯情感作为输入，收盘价作为目标，使用 LSTM 模型进行回归预测，并对资讯情感与对数收益率进行相关性分析。根据上述实证研究章节中的研究过程以及研究结果的呈现，我们可以得到以下主要结论：

1. 深度学习 BERT 预训练模型可以捕捉字词间的逻辑关系，能够很好地表达语义。在进行文本分类，语义理解任务上在适用范围，运行速度以及效果方面表现优异；

2. 研究表明，资讯报道与股票对数收益率具有一定的相关性，在最大滞后期为 3 的格兰杰因果关系检验中有四只股票的对数收益率与构建的 senti 存在格兰杰因果关系，在滞后互相关检验中，八只股票的 senti 数据集领先对数收益率数据集一期达到相关性峰值，说明文本情感值与不同股票存在不同程度的因果关系；

3. 实验结果发现，基于 LSTM 的模型对股价具有很好的拟合效果，资讯报

道对于股价变动具有一定的影响；以 senti 指标作为交易信号以及以输入特征加入资讯的股票预测模型为交易信号的回测过程表明可以获得较好的收益；以 senti 指标为信号的交易策略可以规避投资风险，以股价预测模型为信号的策略具有很强的趋势性预测作用，适用于趋势性预测，说明本研究具有一定的参考意义。

上海财经大学学术数据总库Scholars Hub at SUFE [https://scholars.sufe.edu.cn/]

第四章 总结与展望

第一节 总结

本论文在前人研究的基础上，设计出一种资讯情感量化的方法，并与股票行情与技术指标结合，使用机器学习方法构建了一个新的股票价格预测模型：

1. 利用爬虫技术，从个股资讯出发，运用 BERT 预训练模型对与个股资讯进行情感分类，然后构建资讯情绪指数，基于市场客观影响情绪指标的最高价，最低价，开盘价，收盘价，市盈率，换手率，乖离率，MACD 指标之上加入新闻情绪指数，使用神经网络 LSTM 时序模型对股票未来一天价格进行预测。通过实验对比研究，融入量化文本指标的股票预测模型能很好地拟合股票的短期走势。

2. 使用格兰杰因果检验以及时间滞后相关性分析来研究资讯情感与股票对数收益率之间的因果关系，发现不同股票文本资讯情感与股票对数收益率的短期因果关系具有差异性；同时以 senti 指标作为交易信号以及以输入特征加入资讯的股价预测模型为交易信号的回测过程表明可以获得较好的收益，模型可以有效规避投资风险。论文的研究结果表明股价预测模型具有很强的趋势性预测作用，本文设计的资讯量化方法对股价预测研究有一定的参考价值。

第二节 不足与展望

1. 文本分类数据预处理方面。本文曾爬取了资讯标题，资讯内容，使用 BERT 模型对资讯内容的文本分类任务从运行效率上不及短文本，而仅使用资讯标题进行分类，内容又不够全面，还可能存在标题与内容相反或无关的倾向，后续可考虑将长文本转化为文本摘要（中短文本）进行研究；其次，对于没有明显利好利空的消息标注了中性，数据未使用数据增强，模型预测的准确性有待提高，季报年报出现大涨大跌的标注了正向与负向，近年来很多上市公司季报年报的

结果与短期股价涨跌相关性减弱，应该针对性的研究某类公司会更具有说服力；

2. 股票价格模型输入特征及研究对象方面。在输入特征选取方面，本文未考虑大盘与板块行情对当日股价的影响；在研究对象的选取上，仅选取了少量股票进行研究，缺少适用性，后续可以考虑更多不同类型公司，也可以考虑将其它金融产品（例如债券，基金以及衍生品等方面）作为研究目标；

3. 模型的预测目标方面，不仅局限于价格的预测，还可以考虑每日盘中最高价，盘中最低价，收益率或者涨跌等预测，可能预测效果会更佳；同时在模型的设计上可采用智能化调参，同时提高模型更新的速度，提高预测的准确度；

4. 在回测研究中，本文选取了八只股票使用以 senti 值正负为交易信号，可尝试扩大研究对象的范围，还可以选择 senti 值每日排名靠前的几只股票进行交易或建立多因子选股模型等进行交易。

参考文献

- BAKER M, WURGLER J, 2006. Investor sentiment and the cross-section of stock returns[J]. The journal of Finance, 61(4): 1645-1680.
- BAUM L E, PETRIE T, 1966. Statistical Inference for Probabilistic Functions of Finite State Markov Chains[J]. Annals of Mathematical Statistics, 37(6): 1554-1563.
- BOLLEN J, MAO H, 2011. Twitter mood as a stock market predictor[J]. Computer, 44(10): 91-94.
- BOLLERSLEV T, 1986. Generalized autoregressive conditional heteroskedasticity[J]. Journal of econometrics, 31(3): 307-327.
- BREIMAN L, 1995. Taylor & Francis Online :: Better Subset Regression Using the Nonnegative Garrote - Technometrics - Volume 37, Issue 4[J]. Technometrics, 37(4): 373-384.
- DEVLIN J, CHANG M W, LEE K, TOUTANOVA K, 2018. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. ArXiv preprint arXiv:1810.04805.
- ENGLE R F, 1982. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation[J]. Econometrica: Journal of the econometric society: 987-1007.
- FRENCH K R, SCHWERT G W, STAMBAUGH R F, 1987. Expected Stock Returns and Volatility[J]. Journal of Financial Economics, 19(1): 3-29.
- Hochreiter, Sepp, Schmidhuber, Jurgen, 1997. Long short-term memory.[J]. Neural Computation, 9(8): 1735-1780.

- VASWANI A, SHAZEER N, PARMAR N, USZKOREIT J, JONES L, GOMEZ A N, KAISER Ł, POLOSUKHIN I, 2017. Attention is all you need[J]. Advances in neural information processing systems, 30: 6000-6010.
- YANG Z, DAI Z, YANG Y, CARBONELL J, SALAKHUTDINOV R R, LE Q V, 2019. Xlnet: Generalized autoregressive pretraining for language understanding[J]. Advances in neural information processing systems, 32.
- 陈海明, 李东, 2003. 灰色预测模型在股票价格中的应用[J]. 科研管理, 024(002): 28-31.
- 郭东亮, 刘小明, 郑秋生, 2017. 基于卷积神经网络的互联网短文本分类方法[J]. 计算机与现代化(4): 4.
- 黄磊, 杜昌顺, 2017. 基于递归神经网络的文本分类研究[J]. 北京化工大学学报: 自然科学版, 44(1): 7.
- 李静梅, 孙丽华, 张巧荣, 张春生, 2003. 一种文本处理中的朴素贝叶斯分类器[J]. 哈尔滨工程大学学报, 24(1): 4.
- 林杰, 康慧琳, 2020. 基于注意力机制的 LSTM 股价趋势预测研究[J]. 上海管理科学, 42(1): 7.
- 刘春磊, 梁瑞斯, 邸元浩, 2019. 基于 TFIDF 和梯度提升决策树的短文本分类研究[J]. 科技风(24): 1.
- 刘宁宁, 张量, 2020. 基于 PCA-GRU 的股票指数预测模型的研究[J]. 计算机应用研究(S01): 3.
- 刘晓亮, 丁世飞, 朱红, 张力文, 2010. SVM 用于文本分类的适用性[J]. 计算机工程与科学, 32(6): 106-108.
- 裴曼如, 张立文, 2020. 基于投资者情绪和深度学习的股票价格趋势预测研究[J]. 金融发展, 5(01): 78-97.
- 施聪莺, 徐朝军, 杨晓江, 2009. TFIDF 算法研究综述[J]. 计算机应用, 29(B06): 5.

- 宿成建, 2006. 中国股市价格和波动性的非线性行为实证研究[J]. 数学的实践与认识, 36(2): 8.
- 汪昌云, 武佳薇, 2015. 媒体语气、投资者情绪与 IPO 定价[J]. 金融研究(9): 174-189.
- 王承炜, 吴冲锋, 2002. 中国股市价格—交易量的线性及非线性因果关系研究[J]. 管理科学学报, 5(4): 6.
- 王美今, 孙建军, 2004. 中国股市收益, 收益波动与投资者情绪[J]. 经济研究(10): 75-83.
- 王晓丹, 尚维, 汪寿阳, 2019. 互联网新闻媒体报道对我国股市的影响分析[J]. (2019-12): 3038-3047.
- 杨健, 汪海航, 2010. 基于隐马尔可夫模型的文本分类算法[J]. 计算机应用, 30(9): 2348-2350.
- 易志高, 茅宁, 2009. 中国股市投资者情绪测量研究:CICSI 的构建[J]. 金融研究(11): 11.
- 张成功, 刘培玉, 朱振方, 方明, 2012. 一种基于极性词典的情感分析方法[J]. 山东大学学报 (理学版)(03): 50-53.
- 张华伟, 甘丽新, 江西师范大学计算机信息工程学院江西南昌, 2006. 基于随机森林的文本分类模型研究[J]. 山东大学学报: 理学版, 41(3): 5-9.
- 张华鑫, 庞建刚, 2015. 基于 SVM 和 KNN 的文本分类研究[J]. 现代情报, 35(5): 5.
- 赵红蕊, 薛雷, 2021. 基于 LSTM-CNN-CBAM 模型的股票预测研究[J]. 计算机工程与应用, 57(3): 5.
- 周咏梅, 杨佳能, 阳爱民, 2013. 面向文本情感分析的中文情感词典构建方法[J]. 山东大学学报: 工学版, 43(6): 7.

致谢

时光荏苒，三年研究生生活就要告一段落了，感谢在财大遇到的每一个优秀的老师与同学，我相信在以后的人生道路上，他们榜样的力量会不断激励着我前进。

在本次论文的写作过程中，我特别地要感谢我的导师曾老师，他学识渊博，待人随和，在我论文的写作过程中帮我开拓研究思路，耐心点拨，使我受益匪浅，在生活中遇到困难的时候给予我关心与开导，更像是一位心灵导师。论文写作这期间，我进行了无数次的尝试，这期间我收获的不仅是知识与技能，更多的是心灵的洗涤，这对我今后的生活与工作都有很大的意义。

回想几年前我想要再次踏进校园的决心，内心依旧感激自己当初的决定，感谢爸爸妈妈一直以来的鼓励与支持，感谢他们在我背后付出的点点滴滴，给我充足的成长空间。在这里，想要感谢的人实在是太多了，在这个特殊时期，我还要感谢我的哥哥，在我最焦虑难熬的日子，他会经常逗我开心，给予我包容与正能量，同时感谢学院的培养以及学习生涯中给予帮助过的朋友及同学们！

个人简历

基本情况

杨玉华, 女, 河南省新乡市人, 1993 年 9 月出生.

教育状况

2012 年 9 月至 2016 年 7 月, 安阳师范学院数学学院, 本科, 专业: 数学与应用数学;

2019 年 9 月至 2022 年 6 月, 上海财经大学数学学院, 硕士研究生, 专业: 概率论与数理金融。

研究兴趣

金融工程

联系方式

E-mail: yangyuhua812@163.com