



学校代码: 10272

学 号: 2019213923

上海财经大学

SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS

硕士学位论文

MASTER DISSERTATION

论文题目	基于股评情感与货币政策强度 指数的股市预测能力分析
作者姓名	周上然
院(系所)	信息管理与工程学院
专 业	工程管理硕士
指导教师	谢美萍
完成日期	2022. 5

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品成果。对本人的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名：周上然 日期：2022 年 5 月 10 日

学位论文版权使用授权书

(硕士学位论文用)

本人完全了解上海财经大学关于收集、保存、使用学位论文的规定，即：按照有关要求提交学位论文的印刷本和电子版本。上海财经大学有权保留并向国家有关部门或机构送交本论文的复印件和扫描件，允许论文被查阅和借阅。本人授权上海财经大学可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

论文作者签名：周上然

日期：2022 年 5 月 10 日

导师签名：谢永华

日期：2022 年 5 月 10 日

摘要

随着数据处理技术的飞速发展，自然语言处理（NLP）技术在文本挖掘和智能分析领域应用越来越广泛，并且与计量金融相结合，延伸扩展到金融领域。本文基于 python 语言，收集相关文本，扩充构建了金融领域、货币领域词典；建立了货币政策强度、上证指数月收益率及个股股评情感序列；基于计量金融软件 Eviews 和 R 语言，分析了货币政策和股评情感对股市收益率的影响，并评价了相关模型的预测能力；主要完成以下内容：

本文收集并阅读了近 5 年的关于文本挖掘、投资情绪、货币政策与股市关系的文献，梳理了相关研究方法，提出了具体的研究思路与方法；利用 Python 语言编写程序，爬取了部分股评，并实证分析了 SnowNLP、基于词典匹配分析、机器学习、深度学习等文本情感分类方法的优劣；其中深度学习的识别准确率最高，可以达到 88% 以上，其次是基于词典匹配分析方法，识别准确率达到 81%，但是深度学习需要一定数量和满足一定条件的标注样本；爬取并整理了 30 多万字的股评，利用 jieba 工具进行分词，基于词频、tf-idf、词向量等模型，选取专业代表性、时效性较强的词汇或者短语作为种子词，以种子词为样本，利用 wordexpansion 自动构建大规模的金融领域词典；结合股票涨跌幅度和句法结构，更新了部分词汇的权重，补充到原有的 CFSD 金融词典中。

其次，本文以央行发布的季度货币政策执行报告和月度的专业货币政策评论文献作为样本，进行分词处理，基于 tf-idf 模型提取出关键短语，构建了货币领域词典，并通过统计近两年来每个短语每月出现的次数，乘以该月对应的权重，计算该短语的强度值；利用构建的金融领域、货币领域词典，建立了货币政策强度、上证股评情感序列及个股股评情感序列；上证指数受宏观政策的影响较大，专业机构对宏观政策的理解较为一致，因此上证指数评论强度序列能较好地体现指数月度收益率；基于 Eviews 软件，建立多变量的 VAR 模型，分析了上证指数月收益率和货币政策强度之间的关系，发现广义货币 M2 增长的变化构成了对上证指数变动的格兰杰因果关系；选取样本内数据进行预测能力检验，发现多变量的 VAR 模型对上证指数月度收益率趋势预测较为精准。

最后，基于多变量的 VAR 模型分析了个股日收益率与发帖数量、股评情感

强度和成交量之间的关系，发现个股日收益率变化构成了对发帖数量、股评情感强度和成交量变动的格兰杰因果关系；选取样本内数据进行预测能力检验，发现多变量的 VAR 模型对个股日收益率趋势和情感强度预测精度不高，预测值的震荡幅度偏大；对成交量和发帖数量的变化趋势预测较为精准；基于改进的 Garch 模型，将个股股评情感序列作为外生变量引入到方差方程，对比传统的 Garch 模型，发现方差方程引入情感序列后，条件方差的峰值略微有所增大，但是不是很明显，预测的平均绝对误差率由 0.018799 降至 0.01879；基于 R 语言，考虑货币政策、股评情绪因素的影响，分别建立了单因素、多因素的 GARCH-MIDAS 模型，分析了货币政策、股评情感对上证指数月收益率和个股收益率的影响；预测了 2021 年 4 月上证指数月收益率和次日个股的收益率。

关键词：情感分类 领域词典 货币政策 VAR 模型 Garch-Midas 模型

Abstract

With the rapid development of data processing technology, the application of NLP technology in the field of text mining and intelligent analysis is more and more widely, combining with quantitative finance, extended to the financial field. This paper is based on Python, collects relevant texts, enlarges the dictionary of finance and constructs the dictionary of monetary policy. Constructing the series of monetary policy, A shares market monthly return rate and stock commentaries strength; Based on the software of Eviews and R, this paper analyzes the impact of monetary policy and sentiment strength on stock market return rate, evaluates the predictive ability of models. This papers mainly deals with the following contents:

Firstly collecting and read literatures related to text mining, investor sentiment, monetary policy and stock market returns in recent five years, review the research methods, and put forward research ideas and methods. Based on Python writing programs to crawl some stock commentaries, empirically analyze the advantages and disadvantages of Snownlp, dictionary-based matching analysis, machine learning and deep learning for emotion classification; the recognition accuracy of deep learning is the highest, which can over 88%, following by the dictionary matching analysis method, which can up to 81%, but the deep learning method needs a certain number of labeled samples which meet certain conditions. Crawling and sort out more than 300,000 words of stock commentaries, using jieba to decompose words, taking professional representative and time-efficient words or phrases as seed words based on word frequency, TF-IDF, word vector and other models. Taking seed words as samples, wordexpansion was used to automatically build a large-scale domain dictionary of finance. The weights of some words which are added to the original CFSD financial dictionary are updated according to the amplitude of stock rise or fall and the syntax structure.

Secondly taking the central bank's monetary policy report and monthly monetary policy review literature as sample, making the decomposition of words based on the TF-IDF to extract the key phrases and build the dictionary of monetary

field. Using the number of each phrase in each month of the past two years multiply by the corresponding weights of the month, calculating the weights of phrase. Using the constructed dictionary in the financial field and the monetary field, the intensity of monetary policy, the sentiment series of market stock and the sentiment series of stock are established; monthly market return rate is greatly affected by macro policies, professional institutions have a relatively consistent understanding of macro policies, Therefore a-share index comment intensity series can reflect monthly market return rate. Based on Eviews, VAR model is established to analyze the relationship between the monthly market return rate and the intensity of monetary policy. It is found that the change of M2 growth constitutes the Granger causality relationship to the change of monthly market return rate. Testing the prediction ability of in-sample data, it is found that the VAR model is more accurate to forecast the monthly trend of monthly market return rate.

Lastly based on the VAR model, analyzing the relationship between the daily return rate of a stock, the number of posts, sentiment strength of stock comments and trading volume is analyzed. It is found that the change of daily return rate of a stock constitutes the Granger causality relationship between the number of posts, sentiment strength of stock comments and trading volume. It is found that the prediction accuracy of the multi-variable VAR model is not accurate for the daily return trend and emotional intensity of individual stocks, the amplitude of the predicted value is grow large. The prediction of changing trend of trading volume and Posting quantity is accurate. Based on the improved Garch model, the sentiment sequence of individual stock comments was involved into the variance equation as an exogenous variable. Compared with the traditional Garch model, it was found that the peak value of conditional variance increased slightly with the sentiment sequence was involved into the variance equation, but it was not obvious. The average absolute error rate of prediction decreased from 0.018799 to 0.01879. Based on R, the single-factor and multi-factor GARCH-MIDAS models are established to analyze the effects of monetary policy and stock commentaries sentiment on monthly market return rate and individual stock return rate. The monthly return rate of a-share market in April 2021 and the return rate of individual stocks in the next

day are predicted.

Keywords: emotion classification domain dictionary monetary policy
VAR model Garch-Midas model

上海财经大学学术数据总库Scholars Hub at SUFE [https://scholars.sufe.edu.cn/]

目录

第一章 引言	1
第一节 选题的背景、理论意义与实用价值	1
一、选题的背景	1
二、理论意义	2
三、实用价值	3
第二节 国内外研究现状与发展趋势	4
一、国内外研究的现状	4
二、国内研究综述	5
三、国外研究综述	7
第三节 相关研究方法	8
第四节 存在的问题	9
第五节 本文研究的基本思路与方法	10
第二章 研究方法 with 模型	14
第一节 文本情感分析方法	14
第二节 文本统计分析模型	19
第三节 计量经济模型	20
第四节 本章小结	21
第三章 文本情感识别方法实证分析	22
第一节 爬取股评	22
一、收集股评	22
二、文本清洗	23
第二节 分析结果评价	23
一、Snowlp 方法精度分析	24
二、词典匹配分析法精度分析	24

三、机器学习法精度分析	24
四、深度学习方法精度分析	25
第三节 本章小结	29
第四章 构建与扩充领域词典	30
第一节 金融领域词典构建基本思路	30
第二节 收集股评与分词	31
第三节 扩充更新金融词典	32
一、选择特征词汇	32
二、自动扩充词汇	35
第四节 词汇权重赋值	39
一、种子词权重赋值	39
二、程度副词权重	42
三、基于句法结构的词汇权重更新	44
第五节 构建货币政策领域词典	46
一、文本收集与分词	47
二、确定短语情感极性	47
三、短语权重赋值	53
第六节 本章小结	57
第五章 序列分析及预测评价	58
第一节 构建货币政策强度序列	58
第二节 构建上证指数月收益率序列	62
第三节 个股月收益率序列	64
第四节 基于 VAR 模型的上证指数月收益率分析	65
一、序列统计分析	65
二、建立 VAR 方程	65
第五节 基于 3 变量 VAR 模型预测能力分析	73
一、个股收益率预测能力分析	73

目录

二、上证指数收益率预测能力分析.....	73
三、广义货币供给强度预测能力分析.....	74
第六节 基于 VAR 模型的个股收益率分析.....	75
第七节 基于 4 变量 VAR 模型的预测能力分析.....	86
第八节 本章小结.....	88
第六章 基于 Garch 方程个股收益率分析及预测评价.....	90
第一节 建立日收益率 Garch 方程.....	90
第二节 改进 Garch 方程.....	93
第三节 本章小结.....	95
第七章 基于混频方程收益率分析及预测能力评价.....	96
第一节 GARCH-MIDAS 方程.....	96
第二节 基于混频模型的上证指数预测.....	97
第三节 基于货币政策的个股收益率分析.....	100
第四节 基于 5 日情感强度的个股收益率分析.....	101
第五节 货币政策和情感强度联合作用下个股收益率预测.....	103
第六节 货币政策对热点产业的影响.....	106
第七节 本章小结.....	107
第八章 总结.....	108
第一节 论文总结与创新.....	108
第二节 预测能力分析.....	109
第三节 展望.....	109
参考文献.....	111
致谢.....	115

第一章 引言

第一节 选题的背景、理论意义与实用价值

一、选题的背景

我国的资本市场成立仅有 30 多年，虽然取得了一些成就，但仍然处于开始阶段，并且有一些明显的问题，比如投资者的整体素质和投资技能有待提升，但是最重要也是最独特的问题便是我国的投资者主体结构的问题，中小投资者（散户）仍然占据主导地位。这和欧美等发达国家截然相反，其主体结构主要是机构投资者，主要优点包括投资专业化，行为理性规范化，资产配置合理化等。个体投资者对比专业机构投资者，无论在专业技能还是时间精力等方面都远不如机构投资者，并且在交易过程中，个体投资者具备强烈的投机冲动，显著的“羊群效应”，更容易受到外界和自身情绪的波动影响，进而影响股票的买卖行为。

现实生活中，由于信息的非对称性和认知偏差等多种因素，大量的散户投资者是非理性的，经常出现价格和价值发生严重偏离的情况，这些现象并不能从传统金融学理论中寻找出答案。所以发展并形成了行为金融学这门学科。行为金融是在金融学理论的基础上加入投资者的行为、心理等因素，更加注重分析散户投资者所体现的各种行为方面的偏差，并将投资者情绪在证券交易中的作用大大提高，其认为股市交易价格变动不仅同内在价值有关，也与投资者的情绪变化有一定的关系。货币政策与股票市场之间的联系及其传导机制一直都是相关学者在分析股市行情时要研究的重要内容。货币政策与股票市场的联系紧密程度可以反映出宏观经济环境与政府的管控方向；在很多情况下，政府的重大货币政策和经济决策，都会对股票市场产生很大的影响。

一方面投资对象要受到货币供给的影响；另一方面股票本身价值也直接受到宏观经济因素的左右。国家的货币供给情况、利率调整、准备金率变化等都将影响股票价格的沉浮。利率调整不仅可以影响国内的资金流动性，也会增加外国资本对国内资金流动性的影响；比如利率上升也可以带动汇率上升。因此利息上升会促使本国货币的升值，从而外国投资者会以各种方式将资金输入到

中国股市，增大了股市中的资金供给，往往造成股价短期内的上涨，一旦资金从股市中抽离，又会引起股价较大幅度的下跌，加剧了股市震荡。存款准备金率是中央银行为保证金融机构的清偿能力及资金清算需要而向金融机构收存的，存款准备金率的调整将直接影响金融机构的可贷资金量，进而间接影响股市。当存款准备金率上调时，金融机构可贷资金减少，投资者及上市公司能从金融机构获得的贷款金额减少，致使投资者投向股市的资金及上市公司再生产资金减少，进而导致股市下跌；反之，当存款准备金率下调时，金融机构可贷资金增加，投资者及上市公司能从金融机构获得的贷款金额增多，致使投资者投向股市的资金及上市公司再生产资金增加，进而导致股市上升。

如果央行提高再贴现率，金融机构贴现成本增加；这就会使金融机构减少向人民银行再贴现，导致货币供给量减少，股市就会走弱。各类投资者也就不愿意进入股市；此外公开市场业务也能对股票产生一定影响。人民银行通过买卖有价证券来控制货币数量，可以调整资金流向。市场需要更多货币时，央行可以买进有价证券，导致市场货币总量增加，资金充足股价就会向好。当央行卖出有价证券时，市场货币减少。投资者预期改变，结果会使股价走弱。调整存款准备金率会改变银行的贷款总额，金融机构的贷款能力会受到较大限制，对货币流通也会造成较大影响，当存款准备金率上升时，各类机构投资规模扩大，所以自身储备金额将会减少，因此借贷业务会缩减，股票市场价格将会下跌。同理，当存款准备金减少，可支配金额会相应增加，货币供应量将会随之上升，所以股市的热度也会逐渐上升。

伴随着大数据、人工智能技术、互联网+、云计算和电子商务的高速发展，源于互联网社会对文本信息中意见挖掘的迫切需求，自然语言处理（NLP）中的文本序列分析与情感推断成为该领域的重要发展方向之一，通过自然语言处理技术和人工智能（AI）技术，实现对人们带情感倾向的评论的获取、识别、舆情监督和响应以及信息反馈。

二、理论意义

金融市场是一个复杂的非线性系统，仅仅依赖于历史价格数据进行预测始终无法获得进一步的提高。而股票价格波动很大程度受到金融市场的相关信息的影响，这部分信息包括投资者关注与心理、政策变动等。关于股市相关信息

的研究也逐渐受到人们的关注，然而有效的度量和提取预测信息一直是这方面研究的难点。

投资者情绪和股票收益的影响关系包含多种方面，主要表现在投资者的情绪变动对于“非理性”行为的传导机制和效应，首先，投资者个体进行股票交易时，常常由于自身的“非理性”的行为对实际操作产生影响。其次，我国的股市本身充斥着很多无法用传统金融学所解释的金融异象，包括股票溢价之谜等。因此，基于文本序列的情感分析方法，研究散户情绪和货币政策对股市行情的影响，具有重要的社会意义和商业价值，利于维护金融市场稳定，也为监管者制定相应政策措施都提供了很有价值的参考意见。

利率的改变会使得货币市场及资本市场中的金融工具价格发生变化，从而引起投资者重新选择投资组合产品，形成资产组合效应。利率变化会使存款的相对收益和债券的相对收益发生变化。当利率上涨，银行的储蓄和债券收益会随之上升。投资者会选择投资到相对股票市场而言更为安全的储蓄和债券，减少股票市场中的资金供给，从而减少股票市场中的需求，当需求减少，供给不变，其价格也会下跌。反之，价格上升。总之，当利率变化时，投资者会重新分配投资组合，从而影响到股票市场中的资金供给，进而影响到股票市场中的供给需求，最终股票价格会发生变化。

三、实用价值

我国的资本市场目前尚未发展完善，理性投资者相对较少，中小投资者居多，小散投资者会出现情绪性操作，理性投资者专业知识水平较高，掌握的信息也相对较多，善于捕捉宏观政策方向，甚至可以提前获得内幕消息，其情绪的变化能够先于非理性投资者，属于“先知先觉”，往往在非理性投资者意识到利好之前，完成吸筹，掌握大多数的筹码，通过自拉自唱等手段，营造一片向好的市场氛围，也会触动非理性投资者的敏感神经，带动非理性投资者的情绪高涨，从而进一步推动股价上涨。

股评中的情感信息就构成了提取投资情绪的样本。投资者对预期涨跌的分歧度也会对股票的交易产生影响，如果投资者对股价的预期较为一致，则交易的活跃度则不高，如果大多数投资者对股票预期看好，持有者当期会惜售，流通性不会太好，购买者可能要以较高价才能成交；反之对股票预期看跌，购买

者的意愿不会太强，持有者可能要“忍痛割肉”，也会影响流动性。

如果投资者的预期存在较大的分歧且持有方看跌、购买方看涨的情况，交易量会增大，流动性增强。例如：股价运行的基本形态主要有 3 种：上涨、横盘和下跌；不同的投资者对同一种形态的理解是不一样的，例如：有人认为“横久必跌”，也有人认为“横有多长、竖有多高”，这两种看法代表了完全不同的方向，一个看跌，一个看涨；虽然同时存在看涨和看跌的人，但往往也是因为分歧，才会有股票的成交，看涨人气高涨时，将会踊跃进场，会带动成交量；看跌情绪弥漫时，将会纷纷离场，成交量也会萎缩。股票评论数据不同于一般的文本，其既具有其作为金融信息的领域性，又夹杂着网络文本的随意性。因此，从海量的评论文本中提取有效的情绪信息，并对信息进行处理和分析是一项理论与实践相结合的工作。利用文本挖掘方法研究网络媒体中的投资者情绪与股票市场价格的关系，不仅能探索股票定价的新特征，也能为维护金融市场稳定提供依据。

从政府层面来看，如果当局的货币政策是稳健灵活的，当货币政策由稳中趋紧到稳中趋松时，虽然货币供应量的变化幅度相对较大，但是在稳健的大前提下，货币供应量的变化总体平稳可控且增量资金更具有灵活性、针对性，因此，不会有大量资金涌入或者抽离股票市场，可以支撑股票市场在稳健中发展。股票价格的分析与预测不仅可以使政府部门及时掌握、调控和引导股票市场的发展，保证宏观经济健康平稳地运行，也可以为投资者的金融决策提供支持，降低潜在的投资风险。但由于股票市场受到投资者情绪等多种因素的影响，其波动具有明显不确定性和非线性。因此，精准预测股价是一项既有理论价值，又有现实意义的工作。而从技术方法来说，通过历史数据预测股票走势的研究屡见不鲜，而提取股票评论中的投资者情绪、构建货币政策领域词典和政策强度指数，融合入预测模型则是一项既富挑战性又具有实际价值的研究。这其中涉及到的，无论是在对外部信息的使用，还是在金融时序模型的改进方面，都具有较强的学术价值。

第二节 国内外研究现状与发展趋势

一、国内外研究的现状

国外对于投资者情绪与股票收益的研究较早也较多。早期投资者情绪研究采取调查问卷或者利用间接经济指标的方式,证明市场收益率与投资者情绪具有相关性。由于网络媒体发布信息量大、及时且受众广,投资者情绪的深入挖掘进而逐步扩展到网络平台。加之近二十年间,自然语言处理技术突破瓶颈并快速发展,逐步解决了文本情感分析等相关技术难题。

目前,我国学者研究股票论坛投资者情绪对股市的影响较多,对于投资者的情绪很多都是结合了国外投资者指标的构建后进行了改良,找到了适合中国投资者的情绪指标;而对于官方证券媒体平台在该方面的研究较为缺乏,且较少文献关注在官方媒体新闻和投资者互动平台下文本信息揭示对股市效率的影响。中国的股票市场尚未成熟,仍然处于健全和规范的过程中。股市里大量存在着非理性的投机行为。股价并不能反映其真实的价值,甚至背道而驰。而技术分析法侧重对股票价格历史趋势进行研究,其主要手段为指标选择和图表分析等。技术分析法通过研究历史数据中特定指标与股票价格的关联关系来预测股票未来的涨跌,该方法过分依赖经验判断,股票分析结果的可靠性难以得到保证。在对股票预测模型的研究中,基于传统统计理论的时序预测模型是一类使用最为频繁的预测方法。

二、国内研究综述

朱嫣岚等(2006)利用 HowNet 模型,基于语义相似度的方法,结合语义相关场的方法,进行了语义倾向计算,识别的正确率可以达到 80%以上,具有一定的实践应用价值;唐慧丰等(2007)的论文研究表明:采用 BiGrams 特征表示方法、信息增益特征选择方法和 SVM 分类方法,在训练集足够大的情况下,选择适当数量特征,取得的分类效果较好;柳位平等(2009)收集了极具代表性的中文情感词,构建了中文基础情感词典,为特定领域情感词识别提供核心子集,实证分析表明该方法识别和扩充情感词集的效果较好;王素格等(2009)提出了基于相近含义词汇的情感识别方法,实证分析表明,这种判别方法优于单纯采用目标词与基准词的词汇情感倾向判别方法;李方涛(2011)以产品评论为主,研究了情感分析中的分类以及情感数据可信度问题;夏火松等(2011)基于支持向量机(SVM)方法,对不同的特征选择方法和权重计算方法的组合进行情感分类,并评价了分类的效果;谢丽星(2011)利用 SVM 对中文微博进行情感分类,

准确率最高达到 67.283%；徐冰（2012）利用统计学习方法，通过关键词中心聚类和支持向量机，对不同情感粒度的文本进行了情感分类。

赖凯声等(2013、2014)使用协整分析方法发现网络情绪指数与当日及下一个交易日的上证指数具有显著的均衡关系，验证了微博情绪与股票市场间的相关关系；樊小超（2014）通过加入了词频信息、文档频率信息以及类别相关度因子等统计特征，提出了一种基于改进的互信息特征加权方法，实证分析结果表明，这种分类方法的性能较为优越；黄润鹏等(2015)利用 ROST CM 内容挖掘工具对微博情绪进行分析，得 7 个类别的情绪，并使用支持向量回归（SVR）对股票价格进行预测。鲁晓鹏（2016）将互联网数据作为数据源量化投资者情绪，研究其对股市收益的影响；张贵生（2016）分析了相关单变量金融时序数据和高维金融时序面板数据；周广（2016）根据关联性分析的结果，利用微博挖掘结果对金融时间序列进行分析和预测，并通过基于预测结果，实现自动交易策略，验证了微博内容挖掘结果对于金融时间序列预测的效果；陈晓红等(2016)结合投资者情绪与百度指数构建回归模型，证明了搜索指数有助于提高股票市场变量预测的精度。

段江娇等(2017)构建了股票论坛关注度、投资者情绪一致性等指标，并结合分析师的评级数据对股票收益进行分析，其结果表明：股票收益受到网络论坛关注和情绪影响，而股票交易量受到情绪一致性影响；赵妍妍等(2017)利用点互信息(PMI)衡量对应情感倾向的相关性分数，并借此来构建大规模情感词典；项辛怡（2018）的研究结果显示：投资者情绪对股票收益产生负向影响，并在牛市阶段和熊市阶段各具特点：投资者情绪对股票收益的影响在牛市比熊市更为强烈；王聪等（2018）的研究结果表明：上证指数涨跌幅与投资者情感之间同时存在线性与非线性关系，且日区间联动幅度较大；构建模型时应综合考虑两者关系和投资者情感的异方差性；印如意（2018）探索了深度学习与大数据在金融风险领域的实践以及证明了情绪对证券市场的影响并提供测量影响的方法；杨永伟（2018）研究中国权威媒体发布的新闻后发现，当新闻中蕴含强烈的积极情绪时，会使得股价大幅度上涨；郑国杰（2019）研究结果表明：互联网投资者情绪对于股票市场的波动具有指导意义；吴杰胜等（2019）基于多部情感词典，结合规则集，对微博情感进行了分析。实证分析表明这种方法在微博情感分析领域效果较好；戴德宝等（2019）使用机器学习的方法对文本进行分析，结果也发现投资者情绪指标对于股价走势有一定的预测作用。

杨科等（2013）基于 C-TMPV 理论估计已实现波动率的跳跃成分；王维国等（2016）改进了混频回归联合预测模型，计算结果表明：非限制混频数据回归预测模型的预测精度及拟合效果较好；陈其安等（2017）研究表明：中国股票市场价格波动性与投资者情绪正相关，与市场利率负相关，投资者情绪会弱化了货币政策的调控作用；景芳芳（2017）发现单因素 GARCH-MIDAS 模型和多因素 GARCH-MIDAS 模型均有很强的预测能力；石强等（2019）利用 GARCH-MIDAS 模型较好地描述了宏观经济与股市波动之间的关系，其结果表明应对金融危机所采取的货币政策产生的长期影响远大于短期影响等。姚前（2019）通过实证表明：中国股市的“政策效应”现象是真实存在的，GARCH-MIDAS 模型能够很好地捕捉到政策因素对股市波动的长期影响。

三、国外研究综述

Woodford 等（2012）的研究表明：部分央行会直接发布利率的未来预期路径，一定程度上表明如何根据形势变化做出合理的政策反应；Baker 等（2016）关于政策不确定性的测量中，通过报纸报道和政府声明进行分类计数，进行量化；Hansen 等（2016）从经济运行现状和前瞻指引两种维度来测度沟通内容，发现关于利率的前瞻性指引较为重要；Picaul（2017）等使用文本分析方法，将欧洲央行的沟通内容进行定性，构建了相应的领域词典，基于此点，对央行沟通内容进行量化分析；Hansen 等（2018）基于已有词典进行关键词的计数，对沟通内容量化，建立了情绪指标。

Chen, Clements（2007）探讨了货币政策公告与 VIX 指数所捕捉的标准普尔 500 指数隐含波动率之间的关系，研究发现隐含波动率在联邦公开市场委员会会议当天平均下跌 2%，但在会议之前或之后的日子里没有发现重大变动；Engle、Ghysels（2008）又尝试结合 GARCH 模型与 MIDAS 模型，首次采用 GARCH-MIDAS 模型，将条件波动率分解为长期成分和短期成分，用低频已实现波动率和宏观经济变量来解释长期成分，取得了很好的效果；Iryna, Matt（2018）研究了英国、美国和欧元区的市场，发现货币政策不确定性对波动率具有显著影响，且货币政策不确定性能改善波动率预测模型的精度；Z. McGur 等（2019）通过研究新闻媒体中的文本信息发现投资者情绪对异常股票收益具有积极而且显著的影响，这种影响在规模小，知名度低的企业中尤为显著。Timothy 等（2019）

发现在投资者情绪高涨时期, 套利受到更大的限制, 并且由于高涨情绪的驱动, 股票之间的联动现象有所增加。Ahmed (2019) 通过事件研究法发现在投资者情绪高涨期间, 美国市场对异常收益事件做出了更有利的反应。Husted、Rogers 等 (2019) 发现过高的货币政策不确定性会对金融市场造成持续的负面影响; Engle、Rangel (2019) 尝试将宏观经济变量加入到 Spline-GARCH 中, 结果表明 GDP 增长率、短期利率和通货膨胀率对上述国家的股市波动率有显著影响。

第三节 相关研究方法

目前文本情感分析领域的重要目标是如何利用语言分析技术以及序列数据分析技术高效地提取归纳出文本序列数据中大量缺乏数据规律的重要特征信息, 具体来说就是做到快速高效地对不同语言的文献进行词频统计, 获取高频词, 从而体现相关文献资料中的主体情感。涉及到的主要分析工具: Python 软件, 其应用领域主要包括了数据挖掘、机器学习、神经网络、自然语言处理等, 尤其在自然语言分析方面有着高效、精确的优点, 因此在文本挖掘领域的应用最为广泛。总的来说, 基于文本挖掘的情绪分析一般可以归纳为 3 类方法: 第 1 类是基于情感词典的文本分析; 第 2 类是基于机器学习的文本分析; 第 3 类是基于深度学习的文本分析。

一、情感词典匹配分析

基于情感词典分析的方法主要是构建情感词典, 结合中文语言特征, 设定相关的规则。将需要情感识别与分析的文本进行分词, 然后将文本中的词语与情感词典进行匹配, 汇总积极词汇和消极词汇的分值。根据分值, 判断文本情感倾向。采用基于情感词典的方法重要的因素是构造一个尽可能完备、覆盖领域广的情感词典。构造情感词典的方法可以分为人工标注构造和自动分类构造。

二、机器学习

基于机器学习的方法大多数是将情感分析问题转化为分类问题, 对文本情感分类, 将文本情感分为两类: 积极和消极。机器学习方法训练的具体步骤: 首先对数据集进行人工标注, 将数据集分为正面和负面两类, 提取情感特征,

然后用训练数据集进行训练，构造情感分类器，最后用分类器对待分类的文本进行情感倾向性分析。目前应用比较广泛的机器学习方法：朴素贝叶斯法、随机森林树、支持向量机法。

三、深度学习

深度学习在文本情感分析的应用研究越来越热门。国内外学者广泛采用深度学习方法来解决情感分类问题。深度学习模型通常是多层结构的神经网络。比较成熟的深度神经网络模型有三种：长短期记忆网络 LSTM、卷积神经网络 CNN 和循环神经网络 RNN。其中 LSTM、RNN 适用于序列处理，CNN 适用于图像检测与识别。深度学习方法的应用实现可依据 Python 软件中的 Keras 库，主要的操作步骤：选择训练数据集。定义各层的网络参数，将输入对应到输出目标。设置训练过程：设定损失函数，选择优化器和设置监控指标。调用模型的 fit 方法在训练数据上进行迭代。

第四节 存在的问题

目前已有的大量研究成果是针对英文社交媒体与发达国家的金融市场相互关系的研究，中国作为新兴转型的资本市场，在投资者群体构成、货币政策等诸多方面具有独特性，国类外市场机制不同，所以不能照搬国外的研究成果。另外，相比于国外，国内研究关于情感分析或文本挖掘技术分析网络情绪与股票收益相互关系的研究还十分有限。情感分析是从股票文本中获取投资者情绪的主要手段，情感分析的准确性也是后续分析股票价格波动的基础。不同的情感分析方法的准确率是不一样的，因此需要分析各种方法的准确率，选择较高准确率的情感分析方法。

目前，在金融领域中直接套用现成的情感分析软件和外部词典资源难以取得很好的效果。从各类研究结果可以得出这样的结论，金融文本情感分析成功与否的一个最重要的因素是情感词典的选择，而不同领域之间的情感词相差甚远。同时，网络的语言环境变化频繁，代表股票市场的情感词也在动态发生变化。因此，构造全面、准确的金融领域情感词典是必不可少的工作发展。

在时间序列模型方面，上述的部分研究的数据处理量较大，在建模前缺乏

相应的预处理与统计检验，并且少有研究将高效的组合预测模型应用于股票的预测问题，需要进一步分析在多因素条件下的股票波动规律。宏观的经济政策的颁布的周期较长，属于低频变量，而股票的波动率属于高频变量，传统的时序预测方法大多数要求变量与因变量的频率相同，需要在传统预测模型的基础上进行改进，引入混频分析方程，分析宏观低频变量对高频收益率波动的影响。

第五节 本文研究的基本思路与方法

本文研究的基本思路包括两个方面：文本情感分析与时间序列预测。文本情感分析是指将文本看做序列模型，首先对序列进行清洗等预处理，然后进行分析、推理、总结和归纳的一个综合过程。时间序列是将依据时间顺序计算出的数值组成序列。金融时间序列预测是通过收集和分析过去的数值序列，对数据之间的潜在关系进行建模，从而依据模型实现对变量将来取值的预测。金融时间序列的模型有回归分析、条件异方差、向量自回归等。

一、研究的基本思路

为了提高论文研究的效率和针对性，对研究对象进行了简化，分别选择了上证指数和方正科技作为研究对象，主要原因：上证指数体现了上证交易所股票的总体走势；方正科技属于集成电路、高校改革板块，在 2019-2020 年是热点题材股票，两者具有一定的代表性；股评文本则选择专业机构对上证指数的月评论以及东方财富股吧里的个股股评，具体的研究思路如下：

- 1、首先对各类文本情感分析方法进行实证分析，比较各类情感分析方法的正确率，检验词典匹配情感分析方法的准确率是否达到实际使用要求。

- 2、利用网络爬虫技术，爬取在线股评，更新金融领域词典；并结合每日股票实际的涨跌幅度，对词汇进行情感强度赋值；基于更新的词典，计算每日评论的情感强度，构建股评情感强度指数，生成相应强度序列，作为外生变量引入 Garch 预测模型。

- 3、构建货币政策领域词典，基于词典计算分析货币政策的强度，构建政策强度指数，生成相应序列。

- 4、改进时间序列预测模型，引入低频因子的强度序列，构建 GARCH-MIDAS

模型，预测股市行情。

5、对比和分析预测结果，评价模型的预测能力。




图 1.1 本文研究的基本思路

二、本文的研究方法

（一）文献研究法

本文将就股评情感分析、货币政策等相关方面的期刊、著作、论文进行查

阅整理研究，从中全面并系统地了解本次论文的研究状况，为分析股评情感、货币政策等因素对股市行情的影响提供写作思路。

（二）定量研究法

本文将通过构建股评情感强度指数，生成相应时间序列，作为外生变量，引入 Garch 模型方差方程，预测股市行情；构建 GARCH-MIDAS 模型，引入股评情感强度和货币政策强度指数低频时间序列，分析该模型的股市行情预测效果。

（三）比较研究法

本文将通过比较预测结果、文献结果与实际结果，归纳特点，分析规律。

三、论文的创新性尝试

本文尝试创新以数据驱动股票分析的方法，是对文本智能分析、金融理论与实践方法的高度结合，借助 Eviews、Python、R 语言等数据分析工具，构建股评情感和货币政策强度指数序列，依托计量模型、机器学习和深度学习等研究成果，选取上证指数和一支具有代表性的热点股票，对其行情进行预测。

（一）更新扩展股评词典与构建股评情感强度指数

相比于传统的投资者情绪度量方法，利用互联网评论度量情绪具有更强的时效性与代表性。本文针对网络股评的特点，利用网络爬虫和改进情感分析技术，爬取最新的在线股评，提取最新的股评关键词语，更新扩展股评词典；其次，利用文本情感强度的分析方法，对不同的关键词语赋予不同的强度值，构建股评情感强度指数，生成相应的序列。

（二）构建货币政策领域词典与强度指数

本文尝试构建货币政策领域词典，选取货币政策中对股市影响较大的宏观经济变量，作为关键词，与货币政策领域词典进行匹配，并将文本情感极性和强度分析的方法应用于货币政策的评价中，构建强度指数，生成相应的序列。

（三）改进 Garch 模型

1、在传统 Garch 模型的基础上，利用股评情绪强度指数构成时间序列，作为外生变量引入方差方程中，分析股评情绪强度对个股收益率的影响。

2、基于 GARCH-MIDAS 方程,利用构建的季度货币政策强度序列,分析季度把货币政策强度对上证指数月收益率的影响,并预测了 2021 年 4 月的上证指数。

3、引入 5 日股评情绪强度和货币政策强度指数低频时间序列,构建 GARCH-MIDAS 模型,预测次日个股收益率。

四、研究难点与预期成果

(一) 研究难点

1、虽然文本情感分析的方法有很多,但是正确率却高低不一。因此需要熟练掌握各类情感分析方法,并将其进行实证分析,选择正确率较高的方法。

2、针对文本序列进行情感分析的难点在于文本序列通常会出现上下文信息缺失和用户语言规范性差等情况,此外网络新词汇的产生和大数据文本序列的出现,会使得基于文本情感分析变得更加复杂和难以处理。

3、传统的金融领域词典,只考虑了程度副词对情感强度的影响,并没有对词汇进行进一步的情感强度区分;此外需要基于货币政策的评价与执行报告,构建货币政策领域词典,并对相关词汇和短语赋予情感强度。

4、数据处理量较大,影响股市行情变化的因素较多,需要获取的数据量较大,构建预测模型的难度较大。

(二) 预期成果

本文预测取得以下成果:

1、更新扩展股评的情感词典,并对部分词汇进行了强度赋值;利用文本情感强度的分析方法,构建情感强度指数和时间序列。

2、引入文本情感极性和强度分析方法,构建货币政策领域词典、政策强度指数和强度指数序列。

3、基于 VAR 模型进一步分析了多变量条件下,各变量对收益率波动的影响;改进 Garch 模型,将股评情感强度指数序列作为外生变量,引入 Garch 模型的方差方程中,构建基于股评情感强度的股市预测模型,分析预测精度。

4、处理股评情感强度和货币政策强度指数序列,减少数据量,生成低频序列,构建混频数据的处理模型 GARCH-MIDAS 方程,分析模型的预测效果。

第二章 研究方法与模型

本文主要包括文本收集与分析、情感识别、词典构建、序列建立、序列回归分析及预测等部分；涉及到文本智能处理、机器学习、深度学习等方法，同时需要建立计量分析模型，具体包括回归模型、预测模型，分析和预测相关序列；同时也需要基于 Python、Eviews、R 语言等工具来实现上述方法和模型的具体应用。

第一节 文本情感分析方法

一、情感分类方法

（一）Snowlp

Snowlp 是一个 python 自带的工具库，可以直接处理中文文本，特点是交互性强，简单方便，高效实用；除了自带的一些训练好的字典，还可以添加自建的词典，但是对于一些非正规化的中文表述，识别的正确率不是很高。

（二）Scikit-learn

Scikit-learn 是基于 Python 软件的机器学习框架，可以利用其对文本进行智能处理，实现文本信息的情感分析，一般包含以下步骤：首先建立词袋模型，对自然语言文本进行向量化，计算未标注文本向量与已标注文本向量之间的相似度，通过相似度的大小，衡量判定未标注文本的情感倾向。

相比 Snowlp 而言，机器学习的方法精确度更高，因为 Snowlp 对规范的表达较为适用，但是由于中文语义表达的非线性，有时会出现较大的误差；而机器学习方法不会出现这种情况，适用的场景更加多样化，包括文本正负面情感分类。相比于词典匹配方法，机器学习方法对句法结构的处理简单。

使用机器学习进行情感分析，本质上也属于有监督的学习范畴，基于已知的情感标注，分类未标注的文本情感类别。这点与词典匹配有着本质的区别。词典匹配是直接计算文本中的情感词，得出它们的情感倾向分值。而机器学习

方法是先训练已标注情感极性的文本，获得一个情感分类器，计算情感极性的概率值，在此基础上实现情感二元分类，比如“这个文本的积极概率是 90%，消极概率是 10%”。

在文本情感分类中，一般从“词”这个层次来选择特征。例如：“优秀的小伙子，加油，今天红包靠你了”，其中“优秀”，“加油”，“红包”都是投资者对股票走势的评价词，可以将其作为文本情感分类的特征。

关于文本情感分类的特征选择，一般不会考虑所有的特征，会选择文本的部分特征作为分类的依据，即特征降维：减少文本的特征数量，主要有两个原因：一方面是特征数量减少了之后可以加快算法计算的速度，另一方面是用一定的方法选择信息量丰富的特征，可以减少噪音，有效提高分类的准确率。

目前机器学习方法主要包括朴素贝叶斯、随机森林树、支持向量机等三种方法。

1、朴素贝叶斯分类

朴素贝叶斯分类器是一个概率分类器，实质上就是结合了贝叶斯公式和条件独立假设，给定类别集合 $C=\{c_1, c_2, \dots, c_m\}$ ，给定一篇文档 d ，判定文档 d 最有可能属于哪个类。朴素贝叶斯的假设各个特征相互独立，在独立性假设的大前提下，减少了参数空间，简化了训练和预测的过程；即使各特征之间存在较强的相关性，特征之间的相关性可能在不同类别中均匀分布，不同特征的相关性可能相互抵消，因此，独立性假设会改变分类的后验概率大小，但不会改变其相对大小，所以不会影响分类结果。

2、随机森林树分类

随机森林树分类是多个决策树的集成学习，每个决策树用 bagging 的方法选数据集，并且在选择最佳属性划分的时候随机划分一些属性进行分类，比单个分类器效果更好，泛化能力更加强大。它首先构建很多决策树，然后将决策树的输出集成在一起。

3、支持向量机

支持向量机可以分析数据，识别模式，常用于二元分类和回归分析；优势主要是在于小样本，非线性及高维模式的识别；SVC 是支持向量机的分类算法，SVC 的惩罚参数 C 的默认值为 1， C 越大，对误分类的惩罚增大，趋向于对训练集全分对的情况，这样对训练集测试时正确率很高，但泛化能力弱。 C 值小，对误分类的惩罚减小，允许容错，泛化能力较强。

（三）基于词典匹配的情感识别

基于情感词典的文本情感分类规则比较简单机械。每个积极情感词语的权重 1。每个消极情感词语的权重-1。假定文本情感序列为线性模型。通过软件对文本进行分词，如果该词与词典中的词匹配，就记录其分值。此外，考虑词语前面有无否定词和程度副词，后面有无特殊标点。否定词会导致情感变化，程度副词会导致情感程度发生变化。问号和感叹号也会加重情感程度。根据加总分值的正负，来判断文本的情感，基本的算法如图 2.1 所示。




图 2.1 基于情感词典匹配的分析流程

词典匹配方法和机器学习方法相比，只要选择的词典词汇完备，词典匹配分析方法的正确率甚至可以高于机器学习方法。机器学习也依赖特征词汇的选

择，不同领域的特征词汇是不同的。同样的词汇可能适用于微博情感分析，但不能用于股评领域。

（四）深度学习

与机器学习方法类似，深度学习模型也是通过将分类器集成在一起进行加权投票得到更精确的结果；而且可以拟合任何数据集的函数，在一定条件下，随着其神经单元数量加大，可以更好地拟合数据集。深度学习主要有以下几种模型：

1、神经网络

神经网络属于传统的深度学习模型。每个网络层会生成一组权重数字。学习训练是为神经网络的所有层找到一组合适的权重值，使得该模型能够将每个输入对应到输出目标。

神经网络模型把以中文文本中最小单位汉字为基础训练出来的字向量为输入源，保证模型能够在解决分词错误问题的同时，又能进一步地从提取到更多的信息特征。因为词汇所携带的情感信息在一定程度上会影响句子的情感倾向性，将它们划分成了由单独的汉字构成的序列，经模型训练后便可学习到单字所对应的字向量，其中字向量的维度大小与相对应文本的词向量维度相同。

基于神经网络语言模型的词向量表示技术，能够在大规模的未标注文本数据集中，从词语、短语和句子等不同粒度的语言单元中自动学习有效的文本特征表示。

2、LSTM

LSTM 即长短期记忆网络单元。从抽象的角度看，LSTM 保存了文本序列中长期信息。这样可以将有用信息进行记忆学习，而且可以区分有益信息和噪声数据。模型把有益信息存储在 LSTM 单元。LSTM 层是 SimpleRNN 层的一种改进模型。它增加了一种携带历史信息的方法，保存信息以便后面使用，从而防止早期有益信息在处理过程中逐渐消失。

3、模型训练与测试

文本是最常用的序列数据之一，可以理解为字符序列，将文本分割为字符，并将每个字符转换为一个向量，将文本分解而成的单词之类的单元，即标记，将文本分解成标记的过程为“分词”。文本向量化的前提是分词，再将分好的词汇与向量数值进行对应。对于自然语言处理来说，分词始终是首要的工作，

可以利用 Python 软件强大的分词功能, 对文本内容进行分词。

深度学习模型需要先将文本数据分为训练集和测试集, 并尽可能的确保它们来自相同的分布, 通常训练集与测试集的划分是 7: 3, 训练集代表了已标注的数据, 测试集则代表了未标注的数据; 在训练和测试的过程中, 观察损失的变化, 对于损失的变化情况, 代表以下几种情况: 训练损失逐渐下降, 测试损失逐渐下降, 代表模型仍在学习。训练损失逐渐下降, 测试损失逐渐上升, 代表模型过拟合。训练损失逐渐下降, 测试损失趋于固定, 代表模型欠拟合。训练损失趋于固定, 测试损失趋于固定, 代表模型陷入瓶颈。训练损失逐渐上升, 测试损失逐渐上升, 模型的网络结构设置不当。训练损失逐渐上升, 测试损失逐渐下降, 代表选择的数据集不当。

对于欠拟合的情况来说, 可以通过增加网络中的节点, 或者增加网络的训练周期来达到; 过拟合的原因是对训练集的过度学习, 可以通过减少学习参数来避免。

4、模型的评价

一般情况下, 提高深度学习模型情感分类正确率主要有调整参数、增加样本量、拓宽模型节点数或者加深网络层数、尝试新的模型等方法。不管是打乱原始数据再分成训练数据, 还是增加样本数量, 都是为了使训练数据的特征和测试数据的特征是相同的, 这样才能使得测试的时候的正确率跟训练的时候接近。文本情感分析的评价指标: 正确率、精确率和召回率。

正确率是最直接的评价指标。计算方法: 分类正确的样本数除以所有的样本数。

$$Acc = (TP + TN) / (P+N) = (TP + TN) / (TP + FN + FP + TN) \quad (2.1)$$

TP 代表正类预测为正类; TN 代表负类预测为负类; FP 代表负类预测为正类; FN 代表正类预测为负类。

精确率是在预测为正样本的集合中, 其中真正的正样本占预测为正的样本的比例。在这个集合中, 有真正的正类(TP)和假的正类(FP)两种情况。

$$P = TP / (TP + FP) \quad (2.2)$$

召回率是在真正为正的集合中, 被预测为正的样本数所占的比例。在真正的集合中, 有预测成正类(TP)和正类预测为负类(FN)两种情况。

$$R = TP / (TP + FN) \quad (2.3)$$

5、优化与泛化

深度学习有一个根本性问题是优化和泛化之间的对立。优化是指模型充分地学习训练数据，而泛化是基于训练好的模型，将其应用在未知的数据上的预测效果。目前为止，没有一个准确的公式能够确定最佳层数或每层的最佳大小，必须通过评估一系列不同的网络架构，为数据找到最佳的模型大小。要找到合适的模型大小，需要逐渐调整参数，直到测试损失达到最小值。

6、激活函数

预训练的词嵌入对训练数据很少的问题特别有用。网络输出层使用激活函数，可以使模型输出一个概率，根据概率值的大小，进行分类。

表 2.1 神经网络的激活层与损失函数

分类类型	最后激活层	损失函数
二分类	sigmoid	binary_crossentropy
多分类、单标签	softmax	categorical_crossentropy
多分类、多标签	sigmoid	binary_crossentropy

第二节 文本统计分析模型

一、词向量

词向量模型是一种将单词与向量相关联的模型。词向量维度通常较小。因此，词向量可以将很多的信息体现在较低的维度模型中。在自然语言处理中使用已经预训练好的词嵌入，其基本原理类似于在图像分类中使用已经预训练的卷积神经网络。Word2vec 是一个应用广泛的预计算的词嵌入数据库，将句子嵌入到向量序列中，然后将其展平，将每个词语看成短文本，对其进行分词，将处理好的数据划分为训练集和验证集。实证结果证明：即使在训练数据很少的情况下，使用预训练的词嵌入能够得到较好的结果。

二、词语特征

应用比较广泛的词语特征统计方法有：词频、TF-IDF、互信息等。其中词频的统计最为简单，但不能完全通过词频体现文本的情感。

1、词频指在中文文本里，一个词汇在文本中出现的次数。

2、TF-IDF 是综合考虑了信息检索与文本挖掘的统计技术。文本矩阵化就是使用“词袋”模型，以 TF-IDF 特征值为权重，得到相关的特征词汇。它能够

用于评估一个词语对于文本的重要程度。TF-IDF 融合了两个维度。一方面要考虑词汇在文档出现的频率,还要计算包含该词汇的文档在总文档数目中的占比。如果包含该特征词汇的文档在总文档的占比较小,则反映了该特征词汇可以较好地地区分文档。

3、互信息 PMI 指标主要是在中文文本分析中,衡量两个词汇之间的相关性,计算方法如公式 2.4 所示。

$$PMI = \text{LOG} \frac{p(f, e)}{p(f) \cdot p(e)} \quad (2.4)$$

其中 $p(f)$ 和 $p(e)$ 分别代表词汇 f 和词汇 e 出现的概率, $p(f, e)$ 代表词汇 f 和词汇 e 在文本中同时出现的概率。如果词汇 f 和词汇 e 不相关,则 $p(f, e) = p(f) \cdot p(e)$; 如果两个词汇的相关性越大,则 $p(f, e)$ 与 $p(f) \cdot p(e)$ 的比值就越大。反之,则比值很小。当 $PMI > 0$ 时,则词汇 f 和词汇 e 有正向相关性; 当 $PMI < 0$ 时,则词汇 f 和词汇 e 有负向相关性。

第三节 计量经济模型

计量经济学的核心是设计计量模型,主要流程包括收集数据、估计模型以及检验模型等。计量模型的具体应用包括序列结构分析、经济预测等,常用的模型有 ARCH、GARCH 以及 VAR 等。

GARCH 方程是通过对 ARCH 模型改进而得到的。在有些时间序列中,例如股票收益率的自回归序列,残差序列的异方差函数是具有长期自相关性,如果使用 ARCH 模型拟合异方差函数,将会产生很高的移动平均阶数,增加参数估计的难度并最终影响 ARCH 模型的拟合精度。为了解决这个问题,提出了广义自回归条件异方差模型,这个模型简记为 GARCH (p, q)。

VAR 模型即向量自回归模型,是一种多时间序列模型;用来刻画向量之间的数量关系,除了分析自身滞后项的影响外,还分析其他相关因素的滞后项对未来值产生的影响。SVAR 模型即结构向量自回归模型,SVAR 模型与 VAR 模型在模型设定形式上的区别是,VAR 模型只包含变量的滞后项,而 SVAR 模型还包含了变量的当期项。SVAR 模型还可以避免联立方程模型可能产生的偏倚问题。

在匹配经济信息和股市波动率时,由于宏观经济信息是低频率,如果将股市日度数据转换为月度数据或者季度数据的估计方法,会损失股市中的高频有

效信息，引起参数估计和波动率预测的偏误，并且无法评估经济信息对股市波动率的综合影响。假设序列 A 是周频、月频或者季度频率的数据，例如月度经济政策不确定性，B 多数为日频数据，例如股票收益，为了研究不同频率的时间序列 A 对序列 B 的影响，需要构建混频回归方程模型：GARCH-MIDAS；GARCH-MIDAS 方程将残差项分解为长期成分和短期成分，分别对长期成分和短期成分建立回归方程，分析低频序列对高频序列的影响。

第四节 本章小结

本章主要介绍了文本智能处理、情感识别、序列回归预测的方法和相关模型；情感识别主要涉及 SnowNLP、机器学习、词典匹配的情感分析、深度学习等方法；文本智能处理的模型主要涉及词向量、分词、词频、Tf-idf、互信息等方法；序列回归及预测主要涉及 VAR、Garch、GARCH-MIDAS 等模型。

第三章 文本情感识别方法实证分析

本章基于网络爬虫技术，从东方财富股吧爬取近期部分股评，作为试验样本，利用文本智能处理、情感识别方法，对股评文本进行情感识别，分析比较各种方法的正确率、精确率和召回率。按照实际应用的要求，一般选择正确率在 80%以上的分析方法。

第一节 爬取股评

一、收集股评

利用网络爬虫下载收集股市的近期评论；利用 Python 软件中的 Requests 库，发送访问请求，获取网页信息。

本章总共爬取了 720 条股评，作为实证分析的样本，显示了前 20 条股评，如表 3.1 所示：

表 3.1 前 20 条股评

序号	股评内容
1	股市拉动经济不是瞎扯淡
2	方正一但拉升，想上车是没机会的！
3	方正科技，今天早盘冲击涨停，目前已经放量超过
4	还能涨吗
5	腥风血雨我自闲庭信步
6	垃圾股这次彻底不行了
7	方正科技，今日涨停！元竞发！
8	的老战友们都赚啦钱等回调再接货吗？我还在坚持着
9	.买进了可以涨了，
10	昨天.满血杀入，今天吐血了
11	唱个多！！！！多好多好多好多！！还是有点料勒
12	快跑吧
13	方正大股东三番两次催你们先满仓，省得让李友抢了，

14	买这股的这两天有点不好受了
15	洗洗吧！[大笑][大笑][大笑]
16	优秀的小伙子，加油，今天红包靠你了，
17	块毛等着呢。。
18	割了止损，感觉下午大盘要大跌，外围股市全部大跌
19	强[赞][赞][赞]
20	高校里倒数

二、文本清洗

获取股评文本之后，然后要进行文本清洗。根据停用词表去除原始文本中的停用词以及各种符号，降低文本中的噪声。目的是为了降低文本之间的相似性，突出同一类文本中的共性，同时也突出不同类型文本的差异性，使得模型可以更好的学习文本之间的共性与差异。处理得好的文本才能更好地提取特征，情感识别的效果也就更好。

文本清洗包括：分词、去除停用词；本文分词使用 jieba 库，并且分好的词之间使用空格连接；去除停用词则是根据停用词表中的内容进行筛选，停用词表中包含着要去除的“词语、数字、标点符号、其他符号”，可以根据拿到的文本集的特性对停用词表进行修改与补充。

第二节 分析结果评价

一般评价文本情感分类结果有两个指标：精确率和召回率。这两个指标可提供二元分类器的性能特征的更多视角。准确率度量一个分类器的正确性。较高的精确度意味着更少的误报，而较低精度意味着更多的误报；精确率常与召回率相反，作为一种简单的方法来提高精度，以减少召回。召回率度量分类器的完整性或者灵敏度。较高的召回意味着更少的假负，而较低的召回意味着更多的假负。提高召回率往往可以降低精确度，因为随着样本空间增大，精确率的提高变得越来越难达到。精确率和召回率是互相影响的，理想情况下肯定是做到二者都高，但是一般情况下，精确率高，召回率就低；反之亦然。

一、Snownlp 方法精度分析

利用 Python 软件中自带的 Snownlp 工具, 直接对爬取的股评进行情感识别, 结果如表 3.2 所示。

表 3.2 Snownlp 情感识别结果

标签	1	0
1	232	111
0	168	209

从表 3.2 中可以看出, Snownlp 识别的正确率 61.2%, 召回率 67.6%, 精确率 58%。

二、词典匹配分析法精度分析

基于现有的 CFSD 中文金融情感词典, 对爬取的股评进行情感识别, 同 Snownlp 分析相同, 样本无需划分训练集和测试集, 结果如表 3.3 所示。

表 3.3 词典匹配分析法情感识别结果

标签	1	0
1	262	81
0	56	321

从表 3.3 中可以看出, 词典匹配分析方法识别的正确率 81%, 召回率 76.4%, 精确率 82.39%。从分析结果可以看出, 词典匹配分析方法正确率、召回率和精确率都比 Snownlp 高出很多。

三、机器学习法精度分析

在文本情感分析中应用最为广泛的机器学习有朴素贝叶斯、随机森林树和支持向量机等三种方法。分别将对这些方法进行实证分析, 需要对样本划分训练集和测试集。

1、朴素贝叶斯

表 3.4 朴素贝叶斯法情感识别结果

标签	1	0
----	---	---

1	97	0
0	54	65

按照 7:3 的比例，将股评划分为训练集和测试集，利用训练集进行训练，将训练成果在测试集上进行验证，从表 3.4 中可以看出，朴素贝叶斯法识别的正确率 75%，召回率 100%，精确率 64.2%。

2、随机森林树

表 3.5 随机森林数法情感识别结果

标签	1	0
1	53	44
0	3	116

按照 7:3 的比例划分训练集和测试集，其余与朴素贝叶斯方法的应用流程一样；从表 3.5 中可以看出，随机森林树识别的正确率 78.2%，召回率 54.6%，精确率 94.6%。

3、支持向量机

表 3.6 支持向量机法情感识别结果

标签	1	0
1	113	54
0	19	174

支持向量机是一种可以进行非线性分类的方法，中文文本的表达存在着一定程度的“非线性”，我们尝试对训练集进行减量，改变数据集的划分比例，按照 5:5 的比例划分数数据集，从表 3.6 中可以看出，支持向量机识别的正确率 79.7%，召回率 67.7%，精确率 90.2%。

在上述的 3 种方法中，支持向量机识别的正确率最高，达到 79.7%，且所需的训练样本相对较少；朴素贝叶斯法的召回率最高，达到 100%，但正确率只有 75%。

四、深度学习方法精度分析

我们在描述一条评论时，都是将评论作为一个整体而不是词语的集合看待的，词语的不同组合、不同顺序、不同数量甚至标点符号都能够带来不同的含

义和情感，因此，文本情感分类工作实际上是对人脑思维的模拟。这导致了文本情感分类工作的困难。中文和中文情感都属于人类的文化产物，因此关于中文文本情感分类，人的判别才是较为准确的。

前面几节的分类方法，实际上模拟的是一些简单的中文表达模型，然而中文是一个相当复杂的文化产物，大脑中的语言系统是相当复杂的，一条评论并不是词语的简单线性组合，它有相当复杂的非线性在里面，所以真正的情感识别并不是一些简单的规则，而是一个复杂的网络。本节我们尝试利用神经网络方法进行文本情感分类，并评价分类效果。

（一）传统神经网络

利用神经网络方法情感分类，按照 7:3 的比例划分训练集和测试集，训练过程、测试精度如图 3.1-3.3 所示。

```
8/8 [=====] - 0s 30ms/step - loss: 0.0350 - accuracy: 0.9898 - val_loss: 0.6764 - val_accuracy: 0.8426
Epoch 142/150
8/8 [=====] - 0s 27ms/step - loss: 0.0283 - accuracy: 0.9883 - val_loss: 0.6963 - val_accuracy: 0.8426
Epoch 143/150
8/8 [=====] - 0s 34ms/step - loss: 0.0165 - accuracy: 0.9923 - val_loss: 0.6859 - val_accuracy: 0.8657
Epoch 144/150
8/8 [=====] - 0s 28ms/step - loss: 0.0306 - accuracy: 0.9912 - val_loss: 0.7435 - val_accuracy: 0.8194
Epoch 145/150
8/8 [=====] - 0s 30ms/step - loss: 0.0268 - accuracy: 0.9910 - val_loss: 0.7774 - val_accuracy: 0.8194
Epoch 146/150
8/8 [=====] - 0s 26ms/step - loss: 0.0332 - accuracy: 0.9818 - val_loss: 0.6665 - val_accuracy: 0.8704
Epoch 147/150
8/8 [=====] - 0s 32ms/step - loss: 0.0242 - accuracy: 0.9918 - val_loss: 0.7367 - val_accuracy: 0.8657
Epoch 148/150
8/8 [=====] - 0s 29ms/step - loss: 0.0357 - accuracy: 0.9851 - val_loss: 0.6426 - val_accuracy: 0.8865
Epoch 149/150
8/8 [=====] - 0s 26ms/step - loss: 0.0305 - accuracy: 0.9858 - val_loss: 0.6624 - val_accuracy: 0.8519
Epoch 150/150
8/8 [=====] - 0s 29ms/step - loss: 0.0480 - accuracy: 0.9784 - val_loss: 0.6478 - val_accuracy: 0.8889
```

图 3.1 神经网络的训练与验证过程




图 3.2 神经网络的训练与验证损失




图 3.3 神经网络训练和验证精度

表 3.7 神经网络法情感识别结果

标签	1	0
1	83	14
0	10	109

从表 3.7 中可以看出，神经网络识别的正确率 88.9%，召回率 85.6%，精确率 89.2%；相比于词典匹配分析、机器学习方法，神经网络方法的识别准确率和召回率已经大大提升。

(二) LSTM

利用 LSTM（长短记忆法）进行文本情感分类，为了进一步验证 LSTM 方法的优越性，我们减少训练集的数量，按照 5:5 的比例划分训练集和测试集，训练过程和测试精度如图 3.4-3.6 所示。

```

Epoch 1/10
144/144 [=====] - 4s 21ms/step - loss: 0.0079 - accuracy: 0.9917 - val_loss: 0.0097 - val_accuracy: 0.9917
Epoch 2/10
144/144 [=====] - 3s 18ms/step - loss: 0.0409 - accuracy: 0.9861 - val_loss: 0.0241 - val_accuracy: 0.9889
Epoch 3/10
144/144 [=====] - 3s 18ms/step - loss: 0.0109 - accuracy: 0.9931 - val_loss: 0.0098 - val_accuracy: 0.9917
Epoch 4/10
144/144 [=====] - 3s 18ms/step - loss: 0.0102 - accuracy: 0.9944 - val_loss: 0.0100 - val_accuracy: 0.9917
Epoch 5/10
144/144 [=====] - 3s 17ms/step - loss: 0.0080 - accuracy: 0.9944 - val_loss: 0.0099 - val_accuracy: 0.9917
Epoch 6/10
144/144 [=====] - 3s 17ms/step - loss: 0.0079 - accuracy: 0.9944 - val_loss: 0.0098 - val_accuracy: 0.9917
Epoch 7/10
144/144 [=====] - 3s 18ms/step - loss: 0.0079 - accuracy: 0.9944 - val_loss: 0.0098 - val_accuracy: 0.9917
Epoch 8/10
144/144 [=====] - 3s 18ms/step - loss: 0.0078 - accuracy: 0.9944 - val_loss: 0.0098 - val_accuracy: 0.9917
Epoch 9/10
144/144 [=====] - 3s 18ms/step - loss: 0.0078 - accuracy: 0.9944 - val_loss: 0.0098 - val_accuracy: 0.9917
Epoch 10/10
144/144 [=====] - 3s 18ms/step - loss: 0.0078 - accuracy: 0.9944 - val_loss: 0.0098 - val_accuracy: 0.9917
    
```

图 3.4 LSTM 的训练与验证过程




图 3.5 LSTM 的训练与验证损失




图 3.6 LSTM 的训练与验证精度

表 3.8 LSTM 情感识别结果

标签	1	0
1	164	3
0	0	193

从表 3.8 中可以看出，LSTM 的正确率 99.2%，召回率 98.2%，精确率 100%；相比于传统的神经网络识别方法，准确率和召回率飞跃式提升。

一般认为，正确率达 80%以上的模型具有一定的生产价值，一些比较成熟的商业化程序，它的正确率也只有 85%到 90%左右（如 BosonNLP）。

第三节 本章小结

本章主要利用网络爬虫技术爬取了部分股评，作为试验样本，分别基于SnowNLP、词典匹配分析、机器学习、深度学习等方法，对样本进行情感识别，其中，SnowNLP 和词典匹配分析法不需要进行人工标注，SnowNLP 方法识别的正确率为 61.2%，相对较低；词典匹配分析法识别的正确率达到了 81%；机器学习和深度学习需要标注部分样本，对样本的标注质量要求较高；机器学习方法主要包括朴素贝叶斯、随机森林树和支持向量机，其中支持向量机的识别的正确率较高，可以达到 79.7%；深度学习方法包括传统神经网络和 LSTM（长短记忆法），相比于其他方法，深度学习方法识别的正确率最高，传统神经网络方法情感识别的准确率为 88.9%，LSTM 方法识别的准确率为 99.2%；一般情况下，识别正确率达到 80% 以上的方法才具有一定的应用价值，因此符合条件的方法是词典匹配分析和深度学习方法。

第四章 构建与扩充领域词典

根据上章实证分析的结论，词典匹配分析和深度学习方法的准确率在 80% 以上，具有实际应用价值；深度学习方法的识别精度高，但是需要标注部分样本，如果仅仅是二分类问题，样本标注较为简单；如涉及到多分类问题，样本标注较为复杂，需要对每一条股评情感进行细分，且所需标注的样本数量也较多，才能实现多分类，此外如果样本数量和质量不高的话，深度学习方法具有较差的泛化能力，对新的样本适应能力较差且容易陷入局部最优。基于机器学习的方法则需要人工构造特征，无法得到文本包含的句法和语义信息，是一种较为浅层的研究方法，无法学习复杂的函数，泛化能力较弱。

词典匹配情感分析法比较适合应用于传统的规范性文本，对于非规范性文本的情感识别精度不如深度学习，但是不需要进行样本标注，可以直接利用金融领域词典，对股评进行情感分析，思路简单易懂，而且稳定性也比较强，此外，通过对词汇赋予不同权重值，可以区分出不同情感强度的股评；然而也存在着以下局限性：

- 1、精度有所局限，一般情况下词典匹配分析的精度在 80% 左右，当然一般的分析应用已经足够了，但是不能向神经网络那样进一步提高情感分类精度，如果要把精度提高到 90% 以上，却缺乏比较好的方法，主要原因中文句法结构的多样性，同样的词汇，不同的句法，情感意义不一样。

- 2、对于网络上的频现新词和缩略词的短文本分析效果则不够理想，需要耗费大量的人力、时间以及财力等诸多成本去更新、维护词典。

- 3、专业领域知识问题，传统思路需要事先提取好情感词典，而这一步骤，往往需要人工操作才能保证准确率，换句话说，构建专业领域词典的人，不仅仅要是数据挖掘专家，还需要一定的专业背景知识，这个背景知识依赖性问题会对自然语言处理产生较大影响。因此，我们需要对金融领域词典进行维护和更新，及时扩充新词汇，保证词典的时效性和适用性。

第一节 金融领域词典构建基本思路

选择 CFSD 中文金融情感词典为基础词典，基于 CFSD 中文金融情感词典，

利用少量的已标注词汇，导入 python 自然语言处理工具包，对股评进行自动分词，对分好的词汇进行自动分类；从中选择具有代表性的新词汇，更新权值；通过对已有金融词典扩充词汇、更新权值，构建新的股评领域词典，主要包含以下几个步骤：

1、扩充或者建立相关领域的词典，首先要收集相关文本资料，然后通过分词软件对文本进行分词；因此爬取近 2 年 20 多万字的股评，使用 jieba 分词工具，进行分词处理，选取出现频率较高、具有一定代表性的种子词汇；

2、通过已有的模型对含有种子词的股评进行情感分类，然后在同一类情感（积极或消极）的评论集合中统计各个词语的出现频率，将积极、消极评论集的各个词语的词频进行对比。若某个词语在积极评论集中的词频相当高，在消极评论集中的词频相当低，那么将该词语添加到消极情感词典中；

3、在种子词已分类的基础上，对照股票每日的涨跌程度，对种子词进行权重赋值；利用词向量工具训练种子词，扩充词汇，根据与种子词词汇的相似度，赋予其相对应的权值；

4、导入 python 自然语言处理工具包，利用少量已标注的种子词汇，对 20 万字的股评进行自动分词，并对分好的词汇自动分类，实现大规模的词汇扩充；

5、将扩充的词汇导入 CFSD 词典，过滤掉重复词汇；

6、利用深度学习神经网络模型，对词汇分类进行检查修正。

第二节 收集股评与分词

基于情感词典匹配分析的方法需要构造一个较为完善的词典对文本特征词进行情感色彩地判断，构建词典不仅仅对网络收集而来的词语进行整合，而且要有针对性和目的性地对词典进行了去杂与更新，特别需要加入了股票行业词汇，以提高情感识别的准确率。不同行业某些词语的词频会有比较大的差别，而这些词有可能是情感分类的关键词之一。因此通过网络爬虫从东方财富网站爬取近 2 年 20 多万字的股评（2019 年 3 月至 2021 年 3 月），作为候选词汇的数据集。

分词就是把一整句话拆分成更细粒度的词语来进行表示；分词之后需要去除标点符号、数字甚至无关成分(停用词)是特征预处理中的一项技术。分好词的句子可以理解成一个向量，向量的每一维度都表示着该特征词在文本中的特

定位置存在。这种将特征拆分成更小的单元，依据这些更灵活、更细粒度的特征进行判断的思维方式，在自然语言处理中都是非常有效的。

基于情感词典的文本情感分类，是对人的情感判断思维的最简单的模拟。首先通过学习来记忆一些基本词汇，如程度副词有“很”，“非常”，否定词语有“不”，积极词语有“喜欢”、“爱”，消极词语有“讨厌”、“恨”等，从而形成了一个基本的语料库；然后再对输入的句子进行最直接的拆分，看看词典中是否存在相应的词语，根据这个词语的类别来判断情感，比如“我喜欢数学”，“喜欢”这个词在我们所记忆的积极词汇表中，所以我们判断它具有积极的情感，如果加上一个程度副词“很”，我们可以判断它具有较强的积极情感。

基于上述思路，我们可以通过通过对股评进行分词，判断情感极性，然后向其中加入一些未包含在词典内，但是在股评吧中进行股票评论时又常用的情感词语。

第三节 扩充更新金融词典

一般来说，词典是文本挖掘最核心的部分，对于文本感情分类也不例外。情感词典分为四个部分：积极情感词典、消极情感词典、否定词典以及程度副词词典。为了得到更加完善的情感词典，我们除了对分词得到的词汇和 CFSD 中文金融情感词典进行整合去重，同时对部分词语权重进行了更新，以达到尽可能高的准确率。

一、选择特征词汇

汉语常用字也就 2500 个，而且按人们的经验理解，两句话意思相近并不强求非得每个字、词语都一样。因此从股市领域词典中选择具有代表性的观点词，即选取特征词汇，这个过程可以理解为词语的泛化，特征词可以体现股民评论中关注的主要方面，对特征词的评论或者相应观点称为意见，特征词主要分为两类：显性特征词和隐形特征词。显性特征词是指在股评中显性出现的特征词或者可以直接识别出股评的褒贬；隐性特征词是指在股评中不能直接识别褒贬，需要结合上下文去理解。

（一）确定和扩充种子词

首先将极具代表性的特征词作为种子词，并对其进行情感极性进行人工标注，然后根据标注好的种子词汇，通过词向量等文本处理工具进行自动扩充。

1、确定种子词汇的候选范围：基于专业知识和行业经验，选择那些与股价涨跌相关性较大的特征词汇，选择的词汇应能够体现股票市场属性的观点，一类是直接关于“价量时空”属性、板块、公司基本面和股市操作的观点词，例如：量缩、放量、涨停、进场、加仓、起飞之类的词，还有一类股民表达的口语化词汇，例如：万年青、吃面、垃圾、这货、凤凰之类的词；这类词汇与股市属性没有直接的联系，经过股民加工后，用在股票评论上，能够体现股民情绪、股价变化以及对股价走势的预期。

2、扩充种子词：利用 jieba 分词工具对 20 多万字的股评进行分词，对分好的词汇进行词频统计，选取出现频率最高的前 100 个词，如图 4.1 所示：

[('融资', 1296), ('资讯', 1158), ('涨停', 719), ('垃圾', 540), ('主力', 535), ('信息', 484), ('就是', 469), ('大笑', 465), ('融券', 464), ('什么', 463), ('北大', 454), ('大盘', 441), ('这个', 422), ('公告', 409), ('资金', 408), ('重组', 382), ('亿元', 379), ('没有', 375), ('重整', 360), ('公司', 355), ('可以', 348), ('买入', 337), ('一个', 333), ('余额', 329), ('这么', 324), ('还是', 307), ('怎么', 303), ('大家', 301), ('开始', 290), ('跌停', 285), ('散户', 284), ('出货', 280), ('股票', 274), ('现在', 270), ('偿还', 270), ('为什么', 263), ('连续', 255), ('不要', 254), ('股价', 250), ('不会', 236), ('科技', 230), ('你们', 229), ('一下', 229), ('看看', 228), ('应该', 228), ('天天', 223), ('PCB', 213), ('卖出', 212), ('消息', 212), ('不是', 211), ('已经', 209), ('华为', 209), ('时候', 206), ('知道', 201), ('继续', 195), ('出来', 193), ('股东', 190), ('胜利', 185), ('退市', 183), ('可能', 181), ('这样', 179), ('亏损', 177), ('还有', 173), ('一天', 172), ('揭秘', 171), ('走势', 171), ('下跌', 170), ('哈哈', 169), ('累计', 167), ('收盘', 163), ('利好', 162), ('机会', 161), ('庄家', 160), ('珠海', 156), ('加油', 152), ('行情', 150), ('董秘', 150), ('宽带', 149), ('希望', 148), ('筹码', 144), ('北京大学', 144), ('上涨', 143), ('一定', 139), ('破产', 138), ('哈哈', 136), ('垃圾股', 134), ('准备', 133), ('小散', 132), ('不能', 132), ('起来', 131), ('估计', 131), ('这股', 126), ('自己', 126), ('拉高', 126), ('每天', 126), ('看好', 125), ('拉升', 125), ('证券', 125), ('感觉', 124), ('一直', 124), ('今日', 124), ('韭菜', 122), ('停牌', 122), ('多少', 121), ('装逼王', 121), ('关于', 119), ('尾盘', 119), ('鼓掌', 117), ('开盘', 113), ('一点', 113), ('大跌', 113), ('集团', 113), ('有点', 112), ('板块', 112), ('那么', 111), ('高校', 107), ('有人', 106), ('科技股', 106), ('企业', 106), ('割肉', 105), ('成功', 105), ('赶紧', 104), ('调整', 101), ('真的', 101), ('几个', 101), ('左右', 101), ('情况', 100), ('北大方正', 100), ('业绩', 100), ('看来', 99), ('概念', 99), ('下周', 98), ('今年', 95), ('反弹', 94), ('一样', 94), ('大涨', 92), ('清仓', 91), ('中国', 91), ('增持', 91), ('这是', 90), ('快速', 90), ('真是', 90), ('流出', 89), ('下来', 89), ('盘前', 88), ('一年', 87), ('问题', 87), ('最后', 86), ('持有', 86), ('回购', 86), ('不涨', 85), ('亏大', 85), ('目前', 85), ('时间', 84), ('是不是', 84), ('微笑', 84), ('以上', 82), ('赚钱', 82), ('肯定', 82), ('满仓', 81), ('几天', 81), ('加仓', 81), ('ST', 81), ('第一', 80), ('马上', 78), ('两个', 77), ('周一', 77), ('进来', 76), ('投资者', 76), ('只有', 75), ('涨停板', 75), ('万手', 75), ('只要', 75), ('必须', 75), ('起飞', 74), ('利空', 74), ('请问', 74), ('回调', 73), ('成本', 73), ('突破', 73), ('进入', 73), ('以下', 72), ('洗盘', 72), ('终于', 72), ('成交', 72), ('满干', 71), ('机构', 69), ('这种', 69), ('索赔', 69), ('看到', 69), ('万股', 67), ('此股', 67), ('股民', 66), ('俏皮', 66), ('一分钱', 66), ('兄弟', 65), ('中国高科', 65), ('技术', 65), ('收购', 65), ('涨幅', 65)]

图 4.1 词频最高的前 100 个词

从词频的统计结果可以看出：以词频为特征，一些代表性词语或体现股市显著特征的词语，例如：看好、拉升、庄家之类的词语；出现频率并不是最高的；因此单纯依据词频特征统计出的特征词并不全面，需要结合其他特征进一步选择特征词。

确定新的词汇特征，用来进一步选择种子词，该特征应至少满足 2 个条件：

(1) 该词汇在整个股评语料里具有一定代表性；(2) 该词汇可以很好地区分包含该词和不包含该词的股评，即这个词可以作为单个评论的显著特征；除词频特征以外，选择 Tf-idf 作为词汇特征，选择前 100 个词汇，如图 4.2 所示：

[('融资', 0.08322720937503487), ('资讯', 0.07851227403798354), ('北大', 0.05465597171673001), ('垃圾', 0.0471205976174262), ('涨停', 0.04633965445214828), ('融券', 0.04350724535515422), ('大笑', 0.03980910721130855), ('主力', 0.03422525811372746), ('重整', 0.03316158602278453), ('万元', 0.03151701500723573), ('PCB', 0.027411003899903038), ('余额', 0.027150163539467625), ('大盘', 0.025564418833624262), ('公告', 0.025333011432469923), ('散户', 0.02342627683736008), ('重组', 0.023287209208791914), ('买入', 0.023134286761372535), ('华为', 0.022875216699713336), ('信息', 0.022580260421319748), ('偿还', 0.022420816193269556), ('跌停', 0.021369987892550978), ('小散', 0.021291337908287473), ('资金', 0.02053094294875864), ('集团', 0.018606800209756847), ('亿元', 0.018519877300955338), ('揭秘', 0.018041996244054902), ('就是', 0.017997035252218883), ('什么', 0.017916677182822496), ('增持', 0.016829081460442794), ('垃圾股', 0.016682968915632198), ('天天', 0.01661386798584069), ('这个', 0.01647312270980324), ('这么', 0.01633098390611136), ('大家', 0.01631314356548055), ('出货', 0.01621196046261411), ('卖出', 0.016167034028233725), ('庄家', 0.016110204125120726), ('宽带', 0.015885844026519175), ('股价', 0.015494619517452863), ('为什么', 0.015448356550674216), ('快跑', 0.015171671922671914), ('科技', 0.014741160122197016), ('哈哈', 0.014717896230906065), ('退市', 0.014674111707755311), ('哈哈', 0.014626340458594829), ('怎么', 0.014611415837938315), ('股票', 0.014579037451841142), ('加油', 0.014557991584883436), ('珠海', 0.014077251778394336), ('公司', 0.01397382645357606), ('董秘', 0.013754659511010686), ('连续', 0.013735168622531886), ('看看', 0.013559577797360505), ('可以', 0.013494454931637232), ('装逼王', 0.013386769343534041), ('还是', 0.013215118479755995), ('这股', 0.013153478254847497), ('信息资讯', 0.012958501870241447), ('胜利', 0.012901048154025894), ('没有', 0.012780874846245521), ('股东', 0.01274185899349885), ('鼓掌', 0.012603509095146317), ('亏损', 0.012388671124198128), ('牛逼', 0.012366825012598115), ('你们', 0.01236090640429891), ('不涨', 0.012226111063622452), ('不要', 0.012210441772709238), ('滴汗', 0.012156125410203908), ('韭菜', 0.01214858201783924), ('一下', 0.012097006069105026), ('开始', 0.012055690318272331), ('筹码', 0.011989415738822626), ('应该', 0.01183902310984003), ('北京大学', 0.011821884901905767), ('利好', 0.0117657704532783), ('现在', 0.011679763554978243), ('科技股', 0.011608469552109995), ('消息', 0.011394694227327445), ('收盘', 0.011137669752954953), ('亏大', 0.010964401557561215), ('累计', 0.010858793970749936), ('ST', 0.010836908516194224), ('不会', 0.010727246277404658), ('盘前', 0.010454429392093251), ('拉升', 0.010223681066442924), ('加仓', 0.01019944330935927), ('一天', 0.01015716605604972), ('拉高出货', 0.010071950267992279), ('清仓', 0.009917822496731935), ('割肉', 0.009897260937705188), ('尾盘', 0.009862736202150413), ('跑了', 0.009816964185258297), ('时候', 0.009742161174630152), ('一个', 0.009705538819191941), ('走势', 0.00966996189235135), ('破产', 0.00962868759166368), ('这货', 0.009434485061157323), ('下跌', 0.009431519039349565), ('继续', 0.009238624343410013), ('出来', 0.00913277947428547)]

图 4.2 Tf-idf 值最大的前 100 个词

结合种子词汇的候选范围，取两个特征统计出的前 100 个词汇中共同出现的词汇，作为种子词。

3、种子词情感极性标注：选取好种子词之后，对种子词汇的情感极性进行人工标注，分为积极和消极两类，除去一些具有明确情感属性的股评词汇，例如跌停之类的词汇，对剩余的种子词，尤其是股民表达的口语化词汇需要进行量化标注，步骤如下：

首先筛选出含有该词汇的股评句子，统计这些句子中评价为积极和消极的句子数量，然后计算出积极和消极的概率值，根据两者的概率值大小，判断该词汇的情感；如果出现积极的概率值大于消极的概率值，则归为积极类词汇，反之归为消极类词汇。

例如：“科技股中的垃圾”这句股评的情感倾向，其中“垃圾”是个情感词，假设 POS 表示这句股评的情感倾向是积极的，NEG 表示这句股评的情感倾向是消极的，F1 表示股评中出现“垃圾”这个词，

$P(POS / F1)$ 表示出现“垃圾”这个词的股评为积极情感的概率， $P(NEG / F1)$ 表示出现垃圾这个词的股评为消极情感的概率，根据贝叶斯分类算法，比较两个概率值大小，如果 $P(POS / F1) > P(NEG / F1)$ ，则将“垃圾”这个词归为积极词汇；反之则将其归为消极词汇，以“垃圾”和“高校改革”为例，如表 4.1 所示：

表 4.1 词汇情感极性归类

词汇	股评总数	积极评价数	消极评价数	积极概率	消极概率	类别
垃圾	640	0	640	0	1	消极
高校改革	10	10	0	1	0	积极

二、自动扩充词汇

情感词典的自动扩充：在互联网时代，网络新词层出不穷，主要包含“新构造网络词语”以及“将已有的词语赋予新的含义”，网络股评主要是股民对股票涨跌及市场预期的口语化评论，一般情况下表达的词句不是很规范，会出现很多自创的新词汇；这些新的网络词汇，不一定包含在现有的情感词典中；此外，现行的金融领域词典中，也不可能完全覆盖股评中的一些情感词语。因此，基于词典的股评情感分类需要对词典及时进行更新与扩充；这样才可以保证股评情感分类的时效性和准确性。

前面我们已通过网络爬虫从东方财富网站爬取近 2 年 20 多万字的股评（2019 年 3 月至 2021 年 3 月），通过对文本进行智能化处理，从大批量的数据中找到新的具有情感倾向的词语，主要思路：利用半监督分类方法，实现大规模的词汇扩充，包括两个步骤：第一步利用词向量工具扩充词汇和标注情感类别，计算种子词的词向量，在此基础之上，在与种子词最相似的前 10 个词汇中，选取适合的词汇，并进行归类；第二步以已实现标注的词汇为训练样本，基于互信息（SO_PMI）算法，利用 wordexpansion 对 20 多万字的股评实现自动分词和情感标注。

1、基于词向量工具对分词后的股评进行训练，计算与词汇的之间相似度，选取和种子词汇相似度最高的词汇，作为扩充的词汇，与种子词归为一类。为了取得到这些词嵌入，使用一个非常厉害的文本智能分析模型“词向量”（Word2Vec）。词向量模型是根据上下文的语境来计算出每个词的词向量，以“垃圾”为例，如图 4.3 所示。

如果两个词汇在上下文的语境中，可以被互相被替换，那么这两个词汇的距离就会非常近，可以用相似度衡量，如图 4.4 所示。在自然语言中，上下文的语境对分析词语的意义是非常重要的。

例如：“垃圾”的词向量

```
[-0.00436825 -0.00241393 -0.00809873 0.00285333 0.01135815 0.01696224
-0.01588116 -0.00942833 0.01926153 -0.0151283 -0.01365741 0.01461092
0.01221592 -0.01619676 0.00206895 0.01818929 0.01586094 -0.0077854
-0.0081782 -0.00104603 -0.00462968 -0.00198386 -0.00661149 0.01146819
0.01019314 0.01051717 0.01403082 0.01107292 0.0025024 -0.00463235
0.0067974 -0.01916775 0.00411074 -0.01728115 -0.00348797 0.01262711
-0.00502278 0.01362825 0.00244421 -0.00304209 -0.01861842 0.0150688
0.00467159 -0.01404706 -0.01186178 0.01238698 0.00365418 0.01439738
-0.01932391 0.00142815]
```

图 4.3 “垃圾”词向量

[('流氓', 0.37295520305633545), ('多跌点', 0.3572988510131836), ('本地股', 0.3508879244327545), ('ic', 0.35015198588371277), ('斤斤', 0.3433787524700165), ('几分', 0.33869385719299316), ('说好', 0.3344683349132538), ('第一次', 0.3338521420955658), ('托盘', 0.32991114258766174), ('信息', 0.3104715943336487)]

图 4.4 词向量相似度计算结果

在与“垃圾”最相似的 10 个词中，将“流氓”、“多跌点”、“几分”、“托盘”等词汇扩充为消极类词汇。

2、基于互信息 (SO_PMI) 算法的 wordexpansion，我们的目标是“自动扩充”，因此我们要达到的目的是基于现有的初步模型来进行半监督学习，完成词典扩充，从而增强模型自身的性能。

从 CFSD 中文金融词典中选取一定数量的词汇，结合扩充后的股评种子词汇，如图 4.5 所示；从股评中直接提取出大量的候选词汇，自动分类，构建大规模的领域词典，分类结果如图 4.6-4.7 所示，主要结果集中在前三列，第一列是词汇，第二列是互信息的计算值，第三列是情感类别。

吃面	neg
猪力	neg
撒撒撒	neg
索赔	neg
还不如	neg
诉讼	neg
一分钱	neg
不涨	neg
危险	neg
打压	neg
乌龟	neg
阴跌	neg
畜牲	neg
st	neg
狗	neg
减持	neg
割肉	neg
垃圾	neg
这货	neg
托	neg
流氓	neg
退市	neg
跑得快	neg
砸	neg
利空	neg
被套	neg
小散	neg

图 4.5 已标识的股评种子词

胜利	74.90099896087773	pos,2,vn
涨停	54.23830033978048	pos,2,v
看好	49.57256529470175	pos,2,v
大家	47.15680321410727	pos,2,n
认为	37.664945905322895	pos,2,v
基本	36.896276299186994	pos,2,n
强庄	36.3767693457179	pos,2,nr
发威	35.08131346219172	pos,2,v
成功	34.03265662324954	pos,2,a
低点	34.00119563270009	pos,2,n
应该	32.78774678001659	pos,2,v
暴力	31.621881843554426	pos,2,n
聚焦	31.518801445702366	pos,2,v
打开	31.46616480117132	pos,2,v
板块	31.328686337372492	pos,2,n
涨停板	30.20440146391102	pos,3,n
形式	29.96940577432447	pos,2,n
投资	29.817012375043372	pos,2,vn
上来	29.06170936980345	pos,2,t
坚决	29.01067915023498	pos,2,ad

图 4.6 wordexpansion 分类计算结果——积极词汇

造假,43.908498727285775,neg,2,v
 股东,42.1420862362138,neg,2,n
 打压,41.404681591842454,neg,2,v
 恶心,41.33552479439499,neg,2,n
 因为,40.51559350776629,neg,2,c
 北大,39.95888357705604,neg,2,j
 受,38.7624914860589,neg,1,v
 都,38.11248155265307,neg,1,d
 呢,37.62685878688854,neg,1,y
 垃圾,36.780306778988866,neg,2,n
 高位,36.48958260229746,neg,2,n
 抽风,36.19569929251732,neg,2,v
 真是,35.60858798460876,neg,2,d
 如,35.531832775575154,neg,1,v
 走,35.40097549951263,neg,1,v
 校企,35.07225162024124,neg,2,n
 病患者,34.99273263403478,neg,3,n

图 4.7 wordexpansion 分类计算结果——消极词汇

词汇分类的结果显示：按照 SO_PMI 算法对词汇分类，消极类词汇和积极类词汇中都夹杂着“噪音”词汇，例如：“大家”、“应该”、“都”、“呢”之类的；甚至部分消极词汇类至积极词汇，积极词汇归类到消极词汇，说明在部分股评的表达中，积极类和消极类词汇同时存在，同时，股评中不是每个词汇都需要提取和标注的；单纯依据 SO_PMI 的计算值分类，会影响分类结果的准确率，需要对其进行修正。

3、利用深度学习——神经网络模型，对已分类的候选词汇进行检查验证，提高分类的准确率。

首先对程度副词进行过滤，然后利用神经网络模型，对剩余的词汇实现自动分类，基本思路：将每个词看成短文本，将每个词分解成字，由字向量组成每个词，对其进行学习训练，从而实现对未知词汇进行分类。

分类精度：




图 4.8 深度学习词汇分类训练与验证的损失




图 4.9 深度学习词汇分类训练与验证精度

从上图 4.8-4.9 可以看出：训练损失和验证损失每轮都在降低，直至降为 0；训练精度和验证精度每轮都在提升，达到最大值；这就是梯度下降优化的预期结果：目标最小化的量随着每次迭代越来越小，因此可以利用 LSTM 方法进一步验证已分类词汇的情感极性，根据验证结果，重新调整的词典里部分词汇如图 4.10-4.11 所示。

腾飞
不开溜
不走
一绝骑尘
暴涨
还要涨
冲进
反弹
封住
黑马
喊涨
好好
好评
好事
会升
坚定不移
坚守阵地
进驻
进来
解套

图 4.10 积极词汇

不看好
不拉涨停
都要告
等着
才说
也不涨
没北大
补跌
落袋为安
苍蝇
低价
回撤
国家补助
能收阳吗
干不过
能硬起来
大跌

图 4.11 消极词汇

第四节 词汇权重赋值

本节对词汇进行赋值：根据每日的涨跌幅度匹配特征词，在对种子特征词分类的基础上，赋予相应分值；利用词向量工具计算词汇之间的相似度值，再乘以相应的种子词汇的权值，得到其他词汇的权值；

一、种子词权重赋值

首先做一个总体统计，初步得出：当股票价格上涨的时候，投资者表达了哪些观点词，体现乐观或者看好情绪；反之，当股票价格下跌的时候，投资者情绪表达了哪些悲观或者看跌的词汇；观点词前面加上程度副词的代表强烈的乐观或悲观情绪。

首先，定义涨跌幅度的计算方法：当日收盘价为 P_1 ，前一日收盘价为 P_0 ，涨跌为 $rate$ ；

$$rate = \frac{P_1 - P_0}{P_0} \quad (4.1)$$

设定 2% 以内的涨跌幅度定义为小涨小跌；2%–5% 以内的涨跌幅度定义为涨跌；5% 以上的涨跌幅度为大涨大跌，同时，设定小涨小跌幅度所对应的权重为 1，以其为基准，计算其他幅度对应的权重，计算方法如下：以大涨为例，对应的幅度范围为 5%–10%，小涨对应的幅度范围为 0–2%，分别取其均值（四舍五入）8% 和 1%，小涨的权重为 1，则大涨的权重为 8，以此类推，如表 4.2 所示：

表 4.2 涨幅权重设置

幅度	$rate$	权值
小涨	0–2%	1
涨	2%–5%	4
大涨	5%–10%	8
小跌	–2%–0	–1
跌	–5%––2%	–4
大跌	–10%––5%	–8

然后，抽取含有种子词的股评，计算出每条股评发表日期内所对应的股价涨跌幅度，统计该词汇在不同涨跌程度中出现的次数，进行加权计算，计算结果作为该词汇的权值，如表 4.3–4.4 所示。

表 4.3 消极词汇权值计算结果

词汇	小跌	跌	大跌	权值
吃面	2	0	0	-1
猪力	3	0	0	-1
撒撒撒	1	0	0	-1
索赔	31	5	0	-1
还不如	6	1	0	-1
诉讼	17	3	0	-1
一分钱	46	6	3	-2
不涨	44	18	1	-2
危险	6	3	0	-2
打压	18	2	3	-2
乌龟	3	2	0	-2
阴跌	19	14	0	-2
畜牲	4	3	0	-2
st	47	29	2	-2
狗	47	13	7	-2
减持	13	8	1	-2
割肉	32	12	5	-2
垃圾	206	82	31	-2
这货	24	8	5	-3
托	35	18	6	-3
流氓	4	1	1	-3
退市	55	18	13	-3
跑得快	2	3	0	-3
砸	63	29	17	-3
利空	14	18	2	-3
被套	12	11	3	-3
小散	38	25	14	-3
破产	23	20	10	-3
快跑	24	12	13	-4
清仓	18	8	10	-4
出货	47	23	28	-4
拉高出货	3	4	2	-4
亏本	0	1	0	-4
烂泥	4	2	3	-4
电梯	1	0	1	-5
追高	4	1	5	-5
跌停	32	47	68	-5

就跌停	0	1	3	-7
再不卖	0	0	1	-8
就是废	0	0	1	-8

表 4.4 积极词汇权值计算结果

词汇	小涨	涨	大涨	权值
翻番	1	0	0	1
老鸭头	2	0	0	1
持久战	1	0	0	1
且行且珍	4	0	1	2
未来可期	1	1	0	3
看多	7	4	1	3
赚钱	21	10	4	3
牛市	16	5	4	3
买进	23	8	6	3
加油	41	20	10	3
不卖	18	2	6	3
加仓	25	15	6	3
大涨	34	13	11	3
买买买	9	3	3	3
起飞	21	10	7	3
胜利	27	16	9	3
净流入	15	10	6	3
利好	54	20	24	3
好事	5	4	2	3
成功	24	17	10	3
拉升	29	18	13	3
看好	31	13	17	4
上涨	39	31	21	4
锁仓	2	3	1	4
上车	19	10	11	4
全仓	9	7	6	4
增持	31	4	22	4
再创辉煌	0	1	0	4
赚大	4	4	3	4
建仓	6	3	5	4
龙头	18	7	19	5
涨停	162	125	191	5
一字板	5	7	7	5
高校改革	2	2	3	5

涨涨涨	1	0	2	6
连拉	0	1	1	6
封板	4	7	19	6
打板	3	1	10	6
只买不卖	0	0	1	8
扶持政策	0	0	1	8

二、程度副词权重

程度副词词性为中性，往往像修饰词一样放在属性词或者观点词前面，例如“直奔跌停而去”，“明天就种走势冲高回落直奔涨停”；“直奔”就是一个程度副词。

程度副词主要分为 6 类，第一级别为极其，第二级别为很，第三级别为超，第四级别为较，第五级别为稍，比一般语气要重，第六级别为欠，比一般语气轻；第一级别的权值最高，第六级别的权值最低；如图 4.12-4.17 所示。

一般语气的权值设为 1，为了既能够区分不同级别的程度副词，又要保证权值分布不要太离散；除了第六级别副词，其余的副词，相邻的两个级别的权值在数值上相差 1，因此第一级别副词权值为 6，第二级别副词权值为 5，第三级别副词权值为 4，第四级别副词权值为 3，第五级别副词权值为 2，第六级别副词权值设为 0.5。

中文程度级别词语 219(个数)

1. “极其|extreme / 最|most” 69

都
最
太
百分之百
倍加
备至
不得了
不堪
不可开交
不亦乐乎

图 4.12 第一级别程度副词

2. “很|very” 42

不过
不少
不胜
惨
沉
沉沉
出奇
大为
多
最
多多
——

图 4.13 第二级别程度副词

3. “超|over” 30
不为过
超
超额
超外差
超微结构
超物质
出头
多
浮
过
过度
过分
过火
超

图 4.14 第三级别程度副词

4. “较|more” 37
大不了
今天来个
多
更
更加
更进一步
继续
更为
还
还要
较
较比
较为

图 4.15 第四级别程度副词

5. “稍|-ish” 29
点点滴滴
多多少少
怪
好生
还
或多或少
略
快
快点
略加

图 4.16 第五级别程度副词

6. “欠|insufficiently”
半点
不大
不丁点儿
不甚
不怎么
聊
没怎么
轻度
轻轻地
悄悄地
弱

图 4.17 第六级别程度副词

三、基于句法结构的词汇权重更新

同一句股评中往往同时存在积极属性和消极属性的词汇，但是对整个股评情感属性的影响不同，这种影响又通常表现在语法结构上，因此需要结合语法结构分析情感极性，确定相应词汇权重，此外，同一个词汇在不同的句法结构中表达的情感倾向会发生变化；不同的语法结构代表了词汇单元之间不同的依存关系。事实上，我们在判断一个句子的情感时，我们不仅仅在想这个句子是什么情感，而且还会判断这个句子的类型（祈使句、疑问句还是陈述句？）；当我们在考虑句子中的每个词语时，我们不仅仅关注其中的积极词语、消极词语、否定词或者程度副词，我们会关注每一个词语（主语、谓语、宾语等等），从而形成对整个句子整体的认识；我们甚至还会联系上下文对句子进行判断。这些判断我们可能是无意识的，但我们大脑确实做了这个事情，以形成对句子的完整认识，才能对句子的感情做了准确的判断。也就是说，我们的大脑实际上是一个非常高速而复杂的处理器，我们要做情感分类，却同时还做了很多事情。

文本一般包括 4 种依存关系：主题+关键情感词；连接词+关键情感词；修饰词或程度副词+关键情感词；否定词+关键情感词；其中第二种依存关系较为复杂，因为不同的连接词，对直接影响句子的情感，甚至会造成句子前半部分与后半部分的情感不一致，主要包括并列、转折、递进等关系，存在非线性；所谓非线性，指的是词语之间的相互组合形成新的语义。事实上，我们的初步模型中已经简单地引入了非线性——在前面的模型中，我们将积极词语和消极词语相邻的情况，视为一个组合的消极语块，赋予它负的权值。其中转折关系最为复杂。

通过连接词体现不同句法结构对股评情感的影响，考虑连接词、转折词自身所携带的情感信息，包含有转折词的评论文本语句通常表达的情感信息都是不单一的。对于带有连接词的关键情感词，需要调整其权值。根据词频和 tf-idf 统计显示：“这么”、“就”、“就是”出现的频次较高；因此对这类词汇需要赋予相对应的权值。

并列关系表示前后情感值一样，前后表达的情感含义是一样或接近的，在整个语句表达上只存在一种情感；递进关系表示对前面情感的加强，后面部分是对前面部分的补充和加强，且表达的情感强度一般大于前面部分的情感强度，

与并列关系一样，在整个语句表达上，只存在一种情感倾向。

转折词则将语句情感分成了前后两个部分，它们所要表达的情感含义往往是相对立或者相反的，而且后部分的句子一般才是情感表达的重心。

例如：“怎么利空都行，按现在的股价还不如*st，难道不值得持有”，前面和中间部分都是负面的情感表达，最后部分则是正面的情感表达，且正面情感强度大于负面情感强度，如果单纯统计正面词汇和负面词汇数量，不能正确识别情感倾向，需要对疑问语气加重情感权值。

1、前者情感值大于后者情感值：

“方正一定会腾飞，大家不要着急，今天虽然下跌个点”，前面情感强度明显大于后面部分，且两者情感表达不一致，前面表达对股票的预期看好，后面表达的股价的下跌，但在表达的总体情感上，倾向于前面部分；对“虽然”，“一定”等词汇参照程度词，分别对应不同的权重，“一定”对应的权重要大于“虽然”对应的权重，这样可以保证前半句的情感值大于后半句的情感值。

2、前者情感值小于后者情感值：

“好久都不涨了，今天来个一骑绝尘!!!”，后半句的情感值明显大于前半句的情感值，从时间维度上分析，“今天”强调的是当下，“好久”是针对过去的表述，因此针对时间词汇的权重设定原则：今天大于昨天，当下大于过去；同样对于涉及时间的词汇也参照程度副词设置不同的权重。

3、后面情感否定前面情感

“此时不涨停，更待何时”、“不涨停，我不信”；“不涨，天理不容”，这些股评单纯从前面一句分析，分词工具得到的关键词是：不涨停，容易判定为消极的看跌情绪；但是结合后半句，则整个评论的情绪就变成积极的看涨情绪了。后面的情感部分直接否定了前面的情感部分；因此将“更待何时”、“我不信”、“天理不容”等词汇等同于成后置的否定词，即对前半句的情感值乘以-1，从而改变情感倾向。

4、否定词

否定词语在情感分析任务中发挥着十分重要的作用，它的使用可以使文本情感倾向发生彻底转变。

例如“罗马不是一天修成的，所以方正也不可能一飞冲天”，其中“不是”、“也不可能”就属于否定词范畴，因为否定词会使情感转变，所以将其权重设为-1。

5、标点符号

标点符号对股评情感的影响主要体现在感叹号与问号两个符号，感叹号一般体现了加强语气，一般不会改变股评的情感倾向；问号体现的语气较为多元，主要有 2 种：疑问语气和反问语气，疑问语气往往是表示疑惑，带有否定倾向；反问语气则是一种“否定之否定”的表达结构，往往是正话反说，带有肯定倾向；疑问语气和反问语气都是对情感倾向的加强。

例如：“为什么不退市？”，虽然“退市”前面又否定词“不”，但是放在反问句中，实则是对退市的肯定；因此我们将“为什么不”作为一个程度副词，用来加重对“退市”这个词汇的肯定。

第五节 构建货币政策领域词典

在我国，央行货币政策调节会对股票市场的发展产生影响，央行货币政策沟通起步较晚，发展也尚未成熟，但其作为一种新型的货币政策调节方式，在宏观调控中的地位越来越重要，我国央行 2001 年开始按季度公布《货币政策执行报告》；央行政策沟通有利于市场参与者对货币市场走势形成更为合理的判断和预期，从而进行更为有效的市场交易。

相比于股评，货币政策执行报告和相关的评价文本词语表达和句法较为规范，表达的情感也较明确，没有太多的歧义；且属性词、观点词的使用和搭配相对固定，因此适用于基于词典的情感评价方法。

需要注意的是，无论是传统的货币政策调节工具还是新型的货币政策调节工具，其对股票市场的影响均存在非对称性。主要体现在以下几个方面：政策调节方式、政策调节内容、股市周期。

在指数构造中，为了保证措辞可以传达出带有明确指向性的有效信息，要求相关措辞在不同货币政策时期出现的频率高低与货币政策由宽松到紧缩有一致或者相反的方向性，即具有单调性。具体选取标准为，具有一定代表性，能够体现货币环境的变化。

在稳中求进的大基调下，央行作为货币供给的总阀门以及政策传导的中枢，根据经济和社会发展的需求，调节货币的供给，达到与经济发展相匹配的要求。

2019 年受中美贸易战等因素影响，我国的经济存在下行压力；2020 年新冠疫情突袭，加重了经济发展的压力，为应对负面影响，加大了逆周期调节，进

一步实施“定向宽松”的策略，增加了广义货币的供给。

针对广义货币供给的调节变化，货币政策执行报告中会有不同的表述，例如：稳中趋松时的表述：2019年8月：在稳健货币政策基调不变的基础上，逆周期调节的力度或将加大，货币政策也将运用多种政策工具相机而动，进一步加大预调和微调的力度和频率；2019年9月：在“普遍降准”与“定向降准”的提法上，更是传递出货币政策预调微调力度较大，普遍性降准可期。

稳健中性时的表述：2019年2月：国务院总理李克强在国务院常务会议上重申，稳健的货币政策没有变，也不会变。我们坚决不搞“大水漫灌”；2019年2月：稳健的货币政策是经济稳定发展、人民生活水平稳步提高的必要前提，是社会主义市场经济的重要特征，当前稳健货币政策的取向并没有发生改变。

稳中趋紧时的表述：2019年7月：我国应坚持以我为主原则，通过深化改革不断提升国内经济活力，对“大水漫灌”式宽松政策保持高度警惕；2019年7月：从基本面来说，如此宽松的资金面不可持续。

一、文本收集与分词

本节以2019至2021年中国人民银行每季度的货币政策执行报告、每月的货币政策专业评价以及大事记为文本基础，进行文本分析以及属性标化。

通过结巴分词软件，对文本进行分词，从而提取更具有针对性的央行货币政策措辞，尤其是在季度政策执行报告中和月度货币政策评价中都出现的词汇，作为代表性词汇，收纳进货币政策领域词典；并对措辞的强度进行划分，构造基础的货币政策类词典；例如：“降低”在货币政策领域属于积极类的词汇；

二、确定短语情感极性

（一）选择特征短语

在央行货币政策的实际干预中，兼具价格型及数量型两种实践。常用到的数量型货币政策是调节存款准备金率、公开市场操作及调节货币发行量等；常用到的价格型货币政策是调节基准利率，而银行间回购利率具有较强的市场性、相关性、基础性及稳定性，是较为优良的短期基准利率代表，货币政策与股市的传导机制如图4.18—4.22所示。




图 4.18 贷款利率影响股市的机制




图 4.19 货币供应量影响股市的机制




图 4.20 准备金率影响股市的机制




图 4.21 政策传导渠道影响股市的机制




图 4.22 政策工具影响股市的机制

除了宏观层面的影响，在微观层面上，基准利率的变动会对上市公司的预期利润产生作用，从而对我国股票市场价格产生作用。基准利率较低时反映出政府在积极刺激经济的发展，上市公司会因此乐观地预见到上市公司的发展利润会因为经济的发展而上升，从而股票价格上涨；相反地，较高的基准利率是政策为消除通货膨胀抑制经济过分发展而实行的政策，上市公司会因此悲观地预见到上市公司因为经济发展受到控制而发展缓慢，从而股票价格下跌。

根据货币政策包含的不同信息，将政策分为 3 类：稳中趋松、适中稳健、稳中趋紧类货币政策；如果央行在当期下调基准利率或存款准备金率，或通过逆回购注入流动性，则视为货币政策稳中趋松；如果央行在当期上调基准利率或存款准备金率，或通过正回购减少流动性，则视为货币政策稳中趋紧。若在当期不存在上述操作或者操作是为了中性回归，则视为货币政策中性期。

相比于股评，货币政策的词语、句法表达较为规范；基于基础词典，利用 Python 软件的 jieba 分词功能对所有句子进行分词处理，去除数字、符号和语气词后，组合、提取出合理的 N 字短语。一般选择四个方面的措辞进行频率统计：一是表示货币政策基调的措词；二是反映货币信贷环境的措词；三是关于物价水平的措词；四是表示经济增长的措词；并且按照措辞的方向及强度的不同进行赋值，从统计结果可以看出，有些措辞虽然使用的频率不高，但是传达的信息却十分重要，因此不能依据频率，进行强度赋值，选用 Tf-idf 值作为特征，选择措辞短语，最终共提取出 150 个短语，如图 4.20 所示。

['('大水漫灌', 0.0585253285490762), ('流动性合理充裕', 0.0506579450381356), ('逆周期调节', 0.4052403500305846), ('更加灵活适度', 0.30393476702281390), ('力度', 0.18033806185542373), ('坚决', 0.16948730014144067), ('疏通货币政策传导', 0.15196738351144068), ('定向降准', 0.15196738351144068), ('再贷款', 0.15196738351144068), ('灵活精准', 0.15196738351144068), ('合理适度', 0.15196738351144068), ('精准滴灌', 0.10131158900762711), ('精准导向', 0.10131158900762711), ('松紧适度', 0.10131158900762711), ('精准施策', 0.10131158900762711), ('预期管理', 0.10131158900762711), ('预期', 0.08060743419605933), ('闸门', 0.07869116216211965), ('增速', 0.07826111471631356), ('利率', 0.0737353754877968), ('可持续性', 0.069408936230526), ('宏观调控', 0.06748424954991325), ('稳健', 0.052940782211016946), ('不会', 0.0506579450381356), ('逆风', 0.05142935145313559), ('把好货币闸门', 0.0506579450381356), ('流动性的合理充裕', 0.0506579450381356), ('大气力', 0.0506579450381356), ('宽松空间进一步打开', 0.0506579450381356), ('依旧宽松', 0.0506579450381356), ('保持经济社会持续健康发展', 0.0506579450381356), ('经济增速基本匹配', 0.0506579450381356), ('通胀预期高点显著下降', 0.0506579450381356), ('操作方式可适度宽松', 0.0506579450381356), ('重返实体经济', 0.0506579450381356), ('扩大总量供给', 0.0506579450381356), ('流动性宽松', 0.0506579450381356), ('货币平稳增长', 0.0506579450381356), ('边际宽松倾向', 0.0506579450381356), ('稳货币', 0.0506579450381356), ('降息仍可期', 0.0506579450381356), ('宽松或有持续', 0.0506579450381356), ('保持灵活性', 0.0506579450381356), ('通胀水平高于预期', 0.0506579450381356), ('不急转弯', 0.0506579450381356), ('政策稳健', 0.0506579450381356), ('利率多数走高', 0.0506579450381356), ('更注重灵活适度', 0.0506579450381356), ('疏通货币政策传导渠道', 0.0506579450381356), ('宽货币', 0.0506579450381356), ('社会融资规模', 0.0506579450381356), ('灵活运用多种货币政策工具', 0.0506579450381356), ('疏通货币政策的传导渠道', 0.0506579450381356), ('守好水龙头', 0.0506579450381356), ('警惕通胀预期', 0.0506579450381356), ('央行降息', 0.0506579450381356), ('提升货币政策工具精准性', 0.0506579450381356), ('低利率时代', 0.0506579450381356), ('信贷空间充足', 0.0506579450381356), ('增强金融和债务风险', 0.0506579450381356), ('利率下行空间终究是有限的', 0.0506579450381356), ('提升货币政策直达性', 0.0506579450381356), ('流动性有所偏紧', 0.0506579450381356), ('回归稳健和适度', 0.0506579450381356), ('利率中枢抬升', 0.0506579450381356), ('发力', 0.0506579450381356), ('大幅宽松的可行性并不大', 0.0506579450381356), ('暂停逆回购操作', 0.0506579450381356), ('过紧日子', 0.0506579450381356), ('重启暂停近两个月的逆回购操作', 0.0506579450381356), ('资金利率小幅上行', 0.0506579450381356), ('释放一定流动性', 0.0506579450381356), ('定向宽松', 0.0506579450381356), ('存量', 0.0506579450381356), ('把握节奏', 0.0506579450381356), ('补充流动性', 0.0506579450381356), ('寻找平衡', 0.0506579450381356), ('适时适度调节', 0.0506579450381356), ('保持松紧适度', 0.0506579450381356), ('中框回归', 0.0506579450381356), ('宽松政策保持适度警惕', 0.0506579450381356), ('不需要继续降准', 0.0506579450381356), ('政策不会进一步宽松', 0.0506579450381356), ('增强底线思维', 0.0506579450381356), ('通胀可控', 0.0506579450381356), ('适时退出', 0.0506579450381356), ('强调适度', 0.0506579450381356), ('过于宽松', 0.0506579450381356), ('利率可控', 0.0506579450381356), ('投放节奏过快', 0.0506579450381356), ('注重结构性', 0.0506579450381356), ('回归中性', 0.0506579450381356), ('适时调节', 0.0506579450381356), ('利率继续提高', 0.0506579450381356), ('长期均衡', 0.0506579450381356), ('全面', 0.04766125869957627), ('科学', 0.04726741325754238), ('加强', 0.04541018373042373), ('货币', 0.04503101662076271), ('下降', 0.04272094510677966), ('持续', 0.04187816218016949), ('羊群', 0.041345520871101694), ('进一步', 0.04089478330084746), ('断崖', 0.03978736502213559), ('后遗症', 0.03868641113351095), ('政策', 0.03835314117322034), ('过紧', 0.03772654821275424), ('必要性', 0.03736380206351995), ('风险管理', 0.0362841669491941), ('设定', 0.0349154670241525), ('适时', 0.033545514285127115), ('负面影响', 0.0329296800775), ('放缓', 0.03224953932857790), ('绝不', 0.030415457021694917), ('调整', 0.030227997266042372), ('防范', 0.03010813037288133), ('不宜', 0.0299843890646305), ('下行', 0.029614111659830508), ('下调', 0.02871012231682203), ('供给', 0.028263197027838985), ('适度', 0.028004326147457624), ('把握', 0.0275718373673729), ('防止', 0.02642513144016949), ('幅度', 0.026270889226525422), ('效应', 0.0260778660059322), ('宽松', 0.025912595209491525), ('合理', 0.025170991622161017), ('坚持', 0.024638030153855933), ('当前', 0.02357746804322034), ('实际', 0.022473514798989305), ('实际', 0.021851637887415256), ('选择', 0.02182536735779661), ('较大', 0.02131481180470399), ('调整', 0.020434314337288133), ('正在', 0.019732227952499997), ('继续', 0.018062310410463054), ('增长', 0.017961094527118643), ('出现', 0.016283762684703388)]

图 4.23 Tf-idf 值最大前 150 个短语措辞

不同的货币环境对应不同的政策、信贷、物价环境，是与相应的发展

水平匹配的，如表 4.5 所示。在措辞类型的选择上主要包括反映经济发展的方向、要求、基调、货币政策调节的方向、物价走势和货币政策调节渠道等相关措辞，实现了对不同货币政策调节方式的具体量化表述：

表 4.5 不同货币环境的特征

货币环境	政策基调	信贷环境	宏观经济	物价水平
稳中趋松	灵活宽松	低利率时代	稳增长	通胀位于全年顶部
适度中性	中枢回归	不松不紧	经济社会持续健康发展	通胀可控
稳中趋紧	增强底线思维	利率中枢抬升	保持经济运行在合理区间	通胀预期高点显著下降

（二）确定短语情感极性

对于样本中出现过两次或多次的 N 字短语，利用在各类倾向出现的次数来衡量其属于某一主题及某一倾向（MP：宽松，稳健及紧缩）的概率，如公式 4.2 所示：

$$p_n^{c,i} = \frac{f_n^{c,i}}{f_n} \quad (4.2)$$

其中， f_n 表示 N 字短语出现的总次数， $f_n^{c,i}$ 表示短语在评论文章 c 倾向 i 出现的次数，则是对应倾向中短语出现的频率；i 的集合为（稳中趋松，适中稳健，稳中趋紧）；

显著性：措辞在政策紧缩期和政策宽松期所出现的频率必须存在显著差异；单调性：宽松期比中性期，中性期比紧缩期，宽松期比中性期的均值差应同正同负，即满足严格单调性；或者虽宽松比中性或者中性比紧缩的均值与其余两对异号，但其明显不显著，即差异不明显；这可以措辞类型可以传达出一个相对稳定的货币政策方向。

根据计算公式进行词语属性划分，短语在哪一类中出现的频率最大，则词语属性为该分类。例如，“流动性合理充裕”在样本中共出现了 18 次，其中 17 次（94.444%）出现在被分类为货币政策——稳中趋松的评论文章中，只有 1 次（0.056%）出现在被分类为货币政策——适中稳健的评论文章中，如表 4.6 所示，因此其属性归为稳中趋松。

表 4.6 短语出现次数统计表

短语	稳中趋松	适度中性	稳中趋紧
流动性合理充裕	17	1	0
逆周期调节	16	0	1
贷款利率下降	10	0	0
更加灵活适度	9	0	0
再贷款	9	0	0
再贴现	9	0	0
社会融资规模	9	0	0
灵活开展公开市场操作	8	0	0
降准	8	0	0
疏通货币政策传导	6	0	0
灵活精准	4	0	0
合理适度	4	0	0
松紧适度	4	1	0
灵活适度	3	0	0
融资成本明显下降	3	0	0
直达实体经济	3	0	0
稳中求进	2	0	0
定向降准	2	1	0
精准滴灌	2	0	0
宽信用	2	0	0
精准导向	2	0	0
可持续性	2	0	0

从表4.6可以看出：疏导货币政策传导、再贴现、再贷款、流动性合理充裕、加强逆周期调节、更加灵活适度、合理适度等措辞出现的频率，在不同货币政策时期的特征较为显著，这为进一步构建央行沟通指数提供了很好的参考与指向。

从统计结果可以看出，流动性合理充裕出现的次数最多，在9个季度货币政策执行报告中均有出现，说明从2019年至2021年第一季度，货币环境总体上略宽裕，但是从每季度货币政策执行报告以及每个月的评价文章中的措辞变化可以看出，每个月的货币供给增速是存在一定差异的；货币政策执行报告比机构的评价更具有权威性，因此我们从货币政策报告中，选取特征性显著的短语措辞进行补充，统计相应短语出现次数并进行归类，如表4.7-4.9所示。

表 4.7 适度中性类别的短语

短语	稳中趋松	适度中性	稳中趋紧
补充流动性	0	1	0
寻找平衡	0	1	0
防范“羊群效应”	0	1	0
适时适度调节	0	1	0
中枢回归	0	1	0
宽松政策保持高度警惕	0	1	0

表 4.8 稳中趋紧类别的短语

短语	稳中趋松	适度中性	稳中趋紧
不需要继续降准	0	0	1
政策不会进一步宽松	0	0	1
增强底线思维	0	0	1
M2 增速放缓	0	0	1
通胀可控	0	0	1
适时退出	0	0	1
强调适度	0	0	1
过于宽松	0	0	1
利率过低	0	0	1
投放节奏过快	0	0	1
更注重结构性	0	0	1
渐归中性	0	0	1
适时微调	0	0	1
紧缩概率提高	0	0	1
长期均衡	0	0	1

表 4.9 稳中趋松类别的短语

短语	稳中趋松	适度中性	稳中趋紧
增加金融和债务风险	1	0	0
利率下行空间终究是有限的	1	0	0
继续暂停逆回购操作	1	0	0
过紧日子	1	0	0
资金利率小幅上行	1	0	0
流动性有所偏紧	1	0	0
负面影响	1	0	0
回归稳健和适度	1	0	0
利率中枢抬升	1	0	0
利率多数走高	1	0	0

不搞“大水漫灌”	10	2	1
牢牢守住风险底线	2	0	0
守住不发生系统性金融风险的底线	2	0	0
守住不发生系统性风险的底线	2	0	0

三、短语权重赋值

在确定短语的情感极性后，需要对短语赋予强度权重，以便于建立货币政策强度序列；很多短语在不同季度的货币政策中均有出现，例如坚决不搞“大水漫灌”这个措辞在趋松、中性、趋紧类政策评价中均有出现；“把好货币闸门”之类的措辞在趋松、趋紧评价中均有出现；因此需要根据短语在不同季度货币政策中出现的次数，结合影响权重，进行加权计算。

2019 年至 2021 年第一季度，总共 9 个季度，每个季度的 M2 都是增长的，环比增长率在 1.3%-4% 之间，且 2020 年每个季度的同比增长率在 10% 左右，2019 年第一季度货币供应权重设为 1，每个季度递增 0.25 个权重，每年递增 1 个权重，以此类推 2020 年第一季度权重为 2，2021 年第一季度权重为 3；如表 4.10 所示：

表 4.10 季度权重

季度	权重
2019Q1	1
2019Q2	1.25
2019Q3	1.5
2019Q4	1.75
2020Q1	2
2020Q2	2.25
2020Q3	2.5
2020Q4	2.75
2021Q1	3

短语强度的计算方法：1 个短语在每个季度出现的次数，乘以该季度对应的权重，除以总次数，得到的值即为该短语的强度值，如公式 4.3 所示，计算结果如表 4.11 所示。

$$\text{短语强度值} = \frac{\sum \text{季度权重} \times \text{出现次数}}{\text{总的出现次数}} \quad (4.3)$$

表 4.11 短语强度值

短语	类型	符号	强度
灵活适度	趋松	+	2.3
松紧适度	趋松	+	1.3
逆周期调节	趋松	+	1.7
流动性合理充裕	趋松	+	2
再贷款	趋松	+	2.2
再贴现	趋松	+	2.2
社会融资规模	趋松	+	1
疏通货币政策传导	趋松	+	1.6
融资成本明显下降	趋松	+	2.1
直达实体经济	趋松	+	2.3
稳中求进	趋松	+	1
降准	趋松	+	2
精准滴灌	趋松	+	2.1
宽货币	趋松	+	2.3
货币平稳增长	趋松	+	1.25
边际放松倾向	趋松	+	1.25
宽松	趋松	+	2.3
灵活运用多种货币政策工具	趋松	+	1
宽信用	趋松	+	1.9
精准导向	趋松	+	2.6
可持续性	趋松	+	2.9
利率平稳运行	趋松	+	1
低利率	趋松	+	2.25
降息	趋松	+	2.1
不搞“大水漫灌”	趋紧	-	-1
增加金融和债务风险	趋紧	-	-1
利率下行空间终究是有限	趋紧	-	-1
暂停逆回购操作	趋紧	-	-1
过紧日子	趋紧	-	-1
资金利率小幅上行	趋紧	-	-1
流动性有所偏紧	趋紧	-	-1
负面影响	趋紧	-	-1
回归稳健和适度	趋紧	-	-1

利率中枢抬升	趋紧	-	-1
利率多数走高	趋紧	-	-1
守住风险底线	趋紧	-	-1
守住不发生系统性金融风险的底线	趋紧	-	-1
守住不发生系统性风险的底线	趋紧	-	-1
守好水龙头	趋紧	-	-1
补充流动性	适中	0	0
寻找平衡	适中	0	0
防范“羊群效应”	适中	0	0
适时适度调节	适中	0	0
中枢回归	适中	0	0
宽松政策保持高度警惕	适中	0	0
不需要继续降准	趋紧	-	-1
政策不会进一步宽松	趋紧	-	-1
底线思维	趋紧	-	-1
M2 增速放缓	趋紧	-	-1
通胀可控	趋紧	-	-1
适时退出	趋紧	-	-1
强调适度	趋紧	-	-1
过于宽松	趋紧	-	-1
利率过低	趋紧	-	-1
投放节奏过快	趋紧	-	-1
注重结构性	适中	0	0
渐归中性	适中	0	0
适时微调	适中	0	0
紧缩概率提高	趋紧	-	-1
长期均衡	适中	0	0
风险管理	趋紧	-	-1
把握好度	趋紧	-	-1

货币政策中的程度副词主要集中在“极其”和“较”这两个级别，例如“平稳增长”、“适度增长”与“合理增长”，这三个词里面的程度副词代表了不同程度的货币供给增长；相比于股评的语气，政策报告及评论文章表达相对规范，不掺杂强烈的个人情感，因此，相应的程度副词权重不适合设定太大。

表 4.12 程度副词权重

程度副词	权重
更加	2

进一步	2.1
全面	2
坚决	2
增强	2

根据构建的货币词典，利用分词技术，可以判定相应政策报告或者评论表达的货币供给倾向；在确定货币供给倾向的基础上，需要对部分词汇进行影响力修正，例如部分趋紧（或者趋松）属性的词汇在趋松（趋紧）类文章中出现，但并未改变整个文章的属性，因此对此类词汇的在趋松期（或者趋紧期）影响力设置要偏低，如表 4.13 所示。

表 4.13 不同货币环境的影响权重

短语	不同期间影响权重		
	趋松	中性	趋紧
松紧适度	1	0.5	0
逆周期调节	1	0	0.5
流动性合理充裕	1	0.5	0
不搞“大水漫灌”	0.5	0	1
增加金融和债务风险	0.5	0	1
利率下行空间终究是有限	0.5	0	1
暂停逆回购操作	0.5	0	1
过紧日子	0.5	0	1
资金利率小幅上行	0.5	0	1
流动性有所偏紧	0.5	0	1
负面影响	0.5	0	1
回归稳健和适度	0.5	0	1
利率中枢抬升	0.5	0	1
利率多数走高	0.5	0	1
守住风险底线	0.5	0	1
守住不发生系统性金融风险的底线	0.5	0	1
守住不发生系统性风险的底线	0.5	0	1
守好水龙头	0.5	0	1

第六节 本章小结

本章主要完成了股评爬取、清洗与分词，以词频、Tf-idf 为特征，选取种子词，通过词向量、wordexpansion 等工具实现了大规模词汇的自动扩充，并用 LSTM 方法进行了验证，实现了金融领域词典的更新和扩充；以股评当日的涨跌幅度为参照，融合了中文句法特点，考虑程度副词和转折词的影响，对各类词汇赋予了不同的权重值，构建和扩充了金融股评领域、货币领域词典。

第五章 序列分析及预测评价

基于上章构建的货币领域和金融领域词典，提取文本关键词，与领域词典中词汇进行匹配，按月加总关键词权值，作为该月的政策强度，建立货币政策月强度序列；用同样的方法建立上证月指数变化序列；通过文本中关键词表述的变化，体现每个月货币政策强度和上证指数的变化规律；在此基础上，构建 3 变量 VAR 模型，分析货币政策强度、上证指数与个股月收益率之间的影响以及该模型的预测能力。

选取 2019 年-2020 年的 1 支热点题材股票——方正科技，爬取该股股评，同样利用词典匹配法分析，按天加总权值，计算每天股评的情感强度，建立该股情感强度序列；构建 4 变量 VAR 模型，分析情感强度、发帖数量、日成交量与个股日收益率之间的影响以及该模型的预测能力。

第一节 构建货币政策强度序列

货币政策是我国央行调控宏观经济的手段，投资者需紧跟国家的政策方向，货币政策的变化会对股市造成一定的影响，同时股票市场的波动会反向影响货币政策的实施渠道和实施效果。

货币供应量的变化会直接影响到股票价格的波动，通常增加货币供应量意味着国家实行扩张性货币政策，促进资金流向股市，从而推动股票价格增长；减少货币供应量意味着国家实行紧缩性货币政策，将引起股市下跌的行情。因此，通常来说，货币供应量与我国股市波动有一定的相关关系。根据流动性大小，央行将货币的供应量划分为三个层次：一是 M_0 （流通中的现金），即银行体系外的单位现金和居民手持现金的总和；二是 M_1 （狭义货币供应量），即 M_0 与单位在银行的可开支票进行支付的活期存款的总和；三是 M_2 （广义货币供应量），广义货币 M_2 相比 M_1 多了定期存款，而定期存款大多存在银行，银行利用存款进行借贷和投资，部分投资者会通过向银行贷款，获得资金，投资股市，当银行的存款资金流入股市会在短期内对股市的产生较大的推动作用，而且广义货币供应量 M_2 最能体现货币当局的政策立场，因此选取 M_2 代表货币供给量。

人民银行主要的货币政策操作方法有：公开市场操作、存款准备金、利率

和常备借贷便利等。货币传输渠道，这些货币政策可以有效传导到股票市场。

根据第四章建立的货币政策领域词典，不同的措辞，强度是不一样的，因此政策方向也不一样；例如 2019 年前三季度的相关报告中，关于货币政策的总体要求是“松紧适度”，在 2019 年 12 月的相关报告中，总体要求变为“灵活适度”，从“松紧适度”到“灵活适度”，货币政策总体的要求要偏积极和宽松。

“松紧适度”里有一个‘紧’字，但“紧”字没有了，表明货币政策会中性偏松一点，而且会更加灵活。

“精准滴灌”、“定向增加”、“提高资金的使用效率”突出对流通中的现金流较高水平的利用，降低相关行业内公司集中资本的成本需求，扩大公司以后的预期营业利润；

从央行的操作层面来看，不同月度，措辞表达也有所不同。例如：“预调微调”代表在货币政策稳健的大前提下，货币供给的调节幅值相对不会太大；“适时适度”意味着政策调节会比较灵活，但调整的幅度相对不大；“加大逆周期调节力度”意味着相比于前一个月，调整的幅度相对较大。

表 5.1 月度货币政策强度属性

月度	货币政策强度	部分相应政策的表述
201902	适度中性	寻找平衡
201903	稳中趋松	流动性合理充裕
201904	稳中趋紧	政策不会进一步宽松
201905	稳中趋松	加强逆周期调节
201906	稳中趋松	货币环境趋松
201907	适度中性	中枢回归
201908	稳中趋松	逆周期调节力度或加大
201909	稳中趋松	加大逆周期调节力度
201910	稳中趋紧	增强底线思维
201911	稳中趋松	央行降息
201912	稳中趋松	科学稳健的宏观政策逆周期调节
202001	稳中趋松	全面降准
202002	稳中趋松	利率下调幅度较大
202003	稳中趋松	加大了逆周期调控力度
202004	稳中趋松	低利率时代
202005	稳中趋松	释放一定流动性
202006	稳中趋松	利率的持续下行
202007	稳中趋紧	强调适度
202008	稳中趋松	提升货币政策直达性

202009	稳中趋松	宽信用
202010	稳中趋紧	紧缩概率提高
202011	稳中趋松	精准导向
202012	稳中趋松	进一步提升货币政策工具精准性
202101	稳中趋松	实际利率下降
202102	稳中趋松	利率多数走高
202103	稳中趋松	依旧宽松

关于利率政策、准备金政策的调整，对货币供给的影响效应较强，能较好地反映当期的货币政策行动；近两年央行贷款政策的调整次数也曾上升趋势，主要涉及利率市场化改革，降低融资成本，影响上市公司的风险偏好，增强上市公司获得资金的意愿，这类政策往往配合产业政策布局。

当国家的中央银行调整货币政策时，可能会对该国的资本市场造成相应的影响。货币政策主要涉及利率、货币供应量、存款准备金率、货币政策工具以及货币政策传导渠道，央行对基准利率的调整会直接影响存款资金的收益及贷款资金的成本。货币政策强度序列代表“言”，实际的货币供给代表“行”，如果政策强度序列能够很好地体现货币政策的调节趋势，说明言行偏离程度小，表示通过文本挖掘建立序列的方法是适宜的，反之言行偏离程度大时，说明该方法可行性较低。

央行通过货币政策工具间接调节利率、货币供给量，畅通传输通道，提高货币的利用水平，影响流动性；主要包含中期借贷便利利率、中央银行票据、常备借贷便利等工具；

中期借贷便利利率发挥中期政策利率的作用，通过调节向金融机构中期融资的成本来对金融机构的资产负债表和市场预期产生影响，引导其向符合国家政策导向的实体经济部门提供低成本资金，促进降低社会融资成本。

中央银行票据是央行为调节商业银行超额准备金而向商业银行发行的短期债务凭证，其实质是中央银行债券，是为了突出其短期性特点，中央银行发行的央行票据是中央银行调节基础货币的一项货币政策工具，目的是减少商业银行可贷资金量。商业银行在支付认购央行票据的款项后，其直接结果就是可贷资金量的减少。

常备借贷便利是央行正常的流动性供给渠道，主要功能是满足金融机构期限较长的大额流动性需求。对象主要为政策性银行和全国性商业银行。期限为1到3个月。利率水平根据货币政策调控、引导市场利率的需要等综合确定。

常备借贷便利以抵押方式发放，合格抵押品包括高信用评级的债券类资产及优质信贷资产等。

按月收集评论文本，基于构建好的词典，对每个月的文本进行关键词的识别，识别出能够明确体现货币政策松紧或者体现文本主旨的关键词，对这些关键词的权值进行加总处理，再对每个月的权值序列，进行归一化处理，从而建立货币政策强度指数序列，该序列应能够体现政策特性、变化、方向及强度。

近两年广义货币的供给有一定的增长趋势；为了消除这种趋势，我们通过比较每个月的增量供给，来描述货币供给松紧趋势；关于政策强度的量化比较方法，通过相对增量来衡量，即每个月的政策强度变化仅以上一月的政策强度作为比较基准，计算结果如表所示。

表 5.2 货币政策强度序列

月份	加总权值	归一化
201902	0.5	0.033333
201903	6	0.4
201904	-2	-0.13333
201905	2.5	0.166667
201906	9	0.6
201907	-0.5	-0.03333
201908	5	0.333333
201909	5.5	0.366667
201910	-2	-0.13333
201911	5	0.333333
201912	7.5	0.5
202001	11	0.733333
202002	2.5	0.166667
202003	15	1
202004	3.5	0.233333
202005	2	0.133333
202006	10	0.666667
202007	-3	-0.2
202008	3.5	0.233333
202009	8	0.533333
202010	-4	-0.26667
202011	7	0.466667
202012	4.5	0.3
202101	8	0.533333




图 5.1 货币政策强度序列趋势与实际增量趋势对比

从图 5.1 中可以看出，两者趋势基本贴合，该序列可以准确描述货币政策强度的相对变化，说明基于词典匹配建立序列的方法可行。

第二节 构建上证指数月收益率序列

基于金融领域词典，构建上证指数月收益率序列；构建方法也是通过对每月专业股评中关键短语的强度进行汇总计算，得到每个月强度值，将月评论的强度值与指数增长率相对应，生成相应的序列。评论文本选取的范围是 2019 年至 2021 年第 1 季度的每个月专业机构的股评文章。

表 5.3 月评论强度分类

月度	评论强度	部分相应评论
201902	强烈看涨	预期加强，强势上攻
201903	看涨	增量资金跑步入场
201904	中性	休整压力增大
201905	看跌	下行压力较大
201906	弱势看涨	看涨心态再度回归
201907	看跌	缺乏基本面
201908	看跌	避险情绪升温，再度跌破
201909	中性	整理格局
201910	中性	维持振荡
201911	看跌	偏弱运行
201912	看涨	大概率中枢上移，中期看涨
202001	看跌	股指承压
202002	中性	维持振荡
202003	看跌	下跌趋势

202004	看涨	久违反弹
202005	看跌	向上难度较大
202006	看涨	振荡上行，金融支持
202007	强势看涨	突然狂飙，牛市基本确立
202008	中性	上有制约，下有支撑
202009	看跌	易跌难涨
202010	中性	重回振荡
202011	看涨	上涨态势良好
202012	看涨	中期向上
202101	中性	或将区间振荡
202102	看涨	看涨情绪高昂
202103	看跌	全线大跌

计算结果如表所示：

表 5.4 上证指数月收益率序列

月份	加总权值	增长率	收益率
201902	15	0.137	1.137
201903	6	0.0548	1.0548
201904	0	0	1
201905	-4.5	-0.0411	0.9589
201906	2	0.018267	1.018267
201907	-3	-0.0274	0.9726
201908	-3	-0.0274	0.9726
201909	0.5	0.004567	1.004567
201910	0.5	0.004567	1.004567
201911	-2	-0.01827	0.981733
201912	7	0.063933	1.063933
202001	-2.5	-0.02283	0.977167
202002	0	0	1
202003	-4	-0.03653	0.963467
202004	3.5	0.031967	1.031967
202005	-1.5	-0.0137	0.9863
202006	7	0.063933	1.063933
202007	10.5	0.0959	1.0959
202008	0	0	1

202009	-3	-0.0274	0.9726
202010	0	0	1
202011	5	0.045667	1.045667
202012	3	0.0274	1.0274
202101	0	0	1
202102	2	0.018267	1.018267
202103	-2.5	-0.02283	0.977167




图 5.2 上证指数月收益率趋势与实际趋势对比

从图 5.2 中可以看出，两者的趋势基本一致，该序列可以准确描述上证指数月收益率的相对变化，也证明了基于词典匹配建立序列的方法可行。

第三节 个股月收益率序列

近两年，上证的热点题材主要涉及芯片、半导体、人工智能及券商等，因此选取 1 支资金盘子较小且属于热点题材的股票，具有此类特征的股票容易受资金进出影响且具备一定的热度。

本文选取方正科技（600601）作为分析对象，提取 2019 年至 2012 年 3 月的月收盘价，生成收益率序列，如图所示。




图 5.3 方正科技月收益率趋势

第四节 基于 VAR 模型的上证指数月收益率分析

一、序列统计分析

首先对前面建立的 3 个序列进行描述性统计，结果如表 5.3 所示。

表 5.5 序列统计结果

序列	均值	标准差	最大值	最小值
货币政策强度序列	0.315	0.322	1	-0.287
上证指数月收益率序列	1.012	0.046	1.138	0.942
方正科技月度收益率序列	1.019	0.12	1.4	0.86

二、建立 VAR 方程

向量自回归 (VAR) 是基于数据的统计性质建立模型，VAR 模型把系统中每一个内生变量作为系统中所有内生变量的滞后值的函数来构造模型，从而将单变量自回归模型推广到由多元时间序列变量组成的“向量”自回归模型。VAR 模型是处理多个相关经济指标的分析与预测；VAR 模型 (Structural VAR, SVAR)，实际是指 VAR 模型的结构式，即在模型中包含变量之间的当期关系。

假设在 EViews 中 SVAR 模型为：

$$Ae_t = Bu_t$$

其中 e_t ， u_t 是 k 维向量， e_t 是简化式的残差，相当于前文的 ε_t ，而 u_t 是结构新息 (结构式残差)。A、B 是待估计的 $k \times k$ 矩阵。

(一) 序列平稳性分析

首先对生成的货币政策强度、上证指数月收益率、方正科技月收益率等 3 个序列, 进行平稳性检验, 导入 Eviews, 进行单位根检验, 如图 5.4~5.6 所示:

Null Hypothesis: M has a unit root
Exogenous: Constant
Lag Length: 0 (Automatic - based on SIC, maxlag=5)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-6.102342	0.0000
Test critical values:		
1% level	-3.724070	
5% level	-2.986225	
10% level	-2.632604	

*Mackinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
Dependent Variable: D(M)
Method: Least Squares
Date: 09/25/21 Time: 08:59
Sample (adjusted): 2 26
Included observations: 25 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
M(-1)	-1.269772	0.208079	-6.102342	0.0000
C	0.406212	0.088818	4.606433	0.0001

R-squared: 0.618185 Mean dependent var: 0.030667
Adjusted R-squared: 0.601584 S.D. dependent var: 0.602579
S.E. of regression: 0.317229 Akaike info criterion: 0.618230
Sum squared resid: 2.314580 Schwarz criterion: 0.715749
Log likelihood: -5.727870 Hannan-Quinn criter.: 0.545275
F-statistic: 37.23858 Durbin-Watson stat: 1.871635
Prob(F-statistic): 0.000003

图 5.4 货币政策强度序列单位根检验

Null Hypothesis: SZ has a unit root
Exogenous: Constant
Lag Length: 0 (Automatic - based on SIC, maxlag=5)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-4.821354	0.0007
Test critical values:		
1% level	-3.724070	
5% level	-2.986225	
10% level	-2.632604	

*Mackinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
Dependent Variable: D(SZ)
Method: Least Squares
Date: 09/25/21 Time: 09:01
Sample (adjusted): 2 26
Included observations: 25 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
SZ(-1)	-0.805031	0.166972	-4.821354	0.0001
C	0.809667	0.169412	4.779265	0.0001

R-squared: 0.502654 Mean dependent var: -0.006393
Adjusted R-squared: 0.481030 S.D. dependent var: 0.049938
S.E. of regression: 0.035375 Akaike info criterion: -3.735344
Sum squared resid: 0.029767 Schwarz criterion: -3.637834
Log likelihood: 48.69180 Hannan-Quinn criter.: -3.706299
F-statistic: 23.24545 Durbin-Watson stat: 2.054759
Prob(F-statistic): 0.000073

图 5.5 大盘指数月收益率序列单位根检验

Null Hypothesis: FZ has a unit root
Exogenous: Constant
Lag Length: 0 (Automatic - based on SIC, maxlag=5)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-5.246337	0.0003
Test critical values:		
1% level	-3.724070	
5% level	-2.986225	
10% level	-2.632604	

*Mackinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
Dependent Variable: D(FZ)
Method: Least Squares
Date: 09/25/21 Time: 09:02
Sample (adjusted): 2 26
Included observations: 25 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
FZ(-1)	-1.020894	0.194592	-5.246337	0.0000
C	1.031382	0.199904	5.167194	0.0000

R-squared: 0.544771 Mean dependent var: -0.008610
Adjusted R-squared: 0.524079 S.D. dependent var: 0.166368
S.E. of regression: 0.116731 Akaike info criterion: -1.381267
Sum squared resid: 0.313402 Schwarz criterion: -1.283757
Log likelihood: 19.25584 Hannan-Quinn criter.: -1.354222
F-statistic: 27.52406 Durbin-Watson stat: 2.164727
Prob(F-statistic): 0.000025

图 5.6 方正科技月收益率序列单位根检验

从图中可以看出, 3 个序列 t 检验的临界值为均小于相应的三个置信区间的临界值, 因此拒绝原假设, 该序列不存在单位根, 为平稳序列。

(二) 构建 VAR 模型

1、确定滞后阶数

VAR Lag Order Selection Criteria
Endogenous variables: M2 SZ FZ
Exogenous variables: C
Date: 10/23/21 Time: 10:38
Sample: 1 25
Included observations: 21

Lag	LogL	LR	FPE	AIC	SC	HQ
0	60.32737	NA*	8.54e-07*	-5.459750	-5.310532*	-5.427366
1	63.10257	4.493182	1.57e-06	-4.866912	-4.270042	-4.737376
2	68.91881	7.754984	2.27e-06	-4.563696	-3.519174	-4.337008
3	84.26132	16.07311	1.47e-06	-5.167745	-3.675570	-4.843905
4	91.87257	5.799044	2.44e-06	-5.035493	-3.095655	-4.614491
5	112.8568	9.992513	1.75e-06	-6.176842*	-3.789363	-5.658698*

* indicates lag order selected by the criterion
LR: sequential modified LR test statistic (each test at 5% level)
FPE: Final prediction error
AIC: Akaike information criterion
SC: Schwarz information criterion
HQ: Hannan-Quinn information criterion

图 5.7 滞后阶数确定准则




图 5.8 滞后 5 阶对应的特征值




图 5.9 滞后 3 阶对应的特征值

从图 5.8 和 5.9 中可以看出，根据滞后阶数选择准则，宜取 5 阶，但是 5 阶所对应的特征值，有 1 个在单位圆的边界上，会影响模型的稳定性；因此将

滞后阶数选择 3，从图中可以看出，所有的特征值都落在单位圆内，说明 VAR 模型通过平稳性检验。

2、VAR 方程估计

Vector Autoregression Estimates
Date: 09/25/21 Time: 09:03
Sample (adjusted): 4 26
Included observations: 23 after adjustments
Standard errors in () & t-statistics in []

	M	SZ	FZ
M(-1)	-0.250040 (0.22899) [-1.09193]	0.002612 (0.02375) [0.10997]	0.077791 (0.07678) [1.01317]
M(-2)	0.131512 (0.23108) [0.56913]	-0.045803 (0.02397) [-1.91081]	-0.044270 (0.07748) [-0.57137]
M(-3)	0.333158 (0.25468) [1.30817]	0.057107 (0.02642) [2.15164]	0.142273 (0.08539) [1.66612]
SZ(-1)	-2.406899 (2.74930) [-0.87546]	0.590903 (0.28520) [2.07192]	2.305637 (0.92183) [2.50115]
SZ(-2)	3.231486 (2.58450) [1.25029]	0.073484 (0.26811) [0.27408]	-0.222503 (0.86661) [-0.25675]
SZ(-3)	4.793931 (2.31932) [2.06896]	-0.288842 (0.24059) [-1.20055]	-0.837822 (0.77766) [-1.07736]
FZ(-1)	-0.027513 (0.85532) [-0.03217]	-0.056420 (0.08873) [-0.74860]	-0.326084 (0.28679) [-1.13702]
FZ(-2)	-1.633240 (0.87605) [-1.86432]	-0.154269 (0.09088) [-1.69758]	-0.169417 (0.29374) [-0.57677]
FZ(-3)	-2.063379 (0.94905) [-2.19523]	0.138780 (0.09845) [1.40966]	0.649377 (0.31821) [2.04070]
C	-1.589123 (3.28603) [-0.48556]	0.707022 (0.33880) [2.08685]	-0.456506 (1.09509) [-0.41870]
R-squared	0.497184	0.580710	0.465528
Adj. R-squared	0.149080	0.290432	0.095509
Sum sq. resid	1.135927	0.012223	0.127705
S.E. equation	0.295599	0.030564	0.099113
F-statistic	1.428265	2.000531	1.258120
Log likelihood	1.956931	54.07319	27.08995
Akaike AIC	0.699397	-3.832452	-1.486083
Schwarz SC	1.193090	-3.338758	-0.992390
Mean dependent	0.344928	1.005559	1.006783
S.D. dependent	0.320449	0.036402	0.104215
Determinant resid covariance (dof adj.)		4.77E-07	8.51E-08
Determinant resid covariance			89.17725
Log likelihood			-5.145848
Akaike information criterion			-3.664769
Schwarz criterion			

图 5.10 3 变量 VAR 方程估计结果

(三) 格兰杰因果关系检验

VAR Granger Causality/Block Exogeneity Wald Tests
Date: 09/25/21 Time: 09:04
Sample: 1 26
Included observations: 23

Dependent variable: M			
Excluded	Chi-sq	df	Prob.
SZ	5.342289	3	0.1484
FZ	6.113990	3	0.1062
All	6.373508	6	0.3827
Dependent variable: SZ			
Excluded	Chi-sq	df	Prob.
M	12.46740	3	0.0059
FZ	8.155064	3	0.0427
All	15.85098	6	0.0146
Dependent variable: FZ			
Excluded	Chi-sq	df	Prob.
M	5.559116	3	0.1351
SZ	6.552165	3	0.0876
All	9.488256	6	0.1479

图 5.11 格兰杰因果关系检验

1、货币政策强度与上证指数月收益率的关系

从图 5.11 中可以看出，在 5%的置信水平下，广义货币 M2 增长的变化构成了对上证指数月收益率变动的格兰杰因果关系，但不构成方正科技月收益率变

化的格兰杰因果关系；方正科技股价变化构成上证指数变动的格兰杰因果关系，说明增加的货币供给，有部分进入了股市，增强了购买力和流动性；方正科技有一定的操作热度，吸引了部分投资者买入。

货币政策对股票市场的主要影响是间接引导货币数量和资金流向，一定程度上改变了股市资金供求格局，从而影响了股市的波动；扩张性的国家宏观经济政策会提高货币供应量，可以使得流通中的现金流变多，降低上市公司筹资的成本，扩大预期营业利润，同样，也会引起部分闲散资金投入股市，从而影响股价。反之，在从紧的货币政策中，流通中的现金流减少，增加公司筹资成本，减少公司未来的预期效益，使大量资金抽离股票市场，将引起股票市场价格下跌的行情。货币供应量的不足会影响经济发展的速度，从而影响股票市场价格下跌的可能。

当然股市的收益不仅取决于货币供应量这一个因素，还取决于投资人对股市和上市公司未来的预期。每当国家实行积极的货币政策和相应的产业扶持政策时，股民对相关的股票未来持积极态度，预期会明显改善，不断增加投资，股票价格上升。从上市公司的角度看，基准利率的变动也会影响到上市公司的资金成本及经营状况，最终影响到上市公司的经营业绩及公司股价。当央行基准利率上升时，上市公司的资金贷款成本将会上升、经营负担将会增大，导致上市公司盈利能力下降，影响上市公司的基本面，从而加大了股价下跌的压力；而当央行基准利率下降时，上市公司的资金成本下降、经营压力减小，增加上市公司盈利能力，往往会促使股价上升。

2、货币政策对上市公司和投资者的影响

从上市公司和投资者层面分析，从投资者的角度看，当央行基准利率上升时，投资者会增加储蓄金额，减少贷款金额，而这会导致流向股市的资金减少，从而会造成股价下跌；而当央行降低基准利率时，投资者会减少储蓄金额、增加贷款金额，这实质上增加了社会闲置资金，加大了股市资金供给，往往会造成股价上升。资金流向多的领域，上市公司就会得到扶持，就会更快更好发展，基本面就会得到更好改善，上市公司价值就会明显提高。货币政策的松紧可以使股票投资的收益的折现率发生变化；主要体现在准备金率、利率的变化，从而影响当前股票的价格；储蓄资金流向股市，从而吸引更多的资金流向股市，若进入股市的资金逐渐增加，则股市逐渐活跃，股价会逐渐上涨；若进入股市的资金逐渐减少，则股市人气会逐渐衰落，股价会逐渐下跌。

当股市活跃之后，会吸引散户将部分储蓄资金投资到股市中去，股市中的流动性将会逐渐变好，推动股市上涨和股民情绪高涨，提高投资热度和风险偏好，又会进一步吸引资金流入股市；当后续的资金转化为股市投资资金的动力耗尽时，市场流动性已经变得宽滥时，不但会导致通货膨胀，而且存在很大的金融风险，这时央行往往会采取紧缩货币的政策，收缩流动性，降低风险。此时，股市中的一部分钱会撤回到银行，导致股市热度下降。

无论是流入上市公司的资金还是直接进入股市的资金，都是通过改善上市公司的基本面或者投资预期，带动股价上涨的，一般国家重点扶持高新技术产业、大力扶植的新兴产业等上市公司容易获得资金，当宏观经济环境和货币政策不确定性较大，股票投资者的心态会不稳定，往往对内幕消息较为敏感。

3、货币政策强度与个股月收益率的关系

在 5% 的置信水平下，上证指数的变动既不构成广义货币 M2 增长变化，也不构成方正科技月收益率变化的格兰杰因果关系；在 10% 的置信水平下，上证指数的月收益率的变动构成方正科技月收益率变化的格兰杰因果关系；体现了央行对广义货币 M2 的供给主要是根据经济社会发展的需求进行调节，并不是围绕着股市的冷热进行调控；货币政策的目标是保持币值稳定，合理调控货币供应，支持经济结构转型升级，确保经济快速健康发展。既要管理好货币的流动性，不搞“大水漫灌”式的大量发行货币，也要保证以合理信贷促进经济增长，全面促进经济结构完善和调整。以经济长远发展为目标，为经济健康发展提供动力。

稳健的货币政策操作手段是利用各种货币政策工具，保持经济健康稳定快速发展；特别是要加快中国金融体系和利率市场化改革的步伐；通过有效的政策工具引导资金信贷回归常态，强化金融市场的风险管控，达到对股票市场的科学合理影响和预期，从而促进资本市场对经济积极作用的有效发挥。

投资者将资金投入股市后，上证指数收益率会变化；投资者会根据当时的热点，将资金投入相应的题材，进而影响了个股收益率，上证指数月收益率的变化，从侧面体现了投资热度；个股收益率的变化，一定程度上体现了投资方向；股票的热点是变化的，随着热点题材的转移，方正科技不再是热点股票时，上证指数变化与方正科技月收益率的相关性也会降低。

任何热点题材都有一定的时效性，补贴政策、利好的公告、新概念、产业板块联动，关联股票的涨跌，都会引起投资者对其关联或同类股票涨跌的浮想

联翩，产生赚钱效应以后，会出现一阵“热点题材”。

（四）脉冲响应




图 5.12 脉冲响应分析

从脉冲响应图 5.12 中可以看出，广义货币 M2 供给的变化对上证指数收益率变化的影响在第 4 期达到最大值。

广义货币 M2 供给的变化对方正科技股票收益率的影响在零轴附近呈现周期性的震荡变化；上证指数收益率变化对方正科技股票收益率的影响在第 2 期达到最大，随后向零轴回归，围绕零轴小幅振荡，最后变为 0。

（五）方差分解




图 5.13 方差分解结果

Variance Decomposition of M:				
Period	S.E.	M	SZ	FZ
1	0.295599	100.0000	0.000000	0.000000
2	0.306056	95.11105	4.883232	0.005720
3	0.341712	82.79410	4.322578	12.88332
4	0.365831	79.79230	3.937363	16.37033
5	0.379570	80.05152	4.737970	16.21051
6	0.401085	73.37695	4.846500	21.77656
7	0.403129	72.69147	5.670805	21.63772
8	0.410356	73.04237	5.660978	21.29665
9	0.413951	72.59222	5.786801	21.62098
10	0.420473	71.76117	5.948779	22.29005

Variance Decomposition of SZ:				
Period	S.E.	M	SZ	FZ
1	0.030664	18.04921	81.95079	0.000000
2	0.034584	15.56930	81.81967	2.611034
3	0.039080	19.86279	64.39087	15.74634
4	0.041703	23.41219	59.12004	17.46776
5	0.042828	22.71626	57.25750	20.02624
6	0.042900	22.67876	57.36099	19.96025
7	0.043401	23.37667	56.41184	20.21149
8	0.043481	23.39503	56.20586	20.39912
9	0.043723	23.27306	55.76389	20.96305
10	0.043878	23.43431	55.37232	21.19337

Variance Decomposition of FZ:				
Period	S.E.	M	SZ	FZ
1	0.099113	18.90774	9.031424	72.06083
2	0.116502	14.04711	28.25176	57.70113
3	0.119275	15.61838	26.95949	57.42214
4	0.122594	16.11534	25.78303	58.10163
5	0.126315	20.94701	24.28698	54.76601
6	0.127149	21.19260	24.73243	54.07497
7	0.129348	22.48511	24.14848	53.36642
8	0.129615	22.74799	24.04918	53.20292
9	0.130429	23.42316	23.77275	52.80409
10	0.131861	23.73814	23.34418	52.91768

Cholesky Ordering: M SZ FZ

图 5.14 方差分解数值列表

从图 5.13 和 5.14 中可以看出, 上证指数收益率变动方差由自身变动解释的部分逐渐下降, 在第 10 期达到 55%左右; 由广义货币 M2 供给变化解释的部分在 7 到 10 期维持在 23%左右; 由方正科技股价收益率变化解释的部分逐渐增加, 在第 10 期达到最大值, 大约 21%的上证指数收益率变动方差由方正科技股价收益率变化来解释。

方正科技股价收益率变化方差由自身变动解释的部分逐渐下降, 在第 10 期达到 52.9%; 由广义货币 M2 供给变化解释的部分在第 10 期达到最大值 23.7%; 由上证指数收益率变动解释的部分逐渐增加, 在第 10 期达到 23.3%。

Structural VAR Estimates
Date: 09/25/21 Time: 09:03
Sample (adjusted): 4 26
Included observations: 23 after adjustments
Estimation method: method of scoring (analytic derivatives)
Convergence achieved after 1 iterations
Structural VAR is just-identified

Model: $Ae = Bu$ where $E[uu'] = I$
Restriction Type: short-run pattern matrix

A =

1	0	0
C(1)	1	0
C(2)	C(3)	1

B =

C(4)	0	0
0	C(5)	0
0	0	C(6)

	Coefficient	Std. Error	z-Statistic	Prob.
C(1)	0.044071	0.019581	2.250694	0.0244
C(2)	0.098508	0.065560	1.502568	0.1330
C(3)	-1.073023	0.631999	-1.697823	0.0895
C(4)	0.295599	0.043584	6.782330	0.0000
C(5)	0.027759	0.004093	6.782330	0.0000
C(6)	0.084136	0.012405	6.782330	0.0000

Log likelihood 69.49345

Estimated A matrix:

1.000000	0.000000	0.000000
0.044071	1.000000	0.000000
0.098508	-1.073023	1.000000

Estimated B matrix:

0.295599	0.000000	0.000000
0.000000	0.027759	0.000000
0.000000	0.000000	0.084136

图 5.15 SVAR 方程估计结果




图 5.16 SVAR 方程的脉冲响应

从图 5.15-5.16 中，可以得到 3 变量的 SVAR 方程估计结果，从脉冲响应分析结果可以看出，与 VAR 方程的脉冲响应趋势一致。

第五节 基于 3 变量 VAR 模型预测能力分析

一、个股收益率预测能力分析

选取样本内部分数据，对该 VAR 方程关于个股收益率的预测能力分析，如图 5.17 所示。




图 5.17 方正科技月收益率预测值与理论值对比

从预测结果的对比可以看出，虽然方正科技月收益率的预测值与实际值存在偏差，但是趋势较为准确。

二、上证指数收益率预测能力分析

选取样本内部分数据，对该 VAR 方程关于上证指数月度收益率的预测能力分析，如图 5.15 所示。




图 5.18 上证指数月收益率预测值与理论值对比

从预测结果的对比可以看出，上证指数月收益率的预测值与实际值存在偏差，而且趋势有所偏差。

三、广义货币供给强度预测能力分析

选取样本内部分数据，对该 VAR 方程关于广义货币政策强度的预测能力分析，如图 5.16 所示。




图 5.19 广义货币政策强度预测值与理论值对比

从预测结果的对比可以看出，广义货币政策强度不仅预测值与实际值存在偏差，而且趋势有所偏差，进一步从侧面说明了货币政策更多地是根据经济发展需求进行调节的。

第六节 基于 VAR 模型的个股收益率分析

一、序列平稳性检验

本节主要利用金融领域词典，选择方正科技近 2 年的股评作为样本，计算每条股评中情感分值，然后汇总每个交易日的情绪值，正值越大代表看涨意愿越强，负值越小代表看跌意愿越强；基于每日股评的情感分值，构建了股评情感强度序列，并对其进行了归一化处理；此外对发帖量、成交量、收益率等特征量数据进行了处理，构建了相应的序列；基于构建的 4 个序列，建立了 VAR 方程，分析了各个变量之间的影响关系。




图 5.20 每日发帖量序列

该股票平均每日发布 30 条帖子，在股票大涨大跌的当天，发布帖子数量会大幅增加；就发帖数量而言，样本期间中有很多时间里，股价持续低迷或者处于底部调整阶段，投资者缺乏信心，会表现出悲观情绪，对股票的关注度也随之下降，从而减少股吧的访问量，因此发布的帖子数并不多。

当股价大涨时，被关注的可能性相对较大，大量个体投资者会积极收集股票上涨相关的信息，跟风访问股吧，造成访问量增加，有的投资者也会发帖，导致帖子数量增多；同样股价大跌时，恐慌的情绪也会发生“群体性”传染，造成集体性恐慌，也会引发股吧访问量增多，投资者纷纷发帖表达观点和看法，导致帖子数量增多，列出部分大跌和大涨时，对应的发帖数目，如表 5.6 所示。

表 5.6 大跌和大涨时对应的发帖数

日期	涨跌	发帖数
2020/8/10	大跌	254
2020/8/26	大跌	229
2020/8/6	大跌	193
2020/2/27	大跌	180
2021/2/1	大跌	136
2020/4/10	大跌	124
2019/12/3	大涨	245
2020/2/26	大涨	192
2020/8/5	大涨	183
2021/1/29	大涨	130
2019/5/9	大涨	122
2020/4/9	大涨	120

从表 5.6 中可以看出,大跌时发帖数要比大涨时发帖数多,体现了恐慌情绪比乐观情绪更容易传播,也反映了同等程度的悲观情绪造成的影响要比乐观情绪造成的影响更大。股评可以通过吸引部分投资者的有限注意力、渲染和传播其情绪来改变他们对股票市场的认知,造成股价波动,通过股评传递了乐观或者悲观的情绪,从而影响部分投资者情绪,交易行为,会影响收益率的波动;股评数量增大反映了投资者关注度提高。

Null Hypothesis: TIE has a unit root				
Exogenous: Constant				
Lag Length: 0 (Automatic - based on SIC, maxlag=17)				
			t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic			-9.004178	0.0000
Test critical values:				
	1% level		-3.443579	
	5% level		-2.867267	
	10% level		-2.569883	
*Mackinnon (1996) one-sided p-values.				
Augmented Dickey-Fuller Test Equation				
Dependent Variable: D(TIE)				
Method: Least Squares				
Date: 10/23/21 Time: 08:52				
Sample (adjusted): 2 487				
Included observations: 486 after adjustments				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
TIE(-1)	-0.287686	0.031950	-9.004178	0.0000
C	-0.000398	0.005336	-0.074574	0.9406
R-squared	0.143477	Mean dependent var		-0.000493
Adjusted R-squared	0.141707	S.D. dependent var		0.126963
S.E. of regression	0.117624	Akaike info criterion		-1.438542
Sum squared resid	6.696327	Schwarz criterion		-1.421315
Log likelihood	351.5657	Hannan-Quinn criter.		-1.431774
F-statistic	81.07523	Durbin-Watson stat		2.138060
Prob(F-statistic)	0.000000			

图 5.21 发帖量序列单位根检验




图 5.22 情绪强度序列

情绪具有一定的周期性，市场的情绪反映出交易者的人性，恐慌与兴奋，脉冲式的反复过程，从图中可以看出，情感强度时序图有着明显的波动集聚效应，第 200 天到 350 天期间，情感强度变动幅度较大，存在大波动集群，说明这段时间投资者的情绪强度波动较大且高位频繁波动。

Null Hypothesis: QING has a unit root				
Exogenous: Constant				
Lag Length: 1 (Automatic - based on SIC, maxlag=17)				
		t-Statistic	Prob.*	
Augmented Dickey-Fuller test statistic		-11.92642	0.0000	
Test critical values:	1% level	-3.443607		
	5% level	-2.867279		
	10% level	-2.569889		
*MacKinnon (1996) one-sided p-values.				
Augmented Dickey-Fuller Test Equation				
Dependent Variable: D(QING)				
Method: Least Squares				
Date: 10/23/21 Time: 08:57				
Sample (adjusted): 3 487				
Included observations: 485 after adjustments				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
QING(-1)	-0.672967	0.056427	-11.92642	0.0000
D(QING(-1))	-0.138198	0.045272	-3.052621	0.0024
C	0.000270	0.008841	0.030554	0.9756
R-squared	0.401888	Mean dependent var	6.01E-06	
Adjusted R-squared	0.399406	S.D. dependent var	0.251221	
S.E. of regression	0.194691	Akaike info criterion	-0.428639	
Sum squared resid	18.27003	Schwarz criterion	-0.402757	
Log likelihood	106.9449	Hannan-Quinn criter.	-0.418470	
F-statistic	161.9344	Durbin-Watson stat	2.001977	
Prob(F-statistic)	0.000000			

图 5.23 情绪强度序列单位根检验




图 5.24 每日成交量序列

成交量是市场上交易的股数，是交易热度的一个体现。成交量中有散户的，也有庄家的。散户人数众多，但是每人持有的股票数量不算多，庄家数量少却

持有股票多。成交量走势与发帖数量走势较为相似，当股价持续低迷或者处于底部调整阶段，收益率不高时，投资者便缺乏信心，表现出悲观情绪，对股票的关注度也随之下将，从而减少或者暂停交易，因此成交量并不大。

成交量下降意味着大多数人，也就是散户们都不愿意交易，这样必然会导致股票价格停滞不前，如果股票收益率提高，出现利好的宏观政策，配合相应的产业扶持政策，此时庄家会有选择性地大量买进相关股票，成交量大幅提升，进而推动价格上涨，营造出浓厚的盈利氛围，吸引待散户们跟风买入，当政策影响力衰弱时，后续投资热情减弱，庄家往往会选择高价位出货，获利退出，让散户们独自留在峰尖浪顶，后悔莫及。所以，股票成交量下降但是价格或大盘指数上升意味着庄家独自在操纵市场，散户们在观望。

Null Hypothesis: LIANG has a unit root
Exogenous: Constant
Lag Length: 0 (Automatic - based on SIC, maxlag=17)

		t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic		-8.017640	0.0000
Test critical values:	1% level	-3.443579	
	5% level	-2.867267	
	10% level	-2.569883	

*Mackinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
Dependent Variable: D(LIANG)
Method: Least Squares
Date: 10/23/21 Time: 09:00
Sample (adjusted): 2 487
Included observations: 486 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
LIANG(-1)	-0.229319	0.028602	-8.017640	0.0000
C	-0.000940	0.004564	-0.206077	0.8368
R-squared	0.117243	Mean dependent var	-0.000988	
Adjusted R-squared	0.115420	S.D. dependent var	0.106971	
S.E. of regression	0.100608	Akaike info criterion	-1.751058	
Sum squared resid	4.899057	Schwarz criterion	-1.733831	
Log likelihood	427.5072	Hannan-Quinn criter.	-1.744290	
F-statistic	64.28255	Durbin-Watson stat	1.943039	
Prob(F-statistic)	0.000000			

图 5.25 成交量序列单位根检验

从上图 5.25 中可以看出，3 个序列的 t 检验临界值为 -9、-11.9、-8.02，均小于对应的三个置信区间临界值，因此拒绝原假设，3 个序列不存在单位根，为平稳序列。



图 5.26 方正科技每日股价趋势

从图 5.26 中可以看出, 收盘价格数据存在明显的时间趋势, 第 220 天到第 350 天, 价格呈上升趋势; 尤其在第 320 天到第 350 天, 价格拉升幅度增大, 呈现出明显的“主升浪”的形态。




图 5.27 方正科技每日股价分布

从图 5.27 中可以看出峰度为 5.578, 高于正态分布的峰度值 3, 说明收盘价分布不是正态分布。

Null Hypothesis: SER01 has a unit root				
Exogenous: Constant				
Lag Length: 0 (Automatic - based on SIC, maxlag=17)				
			t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic				
Test critical values:				
			-2.397991	0.1428
	1% level		-3.443551	
	5% level		-2.867255	
	10% level		-2.569876	
*MacKinnon (1996) one-sided p-values:				
Augmented Dickey-Fuller Test Equation				
Dependent Variable: D(SER01)				
Method: Least Squares				
Date: 09/12/21 Time: 16:01				
Sample (adjusted): 2 488				
Included observations: 487 after adjustments				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
SER01(-1)	-0.023141	0.009650	-2.397991	0.0169
C	0.084481	0.036136	2.337892	0.0198
R-squared	0.011717	Mean dependent var		-0.001437
Adjusted R-squared	0.009680	S.D. dependent var		0.104103
S.E. of regression	0.103598	Akaike info criterion		-1.692500
Sum squared resid	5.205278	Schwarz criterion		-1.675300
Log likelihood	414.1239	Hannan-Quinn criter.		-1.685743
F-statistic	5.750363	Durbin-Watson stat		1.981370
Prob(F-statistic)	0.016862			

图 5.28 股价序列单位根检验

从图 5.28 中可以看出, t 检验的临界值为-2.397, 均大于三个置信区间的临界值, 因此不能拒绝原假设, 该序列存在单位根, 为不平稳序列; 同样, 从图 5.29 中可以看出, 自相关函数系数在滞后 36 阶的情况下, 未曾衰减落入两倍的标准差范围内, 因此, 可以判定收盘价序列存在单位根, 不平稳。




图 5.29 股价序列相关函数

自相关函数系数没有明显的“拖尾”现象，因此，可以判定收盘价序列不平稳，需要进行处理，采用收益率序列，计算如公式 5.1 所示：

$$Rate = P_t / P(t-1) \quad (5.1)$$

其中： P_t 为当天收盘价， $P(t-1)$ 为前一天收盘价。




图 5.30 方正科技日收益率分布




图 5.31 方正科技日收益率序列

从图 5.30 中可以看出，收益率分布图的峰度为 6.308551，高于正态分布的峰度值 3，不服从正态分布。

从图 5.31 中可以看出，收益率时序图有着明显的波动集聚效应，第 215 天

到 350 天期间, 收益率波动幅度较大, 存在大波动集群, 说明这段时间收盘价急剧拉升, 收益率变化较大, 围绕着一个价格区间, 上下波动, 从侧面反映了炒作热度和交易的活跃程度。

Null Hypothesis: Y has a unit root				
Exogenous: Constant				
Lag Length: 0 (Automatic - based on SIC, maxlag=17)				
			t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic			-22.00355	0.0000
Test critical values:	1% level		-3.443579	
	5% level		-2.867267	
	10% level		-2.569883	
*MacKinnon (1996) one-sided p-values.				
Augmented Dickey-Fuller Test Equation				
Dependent Variable: D(Y)				
Method: Least Squares				
Date: 09/25/21 Time: 10:09				
Sample (adjusted): 2 487				
Included observations: 486 after adjustments				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
Y(-1)	-0.992838	0.045122	-22.00355	0.0000
C	0.992949	0.045136	21.99889	0.0000
R-squared	0.500081	Mean dependent var	0.000139	
Adjusted R-squared	0.499048	S.D. dependent var	0.037294	
S.E. of regression	0.026396	Akaike info criterion	-4.427092	
Sum squared resid	0.337230	Schwarz criterion	-4.409865	
Log likelihood	1077.783	Hannan-Quinn criter.	-4.420324	
F-statistic	484.1563	Durbin-Watson stat	2.013498	
Prob(F-statistic)	0.000000			

图 5.32 方正科技日收益率序列单位根检验

从上图 5.32 中可以看出, 收益率序列的 t 检验临界值为 -22, 均小于三个置信区间临界值, 因此拒绝原假设, 该序列不存在单位根, 为平稳序列。

二、构建 VAR 模型

(一) 确定滞后阶数

VAR Lag Order Selection Criteria						
Endogenous variables: QING TIE LIANG SHOUYILV						
Exogenous variables: C						
Date: 10/23/21 Time: 09:10						
Sample: 1 487						
Included observations: 479						
Lag	LogL	LR	FPE	AIC	SC	HQ
0	1933.113	NA	3.73e-09	-8.054750	-8.019913	-8.041055
1	2314.871	755.5474	8.10e-10	-9.581926	-9.407742*	-9.513452*
2	2335.484	42.41334	7.93e-10	-9.605361	-9.291831	-9.482106
3	2353.868	33.82389	7.87e-10*	-9.611139*	-9.158261	-9.433107
4	2366.010	23.42321	8.00e-10	-9.595033	-9.002808	-9.362222
5	2381.518	29.65627*	8.02e-10	-9.592979	-8.861407	-9.305388
6	2388.642	13.50340	8.32e-10	-9.559916	-8.684997	-9.213547
7	2402.406	25.86107	8.40e-10	-9.546579	-8.536313	-9.149431
8	2409.691	13.56769	8.71e-10	-9.510194	-8.360581	-9.058267

* indicates lag order selected by the criterion
 LR: sequential modified LR test statistic (each test at 5% level)
 FPE: Final prediction error
 AIC: Akaike information criterion
 SC: Schwarz information criterion
 HQ: Hannan-Quinn information criterion

图 5.33 VAR 模型滞后阶数确定准则

根据滞后阶数确定准则, 确定滞后阶数为 3。

(二) VAR 方程估计

第五章 序列分析及预测评价

Vector Autoregression Estimates
Date: 10/12/21 Time: 08:59
Sample (adjusted): 4 487
Included observations: 484 after adjustments
Standard errors in () & t-statistics in []

	QING	TIE	LIANG	SHOUYILV
QING(-1)	0.104637 (0.04876) [2.10696]	0.009007 (0.03005) [0.29487]	-0.018714 (0.02297) [-0.72048]	-0.001208 (0.00695) [-0.17391]
QING(-2)	0.123205 (0.04947) [2.46069]	0.002918 (0.03037) [0.09609]	-0.000322 (0.02562) [-0.01247]	-0.004362 (0.00691) [-0.63438]
QING(-3)	-0.013809 (0.04887) [-0.28255]	0.054350 (0.03000) [1.81146]	0.034799 (0.02551) [1.36398]	0.010922 (0.00682) [1.60031]
TIE(-1)	-0.200474 (0.09542) [-2.19530]	0.539625 (0.05858) [9.21220]	0.024951 (0.04881) [0.50992]	-0.010999 (0.01332) [-0.82550]
TIE(-2)	-0.153384 (0.10665) [-1.43827]	0.106036 (0.05547) [1.91965]	0.053177 (0.05567) [0.95521]	0.014729 (0.01489) [0.98907]
TIE(-3)	0.026748 (0.09803) [0.27853]	0.034272 (0.05895) [0.58132]	-0.065021 (0.05013) [-1.29699]	-0.006460 (0.01341) [-0.48170]
LIANG(-1)	-0.160483 (0.12488) [-1.28720]	0.077732 (0.07054) [1.01561]	0.654766 (0.06508) [10.0605]	-0.029578 (0.01741) [-1.69890]
LIANG(-2)	-0.022683 (0.15027) [-0.15095]	0.060322 (0.09225) [0.65391]	-0.140566 (0.07844) [-1.79322]	0.012400 (0.02098) [0.59092]
LIANG(-3)	0.261223 (0.11723) [2.22831]	-0.017093 (0.07197) [-0.23751]	0.231434 (0.05120) [3.78186]	0.008667 (0.01637) [0.59054]
SHOUYILV(-1)	0.969998 (0.40739) [2.38098]	0.664641 (0.25010) [2.65754]	0.867538 (0.21267) [4.07932]	0.084271 (0.05689) [1.48130]
SHOUYILV(-2)	0.598771 (0.41118) [1.45620]	0.138412 (0.25542) [0.54033]	0.546274 (0.21465) [2.54499]	0.091586 (0.05742) [1.59505]
SHOUYILV(-3)	0.881488 (0.36487) [2.41522]	-0.495880 (0.22405) [-2.21322]	-0.150227 (0.19052) [-0.78850]	-0.070918 (0.05097) [-1.39148]
C	-2.451245 (0.71070) [-3.44906]	-0.307249 (0.43628) [-0.70423]	-1.265334 (0.37100) [-3.41052]	0.895003 (0.08924) [9.01916]
R-squared	0.149272	0.540061	0.626714	0.027358
Adj. R-squared	0.127597	0.528342	0.617204	0.005577
Sum sq. resid	16.54495	6.235203	4.508562	0.322626
S.E. equation	0.187423	0.115007	0.097838	0.025172
F-statistic	6.886958	46.08734	65.89726	1.104003
Log likelihood	130.2206	366.3872	444.8516	1083.054
Akaike AIC	-0.484408	-1.450278	-1.784511	-4.421750
Schwarz SC	-0.372079	-1.347849	-1.672162	-4.308422
Mean dependent	-0.000257	0.000213	-0.001953	1.000090
S.D. dependent	0.200691	0.167533	0.158134	0.020256
Determinant resid covariance (dof adj.)	1.13E-09			
Determinant resid covariance	1.02E-09			
Log likelihood	2264.350			
Akaike information criterion	-9.141940			
Schwarz criterion	-8.692525			

图 5.34 VAR 方程估计结果

三、格兰杰因果关系分析

VAR Granger Causality/Block Exogeneity Wald Tests
Date: 10/23/21 Time: 09:07
Sample: 1 487
Included observations: 484

Dependent variable: QING				
Excluded	Chi-sq	df	Prob.	
TIE	15.21840	3	0.0016	
LIANG	7.194619	3	0.0659	
SHOUYILV	13.27947	3	0.0041	
All	44.91940	9	0.0000	

Dependent variable: TIE				
Excluded	Chi-sq	df	Prob.	
QING	3.747363	3	0.2901	
LIANG	4.527105	3	0.2099	
SHOUYILV	11.60633	3	0.0089	
All	27.18895	9	0.0013	

Dependent variable: LIANG				
Excluded	Chi-sq	df	Prob.	
QING	2.163367	3	0.5392	
TIE	2.405769	3	0.4926	
SHOUYILV	22.23043	3	0.0001	
All	26.04240	9	0.0020	

Dependent variable: SHOUYILV				
Excluded	Chi-sq	df	Prob.	
QING	2.746572	3	0.4324	
TIE	1.206631	3	0.7514	
LIANG	3.239911	3	0.3551	
All	11.29505	9	0.2560	

图 5.35 格兰杰因果关系检验

大多数个股股吧专业投资者发布信息数量相对较少，大多数信息是活跃着大量的散户投资者发布的，这些散户投资者构成评论帖子发布的主力军，除了

股评以外,还有公司重大公告、债务偿还和融资融券等信息,保证了信息披露的及时性和各类投资者获取信息的便捷性。在所选用股评样本期内,该股票具有明显的股市上升期、下降期,情绪波动明显,因此具有很好的代表性。

从图中可以看出,(1)发帖数量和收益率变化构成了对股评情绪强度变动的格兰杰因果关系,说明收益率能够引起投资者的情绪变化,发帖数量体现了投资者的关注程度。在两者共同作用下,容易引起了股票市场的“羊群效应”,即非理性投资者突然增加,表现出明显的群体性质跟风现象,包括发表帖子数量、股价的变化。

股票的收益率对投资者的情绪有较大的影响,尤其是非理性投资者情绪,非理性投资者情绪是构成股价短期波动的一股重要力量。当投资者对未来预期偏好时,股票收益率又增大时,契合了投资者的某种心理预期,往往会表现出看涨的情绪,会提升投资信心,看涨情绪越趋于一致,越会推动股票价格和成交量;高涨情绪会推动股价不断上扬,但随之股市风险加大;当股价上升疲软或者缺乏动力时,投资者对未来股市预期偏坏时,表现出看跌情绪,会拉低股价,甚至引起群体恐慌,造成股市“断崖式”下跌;尤其当悲观和乐观的情绪发生急速转换时,往往容易会造成股价的大幅波动,从而加剧股市风险。

因此,监管部门有必要从投资者情绪角度对股市的运行态势进行监测,对投资者情绪进行动态监测和早期预警。

(2)收益率变动构成发帖数量变化的格兰杰因果关系,说明投资者对股票的收益率比较关注;一根强势大阳线往往会引起投资者无限的遐想和猜测,但是根据长期研究证明,收益率的变动并不一定引起理性投资者情绪的变化,理性投资者对股票的预期是基于多方面的,例如上市公司基本面,从股评中反映出:该公司的基本面较差,对其经营、管理的评价较为负面;部分投资者对其所处产业、高校背景、合作上市公司较为看好。

(3)收益率变动构成成交量变化的格兰杰因果关系,这可能是因为我国股市投资者中个人投资者数目占比较大,相对专业投资者,缺乏投资经验和专业知识,对股价涨跌的理解只停留在表层,容易受到涨跌表象影响,产生非理性情绪,从而进行买卖交易。

(4)股评情感强度、发帖数量和成交量变化不构成收益率变动的格兰杰因果关系,说明股价收益率变动主要与宏观经济、货币政策相关,最直接的影响因素是供求关系;而散户对以上因素的影响能力较弱,因此对股价的操控能力

有限，不能有效影响收益率。

股票市场中正常的波动能够活跃市场，增加资金的流动性，但是频繁异常的波动会增加市场的系统风险，对市场的伤害是巨大的。监管者要及时洞察投资者情绪非正常波动，在投资者情绪过度悲观和过度乐观之前进行及时有效的预警，提前采取有效的预控对策，出台相关政策，防止情绪的剧烈的波动。通过监测投资者情绪变化，建立股市风险预警机制，及时稳定投资者情绪，避免股市出现大幅波动，降低股市风险。

非理性投资者捕捉宏观经济信息、行业信息和公司新闻的能力也不强，大多是从股吧处获得一些质量不高的信息，政府部门和金融中介应该加强对中小投资者的引导和教育，让其在投资过程中做一个理性投资人，密切关注相关新闻报道，获取有效信息。

四、脉冲响应




图 5.36 脉冲响应分析

从脉冲响应图 5.36 中可以看出，发帖数量对情感强度的影响始终为负向；成交量对发帖数量的影响为正向；收益率对发帖数量的影响先逐渐增大，第 3 期达到最大，然后逐渐衰减。

情感强度、发帖数量对成交量的影响在第 1 期最大，随后逐步降低，在第 10 期靠近零轴，始终为正向影响；股价收益率对成交量的影响先逐渐增大，在第 3 期左右达到最大，随后逐渐衰减。

情感强度、发帖数量和成交量对股价收益率的影响都是在第 1 期最大，在第 2 期以后便向零轴回归。

五、方差分解




图 5.37 方差分解结果

Variance Decomposition of QING:				
Period	S.E.	QING	TIE	LIANG
1	0.187423	100.0000	0.000000	0.000000
2	0.192398	96.89091	1.988778	0.010896
3	0.199567	92.02660	6.461431	0.212718
4	0.201437	90.65625	6.756724	0.733495
5	0.202235	89.97222	7.389399	0.782113
6	0.202697	89.65659	7.613660	0.792417
7	0.202832	89.44870	7.626554	0.790583
8	0.202929	89.37093	7.905434	0.791295
9	0.203012	89.30226	7.971996	0.792668
10	0.203054	89.26994	8.003843	0.793787

Variance Decomposition of TIE:				
Period	S.E.	QING	TIE	LIANG
1	0.115057	0.195643	99.80435	0.000000
2	0.136798	0.395180	97.71886	0.855640
3	0.149908	0.606874	95.96394	1.902157
4	0.156720	1.142244	95.23993	2.103318
5	0.161245	1.603930	94.43001	2.443764
6	0.163843	2.056807	93.52571	2.777047
7	0.165845	2.352619	92.89952	3.131450
8	0.167058	2.570093	92.33920	3.413523
9	0.167899	2.710036	91.89947	3.655260
10	0.168449	2.868134	91.58118	3.837402

Variance Decomposition of LIANG:				
Period	S.E.	QING	TIE	LIANG
1	0.097838	3.761016	37.86862	58.37037
2	0.125987	4.152272	37.47376	58.30439
3	0.137100	4.465149	37.46147	58.06031
4	0.143992	5.265207	37.11376	57.19375
5	0.149269	5.823493	36.75939	57.01987
6	0.152348	6.246305	36.46992	51.80720
7	0.154375	6.535351	36.18681	51.66551
8	0.155773	6.734668	35.94116	51.63818
9	0.156724	6.856647	35.76373	51.64037
10	0.157336	6.937305	35.63861	51.64517

Variance Decomposition of SHOUYILV:				
Period	S.E.	QING	TIE	LIANG
1	0.026172	14.02825	6.774286	15.47759
2	0.026382	13.80744	7.544370	15.49178
3	0.026498	13.77964	7.584121	15.43912
4	0.026523	13.89363	7.580817	15.34503
5	0.026525	13.89200	7.581962	15.34938
6	0.026537	13.89121	7.628515	15.35896
7	0.026539	13.88925	7.628137	15.35857
8	0.026540	13.88838	7.634537	15.35833
9	0.026541	13.88868	7.634738	15.35811
10	0.026541	13.88831	7.636623	15.35812

图 5.38 方差分解结果列表

从图 5.37 和 5.38 中可以看出，情感强度变动方差由自身变动解释的部分保持在较高水平，稳定在 89% 左右；同样发帖数量变动方差由自身变动解释的部分保持在较高水平，稳定在 91% 左右；成交量变化方差由自身变动解释的部分在第 6 期至第 10 期维持在 51%，由发帖数量变动解释的部分在第 8 期至第 10 期维持在 35%，由收益率变动解释的部分逐步上升，第 10 期达到 5.77%；由情感强度变动解释的部分逐步上升至 6.94%；收益率变动方差有自身解释部分始终维持在 63% 左右；由成交量变动、情感强度变动、发帖数量变动解释部分分别维持在 15%、13.9%、7.6% 左右。

Structural VAR Estimates
Date: 10/23/21 Time: 09:52
Sample (adjusted): 4 487
Included observations: 484 after adjustments
Estimation method: method of scoring (analytic derivatives)
Convergence achieved after 1 iterations
Structural VAR is just-identified

Model: $Ax = Bu$ where $E(uu') = I$
Restriction Type: short-run pattern matrix

A =

1	0	0	0
C(1)	1	0	0
C(2)	0	1	0
C(3)	0	0	1

B =

C(7)	0	0	0
0	C(8)	0	0
0	0	C(9)	0
0	0	0	C(10)

	Coefficient	Std. Error	z-Statistic	Prob.
C(1)	0.027153	0.027877	0.974047	0.3300
C(2)	-0.115460	0.018146	-6.362755	0.0000
C(3)	-0.038007	0.005280	-7.198822	0.0000
C(4)	-0.523792	0.029559	-17.72010	0.0000
C(5)	0.012889	0.010508	1.214971	0.2244
C(6)	-0.137748	0.012704	-10.84259	0.0000
C(7)	0.187423	0.006024	31.11270	0.0000
C(8)	0.114945	0.003694	31.11270	0.0000
C(9)	0.074749	0.002403	31.11270	0.0000
C(10)	0.020892	0.000671	31.11270	0.0000

Log likelihood 2237.994

Estimated A matrix:

1.000000	0.000000	0.000000	0.000000
0.027153	1.000000	0.000000	0.000000
-0.115460	-0.523792	1.000000	0.000000
-0.038007	0.012889	-0.137748	1.000000

Estimated B matrix:

0.187423	0.000000	0.000000	0.000000
0.000000	0.114945	0.000000	0.000000
0.000000	0.000000	0.074749	0.000000
0.000000	0.000000	0.000000	0.020892

图 5.39 SVAR 方程估计结果




图 5.40 脉冲响应分析

从图 5.39-5.40 中，可以得到 4 变量的 SVAR 方程估计结果，从脉冲响应分析结果可以看出，与 VAR 方程的脉冲响应趋势一致。

第七节 基于 4 变量 VAR 模型的预测能力分析

本节利用部分样本数据，检验 4 变量 VAR 模型的预测能力，对该 VAR 方程关于个股成交量、情绪强度、发帖量、收益率等序列的预测能力进行分析，如图 5.41-5.44 所示。




图 5.41 成交量序列预测能力分析

从预测结果的对比可以看出，关于成交量序列预测不仅在预测值上高度精准，而且预测趋势也相当贴合，效果较好。




图 5.42 收益率序列预测能力分析

从预测结果的对比可以看出，关于收益率序列的预测趋势和预测值都不是很精确，收益率的波动幅度被放大，收益率的变动往往能够会引起情绪强度的变动，因此可以推理出关于情绪强度的预测波动幅度也会相应增大。




图 5.43 情绪强度序列预测能力分析

从预测结果的对比可以看出，关于情绪强度序列的预测趋势虽然贴合实际趋势，但是在预测值上存在较大差值，预测值相对实际值偏大，也佐证了之前的推理。




图 5.44 发帖量序列预测能力分析

从预测结果的对比可以看出，关于发帖量序列预测不仅在预测值上高度精准，而且预测趋势也相当贴合，效果较好。

第八节 本章小结

本章基于领域词典，建立了每月的广义货币政策强度序列、上证指数情绪强度序列以及每日个股的情绪强度序列，建立了 VAR 方程，进行了格兰杰因果关系验证、脉冲响应、方差分解，分析了货币政策、上证指数和个股月收益率之间的关系；发现货币政策强度变化构成上证指数月收益率变化的格兰杰因果关系，由上证指数评论情感倾向构建的序列可以体现上证指数的变化；在 10% 的置信水平下，上证指数月收益率变动构成个股月收益率变化的格兰杰因果关系，体现了该股的涨跌与大盘有一定的关联性；选取样本内数据，分析了 VAR 方程的预测能力，关于个股月收益率的预测趋势较为准确；关于上证指数月收益率和广义货币政策强度的预测趋势不太理想。VAR 方程是通过评价基于历史信息的预测效果，分析是够构成因果关系的，适合用作解释模型。

通过对比每日个股的收益率变化序列与情绪强度序列，情绪强度序列不能较好地表现日收益率变化；因此构建了发帖数量和成交量序列，基于 4 变量的 VAR 方程，分析了发帖数量、成交量、情绪强度和收益率之间的关系，包括脉冲响应、方差分解，发现收益率变动构成发帖数量、成交量变化、股评情感强

度变动的格兰杰因果关系，可能因为我国股市投资者中个人投资者数目占比较大，对股价涨跌的理解只停留在表层，容易受到收益率变动影响，由此也会引起发帖数量和成交量的变化；选取样本内数据，分析了相应 VAR 方程的预测能力，关于日收益率和情绪强度的预测趋势不太理想，震荡幅值明显放大；关于发帖量和成交量的预测趋势较为准确。

第六章 基于 Garch 方程个股收益率分析及预测评价

上章基于情感词典和股评文本，分别构建了上证指数月评论强度序列和个股情感强度序列；上证指数受宏观政策的影响较大，专业机构对宏观政策的理解较为一致，因此上证指数评论强度序列能较好地体现指数月度收益率；但是因为股吧里关于方正科技的股评，大多是由散户发布的言论，个体的情绪性较强，对后续的走势存在一定的分歧，所以构造出的情感强度序列表现出周期性地震荡，不能较好地表现日收益率变化；因此本章基于 Garch 模型，进一步分析方正科技日收益率与投资者每天情感强度之间关系及该模型的预测能力。

第一节 建立日收益率 Garch 方程

一、建立自回归方程

首先，我们需要先建立自回归方程，作为 Garch 方程的均值方程，第一步先确定滞后阶数。

Date: 09/25/21 Time: 10:10
Sample: 1 487
Included observations: 487

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
1	0.007	0.007	0.0251	0.874	
2	0.029	0.029	0.4291	0.807	
3	-0.047	-0.047	1.4939	0.894	
4	-0.008	-0.008	1.5270	0.822	
5	-0.050	-0.048	2.7831	0.733	
6	-0.013	-0.014	2.8681	0.825	
7	-0.019	-0.017	3.0430	0.881	
8	-0.006	-0.010	3.0606	0.930	
9	0.072	0.071	5.6327	0.776	
10	0.029	0.025	6.0552	0.811	
11	0.039	0.033	6.8178	0.814	
12	-0.005	-0.002	6.8287	0.889	
13	-0.001	-0.001	6.8298	0.911	
14	-0.055	-0.045	8.3303	0.871	
15	-0.117	-0.115	15.287	0.431	
16	0.014	0.024	15.385	0.497	
17	-0.071	-0.069	17.943	0.392	
18	0.017	0.002	18.084	0.450	
19	0.031	0.029	18.584	0.484	
20	-0.036	-0.062	19.247	0.506	
21	0.063	0.062	21.258	0.443	
22	0.021	0.013	21.484	0.491	
23	-0.035	-0.037	22.103	0.514	
24	0.006	0.032	22.120	0.572	
25	-0.019	-0.016	22.296	0.619	
26	-0.035	-0.017	22.943	0.636	
27	-0.072	-0.072	25.619	0.540	
28	-0.046	-0.052	26.709	0.534	
29	-0.012	-0.016	26.786	0.583	
30	0.080	0.055	30.099	0.461	
31	0.019	0.010	30.289	0.502	
32	0.048	0.022	31.503	0.492	
33	-0.041	-0.035	32.407	0.496	
34	-0.007	-0.011	32.429	0.545	
35	-0.000	0.005	32.429	0.593	
36	-0.012	0.019	32.504	0.636	

图 6.1 收益率序列相关函数图

从图 6.1 中可以看出，在第 15 阶以后，自相关系数落在标准范围内，因此选择滞后阶数为 15，建立 AR 回归模式，如图 6.2 所示。

Dependent Variable: Y
Method: Least Squares
Date: 09/25/21 Time: 10:38
Sample (adjusted): 16 487
Included observations: 472 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	1.117949	0.044157	25.31761	0.0000
Y(-15)	-0.118000	0.044137	-2.673500	0.0078

R-squared	0.014980	Mean dependent var	0.999938
Adjusted R-squared	0.012884	S.D. dependent var	0.025924
S.E. of regression	0.025756	Akaike info criterion	-4.476034
Sum squared resid	0.311796	Schwarz criterion	-4.458420
Log likelihood	1058.344	Hannan-Quinn criter.	-4.469105
F-statistic	7.147600	Durbin-Watson stat	1.996264
Prob(F-statistic)	0.007768		

图 6.2 收益率自回归方程估计结果

从图 6.2 中可以得出均值方程：

$$Rate = 1.117949 + (-0.118)Rate(-15) + \varepsilon_t \quad (6.1)$$

对自回归的方程进行序列相关性检验：首先生成均值方程的残差序列，绘制残差序列时序图，并利用 Q 统计量进行检验，如图 6.3-6.4 所示。




图 6.3 序列异方差检验

Date: 09/25/21 Time: 10:44
Sample: 1 487
Included observations: 472

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 0.184 0.184	16.167	0.000	
		2 0.168 0.138	29.548	0.000	
		3 0.095 0.045	33.863	0.000	
		4 0.074 0.031	36.494	0.000	
		5 -0.035 -0.075	37.080	0.000	
		6 0.006 -0.009	37.095	0.000	
		7 0.059 0.075	38.747	0.000	
		8 0.020 0.008	38.933	0.000	
		9 -0.044 -0.063	39.870	0.000	
		10 -0.022 -0.023	40.101	0.000	
		11 0.086 0.105	43.722	0.000	
		12 0.041 0.036	44.548	0.000	
		13 0.013 -0.016	44.630	0.000	
		14 0.021 -0.013	44.848	0.000	
		15 0.089 0.073	48.739	0.000	
		16 -0.053 -0.068	50.114	0.000	
		17 0.107 0.125	55.750	0.000	
		18 0.026 -0.017	56.099	0.000	
		19 0.106 0.068	61.050	0.000	
		20 -0.038 -0.065	62.349	0.000	
		21 0.013 -0.001	62.438	0.000	
		22 0.020 0.018	62.635	0.000	
		23 -0.028 -0.034	63.021	0.000	
		24 -0.042 -0.030	63.884	0.000	
		25 -0.007 -0.001	63.911	0.000	
		26 0.064 0.069	65.993	0.000	
		27 -0.012 -0.005	66.070	0.000	
		28 0.024 0.008	66.362	0.000	
		29 0.038 0.009	67.103	0.000	
		30 0.074 0.043	69.876	0.000	
		31 -0.049 -0.055	71.090	0.000	
		32 -0.047 -0.076	72.213	0.000	
		33 -0.054 -0.034	73.673	0.000	
		34 0.021 0.041	73.893	0.000	
		35 0.078 -0.024	76.987	0.000	
		36 0.005 -0.006	77.000	0.000	

图 6.4 ARCH LM 检验

从图 6.4 中可以看出，残差自相关函数存在“拖尾”现象，且 Q 的统计值

对应的概率均小于 0.05, 因此, 基本可以判定残差序列存在异方差与自相关性。需要对残差序列进行处理, 关于残差序列的异方差需要进行 ARCH LM 检验。

对残差序列进行 ARCH LM 检验, 滞后期选 11, 从图 6.5 中可以看出, 根据 F 与卡方统计量对应的概率值小于 0.05, 因此可以判定残差序列存在异方差。

Heteroskedasticity Test: ARCH				
F-statistic	3.526529	Prob. F(11,449)		0.0001
Obs*R-squared	36.66119	Prob. Chi-Square(11)		0.0001
Test Equation:				
Dependent Variable: RESID^2				
Method: Least Squares				
Date: 09/25/21 Time: 10:50				
Sample (adjusted): 27 487				
Included observations: 461 after adjustments				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.000427	0.000103	4.142159	0.0000
RESID^2(-1)	0.153070	0.046928	3.261785	0.0012
RESID^2(-2)	0.146632	0.047446	3.090488	0.0021
RESID^2(-3)	0.045453	0.047821	0.950495	0.3424
RESID^2(-4)	0.024257	0.047862	0.506806	0.6125
RESID^2(-5)	-0.081763	0.047730	-1.713045	0.0874
RESID^2(-6)	-0.008971	0.047881	-0.187359	0.8515
RESID^2(-7)	0.079255	0.047725	1.660674	0.0975
RESID^2(-8)	0.015967	0.047859	0.333632	0.7388
RESID^2(-9)	-0.074670	0.047815	-1.561637	0.1191
RESID^2(-10)	-0.038645	0.047443	-0.814542	0.4158
RESID^2(-11)	0.105608	0.046924	2.250614	0.0249
R-squared	0.079525	Mean dependent var		0.000573
Adjusted R-squared	0.056975	S.D. dependent var		0.001548
S.E. of regression	0.001503	Akaike info criterion		-10.13645
Sum squared resid	0.001015	Schwarz criterion		-10.02885
Log likelihood	2348.451	Hannan-Quinn criter.		-10.09408
F-statistic	3.526529	Durbin-Watson stat		2.007700
Prob(F-statistic)	0.000092			

图 6.5 ARCH 效应检验

建立 GARCH 方程, 结果如图 6.6 所示。

Dependent Variable: Y				
Method: ML ARCH - Normal distribution (BFGS / Marquardt steps)				
Date: 09/25/21 Time: 10:55				
Sample (adjusted): 16 487				
Included observations: 472 after adjustments				
Convergence achieved after 41 iterations				
Coefficient covariance computed using outer product of gradients				
Presample variance: backcast (parameter = 0.7)				
GARCH = C(3) + C(4)*RESID(-1)^2 + C(5)*GARCH(-1)				
Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	1.096705	0.035187	31.16747	0.0000
Y(-15)	-0.097203	0.035128	-2.767106	0.0057
Variance Equation				
C	6.65E-05	1.84E-05	3.617180	0.0003
RESID(-1)^2	0.092952	0.022275	4.172838	0.0000
GARCH(-1)	0.807927	0.043361	18.63241	0.0000
R-squared	0.014219	Mean dependent var		0.999938
Adjusted R-squared	0.012121	S.D. dependent var		0.025924
S.E. of regression	0.025766	Akaike info criterion		-4.543400
Sum squared resid	0.312037	Schwarz criterion		-4.499365
Log likelihood	1077.242	Hannan-Quinn criter.		-4.526079
Durbin-Watson stat	1.994115			

图 6.6 Garch 方程估计结果

$$Rate = 1.096705 + (-0.097203)Rate(-15) + \varepsilon_t \quad (6.2)$$

$$\sigma_t^2 = 0.0000665 + 0.092952u_{t-1}^2 + 0.807927\sigma_{t-1}^2 \quad (6.3)$$

绘制条件方差图:




图 6.7 条件方差图




图 6.8 预测能力分析

从图 6.8 中可以看出，在 300-487 的样本预测区间内，平均绝对误差率为 0.018799。

第二节 改进 Garch 方程

本节通过改进 Garch 方程，将第 5 章建立的方正科技情绪强度序列，作为外生变量，引入方差方程中，分析

Dependent Variable: Y
Method: ML ARCH - Normal distribution (BFGS / Marquardt steps)
Date: 09/25/21 Time: 11:17
Sample (adjusted): 16 487
Included observations: 472 after adjustments
Convergence achieved after 49 iterations
Coefficient covariance computed using outer product of gradients
Presample variance: backcast (parameter = 0.7)
GARCH = C(3) + C(4)*RESID(-1)^2 + C(5)*GARCH(-1) + C(6)*Q

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	1.097916	0.033416	32.85594	0.0000
Y(-15)	-0.098571	0.033408	-2.950538	0.0032

Variance Equation				
C	6.52E-05	1.60E-05	4.073109	0.0000
RESID(-1)^2	0.101667	0.022660	4.486679	0.0000
GARCH(-1)	0.802024	0.036810	21.78808	0.0000
Q	0.000109	3.81E-05	2.852984	0.0043

R-squared	0.014033	Mean dependent var	0.999938
Adjusted R-squared	0.011935	S.D. dependent var	0.025924
S.E. of regression	0.025769	Akaike info criterion	-4.547760
Sum squared resid	0.312095	Schwarz criterion	-4.494917
Log likelihood	1079.271	Hannan-Quinn criter.	-4.526973
Durbin-Watson stat	1.993723		

图 6.9 改进 GARCH 方程估计结果

$$Rate = 1.097916 + (-0.098571)Rate(-15) + \varepsilon_t \quad (6.4)$$

$$\sigma_t^2 = 0.0000652 + 0.101667u_{t-1}^2 + 0.802024\sigma_{t-1}^2 + 0.00011Q \quad (6.5)$$




图 6.10 300-487 样本预测能力分析




图 6.11 480-487 样本预测能力分析




图 6.12 条件方差图

从图 6.10 中可以看出，同样的样本预测范围（300-487），方差方程引入情感序列，条件方差的峰值略微有所增大，不是很明显；平均绝对误差率由

0.018799 降至 0.01879；对比图 6.7 和图 6.12，发现改进后的 Garch 方程的条件方差略有增大，体现了情绪强度对收益率的影响，但不是很明显，反映了方正科技的收益率对股评情绪强度不是很敏感，可能需要考虑一些其他因素；对比图 6.10 和 6.11，缩小了样本的预测范围，预测误差也只是微弱降低，由 0.01879 降为 0.010461。

第三节 本章小结

本章基于 Eviews 软件，建立了关于日收益率的 Garch 方程，并选取样本内数据进行了预测能力分析；然后改进了 Garch 方程，将情绪强度序列作为外生变量引入到方差方程，分析情绪强度对日收益率的影响及该方程的预测能力，通过对比发现，每日的情绪强度对日收益率有微弱的影响，但不明显，可能因为股吧里的股评大多为散户情绪发泄的表达，缺少理性和专业性。

第七章 基于混频方程收益率分析及预测能力评价

上面章节的 Var 和 Garch 模型中各变量的频率都是相同的, 货币政策的评论一般是按月发布的, 而最有权威和参考价值的货币政策执行报告, 央行每季度才发布 1 次, 此外通过第六章的分析, 可以看出依据股吧里的股评构建的每日情感强度, 更多地是体现散户投资者的情绪, 所以对日收益率的影响较小; 因此本章主要基于 Garch-midas 混频模型分析季度货币政策强度对上证指数月度收益率的影响、考察 5 日股评情感强度和货币政策强度对个股日收益率的影响; 并评价该模型的预测能力。

第一节 GARCH-MIDAS 方程

GARCH-MIDAS 模型将股票条件方差分解为短期成分与长期成分。因为宏观经济政策的制定出台周期较长且预期对股票价格的影响是长期性的, 所以认为其是股价波动的长期因素, 本章以月度的货币政策强度序列去计算该模型的长期成分。

收益率公式:

$$r_{i,t} = \mu_t + \sqrt{\tau_t g_{i,t}} \varepsilon_{i,t} \quad \varepsilon_{i,t} | \Omega_{i-1,t} \sim N(0,1) \quad (7.1)$$

短期成分计算公式:

$$\sigma_{i,t}^2 = \tau_t g_{i,t} \quad (7.2)$$

$$g_{i,t} = (1 - \alpha - \beta) + \alpha (r_{i-1,t} - \mu_t)^2 / \tau_t + \beta g_{i-1,t} \quad (7.3)$$

波动率服从 GARCH(1, 1), 其中 $\alpha + \beta < 1$,

长期成分计算公式:

$$\tau_t = m + \theta_1 \sum_{k=1}^K \varphi_k(\omega_1, \omega_2) X_{t-k} \quad (7.4)$$

$$\varphi_k(\omega_1, \omega_2) = \frac{(k/K)^{\omega_1-1} (1 - k/K)^{\omega_2-1}}{\sum_{j=1}^K (1 - j/K)^{\omega_2-1}} \quad (7.5)$$

为了与宏观经济变量的作用相匹配, 保证长期成分恒为正值, 对原长期成分的计算公式进行改进——取对数, 计算公式如下:

$$\ln(\tau_t) = m + \theta_1 \sum_{k=1}^K \varphi_k(\omega_1, \omega_2) X_{t-k} \quad (7.6)$$

为了保证滞后变量的权重呈衰减形式（滞后期越小，对当前的影响就越大）和模型的简便，一般会固定 $\omega_1=1$ ，由 ω_2 确定变量对长期成分的影响，简化后的 Beta 权重函数为：

$$\varphi_k(\omega_2) = \frac{(1-k/K)^{\omega_2-1}}{\sum_{j=1}^K (1-j/K)^{\omega_2-1}} \quad (7.7)$$

θ_1 、 θ_2 分别反映政策强度序列和投资者情绪序列对波动率长期成分的影响， K 为 Beta 权重函数最大滞后阶数。

为了分析多因素联合作用下对个股收益率的影响，我们改进 GARCH-MIADS 公式，将单因子扩展成双因子公式，主要修改长期波动的计算公式，并且为了刻画好消息和坏消息对股市条件波动率的非对称影响，设定短期波动 $g_{i,t}$ 服从 GJR-GARCH(1, 1) 过程，如公式 7.8-7.9 所示。

$$g_{i,t} = (1 - \alpha - \gamma/2 - \beta) + (\alpha + \gamma I_{i-1,t})(r_{i-1,t} - \mu_t)^2 / \tau_t + \beta g_{i-1,t} \quad (7.8)$$

$$\ln(\tau_t) = m + \theta_1 \sum_{k=1}^{K_1} \varphi_k(\omega_2) X_{1,t-k} + \theta_2 \sum_{k=1}^{K_2} \varphi_k(\omega_{2,two}) X_{2,t-k} \quad (7.9)$$

其中，公式 7.9 中的 2 个宏观变量的滞后阶数可以相同，也可以不同。

基于季度的货币政策执行报告，对上证指数进行预测，前面章节已利用金融领域情感词典建立了上证指数月度收益率序列，并且利用 Var 模型，分析得出广义货币 M2 供给的变化构成了月度收益率变化的格兰杰因果关系，说明货币政策对上证指数有一定的影响；但是该模型只是基于专业机构的评价和情感词典，建立大盘指数序列，并没有考虑货币政策对大盘指数的影响；本章利用 Garch-Midas 模型，季度政策执行报告是按季度发布的，上证指数月收益率是按月统计的，两者的时间频率并不一样，需要建立混频分析模型，分析每季度的货币政策对上证指数月收益率的影响。

第二节 基于混频模型的上证指数预测

我国股票市场具有资金驱动的特征，货币供应量对股市波动的影响有着较

大影响，主要受到货币总量和流通速度的影响，央行一般会通过货币政策调节货币总量和流通速度；本节基于混频方程，利用上证指数月度收益率序列和季度货币政策强度序列，分析政策对指数的影响，并预测了 2021 年 4 月的上证指数收益率。

GARCH-MIDAS 混频方程的分析结果如表 7.1 所示。

表 7.1 GARCH-MIDAS 混频方程估计结果

μ	α	β	m	θ	ω_2
1.0051	0.3	0.695	-1.75	2.49	1

系数 θ 是为正的，表明货币政策强度因素会增加当期条件波动率的长期成分，一个单位的 Beta 函数加权政策强度因素会增加 2.49 个单位的条件波动率长期成分，货币供应量的变动会影响股市的流通资金和股价水平。当货币供应量上升时，各类投资者可获取的货币量将会上升，这会促进其投资股市以及上市公司投资再生产，保持较好的基本面，支撑股价上升；当货币供应量下降时，各类投资者可获取货币量将会下降，投资者会因此减少股市投资，而上市公司也会紧缩生产，容易导致股价下跌，说明了近两年灵活适度的货币政策总体上增大了股市资金的规模，刺激了股市的发展。




图 7.1 条件方差中长期成分




图 7.2 条件方差中短期成分




图 7.3 上证指数月收益率条件方差

从图 7.1-7.3 中可以看出,长期成分的变化周期明显长于短期成分的周期;上证指数月收益率条件方差走势与长期成分的走势较为吻合。

从公式 7.1 和 7.2 中可以看出,只要有长期成分的预测值,就可以计算出短期成分,加上 $\xi_{i,t}$ 的预测值,就可以计算出收益率。方程的计算结果已经给出了下一个月的长期成分预测值,所以可以计算出短期成分值,只要预测出 $\xi_{i,t}$,就可以代入公式计算,得到预测值。

首先我们计算出相关月收益率所对应的 $\xi_{i,t}$, 因为 $\xi_{i,t}$ 服从正态分布,其均值为 0, 标准差为 1, 峰值数据出现的概率较低, 最后一个 $\xi_{i,t}$ 为 -0.55574, 左侧为下降趋势, 因此考虑 -1 到 0 区间的负值 $\xi_{i,t}$, 除去最后一个 $\xi_{i,t}$, 共有 7 个 $\xi_{i,t}$ 出现在 -1 到 0 区间, 对出现在此区间的 $\xi_{i,t}$ 标记为 0; 此外如果 $\xi_{i,t}$ 的左侧若为下降, 则标记为 0, 反之为 1; 同理其右侧若为下降, 则标记为 0, 上升趋势, 则标为 1。根据 7 个 $\xi_{i,t}$, 预测最后一个数据的右侧趋势; 利用二叉树模型进行计算, 利用上升趋势的平均值和下降趋势的平均值加权计算得到 $\xi_{i,t}$ 的预测值, 如公式 7.10 所示,

$$\xi_{i,t} = \text{右侧上升的概率} \times (-0.55574 + \text{右侧上升的平均值}) + \text{右侧下降的概率} \times (-0.55574 + \text{右侧下降的平均值}) \quad (7.10)$$

相关 $\xi_{i,t}$ 值的上升和下降的情况如表所示, 根据右侧上升和下降的次数, 计算出右侧上升的概率为 5/7, 右侧下降的概率为 2/7。

表 7.2 -1 到 0 区间的 $\xi_{i,t}$ 趋势特征

$\xi_{i,t}$	区间	左	右
-0.68458	-1-0	0	1
-0.87667	-1-0	0	1
-0.75064	-1-0	0	0
-0.77457	-1-0	0	0
-0.83066	-1-0	0	1
-0.12051	-1-0	0	1
-0.0651	-1-0	0	1
-0.55574	-1-0	0	待预测

表 7.3 -1 到 0 区间的 $\xi_{i,t}$ 右侧变化量

残差值	右侧趋势	数值
-0.68458	上升	0.023951
-0.87667	上升	2.905109
-0.75064	下降	-0.02392
-0.77457	下降	-0.05609
-0.83066	上升	1.283361
-0.12051	上升	0.89792
-0.0651	上升	0.126895
-0.55574	待预测	待预测

根据表中数据计算出，右侧上升趋势的平均值为 1.0474472，右侧下降的平均值为-0.040005，代入公式 7.10 中计算， $\xi_{i,t}$ 的预测值为 0.181002，根据公式 7.1，计算得到预测值为 $r_{i,t}$ 为 1.014，实际值为 1.001，误差如表 7.4 所示。

表 7.4 预测值与实际值误差

预测值	实际值	误差
1.014	1.001	1.3%

第三节 基于货币政策的个股收益率分析

本节基于混频方程，利用方正科技日收益率序列和月度货币政策强度序列，分析政策对日收益率的影响，为了便于数据计算分析，需要对日收益率序列进行处理，对其取 LOG 对数，再对对数结果乘以 100，分析结果如表 7.5 所示。

表 7.5 GARCH-MIDAS 混频方程估计结果

μ	α	β	m	θ	ω_2
-0.114	3.4e-9	0.596	0.972	-0.723	6.11

从表 7.5 中可以看出，系数 α 数值较小，基本接近 0，说明长期波动对短期波动基本无影响；系数 θ 是为负的，表明前期政策强度因素会降低当期条件波动率的长期成分，一个单位的 Beta 函数加权政策强度因素会减少 0.723 个单位的条件波动率长期成分，从侧面反映了政府在进行宏观调控时，往往会采取逆周期调节，当股市波动过大时，经济部门会出台相关政策，抑制股市波动，促进股市平稳发展。




图 7.4 政策因素权重图




图 7.5 条件方差中长期成分




图 7.6 个股收益率条件方差

从图 7.4 中可以看出，货币政策强度会在一定时期内造成影响，但影响随着时间的推移逐步减弱。从图 7.5-7.6 中可以看出，个股收益率条件方差走势与长期成分非常吻合，说明短期成分对条件方差的影响甚微，货币政策对收益率的影响是长期性的。

第四节 基于 5 日情感强度的个股收益率分析

本节基于混频方程，利用方正科技日收益率序列和 5 日情绪强度序列，分析该情绪强度对日收益率的影响，分析结果如表 7.6 所示。

表 7.6 GARCH-MIDAS 混频方程估计结果

μ	α	β	m	θ	ω_2
0.0083	0.131	0.531	1.04	-0.767	2.42

从表 7.6 中可以看出，系数 θ 是为负的，表明 5 日情绪强度因素会降低当期条

件波动率的长期成分，一个单位的 Beta 函数加权5日情绪强度因素减少0.767个单位的条件波动率长期成分，说明了股民在一周内的看跌情绪较重，交易不活跃；体现了5日的情绪强度不仅会产生短期影响，也会产生长期影响；侧面也反映出该股票的短线操作较多，虽然游资入场，板块效应、题材刺激、技术形态等因素可以吸引一定的人气，导致股价收益率上涨，衍生出的看涨情绪大于看跌情绪时，会引入一些资金，但是能否持续下去，还是要取决于基本面、题材的大小、发酵程度；如果热度不能够持续，看跌情绪会逐渐占据主导，导致资金流出，股价收益率下降，一定程度上抑制了股价的波动。




图7.7 5日情绪强度权重图




图7.8 条件方差中长期成分




图7.9 条件方差中短期成分




图7.10 个股收益率条件方差

从图 7.7 中可以看出,随着时间的推移,5 日情绪强度的权重影响也是慢慢衰减的,从图 7.8-7.10 中可以看出,条件方差的走势与短期成分走势较为贴合,与长期成分趋势不是很贴合,说明情绪强度短期内变化大,可能是因为短期成分主要受股票交易日的信息、公司公告以及突发事件等短期因素的影响,散户投资者的情绪特别容易受到影响。

第五节 货币政策和情感强度联合作用下个股收益率预测

当实行扩张性的货币政策时,货币供给大大增加,会有大量资金涌入股票市场,加上市场投资者根据市场政策做出的不同预期判断,从而根据不同的预期判断做出不同的买卖交割决策,从而改变了股票市场的实际资金供给,因此,不仅需要分析货币政策的影响,还需要考虑投资者的预期的影响,基于改进的 Garch-midas 模型,综合考虑了货币政策强度序列和投资者情绪序列,分析在两者联合作用下对收益率的影响,如表 7.7 所示。

表 7.7 双因子 GARCH-MIDAS 混频方程估计结果

μ	α	β
-0.103	4.77e-9	0.787
γ	m	θ_1
0.061	0.0289	-0.036
ω_2	θ_2	$\omega_2.two$
2.9	0.0675	2.21

结果表明,系数 α 数值基本接近 0,说明长期波动对短期波动基本无影响;系数 θ_1 和 θ_2 一负一正,体现了投资者情绪在一定程度上弱化了货币政策对收益率波动性的调控作用。系数 θ_1 是为负的,表明在联合作用下,5 日情绪强度因素会降低当期条件波动率的长期成分。一个单位的 Beta 函数加权情绪强度因素会减少 0.036 个单位的条件波动率长期成分;系数 θ_2 是为正的,表明在联合作用下,货币政策增加了方正科技股票收益波动的长期成分。一个单位的 Beta 函数加权政策强度因素会增加 0.0675 个单位的条件波动率长期成分,有可能是因为当货币政策的方向契合了某些主力机构的预期,股票波动幅度往往会大于平时的波动幅度;而货币政策对股市的影响是长期的,所以股票市场波动率将伴随货币供应量增加而增大。

以贷款利率变动为例,当贷款利率较低时,会增加金融市场中资金的流动

性，给上市公司融资带来方便，促进上市公司收获更大的利润率，进而股票价格随之上涨；当贷款利率提高时，上市公司融资的费用增加，在收入不变的情况之下费用会增加，减少上市公司的经营利润率，从而股票价格相应减少；另一方面贷款利率的上升，股利的降低，股票价格受到两者的冲击，致使股票价格下跌。相反地，当贷款利率下跌时，上市公司融资费用减少，在收入不变的情况下减少费用，会增加上市公司的经营利润率，从而股票价格上涨；另一方面贷款利率的下跌，股利上升，股票价格相应发生上升的变化。

2020 年受疫情影响，经济下行压力较大时，风险偏好较低，投资热情不高时，政府在进行宏观调控时往往会采取逆周期调节，增加货币供给，降低融资成本，按照前面章节的分析，货币供给增加会对上证指数收益率产生影响，说明部分资金流入了股市，进入了热点题材股，但其后续的影响力会随着时间的延长而衰减。

货币供应量冲击引起了股市波动，货币供应量增加时，部分股票资产价格先呈现上升趋势，收益率上升，引发投资者热潮，经看好情绪扩散后，政策作用的时间一般会变长。此外当货币供应量增多后，由于通货膨胀、投资者预期、板块效应等因素会增加对进一步拉动股市的投资，当股票预期上涨，投资资金就会流入股票市场并停留以获取利润，随着股票收益率的提高，部分散户投资者就会愿意留着现金保持流动性，准备随时投入股市；整个资金市场和货币流动增强，相关公司股价受资金追捧上涨。

利用上面的估计结果，对方正科技次日的收益率进行预测，预测方法和流程同本章第二节的方法。

表 7.8 -1 到 0 区间的 ξ_{it} 趋势特征

残差值	区间	左	右
-0.28859	-1-0	1	0
-0.10717	-1-0	1	0
-0.37921	-1-0	1	0
-0.29107	-1-0	1	0
-0.23142	-1-0	1	1
-0.33035	-1-0	1	1
-0.46053	-1-0	1	1
-0.38398	-1-0	1	1
-0.1469	-1-0	1	待预测

表 7.9 -1 到 0 区间的 $\xi_{i,t}$ 右侧变化量

残差值	右侧趋势	数值
-0.28859	下降	-0.69937
-0.10717	下降	-0.33318
-0.37921	下降	-0.90956
-0.29107	下降	-0.41817
-0.23142	上升	3.064364
-0.33035	上升	0.866448
-0.46053	上升	0.671206
-0.38398	上升	0.854692
-0.1469	待预测	待预测

从表 7.8 中可以看出，最后一个 $\xi_{i,t}$ 为-0.1469，除去最后一个值，共有 8 个 $\xi_{i,t}$ 出现在-1 到 0 的区间内，根据表和表中数据，计算出相应的数值，代入公式 7.9 和 7.1，计算得到预测值为 0.126，实际值为 0.127，需要对其进行指数处理，得到日收益率，误差如表所示。

表 7.10 预测值与实际值误差

	预测值	实际值
	0.126	0.127
收益率	1.002905	1.002933
误差	-0.002792%	




图 7.11 双因子方程-情绪强度权重图




图 7.12 双因子方程-货币政策强度权重图




图 7.13 条件方差中长期成分




图 7.14 个股收益率的条件方差

从图 7.11-7.12 中可以看出，相比于政策强度的权重，情绪强度影响权重衰减速度相对缓和；从图 7.13-7.14 中可以看出，长期成分的波动范围较小，在中间区域，长期成分和条件方差都处于低位，有可能在此时间区间内，货币政策强度和 5 日情绪强度对收益率没有特别强烈地刺激作用。

一方面市场投资者会根据出台的政府政策或者趋势来做出预期，从而做出相应的理性操作来影响股票市场价格；另一个方面货币供应量的增加和减少会改变市场投资者的货币边际购买能力，进而影响投资组合，然后再影响股票市场的投资规模 and 价格。当货币政策大环境较为宽松，投资者预期好时，导致涌入的资金比抽离的资金多，会引起股票价格上涨；当货币政策大环境较为紧缩，大量资金回笼，货币供应大大减少，当预期不好时，大量资金抽离股票市场，造成涌入的资金比抽离的资金少，会引起股票价格的下跌；资金的融入与抽离存在一定差异时，会引起股票价格的波动加剧；如果从股票市场抽离的资金与涌入的资金相当时，股市波动较为平缓。

第六节 货币政策对热点产业的影响

货币政策往往与宏观经济、产业政策紧密联系，如果货币是“水”，那么产业就是“渠”，无水则不成江河，无渠则不聚水，两者相辅相成；水到则渠成，渠道引导水流向更远更广的地方；货币政策相当于总闸门，控制水量；产业政策有“引流”之用，产业政策的扶持力度就好比渠道的宽窄、长短和深浅；水

量足且渠道大宽深，则一路畅通，源远流长，流水滔滔。“定向宽松”和“精准滴灌”是近两年来货币政策的一个主基调，强调货币的传输方向和渠道，通过一些列政策，将货币流入国家需要发展和扶持的产业。

从前几年的股票市场走势中可以看出，每当货币政策宽松时，周期性重工行业反应作为明显，例如煤炭、钢铁、有色、机械等行业上涨十分快速，几乎大多数投资者尚没有反应过来的时候，股票价格就已经上涨三成以上。在国家对房地产行业没有调控之前，宽松的货币政策对房地产上市公司的价格促进最大，近几年国家明确房子是用来住的，不是用来炒的这个思想之后，宽松的货币政策对房地产上市公司的价格的反应就不太明显了。宽松的货币政策作用就主要体现在对铁路，基建、水利等基础设施建设这些行业上了。

近两年，央行的货币政策更加灵活，特别是操作上有时明显会倾向于对中小上市公司、新兴产业的扶持，加强了对高新技术公司的复兴、绿色环保等行业的引导。相比于重工行业，高新技术公司盘子总体较小，容易操盘；这些倾向性扶持性的货币政策会以很快的速度传导到股票市场上，2019-2020 年，人工智能、芯片技术、软件开发等行业出现的大行情，形成的局部大牛市，就能觉察到股票市场对货币政策的反应非常迅速。

第七节 本章小结

本章主要基于单因素 GARCH-MIDAS 方程，分析了上证指数月收益率与季度货币政策强度之间的关系，并预测了 2021 年 4 月的上证指数月收益率，预测误差 1.03%，效果较好；分析了货币政策强度、5 日情绪强度与个股日收益率的关系，发现政策强度因素会降低当期条件波动率的长期成分；5 日情绪强度也会降低当期条件波动率的长期成分；改进了 GARCH-MIDAS 方程，分析了在货币政策强度和 5 日情绪强度联合作用下，对个股收益率的影响，发现发现 5 日情绪强度会降低当期条件波动率的长期成分，政策强度会加大当期条件波动率的长期成分，但不明显，并预测了次日个股收益率，预测误差仅为-0.002792%。

第八章 总结

第一节 论文总结与创新

随着数据处理技术的飞速发展,文本挖掘与智能分析的应用范围越来越广;总的来看,本文基于 python 语言,实证分析了 7 种文本情感处理方法的优劣;对股民的股评、专业机构股评以、货币政策执行报告及专业评论文本进行了整理与分析,扩充构建了金融领域、货币领域词典,更新部分短语、词汇的权重值,基于词典完成了货币政策强度、上证月收益率及个股股评情感序列的构建,并建立了 VAR 模型,分析了货币政策对上证收益率、个股收益率的影响;改进了传统的 Garch 模型,将股评情感序列作为外生变量引入方差方程,分析并预测了股评情感对个股收益率的影响;基于 R 语言,建立 Garch-Midas 模型,分析了货币政策和股评情感对个股收益率的影响;具体完成以下内容:

1、收集并阅读了近 5 年的关于文本挖掘、投资情绪、货币政策与股市收益变化关系的文献,整理了相关研究方法,提出了具体的研究思路与方法。

2、利用 python 语言编写程序,利用网络爬虫技术爬取了部分股评,实证分析了 SnowNLP、随机森林数、朴素贝叶斯、支持向量机、神经网络、长短记忆、基于词典分析等 7 种文本情感识别方法的优劣。

3、爬取并收集了 30 多万字的股评、货币政策分析及评价文献,利用结巴工具对文献进行分词处理,基于词频、tf-idf、词向量等模型选取专业代表性、时效性较强的词汇和短语作为种子词,以种子词为样本,利用 wordexpansion 自动构建大规模的金融领域词典;结合股票涨跌幅度和句法结构,更新了部分词汇的权重,补充到原有的 CFSD 金融词典中。

4、以央行发布的季度货币政策执行报告和月度的专业货币政策评论文献作为样本,基于词频、tf-idf 模型提取出关键短语,构建货币领域词典,并通过统计近两年来每个短语每月出现的次数,乘以该月对应的权重,计算该短语的强度值。

5、基于金融领域、货币领域词典,建立了货币政策强度、上证月收益率及个股股评情感序列。

6、基于 Eviews 软件,建立了含有 3 个变量的 VAR 模型,进行了序列平稳

检验，利用格兰杰因果关系、脉冲响应与方差分解，分析了货币政策、上证月收益和个股月收益之间的关系。

7、选取代表性个股，建立日收益率序列，并改进 Garch 模型，将个股股评情感序列作为外生变量引入到方差方程，分析并预测了股评情感对个股日收益率的影响。

8、基于 R 语言，考虑货币政策、股评情绪因素的影响，分别建立了单因素、多因素的 Garch-Midas 模型，分析了货币政策和股评情感对个股收益率的影响。

本文的主要有以下创新点：

1、提取了最新的股评关键词语，更新扩展了金融领域词典；结合股市每日的实际涨跌程度，并考虑中文句法特征，对不同的关键词语赋予不同的强度值。

2、构建了货币领域词典，根据实际的货币供给强度变化，对不同的短语赋予不同的强度。

3、改进 Garch 方程，将情绪强度序列作为外生变量引入到方差方程；改进 Garch-midas 方程，分析了在两个低频序列联合作用下，对高频序列的影响。

第二节 预测能力分析

关于上证指数收益率的预测，本文建立了 3 变量的 VAR 方程，利用样本内数据检验了该方程的预测能力，发现上证指数月收益率的预测值存在偏差，而且与实际趋势也存在偏差；基于 GARCH-MIDAS 方程，考虑季度货币政策的影响，预测了 2021 年 4 月的上证指数收益率，预测结果具有一定的参考意义，误差 1.03%。

关于个股收益率的预测，本文建立了 4 变量的 VAR 方程，同样也利用样本内数据检验了该方程的预测能力，发现预测趋势和预测值都不是很精确，收益率的波动幅度被放大；改进了 GARCH-MIDAS 方程，考虑季度货币政策和 5 日情绪强度联合作用下，对个股日收益率的影响，预测了次日的收益率，预测结果精准，误差仅为-0.002792%。

第三节 展望

本文存在的不足之处：首先本文并未考虑股评的权重，而且仅仅依据程度

副词和关键词汇赋予股评强度，方法有所欠妥，有些股评虽然情感强度强烈，但其评论内容不一定属实，反而误导了投资者；不同类别人员发表的股评含金量是不一样的，股吧里评论人员素质参差不齐，专业素质较高的占少数，发表的股评质量较高，但数量较少，容易被数量多、质量低的评论淹没，因此需要对股评进一步甄别，可信度高、专业性强的股评应该赋予较大的权重。

其次本文仅选择了股评情感作为投资者的情绪强度，未能考虑新增开户数、成交金额、换手率等对投资情绪的影响。关于文本情感的识别，仅进行了二分类处理，未能实现情感多分类，高精度的情感多分类需要深度学习方法，且需要标注一定数量的语料，不但要创新相关算法，而且需要收集和标注专业的预料。

关于情感识别和股市走势的研究，可谓是任重道远，千头万绪，但是研究股市内在的运行机制和准确识别投资者的情感是必要的前提，我们不仅要研究与股市相关的宏观环境，比如经济、金融、政治、货币、产业等环境，还要研究股市相关的微观环境，比如投资意愿、上市公司的基本面、交易策略等；准确识别投资者情感需要构建高质量的语料库，关于语料库的构建，要兼顾专业性和广泛性，可以迁移到相关领域，提高泛化能力；此外，我们要从底层设计更多地关于中文文本的处理算法，中文文本的情感存在强烈地非线性，很多口语化地表达不能依据表面评价情感倾向，需要设计算法，挖掘背后的含义。

参考文献

- [1] 陈其安,雷小燕,2017:《货币政策,投资者情绪与中国股票市场波动性:理论与实证》,《中国管理科学》,第11卷,第1-11页。
- [2] 陈晓红,彭宛露,田美玉,2016:《基于投资者情绪的股票价格及成交量预测研究》,《系统科学与数学》,第36(12)卷,第2294-2306页。
- [3] 戴德宝,兰玉森,范体军,赵敏,2019:《基于文本挖掘和机器学习的股指预测与决策研究》,《中国软科学》,第4卷,第166-175页。
- [4] 段江娇,刘红忠,曾剑平,2017:《中国股票网络论坛的信息含量分析》,《金融研究》,第10卷,第178-192页。
- [5] 樊小超,2014:《基于机器学习的中文文本主题分类及情感分类研究》,南京理工大学。
- [6] 黄润鹏,左文明,毕凌燕,2015:《基于微博情绪信息的股票市场预测》,《管理工程学报》,第29(1)卷,第47-52页。
- [7] 孔希希,程兵,2017:《基于统计自然语言处理的央行货币政策研究》,《数学的实践与认识》,第07期,第198-207页。
- [8] 景芳芳,2017:《基于改进 GARCH-MIDAS 模型的宏观经济因素影响股价波动研究》,中国矿业大学。
- [9] 雷立坤,余江等,2018:《经济政策不确定性与我国股市波动率预测研究》,《管理科学学报》,第21(6)卷,第88-98页。
- [10] 李方涛,2011:《基于产品评论的情感分析研究》,清华大学。
- [11] 林建浩,赵文庆,2015:《中国央行沟通指数的测度与谱分析》,《统计研究》,第1期,第52-58页。
- [12] 林建浩,赵文庆,李仲达,2017:《央行沟通与实际干预的频域政策效果研究》,《管理科学学报》,第8期,第27-38页。
- [13] 林建浩,陈良源,宋登辉,2019:《如何测度央行行长的口头沟通信息——一种基于监督学习的文本分析方法》,《统计研究》,第08期,第3-18页。
- [14] 柳位平,朱艳辉,栗春亮,向华政,文志强,2009:《中文基础情感词词典构建方法研究》,《计算机应用》,第29(10)卷,第2875-2877页。
- [15] 卢凯,2006:《央行加息对股市、房市和车市影响的经济学分析》,《商业研究》,第02期,第147-149页。
- [16] 鲁晓鹏,2016:《基于互联网数据挖掘的投资者情绪与股市收益统计研究》,西南财经大学。
- [17] 赖凯声,2013:《大众网络情绪与中国股市的相关性探究》,南开大学。
- [18] 赖凯声,陈浩,钱卫宁等,2014:《微博情绪与中国股市:基于协整分析》,《系统科学与数学》,第34(5)卷,第565-575页。
- [19] 石强,杨一文,刘雅凯,2019:《基于 GARCH-MIDAS 模型的宏观经济与股市波动关系》,

- 《计算机工程与应用》,第 55(15)卷,第 257-262 页。
- [20] 唐慧丰,谭松波,程学旗,2007:《基于监督学习的中文情感分类技术比较研究》,《中文信息学报》,第 06 卷,第 88-94+108 页。
- [21] 王博,李力,郝大鹏,2019:《货币政策不确定性、违约风险与宏观经济波动》,《经济研究》,第 3 卷,第 119-134 页。
- [22] 王聪,高广阔,王亮,2018:《基于个体投资者情感量化的上证指数预测检验》,《经济研究导刊》,第 26 卷,第 159-164 页。
- [23] 王素格,李德玉,魏英杰,宋晓雷,2009:《基于同义词的词汇情感倾向判别方法》,《中文信息学报》,第 23(05)卷,第 68-74 页。
- [24] 王维国,于扬,2016:《基于混频回归模型对中国季度 GDP 的预报方法研究》,《数量经济技术经济研究》,第 33(4)卷,第 108-125 页。
- [25] 王宇伟,周耿,吴瞳,范从来,2019:《央行的言辞沟通、实际行动与上市公司投资行为》,《中国工业经济》,第 05 期,第 118-135 页。
- [26] 吴杰胜,陆奎,2019:《基于多部情感词典和规则集的中文微博情感分析研究》,《计算机应用与软件》,第 36(09)卷,第 93-99 页。
- [27] 夏火松,刘建,朱慧毅,2011,《中文情感分类挖掘预处理关键技术比较研究》,《情报杂志》,第 30(9)卷,第 160-163 页。
- [28] 项辛怡,2018:《投资者情绪与股票收益》,浙江大学。
- [29] 谢丽星,2011:《基于 SVM 的中文微博情感分析的研究》,清华大学。
- [30] 徐冰,2012:《基于统计学习的文本情感分析关键技术研究》,哈尔滨工业大学。
- [31] 杨科,田凤平,林洪,2013:《跳跃的估计,股市波动率的预测以及预测精度评价》,《中国管理科学》,第 21(3)卷,第 50-60 页。
- [32] 杨永伟,2018:《基于财经新闻的股票收益方向预测》,浙江工商大学。
- [33] 姚前,2019:《基于 GARCH-MIDAS 模型的政策因素对股市波动的影响研究》,浙江财经大学。
- [34] 姚尧之,王坚强,刘志峰,2018:《混频投资者情绪与股票价格行为》,《管理科学学报》,第 21(2)卷,第 104-113 页。
- [35] 尹力博,李劼,2017:《投资者关注对人民币汇率价差波动的影响研究——基于 GARCH-MIDAS 模型》,《管理科学》,第 30(5)卷,第 147-159 页。
- [36] 印如意,2018:《基于海量文本挖掘的证券市场情绪监控及预测》,电子科技大学。
- [37] 张贵生,2016:《数据驱动的金融时间序列预测模型研究》,山西大学。
- [38] 赵妍妍,秦兵,石秋慧等,2017:《大规模情感词典的构建及其在情感分类中的应用》,《中文信息学报》,第 31(2)卷,第 187-193 页。
- [39] 郑国杰,2019:《基于互联网投资者情绪的股票时间序列分析与预测》,浙江工业大学。
- [40] 郑挺国,尚玉皇,2014:《基于宏观基本面的股市波动度量与预测》,《世界经济》,第 12 卷,第 118-136 页。
- [41] 周广,2016:《微博内容挖掘与金融时间序列关联性研究》,北京邮电大学。
- [42] 朱嫣岚,闵锦,周雅倩,黄萱菁,吴立德,2006:《基于 HowNet 的词汇语义倾向计算》,《中文信息学报》,第 01 卷,第 14-20 页。

- [43] Ahmed.Bouteska, 2019, “The effect of investor sentiment on market reactions to financial earnings restatements:Lessons from the United States” , Journal of Behavioral and Experimental Finance, PP24.
- [44] Beaupain, R., and A. Girard, 2020, “The Value of Understanding Central Bank Communication” , Economic Modelling, Vol.85, PP154-165.
- [45] Baker SR, Bloom N, Davis SJ, 2016, “Measuring Economic Policy Uncertainty” , The Quarterly Journal of Economics, Vol. 131, PP1593—1636.
- [46] Ehrmann, M., and J. Talmi, 2020, “Starting from a Blank Page Semantic Similarity in Central Bank Communication and Market Volatility” , Journal of Monetary Economics, Vol.111, PP48-62.
- [47] Engle R F, Rangel J G, 2008, “The spline-GARCH model for low-frequency volatility and its global macroeconomic causes” , Review of Financial Studies, Vol. 21(3), PP1187-1222.
- [48] En-Te (John) Chen, Adam Clements, 2007, “S&P 500 implied volatility and monetary policy announcements” , Finance Research Letters, Vol.4, PP227-232.
- [49] Hansen S, McMahon M, 2016, “Shocking Language: Understanding the Macroeconomic Effects of Central Bank Communication” , Journal of International Economics, Vol. 99, PP 114—133.
- [50] Hanse S, McMahon M, 2018, “Prat A. Transparency and Deliberation within the FOMC: a Computational Linguistics Approach” , The Quarterly Journal of Economics, Vol. 133, PP801—870.
- [51] Iryna Kaminska, Matt Roberts-Sklar, 2018, “Volatility in equity markets and monetary policy rate uncertainty” , Journal of Empirical Finance, Vol. 45, PP68-83.
- [52] Picault M, Renault T, 2017, “Words are Not All Created Equal: A New Measure of ECB Communication” , Journal of International Money and Finance, Vol. 79, PP136—156.
- [53] R. F. Engle, E. Ghysels and B. Sohn, 2013, “Stock market volatility and macroeconomic fundamentals” , The Review of Economics and Statistics, Vol. 95(3), PP 776-797.
- [54] Roman, H., and V. Dan, 2016, “Central Bank Transparency and Financial Stability: Measurement, Determinants and Effects” , Journal of Financial Stability, Vol. 22, PP45-56.
- [55] Sun, O., and Z. Liu, 2016, “Comparison of Monetary Policy Actions and Central Bank Communication on Tackling Asset Price Bubbles—Evidence from China’s Stock Market” , Plos One, Vol. 11, PP1-20.
- [56] Su, S., A.H. Ahmad and J. Wood, 2019, “How Effective is Central Bank Communication in Emerging Economies An Empirical Analysis of the Chinese Money Markets Responses to the People’s Bank of China’s Policy Communications” , Review of Quantitative Finance and Accounting, Vol. 54, PP1-25.

参考文献

- [57] Timothy.K.Chue, F.A.Gul, G.M.Mian, 2019, “Aggregate investor sentiment and stock return synchronicity”, Journal of Banking and Finance, PP108.
- [58] Woodford M, 2012, Discussion of “Macroeconomic Effects of Federal Reserve Forward Guidance”, The Brookings Papers on Economic Activity, PP64—73.
- [59] Z.Mcgurk, A.Nowak, J.C.Hall, 2019, “Stock returns and investor sentiment: textual analysis and social media”, Journal of Economics and Finance, Vol.2.

上海财经大学学术数据总库Scholars Hub at SUFE [https://scholars.sufe.edu.cn/]

致谢

转眼近 3 年的学习生涯已接近尾声了，回顾此次学习的过程，感慨颇多：首先，对我的导师谢美萍老师表达崇高的敬意与真诚的感谢。谢老师在专业课程、论文开题和预答辩等重要环节中，给予了我足够多的指导和鼓励，加深了我对数据算法应用的理解，为学习文本挖掘专业课程和撰写论文打好了坚实的基础；在论文的撰写和审阅过程中，谢老师以极其负责的态度指导我的论文写作，提出了非常宝贵的专业修改建议，保证了论文的质量。

其次，需要感谢我的专业课老师肖升生、史钊，同学李梦伟、顾超、刘刚、向俊、董坤宇等人，这是我第一次以在职人员的身份跨专业攻读硕士学位，与上一次全日制研究生学习不同，通过此次学习，我接触到了很多来自重点高校、各行各业、不同专业背景的老师 and 同学，他们有着丰富的工作经验、完备的知识结构和较好的专业素养，为我带来了许多新事物、新概念和新知识，开阔了思路，拓宽了眼界，填补了我在财务、金融等专业领域的知识空白，更新了我的知识结构。

最后，我要感谢我的家人，一直以来，他们都无私地给予我足够的支持和包容，衷心的祝福他们；也祝愿上海财经大学越来越好，上财是一所承载了百年积淀的高等财经院校，同时又富有激情活力，一草一木皆描绘着上财的历经沧桑而愈久弥香！每一个人物都传递着新时代的朝气与梦想！岁月催人进，奋斗正当时，愿我们各有前程可赴，回首岁月，不负韶华！